



사회과학 통계 입문 시리즈

VOL. 01 · 기초통계

통계가 이해 안 되는 건 당신 탓이 아닙니다

5년간 해온 과외를 그대로 옮겼습니다. 개념이 왜 필요한지부터 논문 결과표까지, R로 끝냅니다.

- ☐ 왜 그 분석을 쓰는지부터 이해시킵니다
- ☐ 가정을 외우지 않고 무엇을 확인하는지 압니다
- ☐ R 코드는 그대로 복사해서 쓰면 됩니다
- ☐ 출력을 논문 표와 문장으로 옮기는 법까지

목차

1권은 '왜 이 분석을 쓰는가'에 답합니다. 회귀분석부터는 2권에서 다룹니다.

PART 0 들어가며

00	이 책의 구성과 전제	2
----	-------------	---

PART 1 기초통계

01	척도가 분석을 결정한다	5
02	자료를 두 숫자로 요약하기	9
03	분포의 형태 진단	19
04	표본에서 모집단을 추론하는 근거	24
05	가설검정의 논리	30
06	추정과 신뢰구간	41
07	두 집단의 평균 비교 — 독립표본 t-검정	51
08	같은 사람을 두 번 재는 경우 — 종속표본 t-검정	63
09	세 집단 이상의 비교 — 일원분산분석	74
10	어느 집단끼리 다른가 — 다중비교	89
11	독립변수가 둘일 때 — 이원분산분석	100

PART 2 부록

12	실전 참고자료	114
----	---------	-----

이 책의 구성과 전제

통계를 처음 배우는 사람이 가장 먼저 막히는 지점은 계산이 아니라 판단입니다. 어떤 분석을 왜 써야 하는가. 이 책은 그 질문에 답하는 순서로 구성되어 있습니다.

■ 이 책을 쓴 이유

이 책은 5년간 진행한 통계 과외의 내용을 정리한 것입니다. 새로 집필한 원고가 아니라, 실제로 학생들을 가르칠 때 쓰던 자료를 다시 정리한 것입니다.

과외를 하면서 확인한 것은 학생들이 막히는 지점이 대체로 같다는 것입니다. 그리고 그 지점은 계산이 아니었습니다.

- 등분산성을 왜 검정해야 하는지 모른 채 절차만 반복하는 경우
- 유의확률이 작아야 하는 검정과 커야 하는 검정을 구분하지 못하는 경우
- 출력 결과는 얻었으나 어느 값을 논문에 옮겨야 하는지 판단하지 못하는 경우

세 경우 모두 공식을 몰라서가 아니라 **그 절차가 무엇을 확인하는 것인지 배우지 못해서** 발생합니다. 많은 통계 강의가 계산 절차는 가르치지만 그 절차의 목적은 설명하지 않습니다.

이 책이 설명하는 순서

이 책은 모든 개념에 대해 **왜 그 절차가 필요한가**를 먼저 설명한 뒤 계산 방법을 제시합니다.

예를 들어 등분산성 검정은 "분산이 같아야 한다"는 요건으로 제시하지 않습니다. 두 집단의 분산이 같다는 것은 처치가 개입하기 이전에 두 집단을 동일한 집단으로 간주할 수 있었다는 뜻이며, 이것이 흔들리면 평균 차이를 처치 때문이라고 말할 수 없다는 점을 먼저 설명합니다. 검정 절차는 그다음입니다.

계산은 R이 수행합니다. 독자가 해야 할 일은 **판단**입니다.

■ 대상 독자

다음 중 하나에 해당한다면 이 책이 적합합니다.

- 학위논문을 쓰면서 통계 분석을 직접 해야 하는 경우
- 통계 강의를 수강했으나 자신의 자료와 연결되지 않는 경우
- 비전공자로서 설문 자료를 처음 다루는 경우
- 실무에서 데이터를 다루다가 기초 개념을 정리하고 싶은 경우

통계학 전공자를 위한 책은 아닙니다. 수식을 유도하거나 증명하지 않습니다. 대신 각 분석이 무엇을 확인하는 절차인지, 결과의 어느 값을 어떻게 읽는지, 그것을 보고서에 어떻게 기술하는지를 다룹니다.

■ 분석 도구로 R을 사용하는 이유

SPSS는 클릭만으로 쓸 수 있어 시작하기 쉽습니다. 그러나 실제 분석 과정에서는 다음과 같은 문제가 발생합니다.

- 변수를 하나 제외하고 재분석해야 할 때 클릭 절차를 처음부터 반복해야 합니다
- 수 주 전에 수행한 분석의 설정을 재확인할 수 없습니다
- 학교나 회사의 라이선스가 끝나면 분석을 할 수 없습니다

R은 분석 과정이 코드로 기록됩니다. 기록이 남으면 수정은 한 줄로 끝나며 언제든 그대로 다시 돌릴 수 있습니다. 그리고 무료입니다.

프로그래밍 학습이 아닙니다

이 책에서 사용하는 R 코드는 대부분 한 줄 분량입니다. `t.test(점수 ~ 집단, data = df)` 형태이며, 독자가 할 일은 변수명을 자기 자료에 맞게 바꾸는 것뿐입니다.

프로그래밍 언어를 습득하는 과정이 아니라 계산기 사용법을 익히는 과정에 가깝습니다.

■ 준비 사항

● 최초 1회만 수행합니다

```
# 1) R 설치: https://cran.r-project.org
# 2) RStudio 설치: https://posit.co/download/rstudio-desktop
# 3) 패키지 설치 (콘솔에 입력)

install.packages(c("psych", "car", "effectsize"))
```

설치를 마쳤으면 분석을 시작할 때마다 다음 두 줄을 실행합니다.

● 분석 시작 시

```
library(psych)           # 기술통계
df <- read.csv("data.csv") # 자료 불러오기
```

자료 파일 만드는 법

설문 자료를 정리할 때는 **1행에 변수명, 1인당 1행**의 구조를 유지합니다. 변수명은 영문 소문자와 밑줄만 사용하는 것이 안전합니다(`self_esteem` , `age` , `gender`). 한글 변수명도 인식되지만 공백이 포함되면 오류가 발생합니다.

정리가 끝나면 엑셀에서 **다른 이름으로 저장 → CSV UTF-8**을 선택합니다.

■ 시리즈 구성

이 책은 네 권으로 구성된 시리즈의 첫 권입니다.

권	내용	적용 상황
1권 기초통계	척도, 기술통계, 표집분포, 가설검정, t-검정, 분산분석	집단 간 차이와 기본 관계를 분석할 때
2권 회귀분석	단순·다중회귀, 더미변수, 매개·조절효과	영향력의 크기를 추정할 때
3권 요인분석	탐색적·확인적 요인분석, 신뢰도·타당도	측정도구를 검증할 때
4권 구조방정식	측정모형, 구조모형, 적합도 지수	변수 간 인과 구조를 검증할 때

1권은 나머지 세 권의 토대입니다. 여기서 다루는 **척도의 구분과 유의확률의 해석**을 이해하지 못하면 2권 이후의 내용을 따라갈 수 없습니다.

요약 — 이 책을 마치면 자신의 자료에서 변수의 척도를 판별하고, 그에 맞는 분석을 골라 R로 돌리고, 출력에서 필요한 값을 식별하여 결과표와 서술문으로 옮길 수 있습니다.

척도가 분석을 결정한다

통계 학습에서 가장 먼저 다루어야 할 것은 개별 분석 기법이 아니라 변수의 척도를 판별하는 절차입니다. 척도가 확정되면 쓸 수 있는 분석이 사실상 하나로 좁혀집니다.

■ 척도를 먼저 다루는 이유

어떤 분석을 적용해야 하는가라는 질문에는 대체로 정해진 답이 있습니다. **변수의 척도가 확정되면 쓸 수 있는 분석이 거의 하나로 좁혀지기 때문입니다.**

분석 방법을 선택하지 못하는 원인은 통계 지식의 부족이 아니라 **변수의 척도를 판별하지 못하는 데** 있습니다. 이 장은 그 판별 절차를 다룹니다.

■ 네 가지 척도

척도	정의	예시	평균 산출
명목척도	범주를 구분할 뿐 순서가 없음	성별, 전공, 지역	불가
서열척도	순서는 있으나 간격이 균등하지 않음	학력, 직급, 선호 순위	원칙상 불가
등간척도	간격이 균등하나 절대영점이 없음	온도, 리커트 척도	가능
비율척도	간격이 균등하고 절대영점이 있음	연령, 소득, 시간	가능

분석 방법을 선택하는 데에는 네 가지 구분을 모두 적용할 필요가 없으며, **두 범주로 축약하면 충분합니다.**

분석 선택을 위한 이분법

- **범주형** = 명목 + 서열 — 각 범주에 몇 사례가 속하는지를 세는 변수
- **연속형** = 등간 + 비율 — 값의 크기를 측정하는 변수

분석 선택에 필요한 구분은 이것으로 충분합니다. 명목과 서열의 구분은 대부분의 경우 분석 결과에 영향을 주지 않습니다.

리커트 척도의 처리

"매우 그렇다(5)~전혀 아니다(1)" 형식은 엄밀하게는 서열척도입니다. 4점과 5점의 간격이 1점과 2점의 간격과 동일하다는 보장이 없기 때문입니다.

그러나 복수의 리커트 문항을 합산하거나 평균한 값을 등간척도로 취급하는 것이 사회과학의 표준 관행이며, 이 처리가 심사에서 문제가 되는 경우는 드뭅니다.

다만 단일 문항의 값을 등간척도로 취급하는 것은 정당화하기 어렵습니다. 최소 3문항 이상을 합산하여 사용합니다.

■ 분석 선택 흐름도

이 도식은 1권 전체의 구조를 요약한 것입니다. 분석 선택에 확신이 서지 않을 때 참조합니다.




그림 1-1 척도로 분석 방법을 결정하는 흐름. 1권에서는 아래 네 가지를 다룹니다.

■ R에 척도를 지정하는 절차

성별 변수에 1과 2가 입력되어 있으면 사람은 이를 범주 구분으로 인식하지만, R은 그렇지 않습니다. 숫자로 저장된 변수는 모두 연속형으로 처리하므로, 성별의 평균이 1.47이라는 무의미한 값이 산출됩니다.

따라서 자료를 불러온 직후 범주형 변수를 factor로 변환하는 절차가 반드시 선행되어야 합니다.

- 자료를 불러온 직후 수행합니다

```
df <- read.csv("data.csv")

# 범주형 변수를 factor로 변환 + 라벨 붙이기
df$gender <- factor(df$gender, levels = c(1, 2), labels = c("남성", "여성"))
df$group <- factor(df$group, levels = c(1, 2, 3), labels = c("통제", "처치A", "처치B"))

str(df) # 변수별 척도가 의도대로 지정되었는지 확인
```

str(df) 출력

```
'data.frame': 240 obs. of 4 variables:
 $ gender      : Factor w/ 2 levels "남성","여성": 1 2 2 1 1 2 ...
 $ group       : Factor w/ 3 levels "통제","처치A",...: 1 1 2 3 2 3 ...
 $ age         : int  23 21 25 22 24 27 ...
 $ selfesteem : num  3.42 4.10 2.85 3.97 3.20 ...
```

출력에서 `Factor w/ 2 levels`로 표시되면 **범주형으로 지정된 것**이고, `int` 또는 `num`이면 **연속형으로 지정된 것**입니다. 그림 1-1의 분기가 이 단계에서 결정됩니다.

탐지되지 않는 오류

`gender`를 factor로 변환하지 않은 상태에서 t-검정을 돌리면 **오류 메시지 없이 잘못된 결과가 나옵니다**. 오류가 발생하지 않으므로 발견이 더 어렵습니다. 분석 전에 `str(df)`로 척도 지정을 확인하는 습관을 들여야 합니다.

■ 보고 방법

척도의 구분은 논문의 측정도구 절에 반영됩니다.

측정도구 절 기술 예시

본 연구의 종속변수인 자아존중감은 Rosenberg(1965)의 척도 10문항을 5점 리커트 척도(1=전혀 아니다, 5=매우 그렇다)로 측정하였으며, 문항 평균을 분석에 사용하였다. 독립변수인 집단은 통제집단, 처치A, 처치B의 세 수준으로 구성된 명목변수이다.

여기서 **문항 평균을 사용하였다**는 기술이 해당 변수를 연속형으로 처리하겠다는 선언에 해당합니다. 이 진술이 있어야 이후 분산분산분석을 쓰는 것이 정당해집니다.

점검 항목

- ☐ 종속변수가 연속형인지 범주형인지 판별할 수 있다
- ☐ 범주형 변수를 `factor()`로 변환했다
- ☐ `str(df)`로 척도 지정을 확인했다
- ☐ 그림 1-1에서 내가 쓸 분석이 어디인지 짚을 수 있다

요약 — 척도가 확정되면 분석이 특정됩니다. 종속변수가 연속형이면 평균 비교(t-검정·분산분석), 범주형이면 빈도 비교(카이제곱 검정)로 진행합니다. 검토해야 할 것은 분석 기법이 아니라 변수의 척도입니다.

자료를 두 숫자로 요약하기

통계 분석은 자료를 대표값과 산포 두 가지로 축약하는 데서 출발합니다. 이 장에서 다루는 평균과 표준편차는 이후 모든 검정의 계산 재료가 되며, 특히 제곱합(SS)은 분산분석과 회귀분석까지 관통하는 개념입니다.

■ 대표값과 산포를 함께 보아야 하는 이유

자료를 하나의 숫자로 축약하면 중요한 정보가 소실됩니다.

두 학급의 시험 평균이 모두 70점이라고 가정합니다. 한 학급은 68~72점 구간에 밀집해 있고 다른 학급은 30점부터 100점까지 분포합니다. 평균만으로는 두 학급이 동일하지만, 교수자가 취해야 할 조치는 전혀 다릅니다.

따라서 자료를 요약할 때는 두 가지를 함께 제시합니다.


- **대표값** — 분포의 중심이 어디인가 (평균, 중앙값, 최빈값)
- **산포도** — 값들이 얼마나 흩어져 있는가 (분산, 표준편차)

논문의 기술통계표에 **M**과 **SD**가 항상 병기되는 것은 이 때문입니다. 어느 하나만으로는 분포를 설명할 수 없습니다.

■ 세 가지 대표값

대표값	정의	중심의 의미
평균(mean)	모든 값의 합을 사례 수로 나눈 값	무게중심
중앙값(median)	크기순 배열에서 50번째 백분위수	순위상 중앙
최빈값(mode)	가장 빈번하게 관측된 값	최다 빈도

분포가 좌우 대칭이면 세 값은 거의 일치합니다. 차이가 드러나는 것은 편포된 자료입니다.



봉우리 · 한가운데 · 무게중심 — 셋이 다른 값을 가리킨다
치우친 분포에서 "평균이 얼마인가"만 물으면 자료의 생김새를 놓친다

그림 2-1 정적분포에서 세 대표값은 서로 다른 지점을 가리킨다. (개념도)

● 예시 자료

```
y ← c(1, 1, 1, 2, 3, 4, 6, 8, 9, 9, 11)
c(합 = sum(y), 평균 = mean(y), 중앙값 = median(y))
```

실행 결과

합	평균	중앙값
55	5	4

평균은 5, 중앙값은 4, 최빈값은 1로 세 값이 모두 다릅니다.

평균의 민감성

평균은 모든 관측값을 계산에 사용하므로 극단값의 영향을 직접 받습니다. 위 자료에서 11을 100으로 치환하면 평균은 5에서 13.1로 이동하지만 중앙값은 4로 유지됩니다.

소득, 재산, 반응시간과 같이 한쪽으로 길게 늘어지는 변수에서는 중앙값이 분포를 더 적절히 대표합니다. 소득 통계에서 평균소득과 중위소득을 구분해 제시하는 이유가 여기에 있습니다.

논문에서 평균을 사용하는 이유

중앙값이 분포를 더 잘 대표하는 경우에도 논문에서는 평균을 보고하는 것이 일반적입니다. t-검정, 분산분석, 회귀분석이 모두 평균을 비교 대상으로 삼는 분석이기 때문입니다.

다만 분포의 편포가 심각한 경우에는 ① 로그 변환 등으로 분포를 조정하거나 ② 비모수 검정(Mann-Whitney U 검정 등)으로 전환하는 방안을 검토해야 합니다. 심사에서 지적되는 대표적 항목입니다.

■ 산포 측정의 네 단계


산포를 측정하는 공식은 네 단계를 거쳐 완성되었습니다. 각 단계는 직전 단계에서 발생한 문제를 해소하기 위해 도입된 것이며, 그 맥락을 이해하면 공식을 암기할 필요가 없습니다.

1단계 — 편차

산포 측정의 출발점은 각 관측값이 평균에서 벗어난 정도입니다. 이를 **편차(deviation)**라 합니다.

$$\text{편차} = X - M$$

사례가 100개면 편차도 100개이므로, 이를 하나의 지표로 축약하려면 합산해야 합니다. 그러나 이 방식은 성립하지 않습니다.



편차를 모두 더하면 $(+3) + (-1) + (+1) + 0 + (-2) + (-1) = 0$
평균은 편차의 합이 0이 되는 지점이다. 그래서 편차를 그냥 더해서는 흩어진 정도를 잴 수 없다

그림 2-2 자료 7, 3, 5, 4, 2, 3의 편차. 평균 위쪽의 양의 편차와 아래쪽의 음의 편차가 상쇄되어 합이 0이 된다.

● 편차의 합

```
x ← c(7, 3, 5, 4, 2, 3)

x - mean(x)      # 편차
sum(x - mean(x)) # 편차의 합
```

실행 결과


```
[1] 3 -1 1 0 -2 -1
[1] 0
```

편차의 합은 항상 0입니다. 이는 우연이 아니라 평균의 정의에서 따라 나오는 결과입니다. 평균은 편차의 합이 0이 되는 지점으로 정의되며, 무게중심이라는 표현이 여기서 유래합니다.

따라서 편차를 단순 합산해서는 산포를 측정할 수 없으며, 부호를 제거하는 절차가 필요합니다.

2단계 — 제곱

부호를 제거하는 방법은 절댓값과 제곱 두 가지입니다.



제곱을 쓰면 평균에서 멀리 떨어진 값이 흩어짐에 더 크게 반영된다. 대신 단위가 제곱이 되어 표준편차로 되돌린다

그림 2-3 절댓값은 모든 편차를 동일한 비중으로 반영하지만, 제곱은 큰 편차에 더 큰 비중을 부여한다. (개념도)

통계학은 제곱을 채택했으며, 근거는 두 가지입니다.

첫째, **큰 편차에 더 큰 비중을 부여하기 위해서**입니다. 평균에서 4만큼 떨어진 값은 1만큼 떨어진 값의 4배가 아니라 16배로 계산됩니다. 산포를 평가할 때 극단값의 기여를 크게 반영하는 관점입니다.

둘째, **수리적으로 다루기 쉽기 때문**입니다. 절댓값 함수는 미분 불가능한 지점이 존재하지만 제곱 함수는 전 구간에서 미분 가능합니다. 이후의 추정 이론이 이 성질 위에 구축됩니다.

편차를 제곱하여 합산한 값을 **제곱합(Sum of Squares, SS)**이라 합니다.

$$SS = \sum (X - M)^2$$

제곱합은 이 책 전체를 관통합니다

제곱합은 산포 측정에 국한된 개념이 아닙니다. 분산분석은 전체 제곱합을 집단 간 제곱합과 집단 내 제곱합으로 분할하는 절차이며(9장), 회귀분석의 결정계수 역시 제곱합의 비율로 정의됩니다(2권).

"산포를 제곱합으로 측정한다"는 하나의 약속이 이후 대부분의 분석 논리를 규정합니다.

3단계 — 사례 수로 나누기

제곱합에는 한 가지 문제가 남습니다. **사례가 많을수록 값이 커지므로** 사례 수가 다른 자료 간 비교가 불가능합니다.

이를 해소하기 위해 사례 수로 나누어 사례당 평균 산포로 환산합니다. 이 값이 **분산(variance)**입니다.

$$s^2 = \frac{SS}{n-1} = \frac{\sum(X-M)^2}{n-1}$$

4단계 — 제곱근

분산은 단위가 제곱이라는 한계가 있습니다. 점수의 분산은 점수를 제곱한 단위이므로 직접 해석하기 어렵습니다.

제곱근을 취해 원래 단위로 환원한 값이 **표준편차(standard deviation)**입니다.

$$s = \sqrt{s^2}$$



자료 7, 3, 5, 4, 2, 3 을 넣으면

$$SS = 16 \rightarrow s^2 = \frac{16}{5} = 3.2 \rightarrow s = \sqrt{3.2} = 1.79$$

그림 2-4 편차에서 표준편차까지. 각 단계는 직전 단계의 한계를 해소한다.

● 네 단계를 한 번에 확인

```
x ← c(7, 3, 5, 4, 2, 3)

c(SS = sum((x - mean(x))^2),
  분산 = var(x),
  표준편차 = sd(x))
```

실행 결과

SS	분산	표준편차
16.00000	3.20000	1.78885

표준편차 1.79는 각 관측값이 평균 4에서 평균적으로 1.79만큼 떨어져 있다는 의미이며, 자료와 동일한 단위를 가지므로 직접 해석할 수 있습니다.

■ 자유도 — $n-1$ 로 나누는 근거

사례당 평균 산포를 구한다면 사례 수 n 으로 나누어야 할 것처럼 보이지만, 실제로는 $n-1$ 로 나눕니다. 근거는 **표본이 모집단보다 산포가 작게 관측되기** 때문입니다.

표본은 모집단보다 덜 퍼져 보인다




그림 2-5 표본추출 과정에서 중심부의 빈번한 값은 잘 포착되지만 양극단의 희소한 값은 누락되기 쉽다. (개념도)

모집단에서 표본을 추출할 때 중심부의 빈번한 값은 잘 포착되는 반면 양극단의 희소한 값은 누락될 가능성이 높습니다. 그 결과 표본으로 계산한 분산은 모분산보다 작게 산출되며, 이를 **과소추정(underestimation)**이라 합니다.

n 대신 그보다 작은 $n-1$ 로 나누면 값이 증가하며, 이 보정이 과소추정을 상쇄합니다.

● 두 방식의 비교

```
x <- c(7, 3, 5, 4, 2, 3)
SS <- sum((x - mean(x))^2)

c(n으로_나눔 = SS / length(x),
  n에서1뺀 = SS / (length(x) - 1))
```

실행 결과

```
n으로_나눔  n에서1뺀
2.666667    3.200000
```

자유도의 의미

$n-1$ 을 **자유도(degrees of freedom, df)**라 합니다.

평균이 4로 고정된 6개의 값을 생각해 보면, 앞의 다섯 값은 임의로 정할 수 있으나 마지막 값은 평균을 4로 맞추기 위해 자동으로 결정됩니다. 자유롭게 변할 수 있는 값이 5개라는 뜻입니다.

자유도는 이후 모든 검정에서 등장합니다. t-검정의 `df = 238`, 분산분석의 `df = 2, 27` 등이 모두 동일한 개념이며, **제약을 받지 않고 변할 수 있는 값의 개수**로 해석하면 됩니다.

R의 `var()` 와 `sd()` 는 표본 기준입니다

R의 `var()` 와 `sd()` 는 $n-1$ 을 분모로 사용하는 표본 분산·표본 표준편차를 반환합니다. SPSS도 동일합니다. 논문에서 다루는 자료는 대부분 표본이므로 이것이 적절한 선택입니다.

모집단 전체를 확보한 경우에만 n 을 분모로 사용해야 하며, 이때는 별도로 계산해야 합니다.

■ 표준편차의 해석

표준편차는 계산 결과에 그치지 않고 **특정 값이 흔한지 드문지를 판단하는 기준**으로 기능합니다.




그림 2-6 정규분포에서 평균 ± 1 표준편차 구간에 약 68%, ± 2 구간에 약 95%가 포함된다.

이른바 68-95-99.7 규칙을 적용하면 다음과 같은 판단이 즉시 가능합니다.

- 평균 70, 표준편차 5인 시험에서 85점은 평균보다 3 표준편차 높으므로 상위 0.1% 수준
- 평균 3.5, 표준편차 0.8인 자아존중감에서 4.3점은 1 표준편차 높으므로 상위 16% 수준

유의수준 .05의 기원

평균에서 2 표준편차 이상 떨어진 값이 전체의 약 5%라는 사실에 주목할 필요가 있습니다. 5장에서 다루는 **유의수준 .05가 정확히 이 지점에서 설정**됩니다. 우연으로 보기 어려운 경계를 어디에 둘 것인가의 문제입니다.


■ 표준점수 — 척도가 다른 값의 비교

수학에서 72.8점, 영어에서 94점을 얻었을 때 어느 과목의 성취가 더 높은지는 원점수만으로 판단할 수 없습니다. 두 시험의 난이도와 점수 분포가 다르기 때문입니다.


필요한 것은 각 분포 내에서의 상대적 위치이며, 편차를 표준편차로 나누면 이를 얻을 수 있습니다. 이 값이 **표준점수(z-score)**입니다.

$$z = \frac{X - M}{s}$$

수학 (평균 70, 표준편차 5)



영어 (평균 90, 표준편차 8)



수학 0.56 > 영어 0.50

원점수는 영어가 훨씬 높지만, 각 과목 안에서의 위치로 바꾸면 수학을 더 잘 본 것이다

그림 2-7 원점수로는 영어가 21점 높으나, 각 분포 내 상대적 위치로 환산하면 수학이 앞선다.

● 두 과목의 비교

```
z_math <- (72.8 - 70) / 5      # 수학: 평균 70, 표준편차 5
z_eng  <- (94 - 90) / 8       # 영어: 평균 90, 표준편차 8

c(수학 = z_math, 영어 = z_eng)
```

실행 결과

```
수학 영어
0.56 0.50
```

원점수는 영어가 21점 높지만 상대적 위치는 수학이 앞섭니다.

표준점수로 변환하면 모든 자료가 **평균 0, 표준편차 1**인 분포에 놓이며 단위가 소거되므로, 척도가 상이한 변수 간 비교가 가능해집니다.

표준화는 분포의 형태를 바꾸지 않습니다

빈번한 오해입니다. z 변환은 **선형변환**이므로 분포의 위치와 척도만 조정하며 형태는 그대로 유지됩니다. 편포된 자료를 표준화해도 편포는 해소되지 않습니다.

분포의 형태를 조정하려면 로그 변환과 같은 비선형 변환이 필요합니다.

표준점수의 활용

① 척도가 다른 변수를 동일 모형에 투입할 때(회귀분석의 표준화 계수 β), ② 이상치를 판별할 때(통상 $|z| > 3$), ③ 복수의 검사 점수를 합산할 때 사용합니다.

R에서는 `scale()` 함수로 처리합니다. `df$z_selfesteem <- scale(df$selfesteem)`

■ 예제 자료의 기술통계

● 이 책의 예제 데이터

```
df <- read.csv("data/sample_data.csv")
s <- df$selfesteem

c(n = length(s), M = mean(s), SD = sd(s),
  중앙값 = median(s), 최소 = min(s), 최대 = max(s))
```

실행 결과

n	M	SD	중앙값	최소	최대
240.00000	3.49700	0.83400	3.50000	1.19000	5.00000

평균 3.50과 중앙값 3.50이 거의 일치합니다. 이는 **분포가 크게 편포되지 않았음**을 시사하며, 평균이 자료를 적절히 대표한다는 근거가 됩니다. 7장에서 이 변수로 t-검정을 할 때 정규성 가정을 크게 우려하지 않아도 되는 이유가 여기에 있습니다.

점검 항목

- ☐ 대표값과 산포를 함께 제시해야 하는 이유를 설명할 수 있다
- ☐ 편차의 합이 0이 되는 이유를 평균의 정의로 설명할 수 있다
- ☐ 절댓값이 아니라 제곱을 채택한 두 가지 근거를 안다
- ☐ $n-1$ 로 나누는 근거를 과소추정으로 설명할 수 있다
- ☐ 표준편차를 "평균에서 평균적으로 이만큼"으로 해석할 수 있다

☐ 표준화가 분포의 형태를 바꾸지 않는다는 점을 안다

요약 — 산포 측정 공식은 네 단계의 문제 해결 과정을 거쳐 성립했습니다. 편차의 합이 0이 되므로 **제곱**하고, 사례 수에 비례해 커지므로 **나누며**, 단위가 제곱이 되므로 **제곱근**을 취합니다. 표본은 산포를 과소추정하므로 분모에 n 이 아닌 $n-1$ 을 사용합니다.

분포의 형태 진단

모수 검정의 대부분은 정규성 가정 위에 성립합니다. 이 장에서는 정규분포가 분석의 기준이 된 근거와, 자료가 그 기준에서 벗어난 정도를 왜도와 첨도로 진단하는 절차를 다룹니다.

■ 정규분포가 기준이 된 근거

정규분포가 통계 분석의 기준 분포로 채택된 것은 자연현상이 그 형태를 따르기 때문이 아니라, 두 가지 실용적 근거 때문입니다.

첫째, **두 개의 모수만으로 분포가 완전히 결정됩니다.** 평균과 표준편차가 주어지면 곡선의 모든 지점이 확정됩니다. 논문에 **M**과 **SD**만 보고해도 독자가 분포를 복원할 수 있는 것은 이 성질에 근거합니다.




그림 3-1 평균은 분포의 위치를, 표준편차는 폭을 결정한다. 추가 정보는 필요하지 않다. (개념도)

둘째, **표본평균의 분포가 정규분포를 따르기 때문**입니다. 이것이 실질적인 근거이며, 4장에서 다루는 중심극한정리가 이를 보장합니다. 검정의 대상은 개별 관측값이 아니라 평균이므로, 원자료가 정규분포를 따르지 않아도 분석이 성립합니다.

정규분포의 성질은 다음과 같습니다.

성질	내용
연속형	값 사이에 단절이 없다
좌우대칭	평균을 기준으로 양측이 동일하다
단봉	최빈값이 하나다
무한	양방향으로 무한히 이어지나 축에 닿지 않는다
두 모수로 결정	평균과 표준편차 외의 정보가 필요하지 않다


정규분포는 이론적 모형입니다

실제 자료가 정규분포와 정확히 일치하는 경우는 없습니다. 신장은 음수가 될 수 없으므로 엄밀한 의미의 무한분포가 아닙니다.

판단 기준은 일치 여부가 아니라 **분석이 건널 수 있을 만큼 근사한가**입니다. 그 정도를 정량화하는 지표가 왜도와 첨도입니다.

■ 왜도 — 편포의 방향과 정도

왜도(skewness)는 분포가 한쪽으로 치우친 정도를 나타내며, 부호가 꼬리의 방향을 지시합니다.



왜도의 부호는 꼬리가 길게 늘어진 쪽을 가리킨다. 절댓값이 2를 넘으면 정규성을 의심한다

그림 3-2 왜도의 부호는 꼬리가 길게 늘어진 방향을 가리킨다. (개념도)

- **양수 — 정적편포(positively skewed)** 오른쪽으로 꼬리가 길다. 소득, 반응시간과 같이 하한은 고정되어 있고 상한이 열린 변수에서 나타납니다.
- **음수 — 부적편포(negatively skewed)** 왼쪽으로 꼬리가 길다. 난이도가 낮은 시험이나 만족도 문항처럼 천장효과가 발생하는 변수에서 나타납니다.

2장에서 확인한 바와 같이 **편포가 존재하면 평균이 꼬리 방향으로 이동합니다**. 따라서 왜도는 평균의 대표성을 판단하는 지표로도 기능합니다.

■ 첨도 — 꼬리의 두께

첨도(kurtosis)는 분포의 중심이 뾰족한 정도로 설명되지만, 정확히는 **꼬리가 얼마나 두꺼운가**를 측정하는 지표입니다.




그림 3-3 첨도가 크면 중심부의 밀집과 극단값의 증가가 동시에 나타난다. (개념도)

첨도가 크다는 것은 중심부에 밀집하면서 동시에 극단값도 많다는 의미이며, 중간 범위의 값이 상대적으로 적다는 뜻으로 해석하면 됩니다.

■ 진단 절차

● psych 패키지를 이용한 기술통계

```
# install.packages("psych")
library(psych)

df <- read.csv("data/sample_data.csv")
describe(df$selfesteem)
```

실행 결과

```
   n mean   sd median  skew kurtosis
1 240  3.5 0.83    3.5 -0.16   -0.57
```

왜도 -0.16, 첨도 -0.57로 두 지표 모두 0에 근접하므로 정규분포에서 크게 벗어나지 않았습니다. 평균 3.50과 중앙값 3.50이 일치하는 것도 동일한 결론을 지지합니다.

판단 기준

연구 분야에 따라 차이가 있으나, 사회과학에서 널리 인용되는 기준은 다음과 같습니다.

지표	허용 범위	출처
왜도	절댓값 2 미만	West, Finch & Curran (1995)
첨도	절댓값 7 미만	West, Finch & Curran (1995)

왜도 1, 첨도 3을 적용하는 더 엄격한 기준도 사용됩니다. 어떤 기준을 채택했는지 출처와 함께 명시하면 심사에서 문제가 되지 않습니다.

정규성 검정 단독으로 판단하지 않습니다

Shapiro-Wilk 검정과 Kolmogorov-Smirnov 검정은 표본이 커질수록 기각 확률이 높아집니다. n 이 500이면 육안으로 정규분포와 구분되지 않는 자료도 $p < .05$ 로 산출됩니다.

따라서 실무에서는 ① 왜도·첨도 수치, ② 히스토그램 또는 Q-Q 플롯, ③ 표본크기를 종합하여 판단합니다. 단일 검정 결과에 의존해서는 안 됩니다.

보고 예시

주요 변수의 정규성을 확인하기 위해 왜도와 첨도를 산출하였다. 자아존중감의 왜도는 -0.16 , 첨도는 -0.57 로 West 등(1995)이 제시한 기준(왜도 절댓값 2, 첨도 절댓값 7)을 충족하여 정규성 가정에 위배되지 않는 것으로 판단하였다.

점검 항목

- ☐ 정규분포가 두 모수만으로 결정된다는 성질을 안다
- ☐ 왜도의 부호가 꼬리의 방향을 지시한다는 것을 안다
- ☐ 편포가 있을 때 평균이 어느 방향으로 이동하는지 설명할 수 있다
- ☐ 정규성 검정의 유의확률만으로 판단해서는 안 되는 이유를 안다

요약 — 정규분포가 기준이 된 근거는 **두 모수로 분포가 결정된다는 점**과 **표본평균이 그 분포를 따른다는 점**입니다. 자료가 기준에서 벗어난 정도는 왜도와 첨도로 진단하되, 정규성 검정의 유의확률에 단독으로 의존하지 않습니다.

표본에서 모집단을 추론하는 근거

240명을 조사하고 모집단 전체에 대해 진술하는 것이 어떻게 정당화되는가. 이 장은 추리통계 전체가 의존하는 표집분포와 중심극한정리를 다룹니다. 이 토대가 불분명하면 유의확률과 신뢰구간은 암기의 대상이 됩니다.

■ 추론의 구조

연구의 관심 대상은 **모집단**입니다. 그러나 모집단 전체를 조사하는 것은 대부분 불가능하므로 **표본**을 추출하여 분석합니다. 여기서 다음 문제가 발생합니다.

표본에서 산출한 평균 3.50이 모집단의 평균과 얼마나 가까운가?

다른 240명을 추출했다면 3.42 또는 3.58이 산출되었을 수 있습니다. **추출된 표본이 모집단을 잘 대표하지 못할 가능성**을 정량적으로 다루는 것이 추리통계의 과제입니다.

용어의 구분

구분	모집단	표본
대상	추론하려는 전체	실제 조사한 일부
평균	μ (뮤)	M 또는 $\bar{X}$
표준편차	σ (시그마)	s
명칭	모수(parameter)	통계치(statistic)

모수는 알 수 없는 참값이고 통계치는 표본에서 계산한 값입니다. **통계치로 모수를 추정하는 것**이 추리통계의 전 과정입니다.

■ 표집분포

추론의 핵심 장치는 다음과 같습니다.

동일한 크기의 표본을 무한히 반복 추출한다고 가정합니다. 표본마다 평균이 산출되며, 이 평균들이 이루는 분포를 **표집분포 (sampling distribution)**라 합니다.




그림 4-1 표집분포는 개별 관측값의 분포가 아니라 표본평균이라는 통계치의 분포다. (개념도)

표집분포는 점수의 분포가 아닙니다

개념상 혼동이 가장 잦은 지점입니다. 표집분포는 240명의 자아존중감 점수로 그린 히스토그램과 전혀 다른 대상입니다.

표집분포는 **통계치의 분포**입니다. 표본평균 **M**의 분포일 수도 있고 **t**값이나 **F**값의 분포일 수도 있으며, 무엇을 계산했는가에 따라 달라집니다.

또한 표집분포는 실제로 관측된 적이 없습니다. 표본은 하나만 추출했기 때문입니다. 그럼에도 이 분포의 성질이 이론적으로 알려져 있기에 추론이 가능해집니다.

표집분포에 대해 다음 세 가지가 알려져 있습니다.

1. **표본평균들의 평균은 모평균과 일치한다** — 편향이 없다
2. **표본크기가 커질수록 표집분포의 폭이 좁아진다** — 추정이 정밀해진다
3. **표본크기가 충분히 크면 표집분포는 정규분포에 근사한다** — 원자료의 형태와 무관하게

세 번째 성질이 **중심극한정리**입니다.

■ 중심극한정리

중심극한정리는 다음과 같이 진술됩니다.

원자료의 분포 형태와 관계없이, 표본 크기 n 이 증가하면 표본평균의 분포는 정규분포에 근사한다.

시뮬레이션으로 확인할 수 있습니다. 검증을 위해 **심하게 편포된 모집단**을 설정합니다.

● 지수분포 모집단에서의 반복 추출

```
set.seed(2025)
pop <- rexp(200000, rate = 1)      # 정적편포가 심한 모집단

library(psych)
skew(pop)                          # 모집단의 왜도


# n명으로 구성된 표본의 평균을 5,000회 산출
means5 <- replicate(5000, mean(sample(pop, 5)))
means30 <- replicate(5000, mean(sample(pop, 30)))

c(원자료 = skew(pop), n5 = skew(means5), n30 = skew(means30))
```

실행 결과


원자료	n5	n30
1.97	0.87	0.40

원자료 하나하나




지수분포 · 심하게 치우침
왜도 1.97 · 표준편차 1.00

5명씩 뽑은 평균



벌써 대칭에 가까워진다
왜도 0.87 · 표준편차 0.45

30명씩 뽑은 평균



정규분포에 근사한다
왜도 0.40 · 표준편차 0.18

모집단이 아무리 치우쳐 있어도, 표본 크기가 커지면 표본평균의 분포는 정규분포로 간다
표본을 많이 뽑는 것이 아니라, 표본 하나의 크기 n 이 커져야 한다

그림 4-2 모집단의 왜도는 1.97이지만, 5명 표본의 평균에서 이미 대칭에 근접하고 30명 표본에서는 정규분포에 근사한다.

왜도가 1.97에서 0.40으로 감소했습니다. 모집단은 정규분포와 거리가 멀지만 표본평균의 분포는 정규분포에 수렴합니다.

표본의 개수가 아니라 표본의 크기입니다

가장 빈번한 오해입니다. 중심극한정리가 규정하는 것은 표본을 몇 번 추출하는가가 아니라 **표본 하나에 포함된 사례 수 n** 입니다.

5명으로 구성된 표본을 100만 회 추출해도 표집분포는 정규분포에 근사하지 않습니다.

$n \geq 30$ 관행의 근거

위 결과에서 $n = 30$ 일 때 왜도가 0.40까지 감소했습니다. 이 수준이면 정규분포로 취급해도 분석에 지장이 없다고 보아, 사회과학에서는 각 집단의 n 이 30 이상이면 정규성 가정을 크게 문제 삼지 않습니다.

다만 원자료의 편포가 극단적인 경우에는 30으로 충분하지 않을 수 있습니다. 이론적 임계값이 아니라 경험적 관행입니다.

중심극한정리는 이 책의 나머지 전체를 지탱합니다. t-검정과 분산분석은 표본평균이 정규분포를 따른다는 전제 위에 성립하며, 그 전제를 보장하는 것이 이 정리입니다.

■ 표준오차

표집분포의 표준편차를 **표준오차(standard error, SE)**라 합니다.

$$SE = \frac{s}{\sqrt{n}}$$

명칭과 달리 오차의 측정값이 아니라 **표본평균이 모평균에서 평균적으로 벗어나는 정도**를 나타냅니다. 표집 과정에서 발생하는 표집오차를 정량화한 값입니다.

● 표준오차 산출

```
s <- df$selfesteem
SE <- sd(s) / sqrt(length(s))


c(SD = sd(s), n = length(s), SE = SE)
```

실행 결과

SD	n	SE
0.8338000	240.000000	0.0538000

표준편차는 0.83이지만 표준오차는 0.054로 현저히 작습니다. 개인 간 차이는 크지만 240명의 평균은 그만큼 크게 변동하지 않는다는 의미입니다.

SD는 그대로 0.83인데, 표본평균의 흔들림만 줄어든다



표본이 4배가 되면 표준오차는 절반이 된다. 제곱근이 붙어 있기 때문이다

그림 4-3 자료의 표준편차가 동일해도 표본크기가 증가하면 표집분포의 폭이 좁아진다.

● 표본크기별 표준오차

```
for(n in c(25, 100, 400)) cat(n, ":", round(sd(s)/sqrt(n), 4), "\n")
```

실행 결과

```
25 : 0.1668
100 : 0.0834
400 : 0.0417
```

표본크기가 4배가 되면 표준오차는 1/2이 됩니다. 분모에 제곱근이 있기 때문입니다. 이 관계는 표본크기 설계에서 중요합니다. 추정의 정밀도를 2배로 높이려면 표본을 4배로 늘려야 합니다.

■ 표준편차와 표준오차의 구분

두 지표는 명칭이 유사하나 측정 대상이 다릅니다.

표준편차 (SD)

사람들이 서로 얼마나 다른가

자료 자체의 성질 · 표본이 커져도 줄지 않는다

$$SD$$

표준오차 (SE)

내 평균이 얼마나 못 미더운가

추정의 정밀도 · 표본이 커지면 줄어든다

$$SE = \frac{SD}{\sqrt{n}}$$

논문 표에 SD를 쓸지 SE를 쓸지는 무엇을 말하려는지에 달렸다

그림 4-4 표준편차는 개인 간 변동을, 표준오차는 추정의 정밀도를 측정한다. (개념도)

	표준편차 (SD)	표준오차 (SE)
측정 대상	개인 간 변동의 크기	표본평균의 변동 가능성
표본크기 증가 시	변하지 않음	감소
성격	자료의 속성	추정의 정밀도
보고 위치	기술통계표	오차막대, 신뢰구간

표에 SD와 SE 중 무엇을 보고할 것인가

집단의 분포 특성을 제시하려면 SD를 사용합니다. 논문의 기술통계표에는 대부분 SD를 보고합니다.

평균 추정의 정밀도를 제시하려면 SE를 사용합니다. 그래프의 오차막대에는 SE를 쓰는 경우가 많습니다.

오차막대를 제시할 때는 **SD인지 SE인지 95% 신뢰구간인지 캡션에 명시**해야 합니다. 명시하지 않으면 해석이 불가능하며 심사에서 지적됩니다.

표준오차는 이후 모든 검정통계량의 분모입니다

6장의 신뢰구간, 7장의 t 값, 9장의 F 값이 모두 표준오차를 분모로 계산됩니다.

관찰된 차이 ÷ 그 차이가 변동하는 정도라는 형태가 반복되며, 검정통계량은 결국 관찰된 차이가 우연한 변동의 몇 배인가를 측정하는 값입니다.

점검 항목

- ☐ 모수와 통계치를 구분할 수 있다
- ☐ 표집분포가 통계치의 분포임을 설명할 수 있다
- ☐ 중심극한정리가 표본의 개수가 아니라 크기에 관한 것임을 안다
- ☐ 표준편차와 표준오차의 측정 대상을 구분할 수 있다
- ☐ 표본크기가 4배가 될 때 표준오차가 1/2이 되는 이유를 안다

요약 — 표본으로 모집단을 추론할 수 있는 근거는 **중심극한정리**입니다. 원자료의 형태와 무관하게 표본평균의 분포는 정규분포에 근사하며, 그 분포의 폭인 **표준오차**가 이후 모든 검정통계량의 분모가 됩니다.

가설검정의 논리

유의확률이 .05보다 작으면 유의하다는 규칙은 대부분 알고 있습니다. 문제는 그 규칙이 어디서 나왔는지 모른 채 적용한다는 데 있습니다. 이 장은 그 규칙이 성립하는 논리를 처음부터 재구성합니다.

■ 왜 하필 영가설을 세우는가

연구자가 확인하고 싶은 것은 대체로 "효과가 있다"입니다. 그런데 통계적 검정은 그 반대 명제, 즉 "**효과가 없다**"에서 출발합니다. 이 구조가 처음에는 납득되지 않습니다.

이유는 간단합니다. **효과가 있다는 명제로는 계산을 시작할 수 없기 때문**입니다.

"프로그램에 효과가 있다"는 진술을 생각해 보십시오. 효과가 3점일 수도, 5점일 수도, 0.7점일 수도 있습니다. 가능한 경우가 무수히 많으므로 어떤 분포를 그려야 할지 정할 수 없습니다.

반면 "효과가 없다"는 진술은 **하나의 값으로 확정됩니다**. 차이가 정확히 0이라는 뜻입니다. 값이 하나로 정해지면 그 값을 중심으로 분포를 그릴 수 있고, 분포를 그릴 수 있으면 확률을 계산할 수 있습니다.

영가설과 대립가설

영가설(null hypothesis, H_0) — 검정의 대상이 되는 명제입니다. 보통 "차이가 없다", "관계가 없다"의 형태이며, 연구자는 대체로 이것이 기각되기를 기대합니다.



대립가설(alternative hypothesis, H_1) — 영가설이 기각되었을 때 채택되는 명제입니다. 보통 연구자가 주장하려는 내용입니다.

두 가설은 연구자의 선호로 정해지는 것이 아니라 **계산 가능성으로 정해집니다**. 값이 하나로 확정되는 쪽이 영가설이 됩니다.

집단상담 프로그램의 효과를 검증하는 연구라면 가설은 이렇게 설정됩니다.

$$H_0 : \mu_{\text{처치}} - \mu_{\text{통제}} = 0 \quad H_1 : \mu_{\text{처치}} - \mu_{\text{통제}} \neq 0$$

영가설만 하나의 값으로 확정됩니다



그래서 계산이 가능한 쪽을 영가설로 세우고, 그것을 기각하는 방식으로 검정한다

그림 5-1 영가설은 값이 0 하나로 정해지므로 분포를 그릴 수 있다. 대립가설은 가능한 값이 무수히 많아 분포를 특정할 수 없다. (개념도)

■ 유의확률이 실제로 재는 것

유의확률은 오해가 가장 잦은 개념입니다. 먼저 정확한 정의부터 확인합니다.

유의확률(p-value) — 영가설이 참이라고 가정했을 때, 지금 얻은 검정통계량만큼 극단적이거나 그보다 더 극단적인 값이 나올 확률.

정의에서 확인해야 할 지점이 세 군데입니다.

"영가설이 참이라고 가정했을 때" — 유의확률은 조건부 확률입니다. 영가설이 참이라는 전제 위에서만 계산됩니다.

"지금 얻은 값만큼 극단적이거나 그보다 더 극단적인" — 특정 지점의 확률이 아니라 꼬리 쪽 면적 전체입니다.

연속확률분포에서 어느 한 점의 확률은 0이므로 면적으로 계산할 수밖에 없습니다.

"나올 확률" — 확률이므로 0 이상 1 이하입니다.




그림 5-2 유의확률은 영가설 분포에서 내 결과보다 바깥쪽에 있는 면적이다. 점이 아니라 면적이다. (개념도)

유의확률은 영가설이 참일 확률이 아닙니다

가장 빈번한 오해입니다. $p = .03$ 은 영가설이 참일 확률이 3%라는 뜻이 아닙니다.


유의확률은 영가설이 참이라고 가정한 상태에서 계산된 값입니다. 전제로 깔아둔 것의 확률을 결과로 돌려줄 수는 없습니다.

정확한 해석은 이것입니다. "영가설이 참이라면, 이만한 결과가 나올 일은 100번 중 3번뿐이다. 그렇게 드문 일이 지금 일어났다고 보기보다는, 애초에 전제가 틀렸다고 보는 편이 자연스럽다."

이 논리를 순서대로 정리하면 다음과 같습니다.

1. 영가설이 참이라고 가정한다
2. 그 가정 위에서 검정통계량의 분포를 그린다
3. 실제로 얻은 검정통계량이 그 분포의 어디에 있는지 확인한다
4. 너무 바깥쪽이면 — 이만한 값이 나올 확률이 너무 작으면 — 가정 자체를 의심한다
5. 따라서 영가설을 기각한다

가설검정은 대립가설을 증명하는 절차가 아니라, 영가설을 소거하는 절차다



그래서 "기각에 실패했다"고 말하지 "영가설이 맞다"고 말하지 않는다

그림 5-3 가설검정의 다섯 단계. 대립가설을 증명하는 절차가 아니라 영가설을 소거하는 절차다. (개념도)

증명이 아니라 소거법입니다. 영가설로는 설명이 어려우니 다른 설명을 찾겠다는 것이지, 대립가설이 참임을 보인 것이 아닙니다.

$p = .000$ 은 존재하지 않습니다

SPSS가 유의확률을 .000으로 표시하는 경우가 있습니다. 소수 넷째 자리에서 반올림한 표기일 뿐 확률이 0이라는 뜻이 아닙니다.

연속확률분포는 음의 무한대에서 양의 무한대까지 정의되므로 어떤 값이든 나올 수 있습니다. 확률이 정확히 0인 사건은 없습니다.

논문에는 반드시 $p < .001$ 로 기술합니다. R은 애초에 `p-value < 2.2e-16` 처럼 표기하여 이 혼동을 방지합니다.

■ 유의수준 — 기준선은 연구자가 정합니다

유의확률을 계산했으면 기각 여부를 판단할 기준이 필요합니다. 이 기준을 **유의수준(significance level, α)**이라 합니다.

사회과학에서는 관행적으로 .05를 사용하지만, **이 값은 수학적으로 도출된 것이 아니라 연구자가 설정하는 것입니다.** 판단이 틀렸을 때의 손실이 클수록 더 엄격한 기준을 적용해야 합니다.

유의수준	적용 상황
.10	탐색적 연구, 선행연구가 거의 없는 영역
.05	사회과학의 일반적 기준
.01	오판의 손실이 큰 경우, 대규모 표본
.001 이하	의학·약학의 임상시험, 다중검정 보정 시

신약의 효과를 검정하는 상황을 생각해 보십시오. 효과가 없는 약을 효과가 있다고 판단하면 환자가 피해를 입습니다. 이런 경우 .05는 지나치게 느슨합니다.

■ 두 종류의 오류

검정의 결론은 참 또는 거짓 둘 중 하나이고 실제 진리도 둘 중 하나이므로, 경우의 수는 네 가지입니다. 이 가운데 둘이 오류입니다.

		실 제	
		H_0 이 참 (효과 없음)	H_1 이 참 (효과 있음)
판 단	기각 실패	옳은 판단 $1 - \alpha$	제2종 오류 β 있는 것을 놓침
	H_0 기각	제1종 오류 α 없는 것을 발견했다고 주장	검정력 $1 - \beta$ 있는 것을 찾아냄

대각선 둘은 옳은 판단이고, 나머지 둘이 오류다. 통계학은 제1종 오류를 더 엄격하게 막는다
 없는 효과를 발표하면 그 위에 후속 연구가 쌓이기 때문이다

그림 5-4 진리와 판단을 교차한 네 칸. 대각선 둘은 옳은 판단이고, 나머지 둘이 제1종·제2종 오류다. (개념도)

	실제로 H_0 이 참	실제로 H_1 이 참
H_0 기각 실패	옳은 판단 ($1 - \alpha$)	제2종 오류 (β)
H_0 기각	제1종 오류 (α)	옳은 판단 = 검정력 ($1 - \beta$)

제1종 오류(α) — 효과가 없는데 있다고 판단하는 오류입니다. 없는 것을 발견했다고 주장하는 셈이므로 **허위 발견**에 해당합니다.

제2종 오류(β) — 효과가 있는데 없다고 판단하는 오류입니다. 있는 것을 놓친 것이므로 **탐지 실패**에 해당합니다.

제1종 오류를 더 심각하게 보는 이유

두 오류 중 어느 쪽이 더 위험한지는 상황에 따라 다르지만, 통계학의 관행은 **제1종 오류를 더 엄격하게 통제합니다**.

없는 효과를 있다고 발표하면 그 주장이 문헌에 남아 후속 연구가 그 위에 쌓입니다. 잘못된 전제 위에 축적된 연구를 되돌리는 데는 훨씬 큰 비용이 듭니다.

반면 있는 효과를 놓치면 발견이 늦어질 뿐 학문적 손실은 회복 가능합니다. 다른 연구자가 다시 확인하면 됩니다.

α 를 .05로 고정하고 β 는 따로 통제하지 않는 관행은 이 비대칭에서 나왔습니다.

두 오류는 동시에 줄일 수 없습니다

α 를 .05에서 .01로 낮추면 제1종 오류는 줄지만, 기각이 어려워지므로 **제2종 오류는 늘어납니다**. 반대로 마찬가지입니다.

두 오류를 동시에 줄이는 방법은 하나뿐입니다. **표본크기를 늘리는 것**입니다. 이 부분은 이어지는 검정력 절에서 다룹니다.

■ 검정력 — 있는 것을 찾아낼 확률

검정력(power, $1 - \beta$)은 대립가설이 참일 때 영가설을 올바르게 기각할 확률입니다. 즉 **실재하는 효과를 탐지해낼 확률**입니다.

연구자가 실질적으로 관리해야 할 값이 이것입니다. 검정력이 낮으면 아무리 자료를 잘 모아도 효과를 찾아내지 못합니다.

● 검정력 계산 — 별도 패키지가 필요 없습니다

```
# 중간 크기 효과( $d = 0.5$ )를 각 집단 30명으로 잡아낼 확률
power.t.test(n = 30, delta = 0.5, sd = 1, sig.level = 0.05)$power
```

실행 결과

[1] 0.4778912


검정력이 .478입니다. 실제로 중간 크기의 효과가 존재하더라도 절반 이상의 확률로 놓친다는 뜻입니다. 각 집단 30명은 통계 교재에서 흔히 제시되는 최소 기준이지만, 검정력 관점에서는 충분하지 않습니다.

● 표본크기를 바꿔 가며 확인

```
for(n in c(20, 30, 50, 64, 100))  
  cat(sprintf("각 집단 n=%3d   검정력 = %.3f\n", n,  
    power.t.test(n = n, delta = 0.5, sd = 1, sig.level = .05)$power))
```

실행 결과

각 집단 n= 20 검정력 = 0.338
각 집단 n= 30 검정력 = 0.478
각 집단 n= 50 검정력 = 0.697
각 집단 n= 64 검정력 = 0.801
각 집단 n=100 검정력 = 0.940



각 집단 30명으로는 실행하는 중간 크기 효과의 절반 이상을 놓친다. 64명이 되어야 .80을 넘는다

그림 5-5 효과크기를 d = 0.5로 고정하고 표본크기만 바꾼 결과. 통상적인 목표선 .80을 넘으려면 각 집단 64명이 필요하다.

Cohen(1988)이 제시한 관행적 목표는 **검정력 .80**입니다. 필요한 표본크기를 거꾸로 구할 수도 있습니다.

● 검정력 .80을 확보하려면 몇 명이 필요한가

```
power.t.test(delta = 0.5, sd = 1, sig.level = 0.05, power = 0.80)
```

실행 결과

Two-sample t test power calculation

```
n = 63.76576
delta = 0.5
sd = 1
sig.level = 0.05
power = 0.8
alternative = two.sided
```

NOTE: n is number in *each* group

각 집단 64명, 합계 128명입니다. NOTE 에 명시된 대로 `n` 은 집단당 인원이므로, 이 값을 전체 표본크기로 오독하면 필요 인원의 절반만 모으게 됩니다.

검정력에 영향을 주는 네 가지

- ① 효과크기 — 실제 효과가 클수록 찾기 쉽습니다. 다만 연구자가 조정할 수 있는 값이 아닙니다. 자연에 존재하는 크기입니다.
- ② 유의수준 — α 를 키우면 검정력은 올라가지만 제1종 오류도 함께 커집니다. 아래 출력이 그 맞바꿈을 보여줍니다.
- ③ 검정 방향 — 일방검정은 양방검정보다 검정력이 높습니다. 그러나 효과의 방향을 사전에 확신할 수 있는 경우가 드물어 실제로는 거의 쓰이지 않습니다.
- ④ 표본크기 — 연구자가 학문적 비판 없이 조정할 수 있는 유일한 요인입니다. n 이 커지면 표준오차 $s/\sqrt{n}$ 이 작아지고, 표준오차가 작아지면 같은 크기의 차이도 더 큰 검정통계량으로 환산되어 기각이 쉬워집니다.


- 유의수준을 바꾸면 (각 집단 $n = 30$, $d = 0.5$)

```
for(a in c(.01, .05, .10))
  cat(sprintf("alpha=%.2f  검정력 = %.3f\n", a,
    power.t.test(n = 30, delta = .5, sd = 1, sig.level = a)$power))
```

실행 결과

```
alpha=0.01  검정력 = 0.244
alpha=0.05  검정력 = 0.478
alpha=0.10  검정력 = 0.606
```

α 를 .01로 낮추면 검정력이 .244로 떨어집니다. 제1종 오류를 줄인 대가로 제2종 오류가 커진 것입니다. 두 오류는 이렇게 맞물려 있습니다.



기각선을 오른쪽으로 옮기면 α 는 줄지만 β 는 늘어난다. 둘을 함께 줄이려면 표본을 키워야 한다

그림 5-6 영가설 분포와 대립가설 분포가 겹치는 구간에서 α 와 β 가 결정된다. 기각선을 오른쪽으로 옮기면 α 는 줄지만 β 는 늘어난다. (개념도)

표본크기는 연구계획서에 근거를 써야 합니다

"선행연구를 참고하여 200명을 표집하였다"는 기술로는 충분하지 않은 경우가 늘고 있습니다. 검정력 분석에 근거한 표집이 요구되는 추세입니다.

선행연구(○○○, 2021)에서 보고된 효과크기 Cohen's $d = 0.50$ 을 기준으로, 유의수준 .05, 검정력 .80을 확보하기 위한 표본크기를 산출한 결과 집단당 64명, 총 128명이 필요한 것으로 나타났다. 탈락률 15%를 고려하여 총 150명을 표집하였다.

효과크기의 출처(선행연구 또는 예비조사)를 함께 밝히는 것이 관건입니다.

■ 유의하다는 말이 중요하다라는 뜻은 아닙니다

검정력 절에서 확인한 대로 표본크기가 커지면 기각이 쉬워집니다. 이 성질에는 대가가 따릅니다. **실질적으로 의미 없는 차이도 표본만 충분하면 유의해집니다.**

100점 만점 능력검사에서 모평균이 30점인 모집단을 가정합니다. 향상 프로그램을 적용한 뒤 평균이 31점, 표준편차가 15로 나왔습니다. **100점 만점에서 1점 차이입니다.**

- 차이는 그대로 두고 표본크기만 바꿉니다

```
for(n in c(50, 100, 400, 1000)) {
  z <- (31 - 30) / (15 / sqrt(n))
  cat(sprintf("n=%4d SE=%.3f z=%.3f p=%.4f d=%.3f\n",
    n, 15/sqrt(n), z, 2*pnorm(-abs(z)), (31-30)/15))
}
```

실행 결과

n= 50 SE=2.121 z=0.471 p=0.6374 d=0.067
n= 100 SE=1.500 z=0.667 p=0.5050 d=0.067
n= 400 SE=0.750 z=1.333 p=0.1824 d=0.067
n=1000 SE=0.474 z=2.108 p=0.0350 d=0.067

100점 만점에서 1점 차이. 표본크기만 바꿨다

표본크기	평균 차이	유의확률 p	효과크기 d
n = 50	1점	0.6374	0.067
n = 100	1점	0.5050	0.067
n = 400	1점	0.1824	0.067
n = 1,000	1점	0.0350 ✓ 유의	0.067

평균 차이도 효과크기도 그대로인데 p값만 작아져 결론이 뒤집힌다

효과크기 공식에는 표본크기가 들어가지 않기 때문이다

그림 5-7 평균 차이 1점과 효과크기 0.067은 그대로인데, 표본크기만 바뀌자 p값이 .637에서 .035로 떨어져 결론이 뒤집힌다.

n 이 50일 때는 $p = .637$ 로 기각되지 않지만, n 이 1,000이 되면 $p = .035$ 로 기각됩니다. 평균 차이 1점은 처음부터 끝까지 변하지 않았는데 결론만 뒤집힌 것입니다.

반면 마지막 열의 효과크기 d 는 네 경우 모두 **0.067로 동일합니다**. 효과크기 공식에는 표본크기가 들어가지 않기 때문입니다.

$$d = \frac{\bar{X}_t - \mu_c}{\sigma}$$

검정통계량에서 $\sqrt{n}$ 만 제거한 형태입니다

효과크기가 하는 일

검정통계량과 효과크기를 나란히 놓으면 차이가 분명해집니다.

$$z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \quad \text{vs} \quad d = \frac{\bar{X} - \mu}{\sigma}$$

분모에서 $\sqrt{n}$ 이 빠진 것이 전부입니다

검정통계량은 **표본크기의 영향을 받도록** 설계되어 있습니다. 표본이 커질수록 추정이 정밀해지므로, 같은 차이라도 더 확신을 갖고 판단할 수 있어야 하기 때문입니다.

효과크기는 그 $\sqrt{n}$ 을 제거합니다. 남는 것은 **표준편차 몇 개만큼 떨어져 있는가**라는 순수한 거리입니다. 그래서 표본크기가 달라도, 연구가 달라도 비교할 수 있습니다.

Cohen(1988)의 해석 기준입니다.

Cohen's d	해석
0.20 내외	작은 효과
0.50 내외	중간 효과
0.80 이상	큰 효과

위 예시의 $d = 0.067$ 은 작은 효과에도 미치지 못합니다. $n = 1,000$ 에서 유의하게 나왔더라도 **실질적 의미는 없다고 보고해야 합니다.**

기준표를 절대적으로 적용하지 않습니다

Cohen 본인이 이 기준을 "참고할 것이 전혀 없을 때의 임시 기준"이라고 밝혔습니다. 분야마다 효과크기의 통상 범위가 다릅니다.

교육 개입 연구에서는 $d = 0.3$ 도 상당한 효과로 평가되는 반면, 실험실 조건의 지각 실험에서는 $d = 0.8$ 이 평범한 수준일 수 있습니다. **같은 주제를 다룬 선행연구의 효과크기와 비교하는 것**이 기준표보다 유용합니다.

■ 결과를 쓸 때

유의성과 실질적 의미를 함께 기술합니다

분석 결과 두 집단의 평균 차이는 통계적으로 유의하였으나($t(998) = 2.11, p = .035$), 효과크기는 Cohen's $d = 0.07$ 로 매우 작은 수준이었다. 이는 표본크기가 큰 데 따른 결과로 해석되며, 실질적인 차이로 보기는 어렵다.

유의한 결과가 나왔다고 해서 효과크기 보고를 생략해서는 안 됩니다. **APA 7판은 효과크기 보고를 요구합니다.** 유의하지 않은 결과에도 효과크기를 함께 제시합니다.

점검 항목

- ☐ 영가설을 세우는 이유가 계산 가능성 때문임을 안다
- ☐ 유의확률이 영가설이 참일 확률이 아님을 설명할 수 있다
- ☐ 제1종 오류와 제2종 오류를 구분할 수 있다
- ☐ 표본크기를 늘리는 것이 검정력을 높이는 정당한 방법임을 안다
- ☐ 유의성과 효과크기를 함께 보고해야 하는 이유를 안다
- ☐ $p = .000$ 이 아니라 $p < .001$ 로 쓴다

요약 — 가설검정은 **영가설이 참이라는 가정 아래에서 지금의 결과가 얼마나 드문 일인지**를 계산하는 절차입니다. 드물면 가정을 버립니다. 유의확률은 표본크기에 좌우되므로 **효과크기를 함께 보고해야** 결과의 의미를 판단할 수 있습니다.

추정과 신뢰구간

논문 심사에서 신뢰구간을 물었을 때 "모수가 이 구간에 있을 확률이 95%"라고 답하면 틀린 답입니다. 이 장은 신뢰구간이 실제로 무엇을 보장하는지와, 왜 z 대신 t 를 쓰게 되었는지를 다룹니다.

■ 두 가지 추정


모수는 알 수 없습니다. 표본에서 계산한 통계치로 추정할 뿐입니다. 추정하는 방식은 두 가지입니다.

점추정(point estimation) — 모수를 하나의 값으로 추정합니다. 표본평균 3.50으로 모평균을 추정하는 것이 여기에 해당합니다.

구간추정(interval estimation) — 모수가 존재할 만한 구간을 추정합니다. "모평균은 3.39에서 3.60 사이일 것이다"와 같은 형태입니다.

점추정은 간명하지만 **틀릴 것이 거의 확실합니다**. 표본평균이 모평균과 소수점까지 정확히 일치할 확률은 사실상 0입니다. 점추정값 하나만 제시하면 그 값이 얼마나 믿을 만한지 알 수 없습니다.

구간추정은 **추정의 불확실성을 구간의 폭으로 표현합니다**. 구간이 좁으면 정밀한 추정이고 넓으면 그렇지 않습니다. 논문에서 신뢰구간 보고가 강조되는 이유가 여기 있습니다.



구간 = 추정치 $\pm$ (임계값 $\times$ 표준오차). 이 형태는 이후 모든 신뢰구간에서 똑같이 반복된다

그림 6-1 점추정은 값 하나를 찍는다. 구간추정은 그 값이 얼마나 흔들릴 수 있는지까지 함께 말한다. (개념도)

신뢰구간을 구성하는 세 가지

신뢰구간은 다음 세 요소로 결정됩니다.

- ① **추정치** — 구간의 중심입니다. 표본평균 $\bar{X}$ 가 여기에 옵니다.
- ② **추정치의 표준오차** — 구간의 폭을 정하는 기본 단위입니다. 4장에서 다룬 $s/\sqrt{n}$ 입니다.
- ③ **신뢰수준** — 몇 퍼센트로 잡을지입니다. 95%면 임계값 1.96, 99%면 2.58입니다.

구간 = 추정치 $\pm$ (임계값 $\times$ 표준오차). 이 형태는 이후 모든 신뢰구간에서 동일하게 반복됩니다.

■ 신뢰구간 공식이 나오는 과정

공식을 암기하는 대신 유도 과정을 한 번 따라가 보면 구조가 보입니다.

표집분포에 대해 알려진 사실에서 출발합니다. 표본평균 $\bar{X}$ 의 분포는 모평균 μ 를 중심으로 하며, 그 분포에서 **중앙 95% 구간**은 μ 로부터 좌우 $1.96\sigma_{\bar{X}}$ 만큼입니다.

$$\mu - 1.96 \sigma_{\bar{X}} \leq \bar{X} \leq \mu + 1.96 \sigma_{\bar{X}}$$

표본평균 100개 중 95개는 이 안에 들어옵니다

그런데 우리가 아는 것은 $\bar{X}$ 이고 모르는 것은 μ 입니다. 부등식을 μ 에 대해 정리합니다.

$$\bar{X} - 1.96 \sigma_{\bar{X}} \leq \mu \leq \bar{X} + 1.96 \sigma_{\bar{X}}$$

아는 값으로 모르는 값을 감싼 형태입니다

이것이 95% 신뢰구간입니다. 일반형으로 쓰면 다음과 같습니다.

$$[\bar{X} - Z_{\alpha/2} \times \sigma_{\bar{X}}, \bar{X} + Z_{\alpha/2} \times \sigma_{\bar{X}}]$$

$Z_{\alpha/2}$ 는 신뢰수준에 대응하는 임계값입니다

유도 과정에서 한 일은 **이항뿐입니다**. 새로운 가정이 추가되지 않았습니다. 그래서 신뢰구간과 가설검정이 항상 같은 결론을 내놓습니다.

■ 95%가 보장하는 것

여기가 이 장의 핵심입니다.

틀린 해석 — "모평균이 이 구간에 있을 확률이 95%다"

매우 흔하게 쓰이지만 **잘못된 진술**입니다.

이유는 이렇습니다. 모평균 μ 는 **고정된 상수**입니다. 알려지지 않았을 뿐 변하지 않습니다. 그리고 우리가 계산한 구간 $[3.39, 3.60]$ 도 이미 확정된 숫자입니다.

고정된 값이 고정된 구간 안에 들어가 있거나, 들어가 있지 않거나 둘 중 하나입니다. 확률이 개입할 여지가 없습니다. 이미 던져서 결과가 나온 주사위를 두고 "6이 나올 확률이 1/6"이라고 말할 수 없는 것과 같습니다.

옳은 해석 — 절차의 성공률입니다

95%가 수식하는 대상은 구간이 아니라 구간을 만드는 절차입니다.

동일한 방식으로 표본을 반복 추출하여 매번 95% 신뢰구간을 계산한다면, 그렇게 만들어진 구간들 중 95%가 모평균을 포함한다.

지금 손에 든 구간 하나가 그 95%에 속하는지 5%에 속하는지는 알 수 없습니다. 다만 이 방법을 쓰면 장기적으로 95%는 맞힌다는 것이 보장됩니다.

✗ 틀린 해석

"모평균이 이 구간에 있을 확률이 95%다"

모평균은 고정된 상수이고
구간도 이미 확정된 숫자다.
들어 있거나 아니거나 둘 중 하나다.

✓ 옳은 해석

"같은 방식으로 구간을 만들면 그중 95%가 모평균을 담는다"

95%가 수식하는 것은 구간이 아니라
구간을 만드는 절차다.
지금 이 구간이 맞는지는 알 수 없다.

심사에서 가장 자주 지적되는 대목이므로 표현을 정확히 써야 한다

그림 6-2 같은 구간을 두고 흔히 쓰는 해석과 옳은 해석. 95%가 수식하는 대상이 다르다. (개념도)

시뮬레이션으로 직접 확인할 수 있습니다. 모평균을 3.50으로 정해 두고 30명짜리 표본을 100번 뽑아 매번 신뢰구간을 만듭니다.

- 100개의 신뢰구간 중 몇 개가 모평균을 담는가

```
set.seed(2025)
mu <- 3.5; sigma <- 0.83; n <- 30

hit <- 0
for(i in 1:100) {
  x <- rnorm(n, mu, sigma)
  ci <- mean(x) + c(-1, 1) * qt(.975, n - 1) * sd(x) / sqrt(n)
  if(ci[1] <= mu && mu <= ci[2]) hit <- hit + 1
}
cat("모평균을 포함한 구간:", hit, "개\n")
```

실행 결과

모평균을 포함한 구간: 97 개

100개 중 **97개**가 모평균을 포함했습니다. 이론값 95개에 근접합니다. 나머지 3개는 모평균을 놓쳤는데, 이것이 오류가 아니라 **설계상 예정된 5%**입니다.




그림 6-3 표본을 100번 뽑아 매번 95% 신뢰구간을 만든 결과. 몇 개는 모평균을 놓치며, 이것이 5%의 의미다.

베이지안 추정에서는 해석이 달라집니다

모수를 상수가 아니라 분포로 보는 베이지안 접근에서는 사정이 다릅니다. 그쪽의 95% 신용구간(credible interval)은 **"모수가 이 구간에 있을 확률이 95%"**라고 해석하는 것이 맞습니다.

일반적인 논문에서 쓰는 신뢰구간은 빈도주의(frequentist) 방식이므로 위의 해석을 적용해서는 안 됩니다. 두 접근이 계산 결과는 비슷할 때가 많지만 **진술의 의미가 다릅니다**.

■ Z에서 t로 넘어가는 이유

앞의 공식에는 문제가 하나 있습니다. $\sigma_{\bar{X}} = \sigma / \sqrt{n}$ 을 계산하려면 **모집단의 표준편차 σ 를 알아야 합니다**.

그런데 모평균도 모르는 상황에서 모표준편차를 아는 경우가 있을까요. 거의 없습니다.

Z검정이 요구하는 조건

전통적인 교재는 단일표본 Z검정부터 소개합니다. 필요한 가정은 다음과 같습니다.

- 종속변수가 양적변수(등간 또는 비율척도)다
- 모집단의 분산 σ^2 을 알고 있다
- 정규성 가정을 충족한다
- 표본의 사례들이 서로 독립이다

$$Z_{\bar{X}} = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1^2)$$

분모에 모표준편차 σ 가 들어갑니다

두 번째 조건이 실무에서 충족되는 일은 사실상 없습니다. Z 검정은 논리를 설명하기 위한 장치이고, 실제 분석에서는 쓰이지 않습니다.

σ 를 모르니 표본에서 구한 s 로 대체합니다. 그런데 s 는 추정치이므로 표본마다 달라집니다. 분자뿐 아니라 분모까지 흔들리게 된 것입니다.


불확실성이 하나 늘었으니 분포도 달라져야 합니다. 그래서 나온 것이 t 분포입니다.

$$t = \frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t_{n-1}$$

분모가 s 로 바뀌면 분포가 t 로 바뀝니다

■ t분포의 성질

t 분포는 정규분포와 닮았지만 세 가지가 다릅니다.



자유도가 작을수록 꼬리가 두꺼워 같은 결론에 더 큰 값을 요구한다. 커지면 정규분포와 겹친다

그림 6-4 자유도가 작으면 t 분포는 정규분포보다 꼬리가 두껍다. 자유도가 커지면 두 분포는 겹쳐진다.

① 분산이 더 큼니다. 분모까지 추정하는 데서 오는 추가 불확실성이 분포의 폭으로 나타납니다.

② 꼬리가 두껍습니다. 극단값이 나올 확률이 정규분포보다 큼니다. 그 결과 **기각이 더 어려워집니다**. 모표준편차를 모르는 만큼 더 보수적으로 판단하겠다는 뜻이며, 이것이 t 분포를 쓰는 대가이자 목적입니다.

③ **모수가 하나입니다**. 정규분포는 평균과 분산 두 개로 결정되지만 t 분포는 **자유도(df 또는 ν) 하나로 결정됩니다**. 단일표본에서 자유도는 $n - 1$ 입니다.

임계값을 직접 확인해 보면 차이가 분명합니다.

● 자유도에 따른 95% 양측 임계값

```
for(d in c(5, 10, 30, 60, 120, 1000))
  cat(sprintf("df=%5d  t 임계값 = %.3f\n", d, qt(.975, d)))
cat(sprintf("          z 임계값 = %.3f\n", qnorm(.975)))
```

실행 결과

```
df=    5  t 임계값 = 2.571
df=   10  t 임계값 = 2.228
df=   30  t 임계값 = 2.042
df=   60  t 임계값 = 2.000
df=  120  t 임계값 = 1.980
df= 1000  t 임계값 = 1.962
          z 임계값 = 1.960
```

자유도 5에서는 2.571이 필요하지만 자유도 1,000에서는 1.962로 z 의 1.96과 거의 같아집니다. **자유도가 무한대로 가면 t 분포는 Z 분포와 일치합니다**.

표본이 작을수록 t 분포를 써야 하는 이유

자유도 5에서 임계값이 2.571이라는 것은, **같은 결론을 내리는 데 더 큰 검정통계량을 요구한다**는 뜻입니다.

표본이 작으면 s 가 σ 를 제대로 추정하지 못할 위험이 큼니다. 그 위험을 임계값을 높여 상쇄합니다. 표본이 커지면 s 가 정확해지므로 패널티가 사라집니다.

n 이 30만 넘어도 t 와 z 의 차이는 미미해지지만, **모표준편차를 모른다면 표본크기와 무관하게 t 를 쓰는 것이 원칙입니다**. R의 `t.test()` 가 항상 t 분포를 쓰는 이유입니다.

■ 단일표본 t -검정

표본 하나의 평균을 **이미 알려진 기준값**과 비교하는 검정입니다. 실무에서 자주 쓰이지는 않지만, 이후 모든 t -검정이 이 구조의 변형이므로 여기서 짚고 넘어갑니다.

$$H_0 : \mu = \mu_0$$

μ_0 은 이론적·경험적 근거에서 나온 특정 값입니다

자아존중감 5점 척도에서 중간값 3.0을 기준으로 검정해 보겠습니다.

● 단일표본 t-검정

```
df <- read.csv("data/sample_data.csv")
s <- df$selfesteem

t.test(s, mu = 3.0)
```

실행 결과

One Sample t-test

```
data: s
t = 9.2397, df = 239, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 3
95 percent confidence interval:
 3.391267 3.603317
sample estimates:
mean of x
 3.497292
```

읽는 순서는 독립표본과 같습니다. $t(239) = 9.24, p < .001$ 로 영가설을 기각합니다. 이 표본의 자아존중감 평균은 척도 중간값보다 통계적으로 유의하게 높습니다.

자유도가 239인 것은 $n - 1 = 240 - 1$ 이기 때문입니다.

■ 신뢰구간과 가설검정은 같은 이야기입니다

출력의 신뢰구간 **[3.391, 3.603]**을 보십시오. 기준값 3.0이 이 구간 **밖에** 있습니다. 그리고 $p < .001$ 로 기각되었습니다.

우연이 아닙니다. 두 판단은 같은 계산에서 나옵니다.

신뢰구간	유의확률	결론
기준값을 포함하지 않음	$p < .05$	영가설 기각
기준값을 포함함	$p \geq .05$	기각 실패

기준값을 3.4로 바꾸면 확인됩니다. 3.4는 구간 [3.391, 3.603] 안에 아슬아슬하게 들어갑니다.

● 기준값만 3.4로 바꿔서 다시

```
t.test(s, mu = 3.4)$p.value
```

실행 결과

```
[1] 0.07191441
```

$p = .072$ 로 .05보다 큼니다. 신뢰구간이 예고한 그대로입니다.



기준값이 구간 안에 들어오면 기각되지 않는다. 신뢰구간과 유의확률은 언제나 같은 답을 준다

그림 6-5 기준값이 신뢰구간 안에 들어오면 기각되지 않고, 밖에 있으면 기각된다. 두 판단은 언제나 일치한다.

두 집단을 비교할 때도 동일합니다

7장의 독립표본 t -검정에서 신뢰구간이 **0을 포함하는**지만 보면 유의성 판단이 끝난다고 했습니다. 같은 원리입니다.

단일표본에서는 기준값이 μ_0 이고, 두 집단 비교에서는 기준값이 "차이가 0"입니다. 검정 대상이 바뀌었을 뿐 구조는 같습니다.

■ 신뢰구간의 폭을 결정하는 것

구간이 좁을수록 정밀한 추정입니다. 폭은 무엇으로 정해질까요.

$$\text{반폭} = t_{\alpha/2, n-1} \times \frac{s}{\sqrt{n}}$$

임계값 $\times$ 표준오차

세 가지가 폭을 좌우합니다. **신뢰수준**을 높이면(95% → 99%) 임계값이 커져 넓어집니다. **자료의 산포** s 가 크면 넓어집니다. **표본크기** n 이 크면 좁아집니다.


이 중 연구자가 조정할 수 있는 것은 표본크기입니다.

● 표본크기별 신뢰구간 폭 (SD는 0.834로 고정)

```
for(nn in c(25, 100, 240, 400)) {
  half <- qt(.975, nn - 1) * sd(s) / sqrt(nn)
  cat(sprintf("n=%3d 반폭 = %.4f 구간 폭 = %.4f\n", nn, half, 2*half))
}
```

실행 결과

```
n= 25 반폭 = 0.3442 구간 폭 = 0.6884
n=100 반폭 = 0.1654 구간 폭 = 0.3309
n=240 반폭 = 0.1060 구간 폭 = 0.2121
n=400 반폭 = 0.0820 구간 폭 = 0.1639
```



25명에서 100명으로 75명을 더 모으면 폭이 0.357 줄지만,
240명에서 400명으로 160명을 더 모아도 0.048밖에 줄지 않는다 — 수확체감

그림 6-6 같은 자료라도 표본크기가 커지면 신뢰구간이 좁아진다. 다만 좁아지는 속도는 갈수록 느려진다.

n 을 25에서 100으로 **4배** 늘렸더니 폭이 0.688에서 0.331로 **약 1/2**이 되었습니다. 4장에서 확인한 $\sqrt{n}$ 관계가 그대로 나타납니다.

여기서 수확체감이 발생합니다. 25명에서 100명으로 75명을 더 모으면 폭이 0.357 줄지만, 240명에서 400명으로 160명을 더 모아도 0.048밖에 줄지 않습니다. 표본을 무한정 늘리는 것이 효율적이지 않은 이유입니다.

신뢰구간 보고 방식

APA 7판은 **주요 추정치에 신뢰구간을 함께 보고할 것**을 권장합니다. 표기는 다음 형태입니다.

자아존중감의 평균은 3.50(SD = 0.83)이었으며, 95% 신뢰구간은 [3.39, 3.60]으로 나타났다.

괄호 안에 95% CI [3.39, 3.60] 처럼 넣기도 합니다. 대괄호를 쓰고 두 값 사이는 쉼표로 구분하는 것이 APA 표기입니다. 소수점 자리수는 원 추정치와 맞춥니다.

점검 항목

- ☐ 점추정과 구간추정의 차이를 안다
- ☐ 신뢰구간이 추정치 $\pm$ (임계값 $\times$ 표준오차) 구조임을 안다
- ☐ 95%가 구간이 아니라 절차의 성공률을 가리킨다고 설명할 수 있다
- ☐ 모표준편차를 모르기 때문에 t 분포를 쓴다는 것을 안다
- ☐ t 분포의 꼬리가 두꺼워 기각이 어려워진다는 것을 안다
- ☐ 신뢰구간과 유의확률이 항상 같은 결론을 준다는 것을 확인했다

요약 — 신뢰구간은 추정치 $\pm$ (임계값 $\times$ 표준오차)로 만들어집니다. 95%는 구간 하나에 대한 확률이 아니라 **같은 절차를 반복했을 때의 성공률**입니다. 모표준편차를 모르는 현실 때문에 대신 t 를 쓰며, 그 대가로 임계값이 커져 기각이 조금 더 어려워집니다.

두 집단의 평균 비교 — 독립표본 t-검정

남녀의 자아존중감에 차이가 있는가. 실험집단과 통제집단의 점수가 다른가. 사회과학 논문에서 가장 많이 등장하는 분석이며, 여기서 배우는 읽는 법이 이후 모든 분석에 그대로 쓰입니다.

■ 이 분석이 답하는 질문

분석 방법의 선택은 기법을 고르는 문제가 아니라 **연구 질문의 성격을 규정하는 문제**입니다.

사회과학의 연구 질문은 크게 두 유형으로 구분됩니다.

집단 간 차이에 관한 질문. 이 유형에서는 개별 사례가 집단의 대표값으로 축약됩니다. 남성 118명은 3.29, 여성 122명은 3.70이라는 단일 수치로 환원되며, 분석의 관심은 두 대표값 사이의 거리에 한정됩니다. 개별 응답자의 점수는 고려 대상이 아닙니다.

변수 간 관계에 관한 질문. 이 유형에서는 개별 사례가 분석의 단위로 유지됩니다. 한 응답자 내에서 자아존중감이 높을 때 학업성취도 함께 높은지를 240회에 걸쳐 확인합니다. 사례를 집단으로 축약하는 순간 이 질문에는 답할 수 없습니다.

전자에 대응하는 분석이 **t-검정과 분산분석**이며, 후자에 대응하는 분석이 **상관분석과 회귀분석**입니다.




그림 7-1 같은 데이터라도 무엇을 궁금해하느냐에 따라 개인이 사라지기도 하고 끝까지 남기도 한다. (개념도)

척도가 분석을 규정하는 기제

1장에서 척도가 분석을 결정한다고 서술했습니다. 보다 정확히는 **척도가 제기 가능한 질문의 범위를 규정하며, 분석 방법은 그 질문에 종속됩니다.**

성별은 범주로만 다를 수 있습니다. 남성과 여성 사이에 중간값이 존재하지 않으므로 "성별이 0.3 증가하면"이라는 진술 자체가 성립하지 않습니다. 따라서 성별로는 차이에 관한 질문만 제기할 수 있습니다.

연령은 범주로 축약할 필요가 없습니다. 23세와 24세 사이에 거리가 정의되므로 "연령이 1년 증가할 때 자아존중감이 얼마나 변화하는가"를 물을 수 있습니다.

동일한 자료라도 독립변수를 무엇으로 설정하는가에 따라 질문이 달라지고, 질문이 달라지면 분석 방법도 달라집니다.

이 장은 첫 번째 유형 가운데 **집단이 두 개인 경우**를 다룹니다. 적용 조건은 두 가지입니다.

- 종속변수가 **연속형**이다 (점수, 소득, 리커트 문항 평균)
- 독립변수가 **범주형**이고 **집단이 2개**다 (성별, 실험/통제, 참여/미참여)

집단이 셋 이상인 경우에는 t-검정을 반복 적용하지 않고 분산분석을 사용합니다. 반복 적용이 부적절한 이유는 9장에서 다룹니다.

세 가지 t-검정의 구분

t-검정에는 세 가지 유형이 있으며, 무엇이 두 개인가에 따라 구분됩니다.

독립표본 t-검정은 두 집단의 **구성원이 서로 다른** 경우입니다(남성 118명, 여성 122명). **종속표본 t-검정**은 **동일 대상을 두 시점에서 측정한** 경우입니다(사전-사후). **단일표본 t-검정**은 집단이 하나이며 이미 알려진 기준값과 비교하는 경우입니다.

이 장의 대상은 독립표본 t-검정입니다.

■ 영가설이 실제로 말하는 것

독립표본 t-검정의 영가설은 이것입니다.

$$H_0 : \mu_1 - \mu_2 = 0$$

두 모집단의 평균이 같다

여기서 유의할 점은 이 진술의 대상이 **표본이 아니라 모집단**이라는 것입니다. 확보한 240명의 표본평균은 이미 서로 다르며, 두 집단의 평균이 소수점까지 일치하는 경우는 사실상 존재하지 않습니다.

따라서 차이의 유무는 표본을 대상으로 판단할 문제가 아닙니다. t-검정이 검정하는 명제는 다음과 같습니다.

이 정도 차이가, 모집단에서는 차이가 없는데도 표집 과정의 우연만으로 생길 수 있는 크기인가?

우연으로 설명하기 어려운 크기라면 모집단에서도 차이가 존재한다고 판단합니다. 추리통계의 논리 구조가 여기에 있습니다.

■ 세 가지 가정이 확인하는 것

가정을 충족해야 할 요건으로만 암기하면 검정의 목적을 이해하지 못한 채 절차만 밟게 됩니다. 세 가정은 각각 **비교가 성립하기 위한 조건**을 하나씩 점검합니다.

독립성 — 한 사례의 값이 다른 사례의 값에 영향을 주지 않는가

두 집단을 비교하려면 두 집단이 서로 독립이어야 합니다. 남매 100쌍을 남성 100명과 여성 100명으로 분할하여 비교하는 설계는 독립성을 충족하지 않습니다. 형제자매 간에는 점수의 상관이 존재하기 때문입니다.

이 경우 실질 표본크기는 200이 아니라 **100**입니다. 종속적인 관측치는 아무리 많아도 표본크기에 1 이상 기여하지 못합니다. 독립성이 충족되지 않으면 종속표본 t-검정으로 전환해야 합니다.

이 가정은 통계적 검정으로 확인하는 것이 아니라 연구 설계 단계에서 결정됩니다. 자료 수집 방식을 검토하면 충족 여부를 판단할 수 있습니다.

정규성 — 평균이 집단을 대표한다고 볼 수 있는가

t-검정은 각 집단을 **평균이라는 단일 값으로 축약**하여 비교합니다. 이 방식이 타당하려면 평균이 집단을 대표해야 합니다.

분포의 편포가 심하면 평균의 대표성이 확보되지 않습니다. 소수의 극단값이 존재하는 소득 변수에서 평균이 대다수 사례보다 현저히 높게 산출되는 경우가 이에 해당합니다. 이때 두 집단의 평균을 비교하는 것은 **집단을 대표하지 않는 두 값을 비교하는 절차**가 됩니다.




그림 7-2 치우친 분포에서는 평균이 중앙값보다 꼬리 쪽으로 끌려간다. 그 평균으로 두 집단을 비교하면 대표하지도 않는 숫자를 비교하는 셈이 된다.
(개념도)

정규성 검정 결과를 절대 기준으로 삼지 않습니다

Shapiro-Wilk 검정에서 $p < .05$ 가 나왔다고 t-검정을 포기하는 경우를 자주 봅니다. **표본이 크면 아주 사소한 비정규성에도 유의하게 나옵니다.** n이 500이면 눈으로는 정규분포와 구분되지 않는 분포도 기각됩니다.

정작 중요한 것은 원자료의 정규성이 아니라 **표본평균의 분포**입니다. 중심극한정리에 따라 각 집단 n이 30 이상이면 표본평균의 분포는 원자료 모양과 무관하게 정규분포에 근사합니다. 그래서 t-검정은 웬만한 비정규성을 견뎌냅니다.

히스토그램을 확인하여 극단적인 편포나 이봉분포가 아니라면 분석을 진행해도 무방합니다.

등분산성 — 두 집단을 같은 잣대로 비교해도 되는가

세 가정 중 오해가 가장 빈번한 항목입니다. 분산이 동일해야 한다는 조건만 암기해서는 이 가정의 목적을 파악할 수 없습니다.

먼저 의미를 검토합니다. 분산은 집단 내 값들이 흩어진 정도를 나타냅니다. 두 집단의 분산이 동일하다는 것은 **처치나 변인이 개입하기 이전에 두 집단을 동일한 집단으로 간주할 수 있었음**을 의미합니다.

반대로 분산에 현저한 차이가 있다면 두 집단은 애초에 이질적인 집단이었을 가능성이 있습니다. **이 경우 평균 차이가 관찰되더라도 그것이 처치의 효과인지 집단 자체의 속성인지 분리할 수 없습니다.** 비교의 근거가 성립하지 않는 것입니다.




그림 7-3 등분산 가정이 묻는 것. 왼쪽은 평균만 다르고 퍼진 정도가 같아 출발선이 같았다고 볼 수 있다. 오른쪽은 애초에 성질이 다른 두 집단이어서, 평균 차이의 원인을 처치로 돌릴 수 없다. (개념도)

계산 절차에서도 동일한 논리가 적용됩니다. t값을 산출하려면 관찰된 차이가 우연한 변동으로 발생할 수 있는 크기인지 판단할 기준, 즉 **차이의 표준오차**가 필요합니다. 이 기준은 두 집단의 산포를 하나로 합산하여 산출하며, 이를 **통합분산 (pooled variance)**이라 합니다.

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

두 집단의 분산을 표본크기로 가중평균한 값

두 집단의 산포가 애초에 다르다면 합산한 값은 어느 쪽도 제대로 대표하지 못합니다. **기준 자체가 부정확하면 그것으로 산출한 t값도 신뢰할 수 없습니다.**

등분산성 검정이 확인하는 명제는 다음과 같습니다.

지금 이 두 집단을, 하나의 잣대로 비교해도 되는가?

■ R로 돌리기

1단계 — 데이터를 불러오고 척도를 정한다

● 1장에서 배운 그대로

```
df <- read.csv("data/sample_data.csv")

# gender가 1, 2 숫자로 되어 있으므로 반드시 factor로
df$gender <- factor(df$gender, levels = c(1, 2), labels = c("남성", "여성"))

str(df)
```

실행 결과

```
'data.frame': 240 obs. of 4 variables:
 $ id      : int  1 2 3 4 5 6 7 8 9 10 ...
 $ gender  : Factor w/ 2 levels "남성","여성": 1 1 1 1 1 1 1 1 1 1 ...
 $ age     : int  19 21 20 19 22 24 22 23 29 23 ...
 $ selfesteem: num  3.39 3.95 2.09 2.07 2.49 2.54 2.86 4.5 3.4 4.31 ...
```

`gender` 가 `Factor w/ 2 levels` 로 지정되었습니다. 이 절차를 생략하면 R은 성별을 연속형으로 처리하며, 오류 메시지 없이 잘못된 결과를 내놓습니다.

2단계 — 기술통계부터 본다

검정 결과를 확인하기 전에 **기술통계를 먼저 산출**합니다. 논문의 결과표에도 이 값들이 보고됩니다.

● 집단별 n, 평균, 표준편차

```
desc <- sapply(split(df$selfesteem, df$gender), function(x)
  c(n = length(x), M = mean(x), SD = sd(x)))

round(desc, 2)
```

실행 결과

	남성	여성
n	118.00	122.00
M	3.29	3.70
SD	0.77	0.84

여성 집단이 0.41점 높습니다. 이 차이가 우연으로 설명 가능한 크기인지를 이하에서 검토합니다.




그림 7-4 실제 데이터의 두 집단 분포. 점선이 각 집단의 평균이고, 두 분포는 상당 부분 겹쳐 있다. 겹치는데도 평균 차이가 유의한지를 판단하는 것이 t-검정이다.

3단계 — 등분산성을 확인한다

앞서 제기한 명제, 즉 두 집단을 동일한 기준으로 비교할 수 있는가를 검정으로 확인합니다. SPSS가 t-검정 결과표에 함께 제시하는 것이 **Levene 검정**이며, R에서는 `car` 패키지로 동일한 검정을 수행합니다.

● `car` 패키지는 처음 한 번만 설치

```
# install.packages("car")
library(car)

leveneTest(selfesteem ~ gender, data = df)
```

실행 결과

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  1  0.9502 0.3307
      238
```

p = .331로 .05보다 큽니다. 영가설을 기각하지 못했으므로 등분산 가정을 유지하며, 두 집단을 동일한 기준으로 비교할 수 있습니다.

유의확률 해석의 방향이 반전됩니다

앞서 유의확률이 작을 때 영가설을 기각한다고 서술했으나, 등분산성 검정에서는 해석의 방향이 반대입니다. **검정마다 영가설의 내용이 다르기** 때문입니다.

t-검정의 영가설은 두 평균이 같다는 명제이며, 연구자는 이를 기각하는 것을 목표로 합니다. 차이의 발견이 연구 목적이기 때문입니다.

등분산성 검정의 영가설은 두 분산이 같다는 명제이며, 연구자는 이것이 유지되기를 기대합니다. 비교의 전제가 성립해야 본 분석으로 진행할 수 있기 때문입니다.

유의확률의 크기 자체에 우열은 없습니다. **현재 검정하는 영가설이 무엇인지 확인하는 것이 선행되어야 합니다.** 이 원칙은 정규성 검정, 요인분석의 적합도 검정, 구조방정식의 카이제곱 검정에서 동일하게 적용됩니다.

기각 실패는 영가설의 증명이 아닙니다

$p = .331$ 은 두 분산이 같음을 증명한 결과가 아니라 **다르다고 판단할 근거를 확보하지 못했음**을 의미합니다. 통계적 검정은 영가설을 증명하지 못하며, 기각하거나 기각에 실패할 뿐입니다.

실무에서는 가정이 유지된 것으로 간주하여 진행하되 표본크기가 작은 경우 주의가 필요합니다. **n이 작으면 검정력이 낮아 실패하는 차이도 탐지하지 못합니다.** 등분산성 검정의 통과가 분산의 동일성을 보장하지는 않습니다.

var.test()와의 구분

R의 `var.test()` 는 두 분산의 **비율**을 F분포로 검정하는 별개의 절차입니다. 정규성 가정에 민감하여 실제 자료 분석에서는 사용 빈도가 낮습니다. **SPSS 결과와 대응시키려면 `car::leveneTest()` 를 사용합니다.** 논문에서도 Levene 검정을 보고하는 것이 표준입니다.

4단계 — t-검정

- 등분산이 만족되었으므로 `var.equal = TRUE`

```
t.test(selfesteem ~ gender, data = df, var.equal = TRUE)
```

실행 결과

Two Sample t-test


```
data: selfesteem by gender
t = -3.9343, df = 238, p-value = 0.0001095
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -0.6172256 -0.2053502
sample estimates:
mean in group 남성 mean in group 여성
      3.288220      3.699508
```

■ 출력을 읽는 법

논문에 필요한 값은 이 네 개입니다.

출력의 이 자리	값	의미
t =	-3.93	검정통계량. 부호는 어느 집단이 큰지만 알려줌
df =	238	자유도. 독립표본에서는 $n_1 + n_2 - 2$
p-value =	.0001	영가설이 참일 때 이만한 차이가 나올 확률
confidence interval	[-.617, -.205]	평균 차이의 95% 신뢰구간

$p = .0001$ 은 .05보다 작으므로 영가설을 기각합니다. 남녀의 자아존중감 평균에 통계적으로 유의한 차이가 있습니다.



영가설이 참이라면 t는 대부분 가운데에 떨어진다. 우리 결과는 꼬리 밖에 있다.

그림 7-5 p값이 무엇인지. 영가설이 참이라면 t는 대부분 가운데 봉우리 안에 떨어진다. 우리 결과 -3.93은 붉은 기각역보다도 바깥이라, 우연으로 보기 어렵다고 판단한다.

신뢰구간도 같은 답을 줍니다. **[-.617, -.205]에 0이 포함되어 있지 않습니다.** 차이가 0일 가능성이 이 구간 밖이라는 뜻이므로, p값과 결론이 일치합니다. 신뢰구간이 0을 걸치면 $p > .05$ 이고, 걸치지 않으면 $p < .05$ 입니다. 항상 그렇습니다.




그림 7-6 신뢰구간과 p값은 같은 이야기를 다르게 말한 것이다. 구간이 0을 걸치지만 보면 유의성 판단이 끝난다. (개념도)

t값의 부호 해석

`t = -3.93`의 음부호는 R이 가나다 순으로 첫 번째 집단(남성)에서 두 번째 집단(여성)을 차감했기 때문에 발생합니다. 집단의 순서를 바꾸면 부호도 반전됩니다. **논문에는 산출된 부호를 그대로 보고하되, 방향의 해석은 각 집단의 평균값을 근거로 합니다.**

■ SPSS 출력과의 대응

SPSS와 R의 출력은 배치가 다를 뿐 동일한 값을 산출합니다.

SPSS	R	비고
Levene의 등분산 검정 F, 유의확률	<code>car::leveneTest()</code>	SPSS는 t-검정 표에 함께 나옴
"등분산이 가정됨" 행	<code>var.equal = TRUE</code>	Student t-검정
"등분산이 가정되지 않음" 행	<code>var.equal = FALSE</code> (R 기본값)	Welch-Aspin 검정
유의확률 (양측)	<code>p-value</code>	동일
차이의 95% 신뢰구간	<code>95 percent confidence interval</code>	동일

R이 기본값으로 Welch를 쓰는 이유

`t.test()`에 아무 옵션도 주지 않으면 R은 **Welch 검정**을 돌립니다. SPSS가 두 줄을 모두 보여주는 것과 달리 R은 안전한 쪽을 기본으로 삼기 때문입니다. Ruxton(2006)은 등분산이 만족되더라도 Welch가 언제나 같거나 나은 결과를 준다고 주장했습니다. 등분산이 만족될 때 두 결과는 거의 같습니다. 위 데이터에서도 Welch는 `t(237.32) = -3.94, p = .0001`로 사실상 동일합니다.

논문 관행상 등분산 검정 결과를 보고하고 그에 맞는 행을 쓰는 것이 여전히 표준이므로, 이 책은 `var.equal`을 명시하는 방식으로 씁니다.

■ 효과크기 — p값만으로는 부족합니다

유의확률은 표본크기에 의존합니다. 실질적 의미가 없는 차이도 n이 충분히 크면 통계적으로 유의하게 산출됩니다. 따라서 **차이의 크기 자체**를 별도로 평가해야 합니다.

평균 차이 0.15점, 표준편차 0.8로 고정 — 표본크기만 바꿨을 때




그림 7-7 평균 차이 0.15점과 표준편차 0.8을 그대로 두고 표본크기만 바꾼 결과. 차이의 크기는 하나도 변하지 않았는데 p값만 작아진다.

$$d = \frac{M_1 - M_2}{s_p}$$

s_p 는 두 집단을 통합한 표준편차

● Cohen's d 직접 계산

```
m <- tapply(df$selfesteem, df$gender, mean)
s <- tapply(df$selfesteem, df$gender, sd)
n <- tapply(df$selfesteem, df$gender, length)

sp <- sqrt(((n[1]-1)*s[1]^2 + (n[2]-1)*s[2]^2) / (n[1]+n[2]-2))
d <- (m[1] - m[2]) / sp

round(c(sp = sp, d = d), 3)
```

실행 결과

```
sp      d
0.810 -0.508
```

effectsize 패키지를 쓰면 신뢰구간까지 한 줄로 나옵니다.

● 신뢰구간까지

```
library(effectsize)
cohens_d(selfesteem ~ gender, data = df)
```

실행 결과

Cohen's d | 95% CI


-0.51 | [-0.76, -0.25]

- Estimated using pooled SD.

Cohen(1988)의 기준입니다.

절댓값	해석
0.2 내외	작은 효과
0.5 내외	중간 효과
0.8 이상	큰 효과

$d = -0.51$ 이므로 **중간 수준의 효과**에 해당합니다. 통계적으로 유의하며 실질적으로도 의미 있는 차이로 보고할 수 있습니다.



d가 커질수록 두 분포가 덜 겹친다. 겹침이 적을수록 두 집단이 실질적으로 다르다는 뜻이다.

그림 7-8 Cohen의 d를 두 분포의 겹침으로 본 것. d가 커질수록 덜 겹친다. 우리 결과 0.51은 가운데에 해당한다. (개념도)

■ 논문 결과표

APA 형식은 3선표를 사용하며 세로선을 넣지 않습니다.

집단	n	M	SD	t	df	p	Cohen's d
남성	118	3.29	0.77	-3.93	238	< .001	-0.51
여성	122	3.70	0.84				

주. $p < .05$ 수준에서 유의함. 등분산성 검정 결과 Levene의 $F(1, 238) = 0.95, p = .331$ 로 등분산 가정이 충족되었다.

■ 논문 문장으로 옮기기

결과표만 제시하는 것으로는 충분하지 않으며, 본문에 다음과 같이 서술합니다.

결과 서술 예시

성별에 따른 자아존중감의 차이를 검증하기 위해 독립표본 t -검정을 실시하였다. 등분산성 검정 결과 Levene의 $F(1, 238) = 0.95, p = .331$ 로 등분산 가정이 충족되어 Student t -검정을 적용하였다.

분석 결과, 여성 집단의 자아존중감($M = 3.70, SD = 0.84$)이 남성 집단($M = 3.29, SD = 0.77$)보다 통계적으로 유의하게 높은 것으로 나타났다($t(238) = -3.93, p < .001$). 효과크기는 Cohen's $d = -0.51$ 로 중간 수준이었다.

이 문단은 다섯 가지 요소로 구성됩니다. ① 분석의 종류와 목적 ② 가정 검토 결과 ③ 각 집단의 M 과 SD ④ 검정통계량·자유도·유의확률 ⑤ 효과크기. 다섯 요소를 모두 갖추면 보고의 완결성이 확보됩니다.

서술상 유의할 표현

"차이가 있었다"가 아니라 "통계적으로 유의한 차이가 있었다"로 기술합니다. "여성이 남성보다 자아존중감이 높다"와 같은 단정적 서술도 부적절합니다. 해당 표본에서 관찰된 결과이므로 "높은 것으로 나타났다"가 적절합니다.

또한 $p = .000$ 으로 표기해서는 안 됩니다. 확률이 정확히 0인 경우는 존재하지 않으므로 $p < .001$ 로 기술합니다.

점검 항목

- ☐ 종속변수가 연속형이고 집단이 두 개인지 확인했다
- ☐ `factor()`로 집단변수를 변환했다
- ☐ 등분산성 검정의 영가설이 분산의 동일성임을 안다
- ☐ 신뢰구간의 0 포함 여부로도 결론을 확인할 수 있다
- ☐ 효과크기를 함께 보고했다
- ☐ $p = .000$ 이 아니라 $p < .001$ 로 기술했다

요약 — 독립표본 t -검정은 두 집단의 평균 차이가 우연으로 설명 가능한 크기인지를 판단하는 절차입니다. 보고에 필요한 값은 M, SD, t, df, p, d 의 여섯 가지이며, 이를 갖추면 결과표와 서술문을 완성할 수 있습니다.

같은 사람을 두 번 재는 경우 — 종속표본 t-검정

사전-사후 설계는 사회과학에서 가장 흔한 실험 설계입니다. 그런데 이 자료를 독립표본으로 분석하면 결과가 크게 달라집니다. 이 장은 왜 그런지, 그리고 짝을 지키는 것이 왜 이득인지를 다룹니다.

■ 독립성이 깨지는 설계

7장의 독립표본 t -검정은 두 집단의 구성원이 서로 다른 경우를 다뤘습니다. 그런데 연구 설계가 언제나 그렇지는 않습니다.

- 프로그램 참여 **전과 후**의 점수를 같은 사람에게서 받는다
- **쌍둥이**나 **부부**처럼 짝지어진 두 사람을 비교한다
- **중간고사와 기말고사** 점수를 비교한다


이 설계들의 공통점은 두 측정치가 **서로 얹혀 있다**는 것입니다. 사전 점수가 높았던 사람은 사후 점수도 높을 가능성이 큼니다. 7장에서 가장 먼저 확인했던 독립성 가정이 성립하지 않습니다.

두 종류의 종속 자료

짝지어진 쌍 자료(matched pair data) — 서로 다른 두 사람이지만 쌍으로 묶인 경우입니다. 남매, 쌍둥이, 부부처럼 애초에 상관이 존재하는 관계입니다.

반복측정 자료(repeated measures data) — 동일인을 두 번 측정한 경우입니다. 사전-사후, 투약 전-후, 중간고사-기말고사가 여기에 해당하며, 임상 실험에서 가장 흔한 형태입니다.

둘 다 **종속표본 t -검정**으로 분석합니다. 검정 대상이 "두 측정치의 짝"이라는 점에서 동일하기 때문입니다.



관측치가 80개여도 독립적인 정보는 40개뿐이다. 자유도가 78이 아니라 39인 이유다

종속적인 관측치는 아무리 많아도 표본크기에 1 이상 기여하지 못한다

그림 8-1 독립성이 깨지는 세 가지 전형. 어느 쪽이든 두 측정치가 서로 얹혀 있다. (개념도)

종속 관측치는 표본크기를 늘리지 못합니다

7장에서 짚은 내용을 다시 확인합니다. 남매 100쌍을 조사했다면 **관측치는 200개지만 실질 표본크기는 100입니다.**

한 쌍의 두 값은 독립적인 정보가 아닙니다. 오빠의 키를 알면 동생의 키에 대해서도 어느 정도 알게 되기 때문입니다. 종속적인 관측치는 아무리 많아도 **표본크기에 1 이상 기여하지 못합니다.**

이 자료를 200명으로 처리하면 실제보다 표준오차를 작게 계산하게 되고, 그 결과 없는 효과를 있다고 판단할 위험이 커집니다.

■ 짝을 차이점수 하나로 줄인다

종속표본 t -검정의 해법은 단순합니다. **두 점수를 빼서 하나로 만드는 것**입니다.

$$D_i = X_{\text{사후},i} - X_{\text{사전},i}$$

사람마다 차이점수를 하나씩 만듭니다

40쌍의 자료가 있다면 40개의 차이점수가 생깁니다. **이 차이점수들은 서로 독립입니다.** 1번 사람의 향상 폭과 2번 사람의 향상 폭 사이에는 아무 관계가 없기 때문입니다.


독립성 문제가 해결되었으므로 나머지는 6장에서 배운 단일표본 t -검정과 완전히 같습니다. 기준값이 0일 뿐입니다.

$$H_0 : \mu_D = 0$$

평균적인 변화량이 0인가

$$t = \frac{\bar{D} - \mu_D}{s_D / \sqrt{n}} \sim t_{n-1}$$

6장의 단일표본 공식과 동일한 형태입니다



원점수는 더 이상 쓰이지 않는다. 검정이 묻는 것은 "이 변화량들의 평균이 0인가" 하나뿐이다

그림 8-2 두 열의 점수를 뺄셈 한 번으로 한 열로 줄인다. 짝이 사라지는 대신 독립성이 회복되고, 문제는 단일표본 검정으로 바뀐다. (개념도)

원점수는 더 이상 쓰이지 않습니다

차이점수를 만드는 순간 **원래 점수가 몇 점이었는지는 검정에 관여하지 않습니다.**

3점에서 4점이 된 사람과 1점에서 2점이 된 사람은 차이점수가 똑같이 1입니다. 검정이 묻는 것은 오직 "**이 변화량들의 평균이 0인가**"입니다.

출발선이 달라도 변화 폭만 비슷하면 같게 취급된다는 뜻이며, 이것이 개인차를 통제하는 방식입니다.

■ 짝을 지키면 무엇이 좋은가

같은 사람을 두 번 재는 설계에는 분명한 이점이 있습니다. **개인차라는 소음을 제거할 수 있다**는 것입니다.

사전-사후 설계에서 점수 차이를 만드는 원인은 두 가지입니다. 하나는 처치의 효과이고, 다른 하나는 사람마다 원래 다른 수준입니다. 독립표본으로 분석하면 이 둘이 뒤섞입니다.

차이점수를 쓰면 **개인의 원래 수준이 뺄셈으로 상쇄됩니다**. 남는 것은 변화량뿐입니다. 소음이 줄어드니 같은 크기의 효과를 훨씬 선명하게 잡아낼 수 있습니다.

이 이점은 공식에서도 확인됩니다. 원점수를 그대로 쓴 형태는 이렇습니다.

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n} + \frac{s_2^2}{n} - 2r_{12}\frac{s_1 s_2}{n}}}$$

분모 끝의 $-2r_{12}(\cdot)$ 이 상관만큼 표준오차를 깎아줍니다

분모에 **두 측정치의 상관 r_{12} 가 음수** 방향으로 들어갑니다. 상관이 높을수록 분모가 작아지고, 분모가 작아지면 t 값이 커집니다.

사전-사후 점수의 상관이 높다는 것은 설계가 잘 작동하고 있다는 신호입니다. 다만 이 식은 계산이 번거로우므로 실제로는 차이점수를 쓰는 간편한 방법을 씁니다. 두 방법의 결과는 동일합니다.

■ R로 돌리기

40명을 대상으로 프로그램 전후의 점수를 측정한 자료입니다.

1단계 — 자료 구조를 확인한다

- 사전-사후 자료는 한 행에 두 점수가 나란히 있어야 합니다

```
pp <- read.csv("data/prepost.csv")
head(pp, 5)
```

실행 결과

```
  id pre post
1  1 3.25 3.89
2  2 3.70 4.97
3  3 2.19 3.04
4  4 2.17 1.88
5  5 2.51 2.92
```

한 사람이 한 행을 차지하고, 두 시점의 점수가 같은 행에 있어야 합니다. 이 구조를 넓은 형태(wide format)라 합니다. SPSS의 대응표본 t -검정도 같은 구조를 요구합니다.

2단계 — 기술통계와 상관을 함께 본다

- 두 시점의 M, SD와 둘 사이의 상관

```
c(사전_M = mean(pp$pre), 사전_SD = sd(pp$pre),
  사후_M = mean(pp$post), 사후_SD = sd(pp$post),
  상관   = cor(pp$pre, pp$post))
```

실행 결과

```
사전_M  사전_SD  사후_M  사후_SD  상관
3.0427500 0.6521286 3.4797500 0.8937776 0.8881052
```

평균이 3.04에서 3.48로 올랐습니다. 그런데 여기서 함께 확인해야 할 값이 **상관 .888**입니다.

상관을 반드시 함께 보고하는 이유

SPSS의 대응표본 t -검정은 결과를 세 개의 표로 내놓는데, 그중 하나가 **대응표본 상관계수**입니다. 습관적으로 넘기기 쉬운 표지만 두 가지를 알려줍니다.

① **짜짓기가 제대로 되었는가**. 상관이 0에 가깝다면 두 측정치가 사실상 무관하다는 뜻입니다. 자료 병합 과정에서 행이 어긋났을 가능성을 의심해야 합니다.

② **이 설계가 얼마나 이득을 보고 있는가**. 상관이 높을수록 표준오차가 작아져 검정력이 올라갑니다. .888은 상당히 높은 값이며, 같은 사람을 두 번 측정한 자료에서는 자연스러운 수준입니다.

3단계 — 차이점수를 직접 확인한다

● 검정의 실제 대상

```
d ← pp$post - pp$pre
c(n = length(d), M = mean(d), SD = sd(d), SE = sd(d)/sqrt(length(d)))
```


실행 결과

n	M	SD	SE
40.00000000	0.43700000	0.43454781	0.06870804


평균 **0.437**만큼 올랐고, 그 **향상 폭의 표준편차가 0.435**입니다. 이 두 숫자가 검정의 전부입니다.

여기서 눈여겨볼 지점이 있습니다. 원점수의 표준편차는 0.65와 0.89였는데 **차이점수의 표준편차는 0.435로 더 작습니다**. 개인차가 뿔셈으로 상쇄된 결과입니다.

원점수 — 사람마다 출발선이 다르다



차이점수 — 개인차가 빠진 뒤



짜을 유지하면 개인의 원래 수준이 뿔셈으로 상쇄되고, 변화량만 남는다

그림 8-3 왼쪽은 두 시점의 원점수. 사람마다 출발선이 제각각이라 분포가 넓게 겹친다. 오른쪽은 차이점수. 개인차가 빠지고 변화량만 남아 0에서 뚜렷이 떨어져 있다.

4단계 — 검정

● paired = TRUE 하나만 붙이면 됩니다

```
t.test(pp$post, pp$pre, paired = TRUE)
```

실행 결과

Paired t-test

```
data: pp$post and pp$pre
t = 6.3602, df = 39, p-value = 1.637e-07
alternative hypothesis: true mean difference is not equal to 0
95 percent confidence interval:
 0.2980249 0.5759751
sample estimates:
mean difference
      0.437
```

읽는 방식은 7장과 같습니다.

출력의 이 자리	값	의미
t =	6.36	검정통계량
df =	39	자유도. 종속표본에서는 쌍의 수 - 1
p-value =	< .001	영가설이 참일 때 이만한 변화가 나올 확률
confidence interval	[0.298, 0.576]	차이점수 평균의 95% 신뢰구간

$t(39) = 6.36, p < .001$ 로 영가설을 기각합니다. 신뢰구간 [0.298, 0.576]에 0이 포함되지 않으므로 같은 결론입니다.

자유도가 78이 아니라 39입니다

독립표본이었다면 자유도는 $n_1 + n_2 - 2 = 78$ 이었을 것입니다. 종속표본에서는 쌍의 수에서 1을 뺀 39입니다.

관측치는 80개지만 독립적인 정보는 40개뿐이기 때문입니다. 출력의 df 가 예상과 다르면 paired 옵션이 의도대로 적용되었는지 확인해 보십시오.

5단계 — 인자 순서를 확인한다

- 순서를 바꾸면 부호가 뒤집힙니다

```
t.test(pp$pre, pp$post, paired = TRUE)$estimate
```

실행 결과

```
mean difference
-0.437
```

`t.test(post, pre, ...)` 는 사후-사전이므로 항상 **양수**로 나옵니다. 순서를 바꾸면 부호만 반대가 되고 *p*값은 동일합니다.

논문에는 **항상이 양수로 나오도록** `t.test(사후, 사전, paired = TRUE)` 순서를 쓰는 것이 읽기 편합니다. 원고의 관행대로 $D = \text{post} - \text{pre}$ 로 정의하면 부호 해석에서 혼란이 없습니다.

■ 짝을 무시하면 어떻게 되는가

이 장에서 가장 중요한 부분입니다. **똑같은 자료**를 독립표본으로 잘못 분석해 보겠습니다.

- `paired` 옵션을 빠뜨린 경우 — 실수로 가장 흔한 형태

```
t.test(pp$post, pp$pre, paired = FALSE, var.equal = TRUE)
```

실행 결과

```
Two Sample t-test


data:  pp$post and pp$pre
t = 2.4981, df = 78, p-value = 0.01459
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 0.08872833 0.78527167
sample estimates:
mean of x mean of y
 3.47975   3.04275
```

비교해 보겠습니다.

	올바른 분석 (짝 유지)	잘못된 분석 (짝 무시)
t	6.36	2.50
df	39	78
p	< .001	.015
95% CI	[0.298, 0.576]	[0.089, 0.785]
평균 차이	0.437	0.437

평균 차이는 0.437로 똑같습니다. 달라진 것은 그 차이를 재는 잣대, 즉 표준오차입니다.

t 값이 6.36에서 2.50으로 2.5배 넘게 줄었습니다. 신뢰구간의 폭도 0.278에서 0.697로 2.5배 넓어졌습니다.



평균 차이는 똑같은 0.437이다. 달라진 것은 그 차이를 재는 잣대, 곧 표준오차뿐이다
 두 점수의 상관 .888만큼 표준오차가 줄어 t 값이 2.5배 커졌다

그림 8-4 같은 자료, 같은 평균 차이. 짝을 유지하면 상관 .888만큼 표준오차가 줄어 t 값이 2.5배 커진다.

이 예시는 결론이 같지만, 항상 그렇지는 않습니다

위 자료에서는 두 방법 모두 $p < .05$ 로 나와 결론이 뒤집히지는 않았습니니다. 효과가 워낙 컸기 때문입니다.

효과가 중간 정도였다면 올바른 분석에서는 유의하고 잘못된 분석에서는 유의하지 않은 상황이 흔히 발생합니다. 애써 모은 자료에서 실재하는 효과를 놓치게 되는 것입니다.

반대 방향의 위험도 있습니다. 독립적인 두 집단을 `paired = TRUE` 로 잘못 돌리면 표준오차가 근거 없이 작아져 **없는 효과를 있다고 판단**하게 됩니다. R은 이 경우 오류를 내지 않으므로 발견하기 어렵습니다.

손해가 아니라 이득으로 보십시오

"짝을 무시하면 검정력이 떨어진다"는 서술은 방향을 거꾸로 읽은 것입니다. 정확히는 짝을 유지하면 개인차라는 소음이 제거되어 검정력이 올라갑니다.

같은 인원으로 더 정밀한 검정을 할 수 있다는 뜻이며, 사전-사후 설계가 널리 쓰이는 실질적인 이유입니다. 표본을 늘리기 어려운 연구일수록 이 설계의 가치가 큼니다.

■ 효과크기

종속표본에서 Cohen's d 는 **차이점수의 표준편차**로 나눕니다.

$$d = \frac{\bar{D}}{s_D}$$

분모가 통합표준편차가 아니라 s_D 입니다

● 차이점수 기준 Cohen's d

```
d ← pp$post - pp$pre  
round(mean(d) / sd(d), 3)
```

실행 결과

```
[1] 1.006
```

`effectsize` 패키지로도 확인할 수 있습니다.

● 신뢰구간까지

```
library(effectsize)  
cohens_d(pp$post, pp$pre, paired = TRUE)
```

실행 결과

Cohen's d	95% CI
1.01	[0.62, 1.38]

$d = 1.01$ 로 큰 효과(0.8 이상)에 해당합니다. 통계적으로도 유의하고 실질적으로도 의미 있는 향상입니다.

독립표본의 d 와 직접 비교하지 않습니다

같은 기호를 쓰지만 **분모가 다릅니다**. 독립표본은 통합표준편차 s_p 로, 종속표본은 차이점수의 표준편차 s_D 로 나눕니다.

s_D 는 상관이 높을수록 작아지므로 **종속표본의 d 가 구조적으로 크게 나오는 경향**이 있습니다. 위 자료에서도 원점수 표준편차는 0.65와 0.89였는데 s_D 는 0.435였습니다.

논문에서는 어느 표준편차를 분모로 썼는지 명시하고, 서로 다른 설계의 효과크기를 나란히 비교할 때는 이 차이를 언급해야 합니다.

■ SPSS 출력과의 대응

SPSS	R	비고
대응표본 통계량	<code>mean()</code> , <code>sd()</code>	두 시점의 M, SD
대응표본 상관계수	<code>cor(pre, post)</code>	넘기지 말고 확인
대응표본 검정 — 평균	<code>mean(post - pre)</code>	$\bar{D}$
대응표본 검정 — 표준편차	<code>sd(post - pre)</code>	s_D
평균의 표준오차	<code>sd(d)/sqrt(n)</code>	$s_D/\sqrt{n}$
유의확률 (양측)	<code>p-value</code>	동일

SPSS는 분석 → 평균 비교 → 대응표본 T검정 에서 두 변수를 한 쌍으로 지정합니다. R의 `paired = TRUE` 가 그 지정에 대응합니다.

■ 논문 결과표

구분	n	M	SD	t	df	p	Cohen's d
사전	40	3.04	0.65	6.36	39	< .001	1.01
사후	40	3.48	0.89				

주. 사전-사후 점수의 상관은 $r = .89$ 였다. 차이점수의 평균은 0.44($SD = 0.43$), 95% CI [0.30, 0.58]이다.

결과 서술 예시

프로그램의 효과를 검증하기 위해 참여 전후의 자아존중감 점수에 대해 종속표본 t-검정을 실시하였다. 두 시점의 점수는 높은 상관을 보였다($r = .89$).

분석 결과, 사후 점수($M = 3.48$, $SD = 0.89$)가 사전 점수($M = 3.04$, $SD = 0.65$)보다 통계적으로 유의하게 높았다($t(39) = 6.36$, $p < .001$). 평균 향상 폭은 0.44점이었으며 95% 신뢰구간은 [0.30, 0.58]이었다. 효과크기는 Cohen's $d = 1.01$ 로 큰 수준이었다.

7장의 다섯 요소에 **두 시점의 상관**이 추가된 형태입니다. 종속표본에서는 이 값을 함께 보고하는 것이 관행입니다.

사전-사후 설계의 한계를 함께 적습니다

통제집단 없이 한 집단의 전후만 비교하는 설계에서는 **항상이 프로그램 때문이라고 단정할 수 없습니다**. 시간이 지나면서 자연히 올랐을 수도 있고, 같은 검사를 두 번 받은 효과일 수도 있습니다.

본 연구는 단일집단 사전-사후 설계로, 성숙 효과와 검사 효과를 통제하지 못한 한계가 있다.

이 문장을 논의 또는 제한점에 넣어두면 심사에서 같은 지적을 받았을 때 대응할 수 있습니다. 통제집단이 있는 설계라면 **집단 × 시점의 이원분산분석(11장)**으로 분석하는 것이 적절합니다.

점검 항목

- ☐ 자료가 한 행에 두 시점 점수를 담은 구조인지 확인했다
- ☐ `paired = TRUE` 를 지정했다
- ☐ 자유도가 쌍의 수 - 1로 나왔는지 확인했다
- ☐ 두 측정치의 상관을 함께 보고했다
- ☐ 효과크기의 분모가 s_D 임을 안다
- ☐ 통제집단이 없다면 한계를 서술했다

요약 — 같은 대상을 두 번 측정한 자료는 **차이점수 하나로 줄여** 단일표본 검정으로 처리합니다. 짝을 유지하면 개인차가 상쇄되어 표준오차가 작아지고, 같은 자료에서 값이 2.50에서 6.36으로 커졌습니다. `paired` 옵션 하나가 결론을 바꿉니다.

세 집단 이상의 비교 — 일원분산분석

집단이 셋이면 t -검정을 세 번 하면 될 것 같습니다. 그런데 그렇게 하면 안 됩니다. 이 장은 그 이유와, 평균을 비교하는 데 왜 분산을 계산하는지를 다룹니다.

■ t -검정을 반복하면 안 되는 이유

집단이 A, B, C 셋이라면 비교할 짝은 A-B, A-C, B-C 세 개입니다. t -검정을 세 번 돌리면 될 것처럼 보입니다.

문제는 오류가 쌓인다는 것입니다.

유의수준 .05는 **한 번의 검정에서** 제1종 오류를 범할 확률입니다. 뒤집어 말하면 한 번의 검정에서 옳게 판단할 확률이 .95라는 뜻입니다. 세 번을 연달아 하면 세 번 모두 옳을 확률은 이렇게 됩니다.

$$.95 \times .95 \times .95 = .857$$

세 번 모두 옳게 판단할 확률

따라서 적어도 한 번 잘못 판단할 확률은 $1 - .857 = .143$ 입니다. 연구자는 .05로 통제했다고 생각했는데 실제로는 14.3%입니다.

일반화하면 다음과 같습니다.

$$\alpha^{FW} = 1 - (1 - \alpha)^c$$

c 는 비교 횟수, FW 는 family-wise를 뜻합니다

- 집단 수가 늘어날 때 제1종 오류가 쌓이는 속도

```
for(k in 2:6) {
  c_ <- choose(k, 2)
  cat(sprintf("집단 %d개 | 비교 %2d회 | 최소 1회 오류 확률 %.4f\n", k, c_, 1 - .95^c_))
}
```

실행 결과

집단 2개 | 비교 1회 | 최소 1회 오류 확률 0.0500
 집단 3개 | 비교 3회 | 최소 1회 오류 확률 0.1426
 집단 4개 | 비교 6회 | 최소 1회 오류 확률 0.2649
 집단 5개 | 비교 10회 | 최소 1회 오류 확률 0.4013
 집단 6개 | 비교 15회 | 최소 1회 오류 확률 0.5367

집단이 여섯이면 **오류 확률이 53.7%**입니다. 동전 던지기보다 나쁩니다.





그림 9-1 집단이 하나 늘 때마다 비교 횟수는 급격히 늘고, 제1종 오류 확률도 함께 치솟는다.



대신 기각되어도 어느 집단끼리 다른지는 알려주지 않는다. 그 확인이 10장의 다중비교다

그림 9-2 같은 세 집단을 두고 t-검정을 세 번 하는 것과 분산분석을 한 번 하는 것의 차이. (개념도)

하나의 검정으로 끝내는 것이 분산분석입니다

Fisher가 제시한 해법은 **비교를 여러 번 하지 않는** 것이었습니다.

"A와 B가 다른가", "B와 C가 다른가"를 따로 묻는 대신 **"세 집단의 평균이 모두 같은가"**를 한 번에 묻습니다. 검정이 한 번이면 유의수준도 .05 그대로 유지됩니다.

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_a$$

a 는 집단의 수입니다

대신 대가가 있습니다. 기각되더라도 어느 집단끼리 다른지는 알려주지 않습니다. 그 확인 절차가 10장의 다중비교입니다.

■ 평균을 비교하는데 왜 분산을 보는가


분산분석이라는 이름이 혼란을 줍니다. 궁금한 것은 평균 차이인데 왜 분산을 계산할까요.

평균 차이의 크기를 판정할 기준이 필요하기 때문입니다.

세 집단의 평균이 68, 74, 77이라고 합시다. 이 차이가 큰 것일까요. 그것만으로는 판단할 수 없습니다. **집단 안에서 사람들이 얼마나 흩어져 있는지를** 함께 봐야 합니다.

집단 내부의 점수가 67~69에 몰려 있다면 6점 차이는 대단한 것입니다. 그러나 40~95에 퍼져 있다면 6점은 우연한 변동의 범위 안입니다.

집단 안이 촘촘할 때



6점 차이는 대단한 것이다

M = 68

M = 74

M = 77

집단 안이 흩어져 있을 때



6점은 우연의 범위 안이다

M = 68

M = 74

M = 77

집단 평균은 위아래가 똑같이 68 · 74 · 77이다. 다르게 판단해야 하는 이유는 집단 안의 산포다

그림 9-3 위아래 두 경우 모두 집단 평균은 같다. 다르게 판단해야 하는 이유는 집단 안에서 얼마나 흩어져 있는가이다. (개념도)

그래서 두 종류의 변동을 나누어 계산하고 그 비율을 봅니다.

$$F = \frac{\sigma_B^2}{\sigma_W^2} = \frac{\text{집단 간 분산}}{\text{집단 내 분산}}$$

평균 차이를 우연한 변동으로 나눈 값

F값이 실제로 재는 것

두 분산이 무엇에서 생기는지 따져보면 의미가 분명해집니다.

집단 내 분산 — 같은 처치를 받았는데도 점수가 다른 이유입니다. **개인차**가 거의 전부입니다.

집단 간 분산 — 집단마다 평균이 다른 이유입니다. 여기에는 두 가지가 섞여 있습니다. **처치의 효과**와, 집단을 구성할 때 우연히 들어간 **개인차**입니다.

$$F = \frac{\text{집단 간 분산 추정치}}{\text{집단 내 분산 추정치}} = \frac{\text{처치효과} + \text{개인차}}{\text{개인차}}$$

분자에만 처치효과가 있습니다

처치효과가 0이면 분자와 분모가 같아져 F 는 **1이 됩니다**. F 가 1보다 충분히 크다는 것은 개인차만으로 설명되지 않는 무언가가 분자에 들어 있다는 뜻입니다.

7장에서 t 값을 "관찰된 차이 ÷ 그 차이가 변동하는 정도"로 읽었던 것과 같은 구조입니다.

처치효과가 0이면
분자와 분모가 같아져

$F = 1$ 이 된다

F 가 1보다 충분히 크면
개인차만으로는 설명되지
않는 무언가가 있다는 뜻

$F =$

집단 간 분산 = 처치효과 + 개인차

집단 내 분산 = 개인차

$$F = \frac{\text{교수법 자료}}{11.56} = 18.12$$

7장에서 t 값을 "관찰된 차이 ÷ 그 차이가 변동하는 정도"로 읽었던 것과 같은 구조다

그림 9-4 F 값의 구조. 분자에만 처치효과가 들어 있고, 그것이 0이면 F 는 1이 된다. (개념도)

F가 1보다 작게 나오는 경우

논리대로라면 F 의 최솟값은 1이어야 합니다. 처치효과가 0일 때 분자와 분모가 모두 개인차뿐이기 때문입니다.

그러나 실제 분석에서는 1보다 작은 F 가 종종 나옵니다. 분자와 분모 모두 **표본에서 나온 추정치**여서 추정 오차가 있기 때문입니다.

$F < 1$ 이면 볼 것도 없이 유의하지 않습니다. 오류가 아니라 **처치효과가 없다는 것을 아주 분명히 보여주는 결과**입니다.

■ 제곱합을 쪼갬다

F 를 계산하려면 두 분산의 추정치가 필요합니다. 계산은 **제곱합(Sum of Squares, SS)**에서 출발합니다.

2장에서 분산을 구할 때 편차를 제곱해 더했던 그 계산입니다. 여기서는 그 합을 세 갈래로 나눕니다.

개인의 점수 하나를 분해하는 것에서 시작합니다.

$$X_{ij} = \bar{X} + (\bar{X}_j - \bar{X}) + (X_{ij} - \bar{X}_j)$$

전체 평균 + 집단 효과 + 개인 오차

전체 평균을 왼쪽으로 옮기면 이렇게 됩니다.

$$\underbrace{(X_{ij} - \bar{X})}_{\text{총 편차}} = \underbrace{(\bar{X}_j - \bar{X})}_{\text{집단 간 편차}} + \underbrace{(X_{ij} - \bar{X}_j)}_{\text{집단 내 편차}}$$

한 사람의 편차가 두 조각으로 나뉩니다

한 사람이 전체 평균에서 벗어난 거리는, 그 사람이 속한 집단이 전체에서 벗어난 만큼과 그 사람이 자기 집단에서 벗어난 만큼의 합입니다. 각각을 제공해서 모두 더하면 제공합이 됩니다.

한 사람이 전체 평균에서 벗어난 거리는 정확히 두 조각으로 나뉩니다




그림 9-5 한 개인의 점수가 전체 평균에서 떨어진 거리는 집단 간 편차와 집단 내 편차로 정확히 쪼개진다. (개념도)

구분	제공합	자유도	평균제공
집단 간	$SS_B = \sum n_j (\bar{X}_j - \bar{X})^2$	$a - 1$	$MS_B = SS_B / (a - 1)$
집단 내	$SS_W = \sum \sum (X_{ij} - \bar{X}_j)^2$	$N - a$	$MS_W = SS_W / (N - a)$
전체	$SS_T = \sum \sum (X_{ij} - \bar{X})^2$	$N - 1$	

주. N 은 전체 표본크기, a 는 집단의 수, n_j 는 j 번째 집단의 크기.

그리고 다음 관계가 성립합니다. 이를 **제공합의 분할**이라 합니다.

$$SS_T = SS_B + SS_W$$

전체 변동은 남김없이 둘로 나뉩니다

집단 내 평균제곱은 통합분산과 같습니다

MS_W 는 7장에서 본 통합분산 s_p^2 과 같은 개념입니다. 집단이 둘에서 셋 이상으로 늘었을 뿐입니다.

$$MS_W = \frac{SS_1 + SS_2 + SS_3}{df_1 + df_2 + df_3} = \frac{SS_W}{N - a}$$

각 집단의 산포를 하나로 합친 값

t -검정에서 통합분산이 "차이를 재는 잣대"였던 것처럼, 분산분석에서도 MS_W 가 같은 역할을 합니다. 두 검정은 같은 논리의 서로 다른 크기 버전입니다.

■ 손으로 계산해 보기

교수법 A, B, C를 각각 10명에게 적용하고 성취도를 측정한 자료입니다. 전체 평균은 73.03입니다.

	A	B	C
	65, 70, 68, 70, 62	69, 73, 74, 75, 67	75, 74, 77, 80, 70
	70, 74, 68, 70, 65	77, 78, 75, 73, 75	81, 79, 78, 79, 80
평균	68.2	73.6	77.3

집단 내 제곱합 — 각자가 자기 집단 평균에서 벗어난 정도입니다.

$$SS_W = (65 - 68.2)^2 + (70 - 68.2)^2 + \cdots + (80 - 77.3)^2 = 312.1$$

30명 전원의 편차제곱합

$$MS_W = \frac{312.1}{30 - 3} = \frac{312.1}{27} = 11.56$$

집단 간 제곱합 — 각 집단 평균이 전체 평균에서 벗어난 정도이며, 집단 인원수만큼 가중합니다.

$$SS_B = 10(68.2 - 73.03)^2 + 10(73.6 - 73.03)^2 + 10(77.3 - 73.03)^2 = 418.9$$

$$MS_B = \frac{418.9}{3 - 1} = \frac{418.9}{2} = 209.43$$

F값

$$F = \frac{MS_B}{MS_W} = \frac{209.43}{11.56} = 18.12$$

$df_1 = 2, df_2 = 27$ 인 F 분포의 임계값은 3.354이므로 18.12는 이를 크게 넘습니다. **영가설을 기각합니다.**

■ F분포의 생김새

t 분포나 정규분포와 달리 F 분포는 **좌우대칭이 아닙니다.**




그림 9-6 F분포는 0에서 시작해 오른쪽으로 길게 늘어진다. 분산의 비율이므로 음수가 될 수 없다. 기각역은 오른쪽 꼬리에만 있다.

- ① 음수가 없습니다. 분산의 비율이므로 0보다 작을 수 없습니다. 0에서 시작해 오른쪽으로 열려 있습니다.
- ② 정적편포입니다. 오른쪽 꼬리가 길니다.
- ③ 자유도 두 개로 결정됩니다. 분자 자유도 $df_1 (= a - 1)$ 과 분모 자유도 $df_2 (= N - a)$ 입니다. df_2 가 커질수록 평균이 1에 가까워지고, 두 자유도가 모두 커질수록 분포가 뾰족해집니다.
- ④ 일방검정입니다. 처치효과가 있으면 F 가 커지는 쪽으로만 움직이므로 기각역이 오른쪽 꼬리에만 있습니다. t -검정처럼 양쪽을 보지 않습니다.

■ R로 돌리기

1단계 — 자료 구조

분산분석용 자료는 **긴 형태(long format)**여야 합니다. 집단을 나타내는 열 하나와 점수 열 하나입니다.

● 집단 열 + 점수 열

```
tc <- read.csv("data/teaching.csv")
tc$method <- factor(tc$method)

str(tc)
```

실행 결과

```
'data.frame': 30 obs. of 2 variables:
 $ method: Factor w/ 3 levels "A","B","C": 1 1 1 1 1 1 1 1 1 1 ...
 $ score : int 65 70 68 70 62 70 74 68 70 65 ...
```

SPSS와 자료 형태가 다를 수 있습니다

SPSS로 분산분석을 할 때도 긴 형태를 쓰지만, 엑셀에서 정리할 때 **집단마다 열을 따로 만드는** 넓은 형태로 작업하는 경우가 많습니다.

R에서는 `stack()` 이나 `tidyr::pivot_longer()` 로 변환해야 합니다. 8장의 종속표본 t -검정은 반대로 넓은 형태를 요구했습니다. **분석마다 필요한 형태가 다르다는 점**을 기억해 두십시오.

2단계 — 기술통계

● 집단별 n, 평균, 표준편차

```
round(sapply(split(tc$score, tc$method),
              function(x) c(n = length(x), M = mean(x), SD = sd(x))), 2)
```

실행 결과

	A	B	C
n	10.00	10.00	10.0
M	68.20	73.60	77.3
SD	3.43	3.37	3.4

세 집단의 표준편차가 3.43, 3.37, 3.40으로 거의 같습니다. 등분산 가정에 유리한 신호입니다.




그림 9-7 세 교수법의 점수 분포. 평균은 순서대로 올라가고, 흩어진 정도는 세 집단이 거의 같다.

3단계 — 등분산성 검정

7장과 같은 이유로 확인합니다. 세 집단을 하나의 잣대(MS_W)로 비교해도 되는가입니다.

- 집단이 셋 이상이어도 함수는 동일합니다

```
library(car)
leveneTest(score ~ method, data = tc)
```

실행 결과

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  2  0.0176 0.9826
      27
```

$F(2, 27) = 0.02, p = .983$ 으로 .05보다 큼니다. 등분산 가정을 유지합니다.

세 집단 이상의 등분산 검정에도 분산분석이 쓰입니다

집단이 둘이면 두 분산의 비율로 확인할 수 있지만, 셋 이상이면 그 방법을 쓸 수 없습니다. Levene(1960)의 방법은 각 사례가 자기 집단 평균에서 떨어진 거리의 절댓값을 새 변수로 만든 뒤, 그 변수로 분산분석을 돌립니다.

집단마다 "평균에서 떨어진 정도"가 비슷한지를 평균 비교로 확인하는 것입니다. 등분산 검정 안에 분산분석이 들어 있는 구조입니다.

R 출력의 `center = median` 은 Brown과 Forsythe(1974)의 제안을 따른 것입니다. 평균은 극단값에 끌려가므로 중앙값을 기준으로 삼는 편이 안정적입니다.

등분산이 깨졌다면

Welch의 F 검정(`oneway.test(score ~ method, data = tc, var.equal = FALSE)`)을 쓸 수 있습니다.

다만 Fisher의 F 검정은 등분산이 깨진 상황에서도 상당히 견고합니다. Tomarken과 Serlin(1986)에 따르면 Welch가 더 나은 경우는 등분산이 깨진 데다 집단 크기까지 다르고, 그중 작은 집단의 분산이 큰 상황입니다.

집단 크기가 같다면 등분산 위반을 크게 걱정하지 않아도 됩니다.

4단계 — 분산분석

- `aov()`로 적합하고 `summary()`로 결과표를 봅니다

```
fit <- aov(score ~ method, data = tc)
summary(fit)
```

실행 결과

```
          Df Sum Sq Mean Sq F value    Pr(>F)
method      2  418.9   209.43    18.12 1.02e-05 ***
Residuals   27  312.1    11.56
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

손으로 계산한 값과 정확히 일치합니다.

출력의 이 자리	값	의미
method 행	집단 간	처치효과 부분
Residuals 행	집단 내	개인차 부분
Df	2, 27	$a - 1, N - a$
Sum Sq	418.9, 312.1	SS_B, SS_W
Mean Sq	209.43, 11.56	MS_B, MS_W
F value	18.12	MS_B/MS_W
Pr(>F)	1.02e-05	유의확률

$F(2, 27) = 18.12, p < .001$ 로 영가설을 기각합니다. 세 교수법의 성취도 평균이 모두 같다고 볼 수 없습니다.

여기서 알 수 있는 것은 여기까지입니다

F 가 유의하다는 것은 "세 평균이 모두 같지는 않다"는 뜻일 뿐입니다.

A와 B가 다른 것인지, B와 C가 다른 것인지, 아니면 셋 다 서로 다른 것인지는 알 수 없습니다. 이 확인이 10장의 다중비교입니다.

반대로 F 가 유의하지 않으면 거기서 분석을 끝냅니다. 유의하지 않은데 사후검정으로 넘어가면 앞에서 애써 막아둔 제1종 오류 누적이 다시 시작됩니다.

■ 효과크기

F 값과 유의확률은 표본크기의 영향을 받습니다. 차이의 크기 자체를 재는 지표가 따로 필요합니다.

분산분석에서는 전체 변동 중 독립변수가 설명하는 비율로 효과크기를 표현합니다.

에타제곱 (η^2)

$$\hat{\eta}^2 = \frac{SS_B}{SS_T}$$

전체 변동 중 집단 차이로 설명되는 몫

● effectsize 패키지

```
library(effectsize)
eta_squared(fit)
```

실행 결과

```
# Effect Size for ANOVA
```

Parameter	Eta2	95% CI
method	0.57	[0.34, 1.00]

$\eta^2 = .57$ 입니다. 성취도 점수의 전체 변동 가운데 **57%가 교수법 차이로 설명된다**는 뜻입니다.

회귀분석의 R^2 과 같은 개념입니다

η^2 은 2권에서 다룰 결정계수 R^2 과 정확히 같은 의미입니다. **설명된 분산의 비율**이라는 점에서 동일합니다.

차이는 독립변수의 척도뿐입니다. η^2 은 **질적 독립변수**(집단)에, R^2 은 **양적 독립변수**에 씁니다. 종속변수가 연속형이라는 점은 둘 다 같습니다.

두 지표가 같은 것이라는 사실은, 분산분석과 회귀분석이 근본적으로 같은 모형이라는 점을 시사합니다. 이 연결은 2권에서 다룹니다.

오메가제곱 (ω^2)

η^2 에는 약점이 있습니다. **표본에서 계산한 값이라 모집단의 효과크기를 과대추정합니다**. 이를 보정한 지표가 ω^2 입니다.

$$\hat{\omega}^2 = \frac{SS_B - (a - 1)MS_W}{SS_T + MS_W}$$

분자에서 우연히 생긴 몫을 빼줍니다

● 보정된 효과크기

```
omega_squared(fit)
```

실행 결과

Effect Size for ANOVA

```
Parameter | Omega2 |      95% CI
-----
method    |    0.53 | [0.29, 1.00]
```

$\eta^2 = .57$ 보다 낮은 **.53**이 나왔습니다. ω^2 이 언제나 η^2 보다 작거나 같습니다. 표본크기가 작을수록 두 값의 차이가 벌어집니다.

효과크기	작음	중간	큼
Cohen's f	.10	.25	.40 이상
η^2	.01	.06	.14 이상
ω^2	.01	.059	.138 이상

$\eta^2 = .57$, $\omega^2 = .53$ 모두 **큰 효과**의 기준을 크게 넘습니다.

무엇을 보고할 것인가

논문 관행상 η^2 이 **가장 널리 쓰입니다**. SPSS가 기본으로 부분 에타제곱을 출력하는 것도 영향을 미쳤습니다.

다만 표본이 작을 때(집단당 20명 미만)는 η^2 의 과대추정이 두드러지므로 ω^2 을 **함께 보고하거나** ω^2 만 보고하는 것이 정확합니다. 어느 지표를 썼는지 표기만 분명하면 됩니다.

Cohen's f 는 $f = \sqrt{SS_B/SS_W}$ 로 계산되며, 검정력 분석([pwr](#) 패키지)에서 입력값으로 쓰입니다. 위 자료에서는 $f = 1.158$ 입니다.

■ SPSS 출력과의 대응

SPSS	R	비고
분산의 동질성 검정	<code>car::leveneTest()</code>	별도 출력
집단-간 (제곱합, 자유도, 평균제곱)	<code>method</code> 행	$SS_B, a - 1, MS_B$
집단-내	<code>Residuals</code> 행	$SS_W, N - a, MS_W$
합계	두 행의 합	SS_T
F, 유의확률	<code>F value</code> , <code>Pr(>F)</code>	동일
부분 에타제곱	<code>eta_squared(fit)</code>	일원분산분석에서는 η^2 과 같음

SPSS 경로는 `분석 → 평균 비교 → 일원배치 분산분석` 입니다.

■ 논문 결과표

분산분석 결과는 두 개의 표로 제시하는 것이 일반적입니다.

표 1. 교수법별 성취도 기술통계

교수법	n	M	SD
A	10	68.20	3.43
B	10	73.60	3.37
C	10	77.30	3.40
전체	30	73.03	5.02

표 2. 일원분산분석 결과

변량원	SS	df	MS	F	p	η^2
집단 간	418.87	2	209.43	18.12	< .001	.57
집단 내	312.10	27	11.56			
전체	730.97	29				

결과 서술 예시

교수법에 따른 성취도의 차이를 검증하기 위해 일원분산분석을 실시하였다. 등분산성 검정 결과 Levene의 $F(2, 27) = 0.02, p = .983$ 으로 등분산 가정이 충족되었다.

분석 결과, 교수법에 따른 성취도의 차이는 통계적으로 유의하였다($F(2, 27) = 18.12, p < .001$). 효과크기는 $\eta^2 = .57$ 로, 성취도 전체 변동의 57%가 교수법으로 설명되었다. 집단별 평균은 C($M = 77.30, SD = 3.40$), B($M = 73.60, SD = 3.37$), A($M = 68.20, SD = 3.43$) 순이었다.

어느 집단 간에 차이가 있는지 확인하기 위해 Tukey HSD를 이용한 사후검정을 실시하였다.

마지막 문장으로 다음 절(다중비교)을 예고하는 것이 일반적인 구성입니다.

점검 항목

- ☐ t -검정을 반복하면 제1종 오류가 누적된다는 것을 안다
- ☐ F 값이 "처치효과+개인차 ÷ 개인차"의 구조임을 안다
- ☐ $SS_T = SS_B + SS_W$ 의 관계를 안다
- ☐ 자료가 긴 형태(집단 열 + 점수 열)인지 확인했다
- ☐ 등분산성 검정을 먼저 했다
- ☐ F 가 유의해도 어느 집단끼리 다른지는 모른다는 것을 안다
- ☐ 효과크기(η^2 또는 ω^2)를 함께 보고했다

요약 — 집단이 셋 이상일 때 t -검정을 반복하면 제1종 오류가 쌓입니다. 분산분석은 "모두 같은가"를 한 번에 물어 유의수준을 지킵니다. 는 **집단 간 분산 ÷ 집단 내 분산**이며, 개인차로 설명되지 않는 뒀이 분자에 얼마나 있는지를 재는 값입니다.

어느 집단끼리 다른가 — 다중비교

F가 유의해도 어느 집단끼리 다른지는 알 수 없습니다. 그런데 확인하려고 t-검정을 반복하면 9장에서 막아둔 문제가 되 돌아옵니다. 이 장은 그 딜레마를 어떻게 푸는지 다룹니다.

■ 분산분석이 답하지 않은 것

9장에서 $F(2, 27) = 18.12, p < .001$ 로 영가설을 기각했습니다. 그런데 기각된 영가설이 무엇이었는지 다시 봅시다.


$$H_0 : \mu_A = \mu_B = \mu_C$$

이 명제가 거짓이라는 것은 "셋이 모두 같지는 않다"는 뜻일 뿐입니다. 가능한 경우가 여럿입니다.

- A만 낮고 B와 C는 같을 수도 있고
- C만 높고 A와 B는 같을 수도 있고
- 셋이 모두 서로 다를 수도 있습니다

논문에 필요한 것은 "차이가 있었다"가 아니라 "어느 교수법이 어느 교수법보다 효과적이었다"입니다. 이를 확인하는 추가 절차를 **다중비교(multiple comparison)** 또는 **사후검정(post hoc test)**이라 합니다.

F가 유의하다 = "세 평균이 한 줄에 있지는 않다"



세 배치 모두 F는 유의하게 나올 수 있다. 어느 경우인지는 F만으로 구분되지 않는다
그래서 사후검정이 필요하다

그림 10-1 F가 유의하다는 것은 세 평균이 한 줄에 있지 않다는 뜻일 뿐이다. 어떤 배치인지는 별도로 확인해야 한다. (개념도)

■ 되돌아온 딜레마

확인 방법은 명확합니다. 세 쌍을 각각 비교하면 됩니다. 그런데 그렇게 하면 9장에서 피하려고 했던 제1종 오류 누적이 그대로 돌아옵니다.

세 번 비교하면 최소 한 번 잘못 판단할 확률이 .1426이었습니다. 분산분석으로 한 번에 물어서 .05를 지켜놓고, 사후검정에서 다시 .1426으로 풀어버리면 앞의 노력이 무의미해집니다.

두 종류의 유의수준

문제를 정확히 보려면 유의수준을 두 층으로 나눠야 합니다.

비교당 유의수준(α^{PC} , per-comparison) — 개별 비교 하나에 적용되는 기준입니다.

군집당 유의수준(α^{FW} , family-wise) — 한 연구에서 수행한 비교 전체를 묶었을 때, 그중 최소 한 번이라도 잘못 판단할 확률입니다.

$$\alpha^{FW} = 1 - (1 - \alpha^{PC})^c$$

c 는 비교 횟수

연구자가 통제해야 하는 것은 α^{FW} 입니다. 논문의 결론은 개별 비교가 아니라 비교들의 묶음에서 나오기 때문입니다.

다중비교 방법들은 모두 α^{FW} 를 .05로 유지하면서 개별 비교를 어떻게 할 것인가에 대한 서로 다른 답입니다.

연구자가 통제해야 할 것은 개별 비교가 아니라 비교들의 묶음이다

보정하지 않으면

비교 1		$\alpha = .05$
비교 2		$\alpha = .05$
비교 3		$\alpha = .05$

쌓이면 군집당 .143

보정하면

비교 1		$\alpha = .0167$
비교 2		$\alpha = .0167$
비교 3		$\alpha = .0167$

전체가 .049로 묶인다

다중비교 방법들은 모두 "군집당 .05를 유지하면서 개별 비교를 어떻게 할 것인가"에 대한 답이다

그림 10-2 보정하지 않으면 비교를 거듭할수록 군집당 오류가 쌓인다. 보정은 개별 기준을 엄격하게 만들어 전체를 .05에 묶어두는 장치다.

■ 네 가지 방법

Bonferroni 방법

가장 직관적인 해법입니다. 비교 횟수만큼 유의수준을 나눕니다.

$$\alpha^{PC} = \frac{\alpha^{FW}}{c}$$

세 번 비교한다면 각각을 $.05/3 = .0167$ 로

세 집단을 비교할 때 각 검정을 $.0167$ 수준에서 판단하면, 군집당 오류는 다음과 같이 계산됩니다.

$$\alpha^{FW} = 1 - \left(1 - \frac{0.05}{3}\right)^3 = 1 - 0.951 = 0.049$$

목표한 $.05$ 안에 들어옵니다

실제로는 유의수준을 나누는 대신 **유의확률에 비교 횟수를 곱해서** 보고합니다. 결과는 같고 $.05$ 기준을 그대로 쓸 수 있어 편리합니다.

비교가 많아지면 지나치게 보수적입니다

Bonferroni는 비교 횟수에 정비례해 기준을 조입니다. 집단이 6개면 비교가 15회이므로 α^{PC} 가 **.0033**이 됩니다.

이 수준이면 실재하는 차이도 대부분 놓칩니다. 제1종 오류를 막으려다 **제2종 오류를 크게 키우는 것**입니다. 비교가 서너 개를 넘어가면 다른 방법을 고려해야 합니다.

Fisher의 LSD 방법

유의수준을 아예 보정하지 않고 t -검정을 그대로 반복합니다. 대신 **두 조건을 붙입니다.**

① 분산분석의 F 검정이 반드시 유의해야 한다. 유의하지 않으면 사후검정으로 넘어가지 않습니다. ② 집단이 정확히 셋일 때만 쓸 수 있다.

두 조건이 지켜지면 보정 없이도 α^{FW} 가 $.05$ 를 넘지 않는다는 것이 알려져 있습니다. F 검정이 1차 관문 역할을 하기 때문입니다.

집단이 넷 이상이면 성립하지 않습니다

LSD가 안전한 것은 집단이 셋일 때뿐입니다. 넷 이상에서는 F 가 유의하더라도 군집당 오류가 $.05$ 를 넘습니다.

집단 수를 확인하지 않고 LSD를 쓰는 것이 사후검정에서 가장 흔한 실수입니다. SPSS의 사후분석 창에서 LSD가 목록 맨 위에 있어 무심코 선택되는 경우가 많습니다.

Tukey HSD

사후검정에서 **가장 널리 쓰이는 방법**입니다. 모든 쌍을 비교하면서 군집당 유의수준을 .05로 유지합니다.

Bonferroni처럼 기계적으로 나누지 않고 **스튜던트화 범위 분포(studentized range distribution)**라는 별도의 분포를 씁니다. 가장 큰 평균과 가장 작은 평균의 차이가 우연히 얼마나 벌어질 수 있는지를 직접 모형화한 분포입니다.

그래서 Bonferroni보다 **덜 보수적이면서도** 군집당 오류를 정확히 통제합니다. 집단 크기가 같을 때 특히 잘 작동합니다.

Scheffé 방법


가장 보수적인 방법입니다. 존재하는 사후검정 중 제1종 오류가 가장 작습니다.

비교의 개수가 **무한히 많다고 가정**하고 설계되었기 때문입니다. 아무리 많은 비교를 해도 α^{FW} 가 통제되지만, 그만큼 기각이 어렵습니다.

쌍별 비교만 할 것이라면 지나치게 엄격합니다. **"A와 B의 평균을 합친 것과 C를 비교"** 같은 복합 비교까지 자유롭게 하고 싶을 때 쓰는 방법입니다.

방법	보수성	적용 상황
Fisher LSD	가장 느슨함	집단 정확히 3개 , F 유의할 때만
Tukey HSD	중간	모든 쌍 비교 . 기본 선택지
Bonferroni	엄격함	비교 개수가 적고 미리 정해졌을 때
Scheffé	가장 엄격함	복합 비교를 포함할 때

사후검정 방법의 보수성



분석을 마친 뒤에 유의하게 나오는 방법을 고르는 것은 유의성 낚시다. 미리 정해두어야 한다

그림 10-3 네 방법을 보수성 축에 놓은 것. 왼쪽으로 갈수록 차이를 잘 찾아내지만 헛발견도 높고, 오른쪽으로 갈수록 그 반대다. (개념도)

■ R로 돌리기

9장의 교수법 자료를 그대로 씁니다. $F(2, 27) = 18.12, p < .001$ 로 이미 유의했으므로 사후검정으로 넘어갈 수 있습니다.

Tukey HSD

- aov 결과를 그대로 넘기면 됩니다

```
fit <- aov(score ~ method, data = tc)
TukeyHSD(fit)
```

실행 결과

Tukey multiple comparisons of means
95% family-wise confidence level

Fit: aov(formula = score ~ method, data = tc)

```
$method
      diff      lwr      upr    p adj
B-A  5.4  1.63010117  9.169899 0.0039568
C-A  9.1  5.33010117 12.869899 0.0000064
C-B  3.7 -0.06989883  7.469899 0.0551655
```


출력을 읽는 법입니다.

열	의미
diff	두 집단의 평균 차이 (뒤 - 앞)
lwr, upr	그 차이의 군집당 보정된 95% 신뢰구간
p adj	보정된 유의확률. 이 값을 .05와 비교

결론입니다.

- **B - A = 5.4, $p = .004$** — B가 A보다 유의하게 높습니다
- **C - A = 9.1, $p < .001$** — C가 A보다 유의하게 높습니다
- **C - B = 3.7, $p = .055$** — 차이는 있지만 유의수준에 미치지 못합니다

신뢰구간으로도 같은 판단이 가능합니다. **C-B의 구간 [-0.07, 7.47]만 0을 포함합니다.**



군집당 오류를 보정한 신뢰구간이다. 0을 걸치는 구간(붉은 점선)은 C-B 하나뿐이다

그림 10-4 Tukey HSD의 세 신뢰구간. 0을 걸치는 구간이 하나 있고, 그것이 C-B다.

Bonferroni와 비교

- `p.adjust.method`로 방법을 바꿉니다

```
pairwise.t.test(tc$score, tc$method, p.adjust.method = "bonferroni")
```

실행 결과

Pairwise comparisons using t tests with pooled SD

data: tc\$score and tc\$method

	A	B
B	0.0043	-
C	6.6e-06	0.0656

P value adjustment method: bonferroni

보정하지 않으면

- 비교를 위해 보정 없이도 돌려봅니다

```
pairwise.t.test(tc$score, tc$method, p.adjust.method = "none")
```

실행 결과

Pairwise comparisons using t tests with pooled SD

data: tc\$score and tc\$method

```
A      B
B 0.0014 -
C 2.2e-06 0.0219
```

P value adjustment method: none

■ 방법에 따라 결론이 갈리는 지점

세 결과를 나란히 놓으면 이 장에서 가장 중요한 사실이 드러납니다.

비교	보정 없음	Tukey HSD	Bonferroni	Holm
B - A	.0014	.0040	.0043	.0029
C - A	< .001	< .001	< .001	< .001
C - B	.0219	.0552	.0656	.0219

주. Holm은 `p.adjust.method = "holm"` 으로 산출하였다.

같은 자료, 같은 비교. 보정 방법만 바꾼 결과

	보정 없음	Tukey HSD	Bonferroni	Holm
B - A	0.0014	0.0040	0.0043	0.0029
C - A	< .001	< .001	< .001	< .001
C - B	0.0219	0.0552	0.0656	0.0219

↑ 이 한 줄에서 결론이 갈린다

C-B 한 쌍에서 보정 없음과 Holm은 유의하고, Tukey와 Bonferroni는 유의하지 않다
그래서 방법은 분석 전에 정해두고, 결과가 어떻게 나오든 그대로 보고한다

그림 10-5 같은 자료에 보정 방법만 바꾼 결과. C-B 한 쌍에서 결론이 갈린다.

C-B 한 쌍에서 결론이 갈립니다. 보정하지 않으면 유의하고($p = .022$), Tukey와 Bonferroni에서는 유의하지 않습니다($p = .055, .066$).

분석을 마친 뒤에 방법을 고르면 안 됩니다

위 표를 보고 "유의하게 나오는 방법을 쓰면 되겠다"고 판단하는 것은 **자료를 보고 기준을 맞추는 것**입니다. 유의성 낚시(p-hacking)에 해당하며 연구윤리 문제로 이어집니다.

분석 계획 단계에서 방법을 정하고, 결과가 어떻게 나오든 그대로 보고합니다. 특별한 사정이 없으면 Tukey HSD를 씁니다.

$p = .055$ 처럼 경계에 걸린 결과는 숨기지 말고 있는 그대로 적는 편이 낫습니다. "유의수준에 근접하였으나 통계적으로 유의하지는 않았다"는 서술이 정확하며, 심사에서도 문제 되지 않습니다.

Holm 방법 — 실무에서 쓸 만한 절충안

표의 마지막 열에 있는 Holm(1979) 방법은 Bonferroni를 개선한 것입니다.

Bonferroni가 모든 비교에 같은 기준을 적용하는 반면, Holm은 **유의확률을 작은 순서로 정렬한 뒤 단계적으로 기준을 완화**합니다. 가장 작은 값에는 α/c , 다음에는 $\alpha/(c-1)$, 그 다음은 $\alpha/(c-2)$ 순입니다.

그 결과 **군집당 오류는 Bonferroni와 똑같이 통제하면서 검정력은 더 높습니다.** 통계적으로 Bonferroni보다 언제나 우월합니다.

논문 관행이 아직 Bonferroni와 Tukey에 머물러 있어 채택률은 낮지만, 방법을 자유롭게 고를 수 있는 상황이라면 Holm이 합리적인 선택입니다. R에서 `p.adjust()`의 기본값이 Holm인 것도 같은 이유입니다.


■ 동질적 부분집합

Tukey 결과를 정리하면 다음 구조가 보입니다.

- A < B (유의)
- A < C (유의)
- B와 C는 구분되지 않음

A는 나머지 둘과 다르고, B와 C는 서로 구분되지 않는다는 것입니다. SPSS는 이를 **동질적 부분집합(homogeneous subsets)** 표로 보여줍니다.

A는 나머지 둘과 다르고, B와 C는 구분되지 않는다



"구분되지 않는다"와 "같다"는 다르다. $p = .055$ 는 다르다고 판단할 근거가 부족하다는 뜻이다
집단당 10명은 사후검정에 넉넉한 수가 아니다

그림 10-6 세 집단을 하나의 축에 놓은 것. A는 따로 떨어지고, B와 C는 같은 묶음으로 남는다.

교수법	n	부분집합 1	부분집합 2
A	10	68.20	
B	10		73.60
C	10		77.30

주. 같은 열에 표시된 집단 간에는 유의한 차이가 없다.

B와 C가 같다는 뜻이 아닙니다

"구분되지 않는다"와 "같다"는 다릅니다. $p = .055$ 는 차이가 없음을 증명한 것이 아니라 다르다고 판단할 근거가 부족하다는 뜻입니다.

7장의 등분산 검정에서 확인한 원칙이 그대로 적용됩니다. 기각 실패는 영가설의 증명이 아닙니다.

집단당 10명은 사후검정을 하기에 넉넉한 수가 아닙니다. 표본이 더 컸다면 3.7점 차이도 유의했을 수 있습니다. 논문에는 이 가능성을 제한점으로 언급해 두는 것이 정확합니다.

■ 사후검정을 하면 안 되는 경우

F가 유의하지 않으면 거기서 끝냅니다

F 가 유의하지 않은데 사후검정으로 넘어가는 경우가 있습니다. 분산분석 전체가 "차이가 없다"고 판정한 자료에서 굳이 짝을 찾는 것이며, 9장에서 막아둔 오류 누적을 되살리는 행위입니다.

F 가 유의하지 않으면 사후검정 없이 "집단 간 차이가 유의하지 않았다"로 보고를 마칩니다.

예외가 있다면 **사전에 계획된 비교(planned comparison)**입니다. 연구 가설에서 특정 두 집단의 비교를 미리 명시했다면 F 와 무관하게 그 비교를 할 수 있습니다. 다만 이는 사후검정이 아니라 **대비(contrast) 분석**이며, 연구계획서에 미리 적혀 있어야 합니다.

■ SPSS 출력과의 대응

SPSS	R
사후분석 → Tukey	<code>TukeyHSD(fit)</code>
사후분석 → Bonferroni	<code>pairwise.t.test(..., "bonferroni")</code>
사후분석 → LSD	<code>pairwise.t.test(..., "none")</code>
사후분석 → Scheffe	<code>DescTools::ScheffeTest(fit)</code>
다중 비교 표의 평균차	<code>diff</code>
다중 비교 표의 유의확률	<code>p adj</code>
동질적 부분집합	직접 정리

SPSS 경로는 `분석 → 평균 비교 → 일원배치 분산분석 → 사후분석` 입니다.

■ 논문 결과표

9장의 분산분석 표에 사후검정 결과를 덧붙이는 형태가 일반적입니다.

표 3. 교수법별 성취도에 대한 사후검정 (Tukey HSD)

비교	평균차	95% CI	p
B - A	5.40	[1.63, 9.17]	.004
C - A	9.10	[5.33, 12.87]	< .001
C - B	3.70	[-0.07, 7.47]	.055

주. 신뢰구간은 군집당 오류를 보정한 값이다.

결과 서술 예시

어느 집단 간에 차이가 있는지 확인하기 위해 Tukey HSD를 이용한 사후검정을 실시하였다.

그 결과 교수법 B($M = 73.60$)와 C($M = 77.30$)는 모두 교수법 A($M = 68.20$)보다 성취도가 통계적으로 유의하게 높았다(각각 $p = .004$, $p < .001$). 반면 B와 C 사이의 차이는 3.70점으로 유의수준에 근접하였으나 통계적으로 유의하지는 않았다($p = .055$, 95% CI $[-0.07, 7.47]$).

이는 기존 교수법(A)에 비해 새로운 두 교수법이 모두 효과적이며, 두 새 교수법 사이에는 뚜렷한 우열을 확인하기 어려움을 시사한다. 다만 집단당 사례 수가 10명으로 제한적이어서 검정력이 충분하지 않았을 가능성을 고려할 필요가 있다.

세 요소가 들어 있습니다. ㉠ 사용한 방법 ㉡ 각 쌍의 결과 ㉢ 경계값에 대한 해석과 한계. 유의하지 않은 쌍을 생략하지 않는 것이 중요합니다.

점검 항목

- ☐ F 가 유의한 것을 확인한 뒤 사후검정에 들어갔다
- ☐ 비교당 유의수준과 군집당 유의수준을 구분할 수 있다
- ☐ 분석 전에 방법을 정했다
- ☐ LSD는 집단이 정확히 3개일 때만 쓸 수 있다는 것을 안다
- ☐ 유의하지 않은 쌍도 결과표에 포함했다
- ☐ 경계값($p \approx .05$)을 있는 그대로 보고했다

요약 — 사후검정은 **군집당 유의수준을 .05로 묶어둔 채** 어느 쌍이 다른지 확인하는 절차입니다. 기본 선택지는 **Tukey HSD**이며, 방법에 따라 결론이 갈릴 수 있으므로 **분석 전에 방법을 정해두어야 합니다**. 가 유의하지 않으면 사후검정으로 넘어가지 않습니다.

독립변수가 둘일 때 — 이원분산분석

성별과 학교 유형이 각각 성적에 영향을 주는지 보는 것이 목적이라면 일원분산분석을 두 번 하면 됩니다. 그런데 이원분산분석을 쓰는 진짜 이유는 따로 있습니다. 두 번 나눠서는 절대 볼 수 없는 것이 하나 있기 때문입니다.

■ 나눠서 하면 안 되는 이유

성별(남/여)과 학교 유형(남녀공학/분반, 남녀공학/합반, 단성학교)이 수학 성적에 미치는 영향을 알고 싶다고 합시다.

일원분산분석을 두 번 돌리는 방법이 있습니다. 한 번은 성별로, 한 번은 학교 유형으로. 그런데 이 방식으로서는 확인할 수 없는 것이 있습니다.

단성학교의 효과가 남학생과 여학생에게 똑같이 나타나는가?

성별만 보면 남녀 평균이 나오고, 학교만 보면 학교별 평균이 나옵니다. 두 변수를 교차했을 때 어떤 일이 벌어지는지는 어느 쪽에서도 보이지 않습니다.

이것이 **상호작용효과(interaction effect)**이며, 독립변수를 한꺼번에 넣어야만 확인할 수 있습니다.

상호작용효과란

하나의 독립변수가 종속변수와 갖는 관계가, 또 다른 독립변수의 수준에 따라 달라지는 현상.

일상적인 표현으로는 "경우에 따라 다르다"입니다. "단성학교가 성적에 좋은가?"라는 질문에 "남학생에게는 그렇고 여학생에게는 별로다"라고 답해야 한다면 상호작용이 있는 것입니다.

사회과학의 흥미로운 발견은 대체로 이 형태입니다. 어떤 개입이 모두에게 똑같이 작동하는 경우는 드물기 때문입니다.

요인설계의 이점은 네 가지입니다.

① **표본이 효율적입니다.** 같은 인원으로 두 요인을 동시에 검정합니다. ② **현실에 가깝습니다.** 실제 현상은 여러 요인이 함께 작용합니다. ③ **검정력이 높습니다.** 다른 요인이 설명하는 변동이 오차에서 빠져나가 MS_W 가 작아집니다. ④ **상호작용을 검정할 수 있습니다.** 나머지 셋이 부수적일 만큼 중요한 이점입니다.

■ 세 개의 영가설

독립변수가 둘이면 검정할 가설도 셋입니다.

$$H_0^{(1)} : \mu_{\text{남}} = \mu_{\text{여}}$$

성별의 주효과

$$H_0^{(2)} : \mu_{\text{분반}} = \mu_{\text{합반}} = \mu_{\text{단성}}$$

학교 유형의 주효과

$$H_0^{(3)} : \text{상호작용이 없다}$$

성별 × 학교 유형

주효과(main effect)는 주변평균을 비교합니다. 성별의 주효과는 다른 요인을 무시하고 남학생 전체와 여학생 전체를 비교하는 것입니다.

상호작용효과는 여섯 개 셀의 평균을 모두 사용합니다. 특정 조합에서 기대와 다른 값이 나오는지 확인합니다.

2 × 3 설계 — 셀 여섯 개, 주변평균 다섯 개, 전체 평균 하나

	분반	합반	단성학교	주변평균
남	66.57 n = 18	74.38 n = 18	83.58 n = 18	74.84
여	67.12 n = 18	76.73 n = 18	75.94 n = 18	73.26
주변평균	66.84	75.56	79.76	74.05

□ 셀 평균 — 상호작용이 본다
 □ 주변평균 — 주효과가 본다
 ■ 전체 평균

주효과는 바깥쪽 붉은 칸만 본다. 그래서 셀 안에서 벌어지는 일을 놓칠 수 있다

그림 11-1 2 × 3 설계의 구조. 셀 평균 여섯 개, 행과 열의 주변평균, 그리고 전체 평균. 주효과는 주변평균을, 상호작용은 셀 평균을 본다. (개념도)

■ 제곱합이 네 갈래로 나뉩니다

9장에서 전체 변동이 SS_B 와 SS_W 로 나뉘었습니다. 이원분산분석에서는 SS_B 가 다시 셋으로 쪼개집니다.

$$SS_T = SS_A + SS_B + SS_{A \times B} + SS_{S/AB}$$

요인 A + 요인 B + 상호작용 + 오차

$SS_{S/AB}$ 는 SS_W 의 다른 표기입니다. **각 셀 안에서의 개인차**를 뜻하며, 이원분산분석에서는 이 표기를 더 많이 씁니다.


F 값도 셋이 나옵니다. **분모는 모두 같습니다.**

$$F_A = \frac{MS_A}{MS_{S/AB}}, \quad F_B = \frac{MS_B}{MS_{S/AB}}, \quad F_{A \times B} = \frac{MS_{A \times B}}{MS_{S/AB}}$$

개인차라는 같은 잣대로 셋을 잴다

일원분산분석

전체 변동을 어떻게 나누는가



이원분산분석



요인을 하나 더 넣으면 그만큼 오차에서 빠져나간다. 분모가 작아지니 F 가 커진다

그림 11-2 일원분산분석에서는 변동이 둘로 나뉘지만, 이원분산분석에서는 설명되는 부분이 다시 셋으로 쪼개진다. (개념도)

검정력이 올라가는 기제

요인을 하나 더 넣으면 $SS_{A \times B}$ 와 두 번째 요인의 SS_B 가 오차에서 빠져나갑니다.


성별만으로 분석했다면 학교 유형 때문에 생긴 변동이 전부 "설명되지 않는 개인차"로 처리됩니다. MS_W 가 커지고, 분모가 커지면 F 가 작아집니다.

두 요인을 함께 넣으면 그 변동에 이름이 붙어 분자 쪽으로 옮겨갑니다. **분모가 작아지므로 같은 자료에서 더 큰 F 가 나옵니다.** 요인설계의 검정력이 높은 이유입니다.

■ 상호작용을 그림으로 읽는 법

상호작용은 수치보다 그래프로 보는 것이 빠릅니다. 가로축에 한 요인, 선으로 다른 요인을 나타내고 셀 평균을 잇습니다.

가로축에 한 요인, 선으로 다른 요인. 셀 평균을 이어 그린다



선이 평행하면 상호작용이 없다. 기울기가 다르거나 교차하면 있다

그림 11-3 상호작용의 네 가지 전형. 선이 평행하면 상호작용이 없고, 기울기가 다르거나 교차하면 있다. (개념도)

선이 평행하면 상호작용이 없습니다. 한 요인의 효과가 다른 요인의 수준과 무관하게 일정하다는 뜻입니다.

기울기가 다르면 상호작용이 있습니다. 정도의 차이만 있는 경우를 **서열적 상호작용(ordinal interaction)**이라 합니다.

선이 교차하면 강한 상호작용입니다. 효과의 **방향 자체가 뒤집히는** 경우이며 **비서열적 상호작용(disordinal interaction)**이라 합니다.

■ R로 돌리기

각 셀에 18명씩, 총 108명의 자료입니다.

1단계 — 두 요인 모두 factor로

- 범주형 변수는 빠짐없이 factor 처리

```
tw <- read.csv("data/twoway.csv")
tw$gender <- factor(tw$gender)
tw$school <- factor(tw$school)

table(tw$gender, tw$school)
```

실행 결과

	남녀공학/분반	남녀공학/합반	단성학교
남	18	18	18
여	18	18	18

여섯 셀에 18명씩 균등하게 배치되어 있습니다. 이를 **균형설계(balanced design)**라 하며, 셀 크기가 다르면 계산이 복잡해집니다(뒤의 제곱합 유형 참고).

2단계 — 셀 평균과 주변평균

- 셀 평균 — 여섯 칸을 모두 봅니다

```
round(tapply(tw$score, list(tw$gender, tw$school), mean), 2)
```

실행 결과

	남녀공학/분반	남녀공학/합반	단성학교
남	66.57	74.38	83.58
여	67.12	76.73	75.94

- 주변평균 — 주효과가 비교하는 값

```
round(tapply(tw$score, tw$gender, mean), 2)
round(tapply(tw$score, tw$school, mean), 2)
```

실행 결과

남	여
74.84	73.26

남녀공학/분반	남녀공학/합반	단성학교
66.84	75.56	79.76

여기서 이미 상호작용의 조짐이 보입니다. **단성학교 열을 보십시오.** 남학생은 83.58인데 여학생은 75.94입니다. 다른 두 학교 유형에서는 남녀가 비슷했는데 단성학교에서만 벌어졌습니다.

주변평균만 보면 이 사실이 사라집니다. 성별 주변평균은 74.84와 73.26으로 거의 같습니다. **평균을 내는 과정에서 단성학교의 격차가 다른 칸들에 희석된 것입니다.**

3단계 — 등분산성 검정

- 여섯 셀의 분산이 모두 같은지 확인합니다

```
library(car)
leveneTest(score ~ gender * school, data = tw)
```

실행 결과

```
Levene's Test for Homogeneity of Variance (center = median)
      Df F value Pr(>F)
group  5  0.7887 0.5601
    102
```

$F(5, 102) = 0.79, p = .560$ 으로 등분산 가정을 유지합니다.

이원분산분석의 등분산 가정은 셀 단위입니다

일원분산분석에서는 집단 수만큼의 분산을 비교했습니다. 이원분산분석에서는 **셀의 개수만큼** 비교합니다.

2×3 설계라면 여섯 개입니다. 출력의 **Df = 5**가 이를 보여줍니다. 여섯 집단이므로 자유도가 5입니다.

gender * school을 지정해야 셀 단위로 검정합니다. **gender + school**로 쓰면 다른 검정이 되므로 주의해야 합니다.

4단계 — 이원분산분석

- 별표(*)는 주효과와 상호작용을 모두 넣으라는 뜻입니다

```
m <- aov(score ~ gender * school, data = tw)
summary(m)
```

실행 결과

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
gender	1	67	67.4	1.653	0.20149
school	2	3125	1562.6	38.335	3.84e-13 ***
gender:school	2	511	255.5	6.269	0.00271 **
Residuals	102	4158	40.8		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

읽는 순서는 상호작용부터입니다

결과표는 주효과, 상호작용 순으로 출력되지만 **해석은 반대 순서로 합니다.**

상호작용이 유의하면 주효과의 의미가 달라지기 때문입니다. 아래에서 자세히 다룹니다.

- ① 상호작용 — $F(2, 102) = 6.27, p = .003$. 유의합니다.
- ② 학교 유형 주효과 — $F(2, 102) = 38.34, p < .001$. 유의합니다.
- ③ 성별 주효과 — $F(1, 102) = 1.65, p = .201$. 유의하지 않습니다.

5단계 — 그래프로 확인




그림 11-4 실제 자료의 상호작용 그래프. 분반과 합반에서는 남녀가 거의 겹치지만, 단성학교에서 선이 벌어진다.

● 상호작용 그래프

```
interaction.plot(tw$school, tw$gender, tw$score,
               xlab = "학교 유형", ylab = "평균 점수", trace.label = "성별")
```

두 선이 단성학교에서 뚜렷하게 갈라집니다. 남학생 선은 계속 올라가는데 여학생 선은 합반과 단성학교 사이에서 오히려 꺾입니다.

그래프의 축을 바꿔서도 그려 봅니다

가로축과 선을 바꾸면 같은 자료가 다르게 보입니다. 원고의 예시처럼 두 버전을 모두 그려 보고 해석이 잘 드러나는 쪽을 논문에 실는 것이 좋습니다.


`interaction.plot(tw$gender, tw$school, tw$score)` 로 축을 바꿀 수 있습니다. 상호작용의 존재 여부는 어느 쪽으로 그려도 동일하게 나타납니다.

■ 상호작용이 유의할 때 주효과를 어떻게 읽는가

여기가 이원분산분석에서 가장 자주 틀리는 부분입니다.

성별 주효과는 $p = .201$ 로 유의하지 않았습니다. 이를 "성별은 성적과 관계없다"로 읽으면 틀립니다.

성별 주효과가 유의하지 않다 ≠ 성별이 성적과 무관하다



방향이 반대인 차이들이 평균을 내는 과정에서 서로 상쇄된 것이다

그림 11-5 왼쪽은 주변평균, 오른쪽은 셀 평균. 왼쪽에서는 아무 일도 없어 보인다.

셀 평균을 다시 봅시다.

	분반	합반	단성학교
남	66.57	74.38	83.58
여	67.12	76.73	75.94

단성학교에서 남녀 차이가 **7.6점**입니다. 결코 작지 않습니다. 그런데 분반과 합반에서는 오히려 여학생이 약간 높습니다. 방향이 서로 반대인 차이들이 평균을 내는 과정에서 상쇄된 것입니다.

상호작용이 유의하면 주효과를 단독으로 해석하지 않습니다

주효과가 말해 주는 것은 "**평균적으로는**"입니다. 상호작용이 있다는 것은 그 평균이 어느 조건도 제대로 대표하지 못한다는 뜻입니다.

"성별의 효과는 유의하지 않았다"까지만 쓰고 넘어가면 **가장 중요한 발견을 놓친 보고**가 됩니다.

올바른 서술은 이렇습니다. "성별의 주효과는 유의하지 않았으나, 상호작용이 유의하여 학교 유형에 따라 성별의 효과가 다르게 나타났다."

■ 단순주효과 분석

상호작용이 유의하면 **다른 요인의 수준별로 나누어** 효과를 확인합니다. 이를 **단순주효과(simple main effect)** 분석이라 합니다.

● 성별로 나누어 학교 효과를 각각 확인


```
for(g in levels(tw$gender)) {
  cat("\n[", g, "]\n")
  print(summary(aov(score ~ school, data = subset(tw, gender == g))))
}
```

실행 결과

```
[ 남 ]
      Df Sum Sq Mean Sq F value    Pr(>F)
school    2   2612   1305.9    28.17 5.73e-09 ***
Residuals 51   2364    46.4

[ 여 ]
      Df Sum Sq Mean Sq F value    Pr(>F)
school    2   1024    512.2    14.56 9.92e-06 ***
Residuals 51   1794    35.2
```

상호작용이 유의하면 다른 요인의 수준별로 나누어 확인한다



두 집단 모두 학교 유형의 효과는 유의하지만 크기가 두 배 이상 다르다
학교 유형이 남학생의 성적에 더 크게 작용한다 — 상호작용이 유의했던 이유

그림 11-6 성별로 나누어 학교 효과를 따로 본 결과. 두 집단 모두 유의하지만 제곱합이 두 배 이상 차이 난다.

두 집단 모두 학교 유형의 효과가 유의하지만 크기가 다릅니다. 남학생은 $F = 28.17$, 여학생은 $F = 14.56$ 입니다. 제곱합으로 보면 2612 대 1024로 두 배 이상 차이가 납니다.

학교 유형이 남학생의 성적에 더 크게 작용한다는 것이 이 분석의 결론이며, 상호작용이 유의했던 이유입니다.

단순주효과에서도 오류 누적을 고려합니다

수준별로 나누어 검정하면 검정 횟수가 늘어납니다. 성별 두 수준으로 나뉘었으므로 두 번입니다.

엄밀하게는 유의수준을 보정해야 합니다($.05/2 = .025$). 위 결과는 두 경우 모두 $p < .001$ 이므로 보정해도 결론이 같습니다.

경계에 걸리는 값이 나오면 **Bonferroni 보정을 적용하고 그 사실을 논문에 명시하십시오.**

■ 효과크기

이원분산분석에서는 **부분 에타제곱(partial η^2)**을 씁니다.

$$\eta_p^2 = \frac{SS_{\text{효과}}}{SS_{\text{효과}} + SS_{\text{오차}}}$$

다른 효과의 몫을 분모에서 제외합니다

일반 η^2 이 전체 변동을 분모로 쓰는 것과 달리, 부분 η^2 은 **해당 효과와 오차만** 봅니다. 다른 요인이 설명하는 부분을 빼고 평가하는 것입니다.

● 부분 에타제곱

```
library(effectsize)
eta_squared(m, partial = TRUE)
```

실행 결과

```
# Effect Size for ANOVA (Type III)
```

Parameter	Eta2 (partial)	95% CI
gender	0.02	[0.00, 1.00]
school	0.43	[0.31, 1.00]
gender:school	0.11	[0.03, 1.00]

학교 유형이 .43으로 가장 크고, **상호작용도 .11로 중간 이상**입니다. 성별 단독 효과는 .02로 작습니다.

부분 에타제곱은 합해서 1이 되지 않습니다

일반 η^2 은 모두 더하면 1 이하가 되지만 **부분 η^2 은 그렇지 않습니다**. 효과마다 분모가 다르기 때문입니다.

"설명된 분산의 비율"로 해석할 때 이 점을 유의해야 합니다. 효과들 사이의 상대적 크기를 비교하는 용도로 쓰는 것이 적절합니다.

SPSS가 기본으로 출력하는 값이 부분 에타제곱이어서 논문에 가장 많이 등장합니다.

■ 제곱합 유형 — 셀 크기가 다를 때

셀마다 사례 수가 다르면 제곱합 계산 방식이 여러 가지가 됩니다. 결과가 달라지므로 어떤 방식을 썼는지 밝혀야 합니다.

유형	방식	사용 상황
제1유형	모형에 넣은 순서대로 배분	순서에 이론적 근거가 있을 때
제2유형	상호작용을 뺀 상태에서 주효과 평가	상호작용이 없을 때
제3유형	다른 모든 효과를 통제하고 평가	SPSS 기본값. 논문 표준

셀 크기가 같으면 세 유형의 결과가 모두 동일합니다. 위 자료는 균형설계이므로 `summary(aov())` 가 준 값을 그대로 써도 됩니다.

셀 크기가 다르면 R의 기본값(제1유형)과 SPSS(제3유형)의 결과가 달라집니다. SPSS와 맞추려면 이렇게 합니다.

● 제3유형 제공합 — SPSS와 동일한 결과

```
options(contrasts = c("contr.sum", "contr.poly"))
m <- aov(score ~ gender * school, data = tw)
Anova(m, type = 3)
```

실행 결과

Anova Table (Type III tests)

Response: score

	Sum Sq	Df	F value	Pr(>F)
(Intercept)	592282	1	14530.1675	< 2.2e-16 ***
gender	67	1	1.6528	0.201491
school	3125	2	38.3349	3.837e-13 ***
gender:school	511	2	6.2686	0.002706 **
Residuals	4158	102		

주효과와 상호작용의 값이 제1유형과 완전히 같습니다. **균형설계이기 때문입니다.**

contr.sum 설정을 빠뜨리면 안 됩니다

`Anova(m, type = 3)` 만 호출하고 `options(contrasts = ...)` 를 생략하면 **잘못된 값이 나옵니다.** R의 기본 대비(`contr.treatment`)는 제3유형 제공합과 맞지 않기 때문입니다.

`effectsize` 패키지도 이 조합을 쓰지 않으면 경고를 냅니다. 제3유형을 쓸 때는 항상 두 줄을 함께 실행하십시오.

(`Intercept`) 행은 전체 평균이 0인지를 검정하는 것으로, **해석 대상이 아닙니다.** 결과표에 옮기지 않습니다.

■ SPSS 출력과의 대응

SPSS	R
일반선형모형 → 일반량	<code>aov(y ~ A * B, data = d)</code>
오차분산의 동일성 검정	<code>leveneTest(y ~ A * B, data = d)</code>
개체-간 효과 검정 표	<code>summary(m)</code> 또는 <code>Anova(m, type = 3)</code>
제3유형 제곱합	<code>options(contrasts = c("contr.sum", "contr.poly"))</code> + <code>Anova(m, type=3)</code>
부분 에타제곱	<code>eta_squared(m, partial = TRUE)</code>
프로파일 도표	<code>interaction.plot()</code>
추정 주변평균	<code>tapply()</code> 또는 <code>emmeans::emmeans()</code>

SPSS 경로는 **분석 → 일반선형모형 → 일반량**이며, 종속변수와 **고정요인** 두 개를 지정합니다.

오차막대가 겹치지 않아야 차이가 있다

SPSS의 프로파일 도표에 오차막대를 넣어 출력할 수 있습니다. 해석의 기본 원칙은 **오차막대가 겹치지 않을 때 차이가 있다고 판단**하는 것입니다.

다만 이것은 눈으로 하는 대략적인 판단이며, 최종 결론은 검정 결과로 내려야 합니다. 오차막대가 SD인지 SE인지 95% CI인지 **캡션에 반드시 명시**해야 한다는 4장의 원칙이 그대로 적용됩니다.

■ 논문 결과표

표 1. 성별과 학교 유형에 따른 성적 기술통계

학교 유형	남 M (SD)	여 M (SD)	전체 M
남녀공학/분반	66.57 (8.43)	67.12 (5.51)	66.84
남녀공학/합반	74.38 (5.18)	76.73 (5.53)	75.56
단성학교	83.58 (6.42)	75.94 (6.68)	79.76
전체	74.84	73.26	74.05

주. 각 셀 $n = 18$, 전체 $N = 108$.

표 2. 이원분산분석 결과

변량원	SS	df	MS	F	p	η_p^2
성별 (A)	67	1	67.4	1.65	.201	.02
학교 유형 (B)	3125	2	1562.6	38.33	< .001	.43
A × B	511	2	255.5	6.27	.003	.11
오차	4158	102	40.8			

결과 서술 예시

성별과 학교 유형이 수학 성적에 미치는 영향을 검증하기 위해 이원분산분석을 실시하였다. 등분산성 검정 결과 Levene의 $F(5, 102) = 0.79$, $p = .560$ 으로 가정이 충족되었다.

분석 결과 성별과 학교 유형의 상호작용효과가 통계적으로 유의하였다($F(2, 102) = 6.27$, $p = .003$, $\eta_p^2 = .11$). 학교 유형의 주효과도 유의하였으나($F(2, 102) = 38.33$, $p < .001$, $\eta_p^2 = .43$), 성별의 주효과는 유의하지 않았다($F(1, 102) = 1.65$, $p = .201$).

상호작용이 유의하여 단순주효과 분석을 실시한 결과, 학교 유형의 효과는 남학생($F(2, 51) = 28.17$, $p < .001$)과 여학생($F(2, 51) = 14.56$, $p < .001$) 모두에게서 유의하였으나 그 크기가 달랐다. 남학생은 단성학교에서 평균 83.58점으로 가장 높았던 반면(분반 66.57점, 합반 74.38점), 여학생은 합반 76.73점과 단성학교 75.94점 사이에 뚜렷한 차이가 없었다.

이는 단성학교 환경이 남학생의 수학 성적에 상대적으로 더 유리하게 작용함을 시사한다.

서술 순서가 중요합니다. 상호작용을 먼저 보고하고, 유의하면 단순주효과로 풀어서 설명한 뒤, 마지막에 그 의미를 해석합니다. 주효과부터 나열하면 읽는 사람이 결론을 잡기 어렵습니다.

점검 항목

- ☐ 두 독립변수를 모두 `factor()` 로 변환했다
- ☐ `gender * school` 로 상호작용항을 포함했다
- ☐ 셀별 사례 수를 `table()` 로 확인했다
- ☐ 등분산 검정을 셀 단위로 했다
- ☐ 상호작용부터 읽었다

- ☐ 상호작용이 유의하면 주효과를 단독으로 해석하지 않았다
- ☐ 단순주효과 분석으로 상호작용의 내용을 설명했다
- ☐ 상호작용 그래프를 그려 확인했다
- ☐ 셀 크기가 다르면 제3유형 제곱합을 썼다

요약 — 이원분산분석을 쓰는 이유는 **상호작용효과** 때문입니다. 한 요인의 효과가 다른 요인의 수준에 따라 달라지는지를 확인할 수 있고, 이는 두 번의 일원분산분석으로는 볼 수 없습니다. **상호작용이 유의하면 주효과는 단독으로 해석하지 않고** 단순주효과 분석으로 풀어냅니다.

실전 참고자료

실제 분석에서 꺼내 쓰는 자료만 모았습니다. 분석 선택 흐름도, 전체 분석 비교표, R 코드 모음, APA 보고 문장 템플릿, 그리고 자주 마주치는 오류 메시지의 원인입니다.

■ 분석 선택 흐름도

1장의 흐름도를 1권에서 다룬 내용 전체로 확장한 것입니다. 분석 방법을 정하지 못할 때는 **종속변수의 척도**부터 확인하십시오.




그림 12-1 1권 전체를 하나로 묶은 분석 선택 흐름도. 종속변수의 척도, 독립변수의 성격, 집단 수, 독립성 여부 순으로 내려가면 분석이 하나로 정해진다.

판단 순서는 네 단계입니다.

① 종속변수가 연속형인가 범주형인가 — 연속형이면 평균 비교, 범주형이면 빈도 비교입니다. ② 독립변수가 범주형인가 연속형인가 — 범주형이면 집단 비교, 연속형이면 관계 분석(2권)입니다. ③ 집단이 몇 개인가 — 둘이면 t -검정, 셋 이상이면 분산분석입니다. ④ 집단이 서로 독립인가 — 같은 대상을 반복 측정했다면 종속표본 계열입니다.

■ 전체 분석 비교표

분석	종속변수	독립변수	검정통계량	자유도	효과크기	장
단일표본 t	연속형	없음 (기준값과 비교)	t	$n - 1$	Cohen's d	6장
독립표본 t	연속형	범주형 2집단 (독립)	t	$n_1 + n_2 - 2$	Cohen's d	7장
종속표본 t	연속형	범주형 2시점 (대응)	t	쌍 수 -1	Cohen's d	8장
일원분산분석	연속형	범주형 3집단 이상	F	$a - 1, N - a$	η^2, ω^2	9장
이원분산분석	연속형	범주형 2개 요인	$F \times 3$	요인별	부분 η^2	11장

각 분석이 확인하는 가정입니다.

분석	독립성	정규성	등분산성	비고
독립표본 t	설계로 확인	각 집단	Levene	깨지면 Welch
종속표본 t	차이점수 의 독립성	차이점수	해당 없음	두 점수의 상관 보고
일원분산분석	설계로 확인	각 집단	Levene	깨지면 Welch's F
이원분산분석	설계로 확인	각 셀	셀 단위 Levene	셀 크기 다르면 제3유형

■ R 코드 모음

자료 준비

- 분석을 시작할 때 반복되는 절차

```
df <- read.csv("data.csv")           # CSV는 UTF-8로 저장
str(df)                             # 척도가 의도대로 잡혔는지 먼저 확인
summary(df)                         # 이상값·결측 훑어보기

df$gender <- factor(df$gender,        # 범주형은 반드시 factor로
                    levels = c(1, 2),
                    labels = c("남성", "여성"))

colSums(is.na(df))                  # 변수별 결측 개수
df <- na.omit(df)                   # 결측 제거 (필요할 때만)
```

기술통계

- 기술통계

```
library(psych)

describe(df$selfesteem)             # n, M, SD, 왜도, 첨도 한 번에
describeBy(df$selfesteem, df$gender) # 집단별로

# 집단별 n / M / SD 만 간단히
round(sapply(split(df$selfesteem, df$gender),
              function(x) c(n = length(x), M = mean(x), SD = sd(x))), 2)
```

가정 검정

- 정규성과 등분산성

```
library(car)

shapiro.test(df$selfesteem)         # 정규성 (n이 크면 참고용)
hist(df$selfesteem)                 # 눈으로도 반드시 확인
qqnorm(df$selfesteem); qqline(df$selfesteem)

leveneTest(selfesteem ~ gender, data = df) # 등분산성 (SPSS와 동일)
leveneTest(score ~ gender * school, data = tw) # 이원분산분석은 셀 단위
```

평균 비교

● 네 가지 t-검정과 분산분석

```
# 단일표본
t.test(df$selfesteem, mu = 3.0)

# 독립표본 (등분산 가정 충족)
t.test(selfesteem ~ gender, data = df, var.equal = TRUE)

# 독립표본 (등분산 가정 위배 → Welch)
t.test(selfesteem ~ gender, data = df, var.equal = FALSE)

# 종속표본
t.test(pp$post, pp$pre, paired = TRUE)

# 일원분산분석
fit <- aov(score ~ method, data = tc)
summary(fit)

# 이원분산분석
m <- aov(score ~ gender * school, data = tw)
summary(m)
```

사후검정

● 다중비교

```
TukeyHSD(fit) # 기본 선택지
pairwise.t.test(tc$score, tc$method, "bonferroni") # Bonferroni
pairwise.t.test(tc$score, tc$method, "holm") # Holm (권장)
pairwise.t.test(tc$score, tc$method, "none") # LSD (집단 3개일 때만)
```

효과크기

● 효과크기

```
library(effectsize)

cohens_d(selfesteem ~ gender, data = df) # 독립표본
cohens_d(pp$post, pp$pre, paired = TRUE) # 종속표본
eta_squared(fit) # 일원분산분석
omega_squared(fit) # 보정된 값
eta_squared(m, partial = TRUE) # 이원분산분석
```

검정력과 표본크기

- 자료를 모으기 전에 계산합니다

```
power.t.test(n = 30, delta = 0.5, sd = 1, sig.level = .05)      # 검정력
power.t.test(delta = 0.5, sd = 1, sig.level = .05, power = .80) # 필요 표본
```

■ APA 보고 문장 템플릿

빈칸을 채우면 그대로 쓸 수 있는 형태입니다. 기울임체 표기와 소수점 자리수를 그대로 유지하십시오.

독립표본 t-검정

○○에 따른 □□의 차이를 검증하기 위해 독립표본 t-검정을 실시하였다. 등분산성 검정 결과 Levene의 $F(_, _) = _, p = .__$ 으로 등분산 가정이 충족되어 Student t-검정을 적용하였다.

분석 결과, ○○집단의 □□($M = _, SD = _$)이 △△집단($M = _, SD = _$)보다 통계적으로 유의하게 높은 것으로 나타났다($t(_) = _, p = .__$). 효과크기는 Cohen's $d = __$ 로 □□ 수준이었다.

종속표본 t-검정

○○의 효과를 검증하기 위해 사전-사후 점수에 대해 종속표본 t-검정을 실시하였다. 두 시점의 점수는 $r = .__$ 의 상관을 보였다.

분석 결과, 사후 점수($M = _, SD = _$)가 사전 점수($M = _, SD = _$)보다 통계적으로 유의하게 높았다($t(_) = _, p = .__$). 평균 향상 폭은 $__$ 점이었으며 95% 신뢰구간은 $[_, _]$ 이었다. 효과크기는 Cohen's $d = __$ 로 □□ 수준이었다.

일원분산분석과 사후검정

○○에 따른 □□의 차이를 검증하기 위해 일원분산분석을 실시하였다. 등분산성 검정 결과 Levene의 $F(_, _) = _, p = .__$ 으로 가정이 충족되었다.

분석 결과 집단 간 차이는 통계적으로 유의하였다($F(_, _) = _, p = .__$). 효과크기는 $\eta^2 = .__$ 였다.

어느 집단 간에 차이가 있는지 확인하기 위해 Tukey HSD를 이용한 사후검정을 실시한 결과, ○○집단($M = __$)이 △△집단($M = __$)보다 유의하게 높았으며($p = .__$), □□집단과 △△집단 간에는 유의한 차이가 없었다($p = .__$).

이원분산분석

○○과 △△가 □□에 미치는 영향을 검증하기 위해 이원분산분석을 실시하였다. 등분산성 검정 결과 Levene의 $F(_, _) = _, p = .__$ 으로 가정이 충족되었다.

분석 결과 ○○과 △△의 상호작용효과가 통계적으로 유의하였다($F(_, _) = _, p = .__, \eta_p^2 = .__$). △△의 주효과도 유의하였으나($F(_, _) = _, p = .__$), ○○의 주효과는 유의하지 않았다($F(_, _) = _, p = .__$).

상호작용이 유의하여 단순주효과 분석을 실시한 결과, [수준별 결과를 서술한다].

유의하지 않은 결과

분석 결과 두 집단 간 차이는 통계적으로 유의하지 않았다($t(_) = _, p = .__$). 효과크기는 Cohen's $d = __$ 로 작은 수준이었다.

유의하지 않은 결과에도 **효과크기를 함께 보고**합니다. "차이가 없었다"가 아니라 "**유의한 차이가 나타나지 않았다**"로 씁니다. 기각 실패는 영가설의 증명이 아니기 때문입니다.

■ 표기 규칙

항목	올바른 표기	잘못된 표기
유의확률이 매우 작을 때	$p < .001$	$p = .000$
유의확률 일반	$p = .034$	$p = 0.034$
통계 기호	t, F, p, M, SD, n (기울임)	t, F, p (정자)
그리스 문자	η^2, α, β (정자)	기울임
신뢰구간	95% CI [0.30, 0.58]	95% CI (0.30~0.58)
자유도	$t(238) = -3.93$	$t = -3.93$ ($df = 238$)
소수점 앞 0	.05 (1을 넘을 수 없는 값)	0.05
소수점 앞 0	3.93 (1을 넘을 수 있는 값)	.93

유의확률·상관계수·효과크기 비율처럼 **1을 넘을 수 없는 값은 소수점 앞의 0을 생략**합니다. t 값이나 F 값처럼 1을 넘을 수 있는 값은 그대로 적습니다.

■ 자주 마주치는 오류 메시지

메시지	원인	해결
<code>object 'df' not found</code>	객체를 만들지 않았거나 오타	<code>ls()</code> 로 확인
<code>undefined columns selected</code>	변수명 오타	<code>names(df)</code> 로 확인
<code>grouping factor must have exactly 2 levels</code>	집단이 2개가 아닌데 <code>t.test</code> 사용	<code>aov()</code> 로 변경
<code>not enough 'x' observations</code>	사례 수 부족 또는 결측 과다	<code>table()</code> , <code>colSums(is.na(df))</code>
<code>there is no package called 'car'</code>	패키지 미설치	<code>install.packages("car")</code>
<code>could not find function "leveneTest"</code>	<code>library()</code> 누락	<code>library(car)</code> 실행
한글이 깨져 보임	인코딩 불일치	CSV를 UTF-8 로 다시 저장
평균이 1.47처럼 나옴	범주형을 숫자로 처리	<code>factor()</code> 로 변환

오류가 나지 않는데 결과가 이상한 경우

가장 찾기 어려운 상황입니다. 오류 메시지 없이 틀린 결과가 나오는 경우는 대개 셋 중 하나입니다.

① **척도 지정 누락** — 범주형 변수를 `factor()` 로 변환하지 않았습니다. `str(df)` 로 확인합니다.

② **결측 처리 차이** — R의 기본 동작은 함수마다 다릅니다. `mean()` 은 결측이 있으면 `NA` 를 돌려주고, `t.test()` 는 해당 사례를 제외하고 계산합니다. 분석 전에 결측을 어떻게 처리할지 정해두어야 합니다.

③ **자료 형태 불일치** — 종속표본 *t*-검정은 넓은 형태(한 행에 두 시점), 분산분석은 긴 형태(집단 열 + 점수 열)를 요구합니다.

■ 자료 정리 점검표

분석에 들어가기 전에 확인할 항목입니다.

자료 구조

- ☐ 1행에 변수명, 1인당 1행 구조인가
- ☐ 변수명에 공백이나 특수문자가 없는가 (`self_esteem` 형태 권장)

- ☐ CSV를 **UTF-8**로 저장했는가
- ☐ 결측이 빈칸 또는 **NA**로 되어 있는가 (99, 999 같은 코드값이 남아 있지 않은가)

변수 설정

- ☐ 범주형 변수를 모두 **factor()**로 변환했는가
- ☐ **str(df)**로 각 변수의 척도를 확인했는가
- ☐ 역채점 문항을 처리했는가
- ☐ 합산 또는 평균 변수를 만들었는가

분석 전

- ☐ 종속변수의 왜도와 첨도를 확인했는가
- ☐ 히스토그램을 그려 보았는가
- ☐ 집단별 사례 수를 **table()**로 확인했는가
- ☐ 극단값이 입력 오류인지 실제 값인지 판단했는가

보고

- ☐ 효과크기를 함께 산출했는가
- ☐ 가정 검정 결과를 기록했는가
- ☐ **p = .000**이 아니라 **p < .001**로 적었는가
- ☐ 유의하지 않은 결과도 빠짐없이 보고했는가

■ 다음 권 안내

1권에서는 **집단 간 차이**를 다뤘습니다. 남성과 여성, 처치집단과 통제집단, 세 가지 교수법. 모두 집단을 하나의 평균으로 축약해 그 거리를 재는 분석이었습니다.

7장에서 구분했던 두 번째 유형의 질문, **변수 간 관계**는 다루지 않았습니다. 그쪽이 2권의 주제입니다.

권	다루는 내용	1권과의 연결
2권 회귀분석	상관, 단순·다중회귀, 더미변수, 매개·조절효과	η^2 이 R^2 으로, 집단 비교가 더미변수로
3권 요인분석	탐색적·확인적 요인분석, 신뢰도와 타당도	여러 문항을 하나의 변수로 묶는 근거
4권 구조방정식	측정모형, 구조모형, 적합도 지수	2권과 3권을 하나의 모형으로

1권에서 익힌 것 가운데 이후 계속 쓰이는 것은 ㉠ 유의확률을 읽는 법 ㉡ 가정을 확인하는 습관 ㉢ 효과크기를 함께 보는 시각 ㉣ 출력을 결과표와 문장으로 옮기는 절차입니다. 분석 기법은 바뀌어도 이 넷은 그대로입니다.

2권에서 이어지는 지점

9장의 η^2 — 회귀분석의 R^2 과 같은 개념입니다. 설명된 분산의 비율이라는 점에서 동일하며, 독립변수가 질적이나 양적이거나 다릅니다.

7장의 집단 비교 — 집단변수를 0과 1의 더미변수로 바꾸면 회귀분석으로 같은 결과를 얻습니다. t -검정은 독립변수가 하나인 회귀분석의 특수한 경우입니다.

11장의 상호작용 — 회귀분석에서는 조절효과(moderation)라는 이름으로 등장합니다. 두 변수를 곱해 모형에 넣는 것까지 발상이 같습니다.

분산분석과 회귀분석은 사실 같은 모형입니다. 2권에서 이 연결을 다룹니다.

■ 마치며

이 책은 5년간 진행한 과외의 내용을 정리한 것입니다. 학생들이 가장 자주 막혔던 지점을 기준으로 순서를 잡았고, 그때마다 설명했던 내용을 그대로 옮겼습니다.

통계가 어렵게 느껴지는 이유는 대체로 계산이 아니라 **왜 그 절차를 거치는지 배운 적이 없기 때문**입니다. 등분산성을 검정하는 이유, 영가설에서 출발하는 이유, 세 집단일 때 t -검정을 반복하면 안 되는 이유. 이 책이 답하려 한 것이 그 질문들입니다.

책에 실린 R 출력은 모두 실제로 실행한 결과입니다. 같은 코드를 같은 자료에 돌리면 같은 값이 나옵니다.

후기를 남겨 주시면

읽고 나서 도움이 되었다면 **후기를 남겨 주십시오**. 어느 장이 특히 유용했는지, 어디가 더 설명이 필요했는지 알려주시면 다음 권에 반영합니다.

수정이 필요한 부분이나 추가로 다뤘으면 하는 주제도 후기로 전달해 주시면 좋겠습니다. 이 책은 과외 자료에서 출발했고, 앞으로도 같은 방식으로 다듬어 갈 생각입니다.

1권을 마쳤습니다. 이제 자신의 자료에서 변수의 척도를 판별하고, 적합한 분석을 골라 R로 실행하고, 가정을 확인하고, 출력에서 필요한 값을 찾아 결과표와 논문 문장으로 옮길 수 있습니다. 2권에서는 변수 사이의 관계를 다룹니다.