




사회과학 통계 입문 시리즈

VOL. 02 · 회귀분석

회귀분석은 돌렸는데 해석이 막힌다면

상관에서 매개·조절, 로지스틱까지. 계수 하나하나가 무슨 뜻인지 알고 논문 문장으로 옮깁니다. R로 끝냅니다.

- ☐ '통제했다'는 말이 실제로 무엇을 하는지 압니다
- ☐ 가정 진단과 다중공선성, 무엇을 보고 판단하는지
- ☐ 매개·조절효과를 부트스트랩까지 R 코드로
- ☐ 장마다 논문 결과표와 서술 예시

목차

2권은 '얼마나, 어떤 경로로 영향을 주는가'에 답합니다. 1권의 제곱합·유의확률·효과크기를 그대로 이어 씁니다.

PART 0 들어가며

00	이 책의 구성과 전제	2
----	-------------	---

PART 1 관계를 재다

01	함께 움직이는 정도 — 상관	8
02	선 하나로 요약하기 — 단순회귀	21
03	다른 변수를 통제한다는 것 — 다중회귀	35

PART 2 모형을 점검하고 넓히다

04	이 결과를 믿어도 되는가 — 가정과 진단	46
05	비슷한 변수를 함께 넣으면 — 다중공선성	60
06	집단도 회귀에 넣는다 — 더미변수	69
07	무엇을 더 설명하는가 — 위계적 회귀	80

PART 3 효과의 구조

08	언제, 누구에게 더 강한가 — 조절효과	88
09	어떤 경로로 영향을 주는가 — 매개효과	99
10	경로가 사람마다 다르다면 — 조절된 매개	109

PART 4 결과가 범주일 때

11	예 또는 아니오를 예측하기 — 로지스틱 회귀	116
----	--------------------------	-----

PART 5 부록

12	실전 참고자료	126
----	---------	-----

이 책의 구성과 전제

1권은 "집단 사이에 차이가 있는가"를 물었습니다. 2권은 "한 변수가 다른 변수와 얼마나, 어떤 경로로 이어져 있는가"를 묻습니다. 질문이 바뀌면 분석도 바뀝니다.

■ 1권에서 2권으로

1권의 분석은 모두 **집단을 나누고 평균을 비교**하는 것이었습니다. 남녀의 자아존중감, 세 교수법의 성취도, 처치 전후의 점수가 그랬습니다. 독립변수가 집단이었습니다.

그런데 연구에서 던지는 질문은 대부분 이런 모양입니다.

- 직무스트레스가 **높을수록** 소진도 높아지는가
- 스트레스가 1점 오르면 소진은 **얼마나** 오르는가
- 사회적지지와 자기효능감을 **함께 고려해도** 스트레스의 영향이 남는가
- 스트레스는 **소진을 거쳐서** 이직의도에 영향을 주는가
- 사회적지지가 높은 사람에게는 스트레스의 영향이 **약해지**는가

독립변수가 집단이 아니라 **연속된 점수**입니다. 그리고 "다른가"가 아니라 "**얼마나**"와 "**어떤 경로로**"를 묻습니다. 이 질문에 답하는 도구가 회귀분석입니다.

새로 배우는 것보다 이어지는 것이 많습니다

2권의 개념 대부분은 1권에서 이미 본 것의 다른 이름입니다.

1권에서 본 것	2권에서 다시 만나는 이름
제곱합의 분할 $SS_T = SS_B + SS_W$ (9장)	회귀의 제곱합 분할 $SS_T = SS_R + SS_E$ (2장)
효과크기 η^2 (9장)	결정계수 R^2 (2장)
독립표본 t -검정 (7장)	더미변수 하나짜리 회귀 (6장)
일원분산분석 (9장)	더미변수 여러 개짜리 회귀 (6장)
이원분산분석의 상호작용 (11장)	조절효과 (8장)
신뢰구간 (6장)	회귀계수의 신뢰구간, 부트스트랩 구간 (2장, 9장)

특히 **분산분석과 회귀분석**은 같은 모형입니다. 6장에서 1권의 교수법 자료를 회귀분석으로 다시 돌려 $F = 18.12$ 가 그대로 나오는 것을 확인합니다.

■ 예제 자료 — 직장인 300명 설문

이 책은 처음부터 끝까지 **자료 하나**를 씁니다. 장마다 자료가 바뀌면 분석 방법보다 자료를 이해하는 데 힘이 더 듭니다. 같은 자료를 두고 질문만 바뀌 가면 각 분석이 무엇을 더 알려주는지가 분명해집니다.

자료는 직장인 300명을 대상으로 한 설문을 가정해 만든 것입니다(가상 자료). 척도 점수는 모두 문항 평균이며 1~5점입니다.

변수	내용	값	M	SD
gender	성별	남 160명, 여 140명		
age	연령	24~55세	37.42	
tenure	근속연수	0~19년	7.35	
position	직급	사원 104, 대리 104, 과장이상 92		
stress	직무스트레스	1~5점	3.08	0.62
workload	업무과부하	1~5점	3.31	0.68
support	사회적지지	1~5점	3.52	0.60
efficacy	자기효능감	1~5점	3.61	0.56
burnout	소진	1~5점	2.86	0.68
satisfaction	직무만족	1~5점	3.28	0.66
turnover	이직의도	1~5점	2.72	0.82
quit	1년 뒤 실제 퇴사	0 = 재직, 1 = 퇴사	63명 퇴사	

● 자료 불러오기

```
d ← read.csv("data/survey.csv")
str(d)
```

실행 결과

```
'data.frame': 300 obs. of 13 variables:
 $ id      : int  1 2 3 4 5 6 7 8 9 10 ...
 $ gender  : chr  "여" "여" "남" "남" ...
 $ age     : int  37 40 44 41 41 46 32 32 37 40 ...
 $ tenure  : int  8 12 12 9 14 14 5 7 8 17 ...
 $ position: chr  "대리" "과장이상" "과장이상" "대리" ...
 $ stress  : num  3.83 2.83 3.17 3.17 3.5 2.33 3.17 3.17 2.33 2.33 ...
 $ workload: num  4.2 3 3.2 4 3.2 2.2 3.2 3.4 2.2 2.8 ...
 $ support : num  3.62 4.62 2.75 4 3.25 3.38 4.25 4.88 4 4.25 ...
 $ efficacy: num  4 4.17 3.33 3.67 3.83 4.67 3.83 4.17 3.83 4.17 ...
 $ burnout : num  3.33 2.89 3.22 2.33 2.44 2.22 2.22 2.56 2.44 1.67 ...
 $ satisfaction: num  3 4 2.6 2.2 3.4 3.6 4.2 3.6 3.2 4.4 ...
 $ turnover: num  3 3.5 4.5 3.25 3.25 3.75 2.25 1.5 1 1.75 ...
 $ quit    : int  0 0 1 0 0 0 0 0 0 0 ...
```

자료는 이렇게 생겨야 합니다

한 사람이 한 행, 한 변수가 한 열입니다. 1권에서와 같습니다.

척도 점수는 문항을 평균 내서 열 하나로 만들어 둡니다. 예를 들어 직무스트레스 6문항이 `st1` ~ `st6`에 있다면 다음 한 줄입니다.

```
d$stress ← rowMeans(d[, c("st1", "st2", "st3", "st4", "st5", "st6")])
```

역문항은 평균 내기 전에 뒤집어야 합니다(5점 척도라면 `6 - 점수`). 척도를 문항 평균으로 만들어도 되는지, 즉 문항들이 한 개념을 재고 있는지 확인하는 절차가 3권의 요인분석과 신뢰도 분석입니다.

■ 이 책이 쌓아 가는 연구 모형

장마다 질문이 하나씩 더해지면서 마지막에는 아래 모형이 완성됩니다. 학위논문에서 흔히 보는 형태입니다.




그림 0-1 이 책 전체가 쌓아 가는 연구 모형. 화살표마다 그 관계를 다루는 장을 적었다. (개념도)

장	묻는 것	분석
1	스트레스와 소진은 함께 움직이는가	상관분석
2	스트레스가 1점 오르면 소진은 얼마나 오르는가	단순회귀
3	지지와 효능감을 함께 고려해도 스트레스의 몫이 남는가	다중회귀
4	이 회귀 결과를 믿어도 되는가	가정 진단
5	비슷한 변수 둘을 함께 넣으면 무슨 일이 생기는가	다중공선성
6	직급(범주)도 회귀에 넣을 수 있는가	더미변수
7	인구학적 변수를 통제한 뒤에도 설명력이 늘어나는가	위계적 회귀
8	지지가 높은 사람은 스트레스의 영향이 약한가	조절효과
9	스트레스는 소진을 거쳐 이직의도로 이어지는가	매개효과
10	그 간접경로가 지지 수준에 따라 달라지는가	조절된 매개
11	이직의도가 실제 퇴사를 예측하는가	로지스틱 회귀

■ 준비

1권에서 설치한 패키지(`psych` , `car` , `effectsize`)에 몇 개를 더합니다.

● 최초 1회만 실행합니다

```
install.packages(c("psych", "car", "effectsize", "lmtest", "sandwich",
                  "emmeans", "lavaan", "performance"))
```

패키지	쓰는 곳
<code>psych</code>	기술통계, 상관행렬 (1장)
<code>car</code>	분산팽창지수, 잔차 진단 (4장, 5장)
<code>effectsize</code>	표준화 회귀계수 (3장)
<code>lmtest</code> , <code>sandwich</code>	등분산 검정, 강건한 표준오차 (4장)
<code>emmeans</code>	다중비교, 단순기울기 (6장, 8장)
<code>lavaan</code>	매개효과·조절된 매개의 부트스트랩 (9장, 10장). 4권 구조방정식에서도 그대로 씁니다
<code>performance</code>	로지스틱 회귀의 유사 결정계수와 적합도 (11장)

회귀분석 자체는 R에 기본으로 들어 있는 `lm()` 함수 하나로 합니다. 이 책의 회귀분석 코드는 대부분 이 모양입니다.

● 이 책에서 가장 많이 보게 될 한 줄

```
fit <- lm(burnout ~ stress, data = d)
```

물결표(`~`) 왼쪽이 종속변수, 오른쪽이 독립변수입니다. 1권에서 `t.test(selfesteem ~ gender)`, `aov(score ~ method)` 로 쓰던 것과 같은 문법입니다. 분석은 바뀌어도 모형을 적는 방식은 하나입니다.

■ "영향을 미친다"는 표현에 대해

학위논문에서는 회귀분석 결과를 "X가 Y에 유의한 영향을 미쳤다"고 쓰는 것이 관행입니다. 이 책의 서술 예시도 그 관행을 따릅니다.

다만 이 표현이 무엇을 말하고 무엇을 말하지 않는지는 알고 써야 합니다.

회귀분석이 인과를 증명하지는 않습니다

회귀분석이 보여주는 것은 "X가 높은 사람이 Y도 높은 경향이 있고, 그 경향의 크기가 이만큼이다"입니다. X가 Y의 원인인지는 회귀분석이 아니라 연구 설계가 답합니다.

이 책의 자료처럼 한 시점에 모든 변수를 설문으로 잰 경우, 스트레스가 소진을 높였는지, 소진된 사람이 같은 상황을 더 스트레스로 느끼는지 자료만으로는 가릴 수 없습니다.

그래서 "영향을 미쳤다"는 이론이 정한 방향을 따라 관계의 크기를 기술한 것으로 읽어야 합니다. 논리 부분에서 이 한계를 적어 두는 것이 정직한 보고입니다. 9장의 매개효과에서 이 문제를 다시 다룹니다.

요약 — 2권은 연속된 독립변수가 종속변수와 **얼마나, 어떤 경로로** 이어져 있는지를 다룹니다. 직장인 300명 자료 하나로 상관에서 시작해 매개·조절, 로지스틱 회귀까지 질문을 넓혀 갑니다. 새로운 개념처럼 보이는 것 대부분은 1권의 제곱합, 효과크기, 상호작용이 이름을 바꿔 다시 나오는 것입니다.

함께 움직이는 정도 — 상관

회귀분석의 출발점은 두 변수가 함께 움직이는지 확인하는 것입니다. 이 장은 상관계수가 무엇을 재는지, 그리고 그 숫자 하나가 언제 우리를 속이는지를 다룹니다.

■ 숫자보다 그림이 먼저입니다

직무스트레스가 높은 사람은 소진도 높을까요. 계산을 시작하기 전에 **산점도**부터 그립니다. 한 사람이 점 하나이고, 가로축이 스트레스, 세로축이 소진입니다.

● 산점도 한 줄

```
d ← read.csv("data/survey.csv")
plot(d$stress, d$burnout, xlab = "직무스트레스", ylab = "소진")
```




그림 1-1 직장인 300명의 직무스트레스와 소진. 점구름이 오른쪽 위로 기울어 있다. 스트레스가 높은 사람일수록 소진도 높은 경향이 보인다.

점들이 오른쪽 위로 기울어진 띠 모양으로 모여 있습니다. 스트레스가 높은 사람이 대체로 소진도 높습니다. 그러나 완벽하지는 않습니다. 같은 스트레스 점수에서도 소진은 사람마다 꽤 다릅니다.

이 장에서 할 일은 "얼마나 기울어진 띠인가, 얼마나 촘촘한 띠인가"를 숫자 하나로 요약하는 것입니다. 그 숫자가 상관계수입니다.

■ 함께 움직인다는 것을 숫자로 — 공분산

1권 2장에서 분산을 구할 때 **편차**에서 출발했습니다. 평균에서 얼마나 떨어져 있는가였습니다. 두 변수가 함께 움직이는지도 편차로 봅니다.

산점도에 두 평균을 기준선으로 그으면 평면이 네 칸으로 나뉩니다.




그림 1-2 두 평균선으로 나눈 네 칸. 오른쪽 위와 왼쪽 아래의 점은 두 편차의 부호가 같아 곱이 양수, 나머지 두 칸의 점은 곱이 음수다.

칸	스트레스 편차	소진 편차	편차의 곱
오른쪽 위	+	+	+
왼쪽 아래	-	-	+
왼쪽 위	-	+	-
오른쪽 아래	+	-	-

두 변수가 같은 방향으로 움직이면 점이 오른쪽 위와 왼쪽 아래에 몰리고, **편차의 곱이 대부분 양수**가 됩니다. 반대 방향이면 음수가 대부분입니다. 아무 관계가 없으면 네 칸에 고르게 흩어져 양수와 음수가 상쇄됩니다.

그래서 편차의 곱을 모두 더해 평균 낸 값을 **공분산(covariance)**이라 합니다.

$$\text{cov}(X, Y) = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{n - 1}$$

편차의 곱의 평균. $n - 1$ 로 나누는 이유는 1권 2장과 같습니다

● 공분산

```
cov(d$stress, d$burnout)
```

실행 결과

```
[1] 0.2297809
```

양수입니다. 300명 가운데 214명이 곱이 양수인 두 칸에 있었습니다.

분산은 자기 자신과의 공분산입니다

공분산 식에서 Y 자리에 X 를 넣으면 $\sum (X_i - \bar{X})^2 / (n - 1)$, 곧 분산이 됩니다.

분산이 "한 변수가 평균 주위로 얼마나 흩어지는가"라면, 공분산은 "두 변수가 평균 주위에서 **얼마나 같은 방향으로** 흩어지는가"입니다.

공분산만으로는 크기를 말할 수 없습니다

0.23이 큰 값일까요. 알 수 없습니다. 공분산은 단위를 따라가기 때문입니다.

소진을 5점 척도가 아니라 100점 만점으로 바꿔 잤다면 소진의 편차가 모두 25배가 되고, 공분산도 25배인 5.74가 됩니다. 관계는 그대로인데 숫자만 달라집니다. 키와 몸무게의 공분산은 센티미터로 재느냐 미터로 재느냐에 따라 100배가 차이 납니다.

■ 단위를 없앤다 — 상관계수

해결책은 1권 2장의 z 점수와 같습니다. 각 변수의 표준편차로 나눠 단위를 없앱니다.

$$r = \frac{\text{cov}(X, Y)}{s_X s_Y}$$

공분산을 두 표준편차의 곱으로 나눈 값

- 정의대로 계산한 값과 `cor()`의 값

```
cov(d$stress, d$burnout) / (sd(d$stress) * sd(d$burnout))
cor(d$stress, d$burnout)
```

실행 결과

```
[1] 0.5505026
[1] 0.5505026
```

$r = .55$ 입니다. 같은 계산을 다르게 볼 수도 있습니다. 두 변수를 먼저 z 점수로 바꾸면 표준편차가 모두 1이 되므로, 상관계수는 z 점수끼리 곱한 값의 평균이 됩니다.


- z 점수의 곱으로 계산해도 같습니다

```
zx <- scale(d$stress)
zy <- scale(d$burnout)
sum(zx * zy) / (nrow(d) - 1)
```

실행 결과

```
[1] 0.5505026
```

이렇게 보면 상관계수가 왜 -1에서 +1 사이에 있는지도 이해됩니다. 모든 사람의 z_X 와 z_Y 가 똑같으면(점이 오른쪽 위로 향한 직선 위에 모두 놓이면) 곱의 평균이 분산과 같아져 1이 됩니다. 그보다 더 커질 수는 없습니다.



부호 = 기울어진 방향 · 크기 = 직선 주위에 모인 정도

그림 1-3 상관계수의 크기에 따른 점구름의 모양. 부호는 기울어진 방향을, 크기는 점들이 직선 주위에 얼마나 촘촘히 모였는지를 나타낸다. 각 패널은 100명.

상관계수는 기울기가 아니라 촘촘함입니다

그림 1-3에서 $r = .8$ 과 $r = .4$ 의 점구름은 기울기가 비슷해 보여도 **흩어진 정도**가 다릅니다. 상관계수가 재는 것은 "점들이 직선 주위에 얼마나 모여 있는가"입니다.

"X가 1 오를 때 Y가 얼마나 오르는가"는 상관계수가 답하지 않습니다. 그것이 2장의 회귀계수입니다.

$ r $	해석 (Cohen, 1988)
.10	작은 관계
.30	중간 관계
.50 이상	큰 관계

스트레스와 소진의 $r = .55$ 는 큰 관계에 해당합니다. 다만 이 기준은 분야를 가리지 않은 대략의 출발점입니다. 같은 개념을 다른 척도로 잴 두 점수라면 .50은 오히려 낮은 값입니다.

r^2 — 함께 나눠 가진 변동

상관계수를 제공하면 해석이 하나 더 생깁니다.

$$r^2 = .55^2 = .303$$

소진 변동 가운데 스트레스와 겹치는 비율

소진 점수가 사람마다 다른 정도(변동) 가운데 30%가 스트레스의 차이와 겹친다는 뜻입니다. 나머지 70%는 스트레스로는 설명되지 않는 몫입니다.




그림 1-4 두 변수의 변동을 원으로 그리면 겹치는 부분이 r^2 이다. 스트레스와 소진은 변동의 30%를 함께 나눠 갖는다. (개념도)

이 30%라는 숫자를 기억해 두십시오. 2장에서 스트레스로 소진을 예측하는 회귀분석을 하면 결정계수 R^2 이 정확히 .303으로 나옵니다. 그리고 그 R^2 은 1권 9장의 η^2 과 같은 개념입니다.

■ 상관이 0이 아닌가 — 유의성 검정

표본에서 구한 $r = .55$ 가 모집단에서도 0이 아니라고 말할 수 있을까요. 1권에서 늘 하던 질문입니다. 영가설은 모집단 상관계수 ρ (로)가 0이라는 것입니다.

$$H_0 : \rho = 0$$

검정통계량은 t 입니다.

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} = \frac{.5505 \times \sqrt{298}}{\sqrt{1-.303}} = 11.38$$

자유도는 $n - 2 = 298$

● 상관계수의 유의성 검정

```
cor.test(d$stress, d$burnout)
```

실행 결과

Pearson's product-moment correlation

data: d\$stress and d\$burnout

t = 11.383, df = 298, p-value < 2.2e-16

alternative hypothesis: true correlation is not equal to 0

95 percent confidence interval:

0.4663326 0.6247942

sample estimates:

cor

0.5505026

출력의 이 자리	값	의미
t, df	11.383, 298	위에서 손으로 구한 값
p-value	< 2.2e-16	$p < .001$
95 percent confidence interval	.466 ~ .625	모집단 상관계수의 95% 신뢰구간
cor	.5505	표본 상관계수

$r(298) = .55, p < .001$ 입니다. 신뢰구간이 .47~.62로 0을 멀리 벗어나 있습니다.

표본이 크면 작은 상관도 유의합니다

$n = 300$ 이면 $|r|$ 이 .113만 넘어도 $p < .05$ 가 됩니다. $r = .12$ 는 $r^2 = .014$, 변동의 1.4%를 공유한다는 뜻입니다. 유의하다고 해서 의미 있는 관계라고 할 수는 없습니다.

1권 5장에서 본 것과 같습니다. **유의확률은 "0이 아닌가"에만 답하고, 크기는 r 자체가 말합니다.** 논문에서는 둘을 함께 보고합니다.

■ 여러 변수를 한 번에 — 상관행렬

실제 논문에서는 주요 변수 사이의 상관을 표 하나로 보여줍니다. `psych` 패키지의 `corr.test()` 가 상관계수와 유의확률을 함께 계산합니다.

● 다섯 변수의 상관행렬

```
library(psych)
vars <- d[, c("stress", "support", "efficacy", "burnout", "turnover")]
ct <- corr.test(vars, adjust = "none")
round(ct$r, 2)
round(ct$p, 3)
```

실행 결과

	stress	support	efficacy	burnout	turnover
stress	1.00	-0.22	-0.14	0.55	0.44
support	-0.22	1.00	0.31	-0.36	-0.22
efficacy	-0.14	0.31	1.00	-0.32	-0.11
burnout	0.55	-0.36	-0.32	1.00	0.56
turnover	0.44	-0.22	-0.11	0.56	1.00

	stress	support	efficacy	burnout	turnover
stress	0.000	0	0.015	0	0.000
support	0.000	0	0.000	0	0.000
efficacy	0.015	0	0.000	0	0.051
burnout	0.000	0	0.000	0	0.000
turnover	0.000	0	0.051	0	0.000

첫 번째 표가 상관계수, 두 번째 표가 유의확률입니다. 대각선을 기준으로 위아래가 같습니다.

소진은 나머지 네 변수와 모두 관련이 있습니다. 스트레스(.55), 이직의도(.56)와는 양의 관계, 사회적지지(-.36), 자기효능감(-.32)과는 음의 관계입니다. 유일하게 유의하지 않은 것은 자기효능감과 이직의도(-.11, $p = .051$)입니다.

adjust 인자에 대해

`corr.test()` 는 기본적으로 유의확률을 다중비교 보정(Holm)합니다. 상관을 10쌍 보면 1권 10장에서 본 것처럼 제1종 오류가 누적되기 때문입니다.

그러나 학위논문의 상관표는 관례적으로 **보정하지 않은 유의확률**을 표시합니다. 상관표의 목적이 가설검정보다 변수 간 관계를 개관하는 데 있기 때문입니다. 여기서도 `adjust = "none"` 으로 보정 없는 값을 썼습니다. 상관 자체가 연구 가설이라면 보정을 고려합니다.

■ 상관계수가 속이는 네 가지 경우

상관계수는 편리하지만 **산점도를 숫자 하나로 줄인 것**입니다. 줄이는 과정에서 정보가 사라집니다. 다음 네 경우는 숫자만 보면 놓칩니다.

1. 직선이 아닌 관계

통계학자 Anscombe(1973)가 만든 자료 네 쌍입니다. R에 `anscombe` 라는 이름으로 들어 있습니다.

● 네 자료의 상관계수

```
sapply(1:4, function(i) cor(anscombe[[i]], anscombe[[i + 4]]))
```

실행 결과

```
[1] 0.8164205 0.8162365 0.8162867 0.8165214
```

네 쌍 모두 $r = .816$ 입니다. 평균과 표준편차도 거의 같습니다. 그런데 산점도는 전혀 다릅니다.




그림 1-5 Anscombe의 네 자료. 상관계수는 모두 .816이지만 ① 직선 관계, ② 곡선 관계, ③ 이상치 하나가 기울기를 바꾼 경우, ④ 이상치 하나가 관계를 만들어 낸 경우로 모두 다르다.

② 곡선 관계는 **상관계수가 직선 관계만 잰다**는 것을 보여줍니다. 뒤집힌 U자 관계라면 관계가 아주 강해도 r 은 0 근처가 될 수 있습니다. 각성 수준과 수행처럼 "적당할 때 가장 좋은" 관계가 그렇습니다.

2. 이상치 하나

③과 ④는 **점 하나**가 상관계수를 좌우합니다. ④는 점 하나를 빼면 관계 자체가 없습니다. 사례 수가 적을수록 이상치의 힘이 커집니다. 4장에서 이런 점을 찾는 방법을 다룹니다.

해결책은 하나입니다

상관계수를 보기 전에 **산점도를 그립니다**. 그림 1-5의 네 경우는 모두 산점도에서 한눈에 보입니다. `plot()` 한 줄이면 됩니다. 변수가 많다면 `pairs(vars)` 가 모든 쌍의 산점도를 한 번에 그립니다.

3. 범위 제한

스트레스가 높은 사람(3.5점 이상)만 따로 모아 상관을 구해 봅니다. 예를 들어 고위험군만 모집한 연구가 이런 상황입니다.

● 스트레스 3.5점 이상인 사람만

```
high <- d[d$stress ≥ 3.5, ]
nrow(high)
cor(high$stress, high$burnout)
```

실행 결과

```
[1] 91
[1] 0.3421627
```

전체에서 .55였던 상관이 **.34로 떨어졌습니다**. 관계가 약해진 것이 아닙니다. 스트레스의 범위가 좁아져서 스트레스의 차이로 소진의 차이를 보여줄 여지가 줄었을 뿐입니다.




그림 1-6 범위 제한. 스트레스 3.5점 이상(진한 점)만 보면 점구름이 뭉글어져 상관이 .34로 낮아진다. 관계는 같은데 보이는 범위가 좁아졌을 뿐이다.

입사 시험 점수와 입사 후 업무 성과의 상관이 낮게 나오는 이유도 이것입니다. 시험 점수가 높은 사람만 입사했기 때문에 범위가 잘려 있습니다.

4. 제3변수

이 자료에서 근속연수와 직무만족의 상관을 구하면 이렇습니다.

● 근속연수와 직무만족

```
cor(d$tenure, d$satisfaction)
```

실행 결과

```
[1] 0.2572506
```

$r = .26$, 유의한 양의 상관입니다. 오래 다닐수록 만족도가 높아진다고 해석하고 싶어집니다.

그런데 직급별로 나눠서 다시 구해 보면 이야기가 달라집니다.

● 직급 안에서 다시 구한 상관

```
d$position <- factor(d$position, levels = c("사원", "대리", "과장이상"))
apply(split(d, d$position), function(g) cor(g$tenure, g$satisfaction))
```

실행 결과

사원	대리	과장이상
-0.052638493	0.008453253	0.001553163

같은 직급 안에서는 **상관이 사실상 0**입니다. 전체에서 보인 .26은 근속연수가 만족을 높여서가 아니라, 근속연수가 길수록 직급이 높고 직급이 높을수록 만족이 높았기 때문에 생긴 것입니다. 직급이라는 **제3변수**가 두 변수를 함께 움직였습니다.




그림 1-7 제3변수. 전체로 보면 근속연수와 직무만족이 함께 오르지만(회색 선), 직급 안에서는 관계가 없다(색깔별 선). 직급이 두 변수를 함께 끌어올린 것이다.

상관은 인과가 아닙니다

상관이 보여주는 것은 함께 움직인다는 사실뿐입니다. 이유는 셋 중 하나입니다. X 가 Y 를 움직였거나, Y 가 X 를 움직였거나, 제3의 변수가 둘을 함께 움직였습니다. 상관계수는 이 셋을 구분하지 못합니다.

다른 변수를 **고정한 채로** 관계를 보는 방법이 3장의 다중회귀입니다. 위에서 직급별로 나눠 본 것이 그 발상의 가장 단순한 형태입니다.

■ 서열척도라면 — 스피어만 상관

피어슨 상관계수는 두 변수가 **등간척도 이상**이라는 전제에서 계산합니다. 1권 1장에서 다룬 척도 구분이 여기서 다시 쓰입니다.

한쪽이라도 서열척도(학년, 순위, 단일 리커트 문항)이거나, 이상치가 걱정되거나, 관계가 직선은 아니어도 한 방향으로 꾸준히 오르는 경우에는 **스피어만 순위상관(ρ)**을 씁니다. 원점수 대신 순위를 매긴 뒤 상관을 구하는 방법입니다.

● 순위상관

```
cor.test(d$stress, d$burnout, method = "spearman", exact = FALSE)
```

실행 결과

```
Spearman's rank correlation rho

data:  d$stress and d$burnout
S = 1953513, p-value < 2.2e-16
alternative hypothesis: true rho is not equal to 0
sample estimates:
      rho
0.5658811
```

$\rho = .57$ 로 피어슨 $r = .55$ 와 비슷합니다. 이 자료는 이상치가 없고 관계가 직선에 가까워 두 방법의 결과가 거의 같습니다. 두 값이 크게 다르다면 산점도를 다시 볼 신호입니다.

■ 논문 결과표

상관표는 대각선 아래 삼각형만 채우고, 왼쪽에 평균과 표준편차를 함께 둡니다.

표 1. 주요 변수의 기술통계와 상관

변수	M	SD	1	2	3	4	5
1. 직무스트레스	3.08	0.62	—				
2. 사회적지지	3.52	0.60	-.22***	—			
3. 자기효능감	3.61	0.56	-.14*	.31***	—		
4. 소진	2.86	0.68	.55***	-.36***	-.32***	—	
5. 이직의도	2.72	0.82	.44***	-.22***	-.11	.56***	—

주. N = 300. * $p < .05$, ** $p < .01$, *** $p < .001$.

결과 서술 예시

주요 변수 간의 관계를 확인하기 위해 피어슨 상관분석을 실시하였다(표 1). 직무스트레스는 소진($r = .55, p < .001$) 및 이직의도($r = .44, p < .001$)와 정적 상관을 보였고, 사회적지지($r = -.22, p < .001$) 및 자기효능감($r = -.14, p = .015$)과는 부적 상관을 보였다. 소진은 이직의도와 높은 정적 상관을 보였다($r = .56, p < .001$). 자기효능감과 이직의도의 상관은 유의하지 않았다($r = -.11, p = .051$).

상관표는 회귀분석에 앞서 **변수 사이의 관계를 미리 보여주는 자리**입니다. 독립변수끼리 상관이 지나치게 높으면(대략 .80 이상) 5장의 다중공선성을 의심할 근거가 되므로, 이 표를 먼저 살펴봅니다.

점검 항목

- ☐ 상관계수를 보기 전에 산점도를 그렸다
- ☐ 공분산은 단위에 따라 바뀌고, 상관계수는 단위가 없다는 것을 안다
- ☐ 상관계수는 기울기가 아니라 직선 주위의 촘촘함이라는 것을 안다
- ☐ r^2 이 공유하는 변동의 비율이라는 것을 안다
- ☐ 곡선 관계, 이상치, 범위 제한, 제3변수를 확인했다
- ☐ 서열척도라면 스피어만 상관을 썼다
- ☐ 상관표에 **M**, **SD**와 유의 표시를 함께 넣었다

요약 — 상관계수는 공분산을 두 표준편차로 나눠 단위를 없앤 값이며, **점수끼리 곱한 값의 평균**입니다. 점들이 직선 주위에 얼마나 촘촘한지를 -1에서 +1로 나타내고, 제공한 두 변수가 공유하는 변동의 비율입니다. 숫자 하나로 줄이는 과정에서 곡선, 이상치, 범위 제한, 제3변수가 가려지므로 **산점도를 먼저 그립니다**.

선 하나로 요약하기 — 단순회귀

상관계수는 두 변수가 얼마나 촘촘히 함께 움직이는지를 알려줍니다. 그러나 "스트레스가 1점 오르면 소진은 얼마나 오르는가"에는 답하지 못합니다. 그 질문에 답하는 것이 회귀선의 기울기입니다.

■ 상관에서 한 걸음 더

1장에서 직무스트레스와 소진의 상관은 $r = .55$ 였습니다. 이 숫자는 점들이 직선 주위에 얼마나 모여 있는지를 말해 줍니다. 그런데 연구자가 정말 알고 싶은 것은 대개 이런 것입니다.

- 스트레스가 1점 높은 사람은 소진이 **몇 점** 높은가
- 스트레스가 4점인 사람의 소진은 **몇 점일 것으로** 예상되는가

둘 다 **선을 하나 그어야** 답할 수 있습니다. 산점도를 가장 잘 요약하는 직선을 찾고, 그 기울기와 높이를 읽는 것이 회귀분석입니다.




그림 2-1 직무스트레스와 소진의 산점도에 그은 회귀선. 기울기 0.60은 스트레스가 1점 높을 때 소진이 평균적으로 0.60점 높다는 뜻이다.

■ 직선의 식

중학교에서 배운 직선의 식 $y = ax + b$ 와 같습니다. 회귀분석에서는 기호만 바꿔 씁니다.

$$\hat{Y} = b_0 + b_1 X$$

b_0 은 절편, b_1 은 기울기

$\hat{Y}$ 위의 모자(^, "와이 햇")는 **실제 값이 아니라 직선이 예측한 값**이라는 표시입니다. 실제 소진 Y 와 예측된 소진 $\hat{Y}$ 의 차이를 **잔차(residual)**라고 합니다.

$$e_i = Y_i - \hat{Y}_i$$

실제 값 - 예측 값. 직선이 설명하지 못한 몫




그림 2-2 잔차는 각 점에서 회귀선까지의 세로 거리다. 선보다 위에 있는 사람은 잔차가 양수(예측보다 소진이 높음), 아래에 있는 사람은 음수다.

잔차를 세로 거리로 재는 데는 이유가 있습니다. 회귀분석의 목적이 X 로 Y 를 **예측하는 것**이기 때문입니다. 예측이 얼마나 빗나갔는지는 Y 방향의 거리로만 잹니다.

■ 어떤 선이 가장 좋은 선인가

산점도 위에 그을 수 있는 직선은 무수히 많습니다. 그중 하나를 고르는 기준이 필요합니다.

잔차가 가장 작은 선을 고르면 될 것 같습니다. 그런데 잔차를 그냥 더하면 양수와 음수가 상쇄됩니다. 그래서 1권 2장에서 분산을 구할 때처럼 **제곱해서 더한 값이 가장 작은 선**을 고릅니다. 이를 **최소제곱법(ordinary least squares, OLS)**이라 합니다.

$$SSE = \sum (Y_i - \hat{Y}_i)^2 \text{ 를 가장 작게 하는 } b_0, b_1$$

SSE는 잔차제곱합, Sum of Squared Errors




그림 2-3 같은 점들에 그은 두 직선. 잔차를 한 번으로 하는 정사각형의 넓이를 모두 더한 값이 잔차제곱합이다. 최소제곱선은 이 넓이의 합이 가장 작은 선이다. (개념도)

회귀선은 "조건부 평균"을 잇는 선입니다

1권 2장에서 평균은 **편차제곱합을 가장 작게 만드는 값**이었습니다. 회귀선은 같은 원리를 한 단계 넓힌 것입니다.

스트레스가 3점인 사람들만 모으면 그들의 소진 평균이 있습니다. 4점인 사람들의 소진 평균도 있습니다. 회귀선은 **X 의 각 값에서 Y 의 평균이 어디쯤인지**를 직선 하나로 이은 것입니다. 그래서 $\hat{Y}$ 를 "스트레스가 X 점인 사람들의 평균적인 소진"으로 읽습니다.

최소제곱을 만족하는 기울기와 절편은 공식으로 바로 구해집니다.

$$b_1 = r \cdot \frac{s_Y}{s_X}, \quad b_0 = \bar{Y} - b_1 \bar{X}$$

기울기는 상관계수에 두 표준편차의 비를 곱한 값

기울기 공식이 상관과 회귀의 관계를 그대로 보여줍니다. **상관계수는 두 변수를 표준편차 단위로 바꿨을 때의 기울기**이고, 거기에 원래 단위를 되돌려 준 것이 회귀계수입니다.

손으로 계산해 봅시다. 스트레스의 평균과 표준편차는 3.080, 0.618, 소진은 2.859, 0.675입니다.

$$b_1 = .5505 \times \frac{0.6754}{0.6180} = 0.602$$

$$b_0 = 2.859 - 0.602 \times 3.080 = 1.006$$

절편 공식을 바꿔 쓰면 $\bar{Y} = b_0 + b_1\bar{X}$ 입니다. 회귀선은 언제나 두 평균이 만나는 점 $(\bar{X}, \bar{Y})$ 을 지납니다.

■ R로 돌리기

● lm()으로 적합하고 coef()로 계수를 봅니다

```
d <- read.csv("data/survey.csv")
fit <- lm(burnout ~ stress, data = d)
coef(fit)
```

실행 결과

(Intercept)	stress
1.006269	0.601694

손으로 구한 값과 같습니다. 회귀식은 다음과 같습니다.

$$\widehat{\text{소진}} = 1.006 + 0.602 \times \text{직무스트레스}$$

기울기 읽기

스트레스가 1점 높은 사람은 소진이 평균적으로 0.60점 높습니다. 이것이 기울기의 전부입니다. 5점 척도에서 0.6점이면 작지 않은 차이입니다.

"1점 오르면"이라고 읽지 않고 "1점 높은 사람은"이라고 읽는 것에 주의하십시오. 이 자료는 한 사람의 스트레스가 변할 때 소진이 어떻게 변하는지를 본 것이 아니라, **스트레스가 서로 다른 사람들을 비교한 것**입니다.

절편 읽기

절편 1.006은 **스트레스가 0점인 사람의 예측 소진**입니다. 그런데 이 척도는 1~5점이라 0점인 사람은 있을 수 없습니다. 이 절편은 직선의 높이를 정하는 데 필요할 뿐 그 자체로는 의미가 없습니다.

절편에 의미를 주고 싶다면 독립변수를 **평균 중심화(mean centering)**합니다. 각 점수에서 평균을 빼는 것입니다.

- 스트레스를 평균 중심화한 뒤 다시 적합

```
d$stress_c <- d$stress - mean(d$stress)
coef(lm(burnout ~ stress_c, data = d))
```

실행 결과

(Intercept)	stress_c
2.859467	0.601694

기울기는 그대로이고, 절편이 **2.859**, 곧 **소진의 평균**이 되었습니다. 중심화된 스트레스가 0이라는 것은 스트레스가 평균인 사람이라는 뜻이기 때문입니다. 이 기법은 8장 조절효과에서 다시 중요하게 쓰입니다.

예측값과 잔차

`fitted()` 는 각 사람의 예측값을, `resid()` 는 잔차를 돌려줍니다.

- 처음 다섯 사람의 예측값과 잔차

```
head(data.frame(stress = d$stress, burnout = d$burnout,
                 fitted = round(fitted(fit), 3), resid = round(resid(fit), 3)), 5)
```

실행 결과

	stress	burnout	fitted	resid
1	3.83	3.33	3.311	0.019
2	2.83	2.89	2.709	0.181
3	3.17	3.22	2.914	0.306
4	3.17	2.33	2.914	-0.584
5	3.50	2.44	3.112	-0.672

다섯 번째 사람은 스트레스가 3.50점이라 소진이 3.11점으로 예측되었지만 실제로는 2.44점이었습니다. 잔차 -0.67은 **스트레스만으로 예상한 것보다 0.67점 덜 소진되었다**는 뜻입니다. 이 차이는 스트레스 말고 다른 무언가, 예를 들어 사회적지나 자기효능감에서 왔을 수 있습니다. 3장의 다중회귀가 그 몫을 찾아 나섭니다.

■ 얼마나 설명하는가 — 결정계수

직선을 찾았으니, 그 직선이 소진의 차이를 **얼마나 설명하는지** 물을 차례입니다. 1권 9장에서 분산분석을 할 때와 똑같이 제곱합을 쪼갭니다.

한 사람의 소진이 전체 평균에서 떨어진 거리는 두 조각으로 나뉩니다.

$$\underbrace{(Y_i - \bar{Y})}_{\text{총 편차}} = \underbrace{(\hat{Y}_i - \bar{Y})}_{\text{회귀선이 설명한 몫}} + \underbrace{(Y_i - \hat{Y}_i)}_{\text{잔차}}$$

전체 평균에서 회귀선까지 + 회귀선에서 실제 값까지




그림 2-4 한 사람의 편차가 두 조각으로 나뉜다. 평균에서 회귀선까지는 스트레스로 설명되는 몫, 회귀선에서 실제 점까지는 설명되지 않는 몫이다.
(개념도)

각 조각을 제곱해 300명 모두 더하면 제곱합이 됩니다.

$$SS_T = SS_R + SS_E$$


전체 = 회귀 + 잔차

제곱합	의미	값
$SS_T = \sum(Y_i - \bar{Y})^2$	소진의 전체 변동	136.41
$SS_R = \sum(\hat{Y}_i - \bar{Y})^2$	스트레스로 설명된 변동	41.34
$SS_E = \sum(Y_i - \hat{Y}_i)^2$	설명되지 않은 변동	95.07

설명된 몫의 비율이 **결정계수(coefficient of determination) R^2** 입니다.

$$R^2 = \frac{SS_R}{SS_T} = \frac{41.34}{136.41} = .303$$

전체 변동 가운데 회귀선이 설명한 비율



$$R^2 = \frac{SS_R}{SS_T} = \frac{41.34}{136.41} = .303$$

그림 2-5 소진의 전체 제곱합 136.41이 회귀 41.34와 잔차 95.07로 나뉜다. 회귀가 차지하는 비율 30.3%가 결정계수다.

1장의 $r^2 = .303$ 과 **정확히 같은 값**입니다. 독립변수가 하나일 때 결정계수는 상관계수의 제곱입니다.

R^2 , r^2 , η^2 은 같은 질문에 대한 답입니다

세 지표 모두 "종속변수의 변동 가운데 몇 %가 설명되는가"를 묻습니다.

지표	독립변수	나온 곳
r^2	연속변수 1개	1장 상관
R^2	연속변수 여러 개도 가능	2장, 3장 회귀
η^2	집단(범주)	1권 9장 분산분석

분산분석의 SS_B 가 회귀의 SS_R 에, SS_W 가 SS_E 에 해당합니다. 6장에서 두 분석이 실제로 같은 계산임을 확인합니다.

추정의 표준오차

잔차제곱합을 자유도로 나누고 제곱근을 씌우면 **잔차의 표준편차**가 됩니다.

$$s_e = \sqrt{\frac{SS_E}{n-2}} = \sqrt{\frac{95.07}{298}} = 0.565$$

자유도 $n-2$: 기울기와 절편 두 개를 추정했으므로

회귀식으로 예측했을 때 보통 0.56점 안팎으로 빗나간다는 뜻입니다. 소진의 원래 표준편차 0.675와 비교하면, 스트레스를 알고 예측할 때 오차가 그만큼 줄었습니다. R 출력에서는 `Residual standard error` 라는 이름으로 나옵니다.

■ 기울기가 0이 아닌가

표본에서 구한 기울기 0.602가 모집단에서도 0이 아니라고 할 수 있을까요. 모집단의 기울기를 β_1 이라 하면 영가설은 다음과 같습니다.

$$H_0 : \beta_1 = 0$$

스트레스가 달라도 소진의 평균은 같다

계수의 t 검정

1권의 t 검정과 같은 구조입니다. 추정값을 그 추정값이 흔들리는 정도(표준오차)로 나눕니다.

$$t = \frac{b_1}{SE(b_1)} = \frac{0.6017}{0.0529} = 11.38$$

자유도 $n-2 = 298$

1장에서 상관계수를 검정할 때의 $t = 11.38$ 과 같은 값입니다. 독립변수가 하나일 때 "상관이 0인가"와 "기울기가 0인가"는 같은 질문이기 때문입니다.

모형의 F 검정

`anova()` 는 1권 9장과 같은 분산분석표를 보여줍니다.

회귀의 분산분석표

`anova(fit)`

실행 결과

Analysis of Variance Table

Response: burnout

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
stress	1	41.339	41.339	129.58	< 2.2e-16 ***
Residuals	298	95.070	0.319		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$$F = \frac{MS_R}{MS_E} = \frac{41.339}{0.319} = 129.58$$

설명된 분산 ÷ 설명되지 않은 분산

독립변수가 하나일 때는 $F = t^2$ 입니다($11.383^2 = 129.58$). 같은 검정을 다른 모양으로 한 것입니다. 3장에서 독립변수가 여럿이 되면 F 검정과 계수별 t 검정은 서로 다른 질문을 하게 됩니다.

기울기의 신뢰구간

계수의 95% 신뢰구간

`confint(fit)`

실행 결과

	2.5 %	97.5 %
(Intercept)	0.6795218	1.3330163
stress	0.4976724	0.7057157

기울기의 95% 신뢰구간은 [0.498, 0.706]입니다. 1권 6장의 해석을 그대로 따릅니다. 이 방법으로 구간을 만들면 100번 중 95번은 모집단 기울기를 포함합니다. 구간이 0을 포함하지 않으므로 t 검정의 결론과 같습니다.

신뢰구간은 유의성보다 더 많은 것을 알려줍니다. 스트레스가 1점 높을 때 소진이 적게는 **0.50점**, 많게는 **0.71점** 높다는 범위입니다.

■ summary() 출력 전체 읽기

실제 분석에서는 `summary()` 한 번으로 지금까지의 값을 모두 봅니다.

● 단순회귀의 전체 출력

```
summary(fit)
```

실행 결과

Call:

```
lm(formula = burnout ~ stress, data = d)
```

Residuals:

Min	1Q	Median	3Q	Max
-1.85305	-0.35807	-0.02364	0.36623	1.45263

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.00627	0.16603	6.061	4.09e-09 ***
stress	0.60169	0.05286	11.383	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5648 on 298 degrees of freedom

Multiple R-squared: 0.3031, Adjusted R-squared: 0.3007

F-statistic: 129.6 on 1 and 298 DF, p-value: < 2.2e-16

출력의 이 자리	값	의미
Residuals	최솟값 ~ 최댓값	잔차의 분포. 중앙값이 0 근처, 1Q와 3Q가 대칭이면 좋은 신호
(Intercept) 행 Estimate	1.00627	절편 b_0
stress 행 Estimate	0.60169	기울기 b_1
Std. Error	0.05286	기울기의 표준오차
t value, Pr(> t)	11.383, < 2e-16	기울기의 t 검정
Residual standard error	0.5648 on 298 DF	추정의 표준오차 s_e
Multiple R-squared	0.3031	결정계수 R^2
Adjusted R-squared	0.3007	수정 결정계수 (3장)
F-statistic	129.6 on 1 and 298 DF	모형 전체의 F 검정

절편의 t 검정($p < .001$)은 보통 해석하지 않습니다. "스트레스가 0점일 때 소진이 0인가"를 검정한 것이라 연구 질문과 관계가 없습니다.

■ 예측과 두 가지 구간

회귀식이 있으면 스트레스 점수를 넣어 소진을 예측할 수 있습니다.

- 스트레스가 2점, 3점, 4점일 때의 예측

```
predict(fit, newdata = data.frame(stress = c(2, 3, 4)))
```

실행 결과

```
      1      2      3
2.209657 2.811351 3.413045
```

스트레스가 4점인 사람의 예측 소진은 3.41점입니다. 그런데 이 예측이 얼마나 정확할까요. 여기서 **두 종류의 구간**을 구분해야 합니다.

● 같은 예측값, 다른 두 구간

```
predict(fit, newdata = data.frame(stress = 4), interval = "confidence")
predict(fit, newdata = data.frame(stress = 4), interval = "prediction")
```

실행 결과

```
      fit      lwr      upr
1 3.413045 3.297817 3.528274
      fit      lwr      upr
1 3.413045 2.295541 4.53055
```

구간	물는 것	스트레스 4점일 때
신뢰구간 (<code>confidence</code>)	스트레스 4점인 사람들의 평균 소진은 어디쯤인가	[3.30, 3.53]
예측구간 (<code>prediction</code>)	스트레스 4점인 한 사람 의 소진은 어디쯤인가	[2.30, 4.53]

예측구간이 훨씬 넓습니다. 평균은 300명의 정보로 꽤 정확히 추정할 수 있지만, 한 사람의 점수에는 **회귀선 주위의 개인차 (잔차)**가 그대로 더해지기 때문입니다.




그림 2-6 회귀선 주위의 두 띠. 좁은 띠는 평균 소진의 95% 신뢰구간, 넓은 띠는 개인 소진의 95% 예측구간이다. 신뢰구간은 자료의 가운데(평균 근처)에서 가장 좁다.

자료 범위 밖으로 예측하지 않습니다

이 자료의 스트레스는 1.33~4.50점 사이에 있습니다. 회귀식에 0점이나 6점을 넣으면 계산은 되지만 그 값을 믿을 근거가 없습니다. 관측된 범위 밖에서도 관계가 직선이라는 보장이 없기 때문입니다. 이를 **외삽(extrapolation)**이라

하며 피해야 합니다.

■ 표준화 회귀계수

두 변수를 모두 z 점수로 바꾼 뒤 회귀분석을 하면 **표준화 회귀계수** β (베타)를 얻습니다.

● 두 변수를 표준화한 뒤 적합

```
coef(lm(scale(burnout) ~ scale(stress), data = d))
```

실행 결과

```
(Intercept) scale(stress)
-1.963741e-16  5.505026e-01
```

절편은 0입니다(두 평균이 모두 0이므로). **-1.963741e-16**은 컴퓨터의 계산 오차로 생긴 0입니다. 기울기 $\beta = .55$ 는 **상관계수와 같습니다**. 위에서 본 기울기 공식 $b_1 = r \cdot s_Y / s_X$ 에서 두 표준편차가 1이 되었기 때문입니다.

β 는 "스트레스가 **1표준편차** 높으면 소진이 **0.55표준편차** 높다"로 읽습니다. 단위가 없어서 서로 다른 척도의 독립변수를 비교할 수 있게 됩니다. 이 쓰임은 3장에서 다룹니다.

'회귀'라는 이름의 유래

19세기 영국의 Francis Galton은 부모와 자녀의 키를 조사하다가, 키가 아주 큰 부모의 자녀는 부모보다 덜 크고, 아주 작은 부모의 자녀는 부모보다 덜 작다는 것을 발견했습니다. 자녀의 키가 평균 쪽으로 **되돌아간다(regress)**는 뜻에서 이 현상을 "평균으로의 회귀"라고 불렀습니다.

이유는 상관이 1보다 작기 때문입니다. z 점수로 보면 $\hat{z}_Y = r \cdot z_X$ 이고 $|r| < 1$ 이므로, 예측값은 언제나 평균 쪽으로 당겨집니다. 이 직선을 구하는 방법에 그 이름이 붙어 지금까지 쓰이고 있습니다.

■ 논문 결과표

표 2. 직무스트레스가 소진에 미치는 영향

변수	B	SE	β	t	p
(상수)	1.006	0.166		6.06	< .001
직무스트레스	0.602	0.053	.55	11.38	< .001

주. $N = 300$. $R^2 = .303$, $F(1, 298) = 129.58$, $p < .001$.

결과 서술 예시

직무스트레스가 소진에 미치는 영향을 검증하기 위해 단순회귀분석을 실시하였다(표 2). 회귀모형은 통계적으로 유의하였으며($F(1, 298) = 129.58, p < .001$), 직무스트레스는 소진 변동의 30.3%를 설명하였다($R^2 = .303$).

직무스트레스는 소진에 정적으로 유의한 영향을 미쳤다($B = 0.602, \beta = .55, t = 11.38, p < .001$). 직무스트레스가 1점 높을수록 소진은 평균 0.60점 높았으며, 기울기의 95% 신뢰구간은 $[0.498, 0.706]$ 이었다.

B 는 비표준화 계수로 원래 척도 단위의 해석을, β 는 표준화 계수로 크기 비교를 위해 함께 보고합니다.

점검 항목

- ☐ 기울기를 " X 가 1 높은 사람은 Y 가 평균 몇 점 높다"로 읽었다
- ☐ 절편이 의미 있는 값인지 확인했고, 필요하면 중심화했다
- ☐ 회귀선이 두 평균의 교점을 지난다는 것을 안다
- ☐ $SS_T = SS_R + SS_E$ 와 $R^2 = SS_R/SS_T$ 를 안다
- ☐ 단순회귀에서는 $R^2 = r^2, F = t^2, \beta = r$ 임을 안다
- ☐ 신뢰구간(평균)과 예측구간(개인)을 구분했다
- ☐ 자료 범위 밖으로 예측하지 않았다

요약 — 단순회귀는 산점도를 잔차제곱합이 가장 작은 직선 하나로 요약합니다. 기울기 은 " 가 1 높은 사람은 가 평균 얼마나 높은가"이고, 로 상관과 이어집니다. 제곱합을 회귀와 잔차로 쪼개 얻는 은 설명된 변동의 비율로, 1권의 과 같은 개념입니다.

다른 변수를 통제한다는 것 — 다중회귀

논문에서 가장 자주 보는 문장 가운데 하나가 "다른 변수를 통제한 상태에서"입니다. 이 장은 그 말이 계산으로는 무엇을 하는지, 그래서 회귀계수가 왜 달라지는지를 다룹니다.

■ 변수 하나로는 부족합니다

2장의 회귀식은 소진 변동의 30%를 설명했습니다. 나머지 70%는 스트레스가 아닌 다른 데서 옵니다. 1장의 상관표를 보면 후보가 있습니다. 사회적지지($r = -.36$)와 자기효능감($r = -.32$)도 소진과 관련이 있었습니다.

세 변수를 각각 따로 단순회귀하면 이렇습니다.

● 세 변수를 하나씩 따로 넣은 단순회귀

```
d <- read.csv("data/survey.csv")
for(v in c("stress", "support", "efficacy")) {
  m <- lm(reformulate(v, "burnout"), data = d)
  cat(sprintf("%-9s b = %.3f   R2 = %.3f\n", v, coef(m)[2], summary(m)$r.squared))
}
```

실행 결과

stress	b = 0.602	R2 = 0.303
support	b = -0.406	R2 = 0.129
efficacy	b = -0.382	R2 = 0.100

세 R^2 을 더하면 약 .53, 소진 변동의 53%입니다. 그런데 세 변수를 **한 모형에 함께** 넣으면 이보다 적게 나옵니다. 그리고 각 변수의 계수도 달라집니다. 왜 그런지가 이 장의 내용입니다.

■ 다중회귀식

독립변수가 둘 이상인 회귀를 **다중회귀(multiple regression)**라 합니다. 식은 단순회귀에 항을 더한 것입니다.

$$\hat{Y} = b_0 + b_1X_1 + b_2X_2 + b_3X_3$$

독립변수마다 기울기가 하나씩

R 코드도 **+**로 변수를 이어 붙이기만 하면 됩니다.

● 세 변수를 함께 넣은 다중회귀

```
fit <- lm(burnout ~ stress + support + efficacy, data = d)
summary(fit)
```

실행 결과

Call:

```
lm(formula = burnout ~ stress + support + efficacy, data = d)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-1.64745 -0.31448 -0.00898  0.36180  1.37610
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.83768     0.31473   9.016  < 2e-16 ***
stress        0.52646     0.05079  10.365  < 2e-16 ***
support      -0.22192     0.05477  -4.052 6.51e-05 ***
efficacy     -0.22655     0.05776  -3.922 0.000109 ***
---
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5282 on 296 degrees of freedom

Multiple R-squared: 0.3946, Adjusted R-squared: 0.3885

F-statistic: 64.32 on 3 and 296 DF, p-value: < 2.2e-16

$$\widehat{\text{소진}} = 2.838 + 0.526 \times \text{스트레스} - 0.222 \times \text{지지} - 0.227 \times \text{효능감}$$

변수	단순회귀의 b	다중회귀의 b
직무스트레스	0.602	0.526
사회적지지	-0.406	-0.222
자기효능감	-0.382	-0.227

세 계수가 모두 0 쪽으로 줄었습니다. 특히 지지와 효능감은 **거의 절반**이 되었습니다. 같은 자료, 같은 변수인데 계수가 달라졌습니다. 둘 중 무엇이 맞을까요.

둘 다 맞습니다. 다른 질문에 대한 답이기 때문입니다.




그림 3-1 단순회귀와 다중회귀의 계수. 세 변수 모두 함께 넣었을 때 0 쪽으로 줄어든다. 줄어든 만큼이 다른 변수와 겹치던 몫이다.

■ '통제한다'는 것의 의미

단순회귀의 계수 -0.406 은 "지지가 1점 높은 사람은 소진이 0.41점 낮다"입니다. 이 비교에는 함정이 있습니다. 지지가 높은 사람은 **효능감도 높고 스트레스는 낮은 경향**이 있습니다(1장 상관표에서 .31, $-.22$). 그러니 0.41점 가운데 일부는 지지 때문이 아니라 함께 따라온 높은 효능감과 낮은 스트레스 때문일 수 있습니다.

다중회귀의 계수 -0.222 는 다른 질문에 답합니다.

다중회귀 계수를 읽는 문장

"스트레스와 효능감이 같은 사람끼리 비교했을 때, 지지가 1점 높은 사람은 소진이 평균 0.22점 낮다."

"다른 변수를 통제했을 때"는 바로 이 **"다른 변수가 같은 사람끼리 비교했을 때"**를 줄인 말입니다. 1장에서 직급이 같은 사람끼리 근속연수와 만족의 관계를 본 것과 같은 발상입니다. 다중회귀는 그것을 연속변수에 대해, 여러 변수에 대해 한꺼번에 해 줍니다.

실제로 확인해 봅시다. 지지와 효능감이 같고(3.5점, 3.6점) 스트레스만 1점 다른 두 사람의 예측 소진입니다.

● 다른 변수는 같고 스트레스만 1점 다른 두 사람

```
two <- data.frame(stress = c(3, 4), support = 3.5, efficacy = 3.6)
predict(fit, newdata = two)
```

실행 결과

1	2
2.824780	3.351236

차이는 $3.351 - 2.825 = 0.526$, 스트레스의 다중회귀 계수 그대로입니다.

계산으로는 무엇을 하는가

"같은 사람끼리 비교"를 실제로 하려면 지지와 효능감이 똑같은 사람을 찾아야 합니다. 그런 사람은 거의 없습니다. 다중회귀는 다른 방법을 씁니다.

① 스트레스 가운데 지지·효능감으로 예측되는 부분을 걷어 냅니다. 스트레스를 지지와 효능감으로 회귀해 잔차를 구합니다. 이 잔차는 "지지·효능감과 무관한 스트레스"입니다.

② 그 잔차로 소진을 회귀합니다.

● 걷어 내고 남은 스트레스로 다시 회귀

```
e ← resid(lm(stress ~ support + efficacy, data = d))
coef(lm(d$burnout ~ e))
```

실행 결과

(Intercept)	e
2.8594667	0.5264557

기울기가 **0.526**, 다중회귀의 스트레스 계수와 소수점 끝자리까지 같습니다.



그림 3-2 '통제'의 계산 과정. 스트레스에서 지지·효능감으로 설명되는 부분을 걷어 내고, 남은 부분만으로 소진과의 기울기를 구한다. 이것이 다중회귀 계수다. (개념도)

통제는 '걷어 낸 뒤 남은 것'으로 재는 것입니다

다중회귀의 각 계수는 그 변수에서 다른 독립변수들과 겹치는 부분을 걷어 내고 남은 고유한 부분이 종속변수와 맺는 관계입니다.

그래서 계수가 줄어든 것은 이상한 일이 아닙니다. 단순회귀의 지지 계수에는 효능감·스트레스와 겹치는 몫까지 들어 있었고, 다중회귀에서는 그 몫이 빠졌습니다. 1장 끝에서 "상관은 인과가 아니다"라고 했던 문제를, 측정한 변수에 한해서는 이렇게 다룰 수 있습니다.

■ 왜 R^2 은 더한 것보다 작은가

세 변수의 변동이 서로 겹치기 때문입니다. 그림으로 보면 분명합니다.




그림 3-3 소진의 변동(가운데 원)과 두 독립변수의 변동. 두 독립변수가 겹치는 부분(c)은 따로 단순회귀하면 양쪽에서 한 번씩 세어진다. 다중회귀는 c를 한 번만 센다. (개념도)

단순회귀를 따로 하면 겹치는 부분 c가 양쪽 R^2 에 모두 들어갑니다. 더하면 두 번 세는 셈입니다. 다중회귀의 R^2 은 c를 한 번만 셉니다.

각 변수가 **혼자서만 설명하는 몫**은 그 변수를 모형에서 뺐을 때 R^2 이 얼마나 줄어드는지로 구합니다.

● 각 변수를 뺐을 때 줄어드는 R^2

```
r2 <- function(f) summary(lm(f, data = d))$r.squared
full <- r2(burnout ~ stress + support + efficacy)
full
c(stress = full - r2(burnout ~ support + efficacy),
  support = full - r2(burnout ~ stress + efficacy),
  efficacy = full - r2(burnout ~ stress + support))
```

실행 결과

```
[1] 0.3946177
      stress      support      efficacy
0.21970767 0.03357248 0.03146538
```




그림 3-4 소진 변동의 분해. 세 변수가 함께 39.5%를 설명하며, 그 가운데 각자의 고유한 몫은 22.0%, 3.4%, 3.1%이고 나머지 11.0%는 둘 이상이 함께 나눠 가진 몫이다.

스트레스 혼자만의 몫이 22.0%로 가장 크고, 지지와 효능감은 각각 3% 남짓입니다. 고유한 몫을 모두 더한 28.5%와 전체 39.5%의 차이 11.0%는 **어느 한 변수의 것이라고 할 수 없는 공유된 몫**입니다.

이 고유한 몫을 **준부분상관의 제곱(sr^2)**이라 부릅니다. 학위논문에서 "각 변수가 고유하게 설명하는 분산"을 보고할 때 이 값을 씁니다.

■ 계수끼리 비교하기 — 표준화 계수

세 변수 가운데 무엇이 소진과 가장 강하게 관련될까요. 비표준화 계수 b 로는 비교하기 어렵습니다. 변수마다 흩어진 정도가 달라 "1점"의 무게가 다르기 때문입니다. 여기서는 모두 1~5점 척도이지만, 연령(세)과 근속연수(년)처럼 단위가 아예 다르면 비교 자체가 불가능합니다.

2장처럼 **표준화 계수 β** 로 바꿉니다. `effectsize` 패키지가 신뢰구간까지 계산합니다.

● 표준화 회귀계수

```
library(effectsize)
standardize_parameters(fit)
```

실행 결과

```
# Standardization method: refit
```

Parameter	Std. Coef.	95% CI
(Intercept)	-1.77e-16	[-0.09, 0.09]
stress	0.48	[0.39, 0.57]
support	-0.20	[-0.29, -0.10]
efficacy	-0.19	[-0.28, -0.09]

변수	β	읽는 법
직무스트레스	.48	다른 두 변수가 같을 때, 1 SD 높으면 소진이 0.48 SD 높다
사회적지지	-.20	다른 두 변수가 같을 때, 1 SD 높으면 소진이 0.20 SD 낮다
자기효능감	-.19	다른 두 변수가 같을 때, 1 SD 높으면 소진이 0.19 SD 낮다




그림 3-5 표준화 회귀계수와 95% 신뢰구간. 스트레스의 영향이 가장 크고, 지지와 효능감은 크기가 비슷하다. 세 구간 모두 0을 지나지 않는다.

표준화 계수로 '중요도 순위'를 단정하지 않습니다

β 는 표본의 표준편차로 계산합니다. 같은 관계라도 표본에서 그 변수의 범위가 좁으면(1장의 범위 제한) β 가 작아집니다. 그래서 다른 연구와 β 를 직접 비교하거나, 이 연구 안에서도 근소한 차이로 순위를 매기는 것은 조심해야 합니다.

위 결과에서 "스트레스가 지지·효능감보다 소진과 더 강하게 관련된다"는 말할 수 있습니다(신뢰구간이 겹치지 않음). 그러나 지지(-.20)와 효능감(-.19)의 순위는 의미가 없습니다.

■ 모형 전체를 보는 값들

결정계수와 수정 결정계수

$R^2 = .395$ 는 세 변수가 함께 소진 변동의 39.5%를 설명한다는 뜻입니다.

그런데 R^2 에는 약점이 있습니다. **아무 관계없는 변수를 넣어도 조금씩 커집니다.** 표본에서는 어떤 변수든 우연히 약간의 관련은 있기 마련이고, 최소제곱은 그 우연까지 끌어다 쓰기 때문입니다. 1권 9장에서 η^2 이 모집단 효과를 과대추정하던 것과 같은 문제입니다.

이를 보정한 것이 **수정 결정계수(adjusted R^2)**입니다.

$$R_{adj}^2 = 1 - (1 - R^2) \frac{n - 1}{n - k - 1} = 1 - (1 - .3946) \times \frac{299}{296} = .388$$

k 는 독립변수의 수. 변수가 늘수록 깎는 몫이 커집니다

1권의 ω^2 이 η^2 을 보정했던 것처럼, 수정 R^2 은 독립변수의 수만큼 대가를 치르게 합니다. 사례 수가 300으로 넉넉해 차이가 작습니다(.395 → .388). 사례가 적고 변수가 많을수록 차이가 벌어집니다.

모형의 F 검정

실행 결과

F-statistic: 64.32 on 3 and 296 DF, p-value: < 2.2e-16

이 검정의 영가설은 **세 계수가 모두 0**이라는 것입니다.

$$H_0 : \beta_1 = \beta_2 = \beta_3 = 0$$

세 변수 중 어느 것도 소진과 관련이 없다

$F(3, 296) = 64.32, p < .001$ 로 기각합니다. "세 변수 가운데 적어도 하나는 소진을 설명한다"는 뜻입니다. 1권 9장의 분산분석 F 검정이 "적어도 한 집단은 다르다"였던 것과 같은 구조입니다.

개별 계수의 t 검정

계수마다 붙은 t 검정은 다른 질문을 합니다.

"다른 변수들이 이미 모형에 있을 때, 이 변수가 추가로 설명하는 몫이 0이 아닌가."

지지의 $t = -4.05(p < .001)$ 는 스트레스와 효능감을 알고 있어도 지지가 소진을 더 설명한다는 뜻입니다. 단순회귀에서 유의했던 변수가 다중회귀에서 유의하지 않게 되는 일이 흔한데, 그것은 **그 변수의 설명력이 대부분 다른 변수와 겹쳐 있었다**는 뜻입니다.

● 계수의 95% 신뢰구간

`confint(fit)`

실행 결과

	2.5 %	97.5 %
(Intercept)	2.2182807	3.4570814
stress	0.4264935	0.6264179
support	-0.3297090	-0.1141221
efficacy	-0.3402125	-0.1128781

■ 어떤 변수를 넣을 것인가

다중회귀의 계수는 **함께 넣은 변수에 따라 달라집니다**. 같은 스트레스 계수라도 지지와 효능감을 함께 넣으면 0.526, 넣지 않으면 0.602였습니다. 그래서 어떤 변수를 넣느냐가 곧 어떤 질문을 하느냐입니다.

변수 선택을 컴퓨터에 맡기지 않습니다

SPSS의 단계선택(stepwise)은 유의확률을 기준으로 변수를 자동으로 넣고 뺍니다. 편해 보이지만 문제가 많습니다.

- 같은 검정을 수십 번 반복하므로 제1종 오류가 누적됩니다(1권 10장).
- 표본의 우연에 맞춰 변수를 고르므로 다른 표본에서는 재현되지 않습니다.
- 남은 변수의 R^2 과 계수가 과장되고, 표준오차는 과소추정됩니다.

변수는 **이론과 선행연구가 정합니다**. 무엇을 통제해야 하는지, 왜 그 변수가 결과에 영향을 줄 것인지를 연구 설계 단계에서 정하고 그대로 투입합니다. 단계적으로 넣고 싶다면 연구자가 순서를 정하는 7장의 위계적 회귀를 씁니다.

사례 수는 얼마나 필요한가

Green(1991)이 제안한 경험 규칙이 자주 인용됩니다.

- 모형 전체의 F 검정을 위해서는 $N \geq 50 + 8k$
- 개별 계수의 검정을 위해서는 $N \geq 104 + k$

k 는 독립변수의 수입니다. 독립변수가 3개라면 74명, 107명입니다. 이 자료의 300명은 두 기준을 모두 넉넉히 넘습니다. 효과크기를 정해 두고 정확하게 계산하려면 `pwr` 패키지의 `pwr.f2.test()` 를 씁니다.

■ 논문 결과표

표 3. 소진에 대한 다중회귀분석 결과

변수	B	SE	β	t	p	95% CI
(상수)	2.838	0.315		9.02	< .001	[2.218, 3.457]
직무스트레스	0.526	0.051	.48	10.36	< .001	[0.426, 0.626]
사회적지지	-0.222	0.055	-.20	-4.05	< .001	[-0.330, -0.114]
자기효능감	-0.227	0.058	-.19	-3.92	< .001	[-0.340, -0.113]

주. $N = 300$. $R^2 = .395$, 수정 $R^2 = .388$, $F(3, 296) = 64.32$, $p < .001$. 95% CI는 B의 신뢰구간.

결과 서술 예시

직무스트레스, 사회적지지, 자기효능감이 소진에 미치는 영향을 검증하기 위해 다중회귀분석을 실시하였다(표 3). 회귀모형은 통계적으로 유의하였으며($F(3, 296) = 64.32$, $p < .001$), 세 변수는 소진 변동의 39.5%를 설명하였다($R^2 = .395$, 수정 $R^2 = .388$).

직무스트레스는 소진에 정적으로 유의한 영향을 미쳤고($\beta = .48$, $p < .001$), 사회적지지($\beta = -.20$, $p < .001$)와 자기효능감($\beta = -.19$, $p < .001$)은 부적으로 유의한 영향을 미쳤다. 즉, 다른 변수가 동일할 때 직무스트레스가 높을수록, 사회적지지와 자기효능감이 낮을수록 소진이 높았다. 표준화 계수의 크기로 볼 때 직무스트레스의 영향이 가장 컸다.

"다른 변수가 동일할 때"를 한 번 써 주면 독자가 계수를 단순상관과 혼동하지 않습니다.

점검 항목

- ☐ 다중회귀 계수를 "다른 변수가 같은 사람끼리 비교했을 때"로 읽었다
- ☐ 단순회귀와 계수가 달라지는 이유(겹치는 몫)를 안다
- ☐ 비교할 때는 표준화 계수 β 를 썼고, 근소한 차이로 순위를 매기지 않았다
- ☐ R^2 과 수정 R^2 을 함께 보고했다
- ☐ 모형의 F 검정과 계수의 t 검정이 다른 질문임을 안다
- ☐ 변수는 이론에 따라 정했고, 단계선택에 맡기지 않았다
- ☐ 사례 수가 독립변수 수에 비해 충분한지 확인했다

요약 — 다중회귀의 계수는 **다른 독립변수가 같은 사람끼리 비교했을 때**의 기울기입니다. 계산으로는 그 변수에서 다른 변수들로 예측되는 부분을 걷어 내고 남은 부분으로 기울기를 구합니다. 그래서 다른 변수와 겹치던 뒤편만큼 계수가 줄고, 순수회귀 계수들의 합보다 작습니다. 크기 비교에는 표준화 계수를, 모형 평가에는 수정 R^2 을 함께 봅니다.

이 결과를 믿어도 되는가 — 가정과 진단

회귀분석은 자료가 특정한 모양이라고 믿고 계산합니다. 그 믿음이 틀리면 계수나 유의확률이 틀어집니다. 이 장은 회귀분석이 무엇을 가정하는지, 그것을 잔차에서 어떻게 확인하는지를 다룹니다.

■ 회귀분석이 믿고 있는 그림

3장의 회귀식은 **평균적인 경향**을 직선으로 나타낸 것이었습니다. 실제 점수는 그 직선 위에 있지 않고 위아래로 흩어집니다. 회귀분석은 그 흩어짐에 대해 다음과 같은 그림을 가정합니다.




그림 4-1 회귀분석이 가정하는 그림. X 의 어느 값에서든 Y 는 회귀선을 중심으로 같은 폭의 정규분포를 이룬다. 각 사람의 오차는 서로 독립이다. (개념도)

식으로 쓰면 이렇습니다.

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_k X_{ki} + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2)$$

오차는 평균 0, 분산이 일정한 정규분포를 따르며 서로 독립이다

이 한 줄에 네 가지 가정이 들어 있습니다. 앞 글자를 따서 **LINE**으로 기억합니다.

가정	뜻	깨지면
Linearity 선형성	평균적인 관계가 직선이다	계수 자체가 관계를 잘못 요약한다
Independence 독립성	한 사람의 오차가 다른 사람의 오차와 무관하다	표준오차가 작게 나와 유의확률이 과장된다
Normality 정규성	오차가 정규분포를 따른다	작은 표본에서 유의확률과 예측구간이 부정확해진다
Equal variance 등분산성	오차의 흩어진 정도가 어디서나 같다	표준오차가 틀어져 유의확률이 틀어진다

가정은 변수가 아니라 잔차에 대한 것입니다

가장 흔한 오해가 "독립변수와 종속변수가 정규분포여야 한다"는 것입니다. 그래서 변수마다 정규성 검정을 하고, 정규성이 기각되면 회귀분석을 못 한다고 생각합니다.

위 식을 다시 보십시오. 정규분포를 따른다고 가정하는 것은 Y 가 아니라 ε , 곧 오차입니다. 독립변수에는 분포에 대한 가정이 아예 없습니다. 독립변수가 0과 1뿐인 더미변수(6장)여도 회귀분석에는 문제가 없습니다.

모집단의 오차 ε 은 볼 수 없으므로, 표본에서 그 추정치인 잔차 e 를 봅니다. 회귀 진단은 거의 전부 잔차를 들여다보는 일입니다.

■ 잔차를 보는 그림 하나

3장의 모형을 다시 적합하고, R의 기본 진단 그림을 그립니다.

● 진단 그림 네 장을 한 화면에

```
d ← read.csv("data/survey.csv")
fit ← lm(burnout ~ stress + support + efficacy, data = d)
par(mfrow = c(2, 2))
plot(fit)
```

네 그림 가운데 가장 많은 것을 알려주는 것이 첫 번째, **예측값 대 잔차** 그림입니다. 가로축이 예측값 $\hat{Y}$, 세로축이 잔차 e 입니다.




그림 4-2 3장 모형의 예측값 대 잔차. 점들이 0을 중심으로 고르게 흩어져 있으면 좋다. 진한 선은 예측값 구간별 잔차의 평균으로, 양 끝에서 약간 위로 휜다.

가정이 모두 맞다면 이 그림에는 **아무 모양도 보이지 않아야** 합니다. 0을 중심으로 위아래 같은 폭의 띠가 가로로 놓인 모습입니다. 모양이 보인다면 그 모양이 어느 가정이 깨졌는지 알려줍니다.




그림 4-3 예측값 대 잔차 그림의 세 가지 전형. 왼쪽은 가정이 맞는 경우, 가운데는 곡선 관계를 직선으로 적합한 경우, 오른쪽은 예측값이 커질수록 오차가 커지는 이분산의 경우다. (모의 자료)

그림 4-2는 대체로 고른 띠입니다. 그런데 진한 선(구간별 잔차 평균)이 양 끝에서 조금 올라갑니다. 이것이 의미 있는 힘인지는 아래 선형성에서 따져 봅니다.

■ 선형성

무엇을 가정하는가

독립변수와 종속변수의 평균적인 관계가 **직선**이라는 가정입니다. 회귀계수는 "1점 높을 때마다 같은 만큼 높다"를 전제로 한 값이므로, 관계가 휘어 있으면 계수가 관계를 잘못 요약합니다.

극단적인 예를 봅시다. 각성 수준과 수행의 관계는 흔히 뒤집힌 U자입니다. 너무 느슨해도, 너무 긴장해도 수행이 떨어집니다. 모의 자료로 만들어 봅시다.

● 뒤집힌 U자 관계를 직선으로 적합하면

```
set.seed(1)
arousal <- runif(200, 1, 5)
perf <- 1 + 2.88 * arousal - 0.48 * arousal^2 + rnorm(200, 0, .5)

m_line <- lm(perf ~ arousal)
round(summary(m_line)$coefficients, 3)
summary(m_line)$r.squared
```

실행 결과

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.900	0.153	32.125	0.000
arousal	-0.045	0.047	-0.954	0.341

[1] 0.004579983

기울기 -0.045 , $p = .341$, $R^2 = .005$. 직선으로 보면 각성과 수행은 아무 관계가 없습니다. 그러나 실제로는 강한 관계가 있습니다. 1장의 Anscombe ② 자료와 같은 상황입니다.




그림 4-4 뒤집힌 U자 관계. 직선(회색 점선)은 관계가 없다고 말하지만, 이차항을 넣은 곡선(진한 선)은 변동의 절반을 설명한다. (모의 자료)

고치는 법: 이차항

곡선 관계는 독립변수의 제곱항을 함께 넣어 표현합니다. 식은 여전히 회귀분석입니다.

● 이차항을 더한 모형과 비교

```
m_curve <- lm(perf ~ arousal + I(arousal^2))
round(summary(m_curve)$coefficients, 3)
summary(m_curve)$r.squared
```

실행 결과

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.137	0.284	4.008	0
arousal	2.778	0.200	13.895	0
I(arousal^2)	-0.464	0.032	-14.314	0

[1] 0.5120627

R^2 이 .005에서 **.512**로 뛰었습니다. (`round()`로 셋째 자리에서 반올림해 유의확률이 0으로 보이면 .001보다 작다는 뜻입니다.) 이차항의 계수가 음수(-0.464)라는 것은 위로 볼록한 곡선, 곧 뒤집힌 U자라는 뜻입니다. `I()`는 R 모형식 안에서 `^`를 산술 제곱으로 읽으라는 표시입니다.

이 자료에서는

이 자료의 모형에도 선형성을 확인해 봅니다. `car` 패키지의 `residualPlots()`는 독립변수마다 잔차 그림을 그리고 곡선 검정을 함께 출력합니다.

● 독립변수별 곡선 검정

```
library(car)
residualPlots(fit)
```

실행 결과

	Test stat	Pr(> Test stat)
stress	3.3365	0.0009570 ***
support	-0.8617	0.3895545
efficacy	-1.4020	0.1619642
Tukey test	3.6852	0.0002285 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

`stress` 행과 `Tukey test` 행이 유의합니다. 스트레스와 소진의 관계에 **힘이 있다**는 신호입니다. 그림 4-2의 양 끝이 올라가던 것과 같은 이야기입니다.

어떻게 판단할까요. 신호가 나왔다고 곧바로 모형을 바꾸지 않습니다. 세 가지를 차례로 봅니다.

① **힘의 크기**. 이차항을 넣어 설명력이 얼마나 느는지 봅니다.

- 스트레스 이차항을 더하면 R^2 가 얼마나 느는가

```
fit_q <- update(fit, . ~ . + I(stress^2))
anova(fit, fit_q)
c(summary(fit)$r.squared, summary(fit_q)$r.squared)
```

실행 결과

Analysis of Variance Table

```
Model 1: burnout ~ stress + support + efficacy
Model 2: burnout ~ stress + support + efficacy + I(stress^2)
  Res.Df    RSS Df Sum of Sq    F    Pr(>F)
1     296 82.579
2     295 79.576   1     3.003 11.132 0.000957 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
[1] 0.3946177 0.4166321
```

유의하지만 R^2 은 .395에서 .417로 **2.2%p** 늘 뿐입니다. 300명이면 이 정도의 작은 힘도 검정에 걸립니다. 각성-수행 예처럼 관계 자체를 뒤바꾸는 힘은 아닙니다.

㉔ **힘이 생긴 이유.** 이론적으로 스트레스와 소진이 U자일 이유는 없습니다. 오히려 **모형에 빠진 무언가**가 있다는 신호일 수 있습니다. 스트레스-소진 연구에는 "사회적지지와 스트레스의 영향을 완충한다"는 유명한 가설이 있습니다. 스트레스의 기울기가 지지 수준에 따라 다르다면, 그것을 무시한 직선 모형의 잔차에는 힘이 남습니다. 8장에서 이 상호작용을 모형에 넣으면 Tukey 검정의 신호가 사라지는 것을 확인합니다.

㉔ **결론에 미치는 영향.** 이차항을 넣어도 지지와 효능감의 계수는 거의 같고, 스트레스가 소진과 정적으로 관련된다는 결론도 같습니다.

진단은 판결이 아니라 단서입니다

진단 검정이 유의하다는 것은 "완벽한 직선이 아니다"라는 뜻이지 "이 분석은 무효다"라는 뜻이 아닙니다. 표본이 크면 아주 작은 어긋남도 유의하게 나옵니다.

크기를 보고, 이유를 묻고, 결론이 바뀌는지 확인합니다. 이 장에서는 직선 모형을 그대로 쓰고, 힘의 이유로 짐작되는 상호작용은 8장에서 다룹니다. 논문에서는 이 판단 과정을 한두 문장으로 밝혀 둡니다.

■ 독립성

한 사람의 오차가 다른 사람의 오차와 관련이 없다는 가정입니다. 이 가정은 **자료를 모으는 방식**이 결정합니다. 잔차 그림으로는 거의 확인할 수 없습니다.

독립성이 깨지는 전형적인 경우는 다음과 같습니다.

- 같은 팀, 같은 학급, 같은 병원에서 여러 명을 조사한 경우. 같은 팀원은 같은 팀장 밑에서 일하므로 소진이 함께 높거나 낮습니다.
- 같은 사람을 여러 번 측정한 경우(1권 8장의 종속표본과 같은 상황).
- 시간 순서대로 쌓인 자료. 어제의 오차가 오늘의 오차와 이어집니다.

독립성이 깨지면 표준오차가 실제보다 작게 계산됩니다. 300명이라도 실제로는 20개 팀에서 나온 자료라면 독립적인 정보는 300개보다 훨씬 적기 때문입니다. 그 결과 **유의확률이 과장됩니다**.

독립성이 걱정될 때

시간 순서 자료라면 `car::durbinWatsonTest(fit)` 로 인접한 잔차끼리의 상관을 검정합니다(값이 2 근처면 문제없음). 팀·학급처럼 묶인 자료라면 **다층모형(multilevel model)**을 써야 하며, 이는 이 시리즈의 범위를 넘습니다.

이 책의 자료는 서로 다른 회사의 직장인을 한 명씩 조사한 것으로 가정하므로 독립성을 충족한 것으로 봅니다. 논문의 연구방법에 표집 방식을 밝히는 것이 곧 독립성에 대한 설명이 됩니다.

정규성

오차가 정규분포를 따른다는 가정입니다. 잔차의 분포를 **Q-Q 그림**으로 확인합니다. 잔차를 크기순으로 늘어놓고, 정규분포라면 그 순위에 와야 할 값과 짝지어 찍은 그림입니다. 정규분포라면 점들이 대각선 위에 놓입니다.




그림 4-5 잔차의 Q-Q 그림. 점들이 대각선을 따라 놓여 있다. 양 끝의 몇 점이 조금 벗어나는 것은 300명 규모에서 흔한 모습이다.

● 잔차의 정규성 검정

```
shapiro.test(resid(fit))
```

실행 결과

Shapiro-Wilk normality test

```
data: resid(fit)
```

```
W = 0.9955, p-value = 0.5401
```

$W = 0.996$, $p = .540$ 으로 정규성을 기각하지 않습니다. 1권 3장에서 본 것처럼 이 검정은 p 가 커야 좋은 검정입니다.

표본이 크면 정규성은 크게 걱정하지 않습니다

회귀계수는 사례들의 가중합입니다. 1권 4장의 중심극한정리에 따라 **사례 수가 충분하면 오차가 정규분포가 아니어도 계수의 표집분포는 정규분포에 가까워집니다**. 그래서 계수의 t 검정과 신뢰구간은 정규성 위반에 꽤 견고합니다.

정규성이 중요해지는 것은 ① 사례 수가 적을 때(대략 30~50명 미만), ② 한 사람의 점수를 예측하는 **예측구간**을 쓸 때입니다. 예측구간은 개인 오차의 분포를 직접 쓰기 때문입니다.

반대로 사례가 수백 명이면 Shapiro-Wilk 검정은 실질적으로 무시해도 될 작은 어긋남까지 잡아냅니다. **검정보다 Q-Q 그림을 먼저 봅니다**.

■ 등분산성

오차의 흩어진 정도가 독립변수 값과 상관없이 **어디서나 같다**는 가정입니다. 1권 7장의 등분산 가정이 집단 사이의 분산이 같은지를 물었다면, 여기서는 예측값이 작은 쪽과 큰 쪽의 잔차 폭이 같은지를 묻습니다.

깨지면 그림 4-3 오른쪽처럼 **칼때기 모양**이 됩니다. 소득처럼 값이 클수록 편차도 커지는 변수에서 흔합니다.

● 잔차의 등분산 검정 (Breusch-Pagan)

```
library(lmtest)
bptest(fit)
```

실행 결과

studentized Breusch-Pagan test

```
data: fit
```

```
BP = 3.8181, df = 3, p-value = 0.2818
```

$BP = 3.82$, $p = .282$ 로 등분산 가정을 기각하지 않습니다.

깨지면 무엇이 문제인가

이분산이어도 계수 자체는 치우치지 않습니다. 문제는 표준오차입니다. 표준오차 공식이 "오차의 폭이 어디서나 σ 로 같다"고 보고 계산하기 때문에, 폭이 다르면 표준오차가 틀어지고 그 결과 t 와 p 가 틀어집니다.

고치는 법: 강건한 표준오차

해결책은 계수는 그대로 두고 **표준오차만 이분산에 맞게 다시 계산하는 것**입니다. 이를 **이분산 강건 표준오차 (heteroscedasticity-consistent standard error)**라 하며, 그중 HC3가 작은 표본에서도 잘 작동한다고 알려져 있습니다(Long & Ervin, 2000).

모의 자료로 확인합니다. 오차가 X 에 따라 커지도록 만들었습니다.

- 이분산 자료에서 보통 표준오차와 강건한 표준오차

```
library(sandwich)
set.seed(2)
x <- runif(200, 1, 5)
y <- 1 + 0.5 * x + rnorm(200, 0, 0.12 * x^1.6)
m_het <- lm(y ~ x)

bptest(m_het)
coeftest(m_het) # 보통 표준오차
coeftest(m_het, vcov = vcovHC(m_het, type = "HC3")) # 강건한 표준오차
```

실행 결과

```
studentized Breusch-Pagan test

data:  m_het
BP = 44.606, df = 1, p-value = 2.41e-11

t test of coefficients:

            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.98176    0.18437   5.3249 2.727e-07 ***
x            0.52433    0.05792   9.0528 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

t test of coefficients:

            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.981759    0.163576   6.0018 9.154e-09 ***
x            0.524333    0.075572   6.9382 5.521e-11 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

등분산 검정이 강하게 기각됩니다($p < .001$). 계수 0.524는 두 출력에서 같고, x 의 표준오차만 0.058에서 **0.076으로 커졌습니다**. 30% 가까이 큼니다. 보통 표준오차가 불확실성을 그만큼 작게 잡고 있었던 것입니다. 이 예에서는 여전히 유의하지만, 경계에 있는 계수라면 결론이 바뀔 수 있습니다.

■ 튀는 사례 — 이상치, 지렛값, 영향점

1장의 Anscombe ③, ④ 자료에서 점 하나가 상관계수를 좌우하는 것을 보았습니다. 회귀에서는 이런 사례를 세 가지로 구분합니다.




그림 4-6 튀는 사례의 세 종류. 이상치는 회귀선에서 세로로 멀리 떨어진 점, 지렛값이 큰 점은 독립변수 값이 다른 사람들과 멀리 떨어진 점이다. 둘을 모두 갖춘 점이 회귀선을 끌어당기는 영향점이다. (개념도)

구분	무엇이 튀는가	재는 값	흔히 쓰는 기준
이상치	Y 가 예측에서 멀다	스튜던트화 잔차	절댓값 2 또는 3 초과
지렛값	X 가 다른 사람들과 멀다	지렛값(hat value)	$2(k + 1)/n$ 초과
영향점	빼면 회귀선이 크게 바뀐다	Cook의 거리	1 초과, 또는 $4/n$ 초과

중요한 것은 영향점입니다. 이상치라도 X 가 평범하면 회귀선을 별로 움직이지 못하고(그림 왼쪽), 지렛값이 커도 회귀선 위에 있으면 오히려 기울기를 안정시킵니다(가운데). **둘이 겹칠 때** 회귀선이 끌려갑니다(오른쪽).

Anscombe ③ 자료로 확인합니다.

● Anscombe ③ 자료의 Cook의 거리

```
round(cooks.distance(lm(y3 ~ x3, data = anscombe)), 2)
```

실행 결과

```
1  2  3  4  5  6  7  8  9 10 11
0.01 0.00 1.39 0.01 0.03 0.30 0.00 0.03 0.06 0.00 0.01
```

세 번째 사례의 Cook의 거리가 **1.39**로 기준 1을 넘습니다. 이 점 하나를 빼면 기울기가 0.50에서 0.35로 바뀝니다.

이 자료에서는

이 자료의 튀는 사례 세기

```
n <- nrow(d); k <- 3
sum(abs(rstudent(fit)) > 2)           # 스튜던트화 잔차 절댓값 2 초과
sum(hatvalues(fit) > 2 * (k + 1) / n) # 지렛값 기준 초과
cd <- cooks.distance(fit)
max(cd); which.max(cd)               # 가장 큰 Cook의 거리
```

실행 결과

```
[1] 16
[1] 19
[1] 0.06318007
249
249
```




그림 4-7 300명의 Cook의 거리. 가장 큰 값도 0.063으로 기준 1에 한참 못 미친다. 점선은 느슨한 기준 $4/n = .013$ 이다.

스튜던트화 잔차가 2를 넘는 사례가 16명입니다. 정규분포에서 5%는 원래 ± 2 밖에 있으므로, 300명이면 15명 정도는 **당연히 나와야 하는 숫자**입니다. 가장 큰 Cook의 거리는 249번 사례의 0.063으로, 회귀선을 움직일 만한 영향점은 없습니다.

249번 사례를 들여다보면 지지는 4.75점으로 높는데 효능감은 2.33점으로 낮은, 드문 조합입니다. 지렛값이 큰 이유입니다. 이 사례를 빼고 다시 적합해 계수가 얼마나 바뀌는지 봅니다.

249번을 뺐을 때 계수 비교

```
round(cbind(all = coef(fit), drop_249 = coef(update(fit, subset = -249))), 3)
```

실행 결과

	all	drop_249
(Intercept)	2.838	2.822
stress	0.526	0.534
support	-0.222	-0.201
efficacy	-0.227	-0.248

계수가 소수 둘째 자리에서 조금 움직일 뿐 결론은 같습니다.

튀는 사례를 함부로 지우지 않습니다

기준을 넘었다는 이유만으로 사례를 지우면 **자료를 연구자의 기대에 맞추는 것**이 됩니다. 순서는 이렇습니다.

1. **입력 오류인지 확인합니다.** 5점 척도에 55가 들어가 있다면 고칩니다.
2. **연구 대상이 맞는지 확인합니다.** 직장인 조사에 학생이 섞였다면 제외 사유가 됩니다.
3. 둘 다 아니라면 **실제로 존재하는 사람**입니다. 지우지 않습니다. 대신 그 사례를 뺀 분석을 함께 돌려 결론이 바뀌는지 확인하고(민감도 분석), 바뀐다면 그 사실을 보고합니다.

■ 논문에 쓰는 법

가정 확인은 결과 절의 첫 단락이나 각주에 짧게 적습니다. 무엇을 확인했고 어떻게 판단했는지가 드러나면 충분합니다.

결과 서술 예시

회귀분석의 가정을 확인하였다. 잔차의 Q-Q 그림과 Shapiro-Wilk 검정($W = 0.996$, $p = .540$)에서 정규성이 확인되었고, Breusch-Pagan 검정($BP = 3.82$, $p = .282$)에서 등분산성이 확인되었다. Cook의 거리는 최댓값이 0.063으로 영향력이 큰 사례는 없었다. 잔차 분석에서 직무스트레스와 소진의 관계에 약한 곡선성이 관찰되었으나, 이차항을 추가하였을 때 설명력의 증가가 2.2%p에 그쳤고 다른 계수의 해석이 달라지지 않아 선형모형을 유지하였다.

다중공선성(5장)도 같은 단락에 함께 적는 것이 일반적입니다.

점검 항목

- ☐ 정규성을 변수가 아니라 잔차에서 확인했다
- ☐ 예측값 대 잔차 그림에서 휼이나 깔때기 모양을 확인했다
- ☐ 곡선 신호가 있으면 크기, 이유, 결론의 변화를 차례로 확인했다

- ☐ 자료 수집 방식에서 독립성을 확인했다(묶인 자료라면 다층모형)
- ☐ 이분산이면 강건한 표준오차(HC3)를 썼다
- ☐ Cook의 거리로 영향점을 확인했고, 사례를 근거 없이 지우지 않았다
- ☐ 가정 확인 결과를 한 단락으로 보고했다

요약 — 회귀분석은 오차가 **선형, 독립, 정규, 등분산**이라고 가정합니다. 이 가정은 변수가 아니라 **잔차**에서 확인합니다. 예측값 대 잔차 그림 하나로 힘과 깔때기를 보고, Q-Q 그림으로 정규성을, Cook의 거리로 영향점을 봅니다. 검정이 유의하다고 곧 무효가 아니며, **크기를 보고 이유를 묻고 결론이 바뀌는지 확인**하는 것이 진단입니다.

비슷한 변수를 함께 넣으면 — 다중공선성

소진과 분명히 정적 관계가 있는 변수가 회귀분석에서는 음수 계수로 나오는 일이 있습니다. 분석이 틀린 것이 아니라 독립변수끼리 너무 닮았다는 신호입니다. 이 장은 그 현상이 왜 생기고, 어떻게 알아보고, 무엇을 할지를 다룹니다.

■ 이상한 결과 하나

이 자료에는 **업무과부하**(`workload`)라는 변수가 있습니다. "처리해야 할 일이 너무 많다"는 정도를 잴 것입니다. 업무과부하가 높은 사람이 소진도 높으리라는 것은 상식입니다. 실제로 상관이 .46입니다.

직무스트레스, 업무과부하, 사회적지지를 함께 넣어 소진을 회귀분석합니다.

● 업무과부하를 함께 넣은 모형

```
library(car)
d <- read.csv("data/survey.csv")
m_both <- lm(burnout ~ stress + workload + support, data = d)
round(summary(m_both)$coefficients, 3)
```

실행 결과

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.250	0.276	8.140	0.000
stress	0.694	0.110	6.280	0.000
workload	-0.155	0.100	-1.554	0.121
support	-0.288	0.054	-5.367	0.000

업무과부하의 계수가 **-0.155**입니다. "다른 변수가 같다면 업무가 많을수록 덜 소진된다"는 결과입니다. 유의하지는 않지만 ($p = .121$) 부호부터 상식과 반대입니다.

비교를 위해 업무과부하를 빼고, 또 스트레스를 빼고 돌려 봅니다.

● 둘 중 하나씩만 넣은 모형

```
m_stress <- lm(burnout ~ stress + support, data = d)
m_load <- lm(burnout ~ workload + support, data = d)
round(summary(m_stress)$coefficients, 3)
round(summary(m_load)$coefficients, 3)
```

실행 결과

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.190	0.274	7.982	0
stress	0.542	0.052	10.456	0
support	-0.284	0.054	-5.294	0
	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.626	0.287	9.156	0
workload	0.400	0.050	8.030	0
support	-0.309	0.057	-5.443	0

	스트레스만	업무과부하만	둘 다
스트레스 b (SE)	0.542 (0.052)		0.694 (0.110)
업무과부하 b (SE)		0.400 (0.050)	-0.155 (0.100)
R^2	.363	.284	.368

따로 넣으면 둘 다 소진과 뚜렷한 정적 관계입니다. 함께 넣으면 다음 네 가지가 동시에 일어납니다.

1. 업무과부하의 부호가 뒤집힙니다.
2. 두 변수의 표준오차가 두 배로 커집니다(0.052 → 0.110, 0.050 → 0.100).
3. 스트레스 계수는 오히려 부풀었습니다(0.542 → 0.694).
4. 그런데 R^2 은 .363에서 .368로 거의 늘지 않습니다.

이것이 다중공선성(multicollinearity)의 전형적인 증상입니다. 원인은 하나입니다. 두 변수의 상관이 .89입니다.




그림 5-1 업무과부하를 따로 넣었을 때와 스트레스와 함께 넣었을 때의 계수와 95% 신뢰구간. 함께 넣으면 구간이 두 배 넓어지고 업무과부하의 부호가 뒤집힌다.

■ 왜 이런 일이 생기는가

3장의 핵심을 떠올립니다. 다중회귀 계수는 **그 변수에서 다른 독립변수들과 겹치는 부분을 걷어 내고 남은 고유한 부분**으로 구한 기울기였습니다.

스트레스와 업무과부하는 상관이 .89입니다. 스트레스에서 업무과부하(와 지지)로 예측되는 부분을 걷어 내면 얼마나 남을까요.

● 스트레스가 다른 두 변수로 얼마나 설명되는가

```
summary(lm(stress ~ workload + support, data = d))$r.squared
```

실행 결과

```
[1] 0.7910769
```

스트레스 변동의 **79%가 다른 두 변수와 겹칩니다**. 걷어 내고 남은 고유한 부분은 21%뿐입니다. 300명의 정보로 기울기를 구하는 것이 아니라, 그 21%의 좁은 정보로 기울기를 구하는 셈입니다.




그림 5-2 스트레스와 업무과부하의 변동이 대부분 겹칩니다. 다중회귀 계수는 겹치지 않는 가장자리(빛금)만으로 계산되므로, 정보가 적어 표본마다 크게 흔들린다. (개념도)

정보가 적으면 추정이 불안정해집니다. **표준오차가 커지는 것이** 그 불안정성의 표현입니다. 부호가 뒤집힌 것도 같은 이유입니다. 고유한 부분이 좁으면 그 안의 우연한 흔들림이 계수를 반대쪽으로 끌고 갈 수 있습니다. 두 변수가 거의 같은 정보를 가지고 있으니, 한쪽이 크게 양수가 되면 다른 쪽이 음수가 되어 합을 맞추는 일도 생깁니다. 스트레스 계수가 부푼 것이 그 짝입니다.

다중공선성은 "틀린 계산"이 아니라 "정보 부족"입니다

계수는 여전히 치우치지 않은 추정치입니다. 다만 **두 변수의 효과를 서로 떼어 낼 정보가 자료에 별로 없습니다**. 그래서 각자의 몫을 정확히 나누지 못하고, 그 불확실성이 큰 표준오차로 나타납니다.

반대로 둘을 합친 설명력은 정확히 추정됩니다. R^2 이 거의 그대로였던 이유입니다. 예측이 목적이라면 다중공선성은 큰 문제가 아닙니다. 각 변수의 고유한 효과를 해석하는 것이 목적일 때 문제가 됩니다.

■ 분산팽창지수 (VIF)

위에서 구한 79%를 이용하면 표준오차가 얼마나 부풀었는지 계산할 수 있습니다.

$$VIF_j = \frac{1}{1 - R_j^2}$$

R_j^2 는 j 번째 독립변수를 나머지 독립변수들로 회귀했을 때의 결정계수

스트레스의 VIF는 $1/(1 - .791) = 4.79$ 입니다. 이 값을 분산팽창지수(variance inflation factor, VIF)라 합니다. 다른 독립변수와 전혀 겹치지 않을 때보다 계수의 분산이 4.79배 크다는 뜻입니다. 표준오차로는 그 제곱근인 $\sqrt{4.79} = 2.19$ 배입니다.

● 분산팽창지수

```
vif(m_both)
vif(m_stress)
```

실행 결과

```
stress workload support
4.786450 4.774919 1.051269
stress support
1.049424 1.049424
```

업무과부하를 넣은 모형에서는 스트레스와 업무과부하의 VIF가 4.8 안팎이고, 빼면 1.05로 떨어집니다. 표준오차가 0.052에서 0.110으로 2.1배가 된 것과 맞아떨어집니다.




그림 5-3 두 독립변수의 상관에 따른 VIF와 표준오차 배율($\sqrt{VIF}$). 상관이 .8을 넘으면 급격히 커진다. 이 자료의 .89는 표준오차를 2.2배로 부풀린다.

기준	해석
VIF < 2.5	문제없음
2.5 ~ 5	주의. 해석에 영향이 있는지 확인
5 ~ 10	다중공선성이 상당함
VIF ≥ 10	심각

공차(tolerance)는 VIF의 역수($1 - R_j^2$)입니다. SPSS가 함께 출력하며 .10 미만을 심각한 수준으로 봅니다(VIF 10 초과와 같은 기준).

"VIF가 10 미만이므로 다중공선성은 없었다"

학위논문에서 가장 자주 보는 문장입니다. 이 장의 예에서 VIF는 4.79로 그 기준에 한참 못 미칩니다. 그런데도 **부호가 뒤집히고 표준오차가 두 배가 되었습니다.**

VIF 10은 "이 정도면 누구나 문제라고 할 수준"이지 "이 아래면 괜찮다"는 보증이 아닙니다. VIF와 함께 **증상**을 봅니다. 상관표에서 독립변수끼리 .80을 넘는 쌍이 있는지, 단순회귀와 부호가 반대인 계수가 있는지, 개념적으로 같은 것을 두 번 켜 변수가 있는지입니다.

■ 표본이 바뀌면

다중공선성이 만드는 불안정성을 직접 확인해 봅니다. 300명을 무작위로 150명씩 둘로 나눠 같은 모형을 따로 돌립니다.

● 무작위로 나눈 두 절반에서 같은 모형

```
set.seed(1)
i <- sample(nrow(d), 150)
A <- d[i, ]; B <- d[-i, ]

f_both <- burnout ~ stress + workload + support
round(rbind(A = coef(lm(f_both, data = A)), B = coef(lm(f_both, data = B))), 3)

f_one <- burnout ~ stress + support
round(rbind(A = coef(lm(f_one, data = A)), B = coef(lm(f_one, data = B))), 3)
```

실행 결과

	(Intercept)	stress	workload	support
A	2.177	0.875	-0.305	-0.265
B	2.304	0.462	0.040	-0.307

	(Intercept)	stress	support
A	2.089	0.575	-0.262
B	2.322	0.501	-0.308

업무과부하를 넣은 모형에서는 절반 A와 B의 계수가 크게 다릅니다. 스트레스는 0.875와 0.462, 업무과부하는 -0.305와 +0.040으로 **부호까지 바뀝니다**. 업무과부하를 뺀 모형에서는 스트레스 계수가 두 절반에서 비슷합니다.




그림 5-4 같은 자료를 무작위로 둘로 나눠 얻은 계수. 업무과부하를 함께 넣으면 두 절반의 계수가 크게 벌어지고, 빼면 가까이 붙는다.

같은 모집단에서 뽑은 두 표본이 이렇게 다른 답을 내놓는다면, 어느 쪽 계수도 그 자체로 해석하기 어렵습니다. 다중공선성이 문제인 진짜 이유는 표준오차라는 숫자가 아니라 이 불안정성입니다.

■ 따로는 유의하지 않아도 함께는

업무과부하는 다중회귀에서 유의하지 않았습니니다. 그러면 업무과부하는 소진과 무관한 것일까요. 스트레스와 업무과부하를 **함께 빼면** 모형이 얼마나 나빠지는지 봅시다.

● 두 변수를 함께 뺐을 때의 F검정

```
anova(lm(burnout ~ support, data = d), m_both)
```

실행 결과

Analysis of Variance Table

Model 1: burnout ~ support

Model 2: burnout ~ stress + workload + support

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	298	118.850				
2	296	86.169	2	32.681	56.132	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$F(2, 296) = 56.13, p < .001$ 입니다. **둘이 함께는 소진을 강하게 설명합니다.** 개별 t 검정이 유의하지 않은 것은 "둘 중 누구의 몫인지 가를 수 없다"는 뜻이지 "둘 다 상관없다"는 뜻이 아닙니다.

■ 어떻게 할 것인가

정답은 하나가 아니라, **두 변수가 무엇이고 연구 질문이 무엇인지에 따라** 정해집니다.

① 같은 개념을 두 번 잰 것이라면 — 하나만 넣거나 합칩니다.

업무과부하는 직무스트레스의 주요 원천이어서 문항 내용도 겹칩니다. 이론적으로 둘을 구분할 이유가 약하다면 연구 질문에 더 맞는 하나를 고릅니다. 둘 다 버리기 아깝다면 표준화한 뒤 평균을 내 **합성 변수**로 만듭니다.

● 두 변수를 표준화해 평균 낸 합성 변수

```
d$load <- (scale(d$stress) + scale(d$workload)) / 2
m_comp <- lm(burnout ~ load + support, data = d)
round(summary(m_comp)$coefficients, 3)
vif(m_comp)
```

실행 결과

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.881	0.196	19.793	0
load	0.322	0.034	9.553	0
support	-0.290	0.055	-5.280	0

	load	support
1.051126	1.051126	

합성 변수의 계수는 0.322로 안정적이고 VIF는 1.05입니다. 다만 이제 계수는 스트레스도 업무과부하도 아닌 **"업무 부담"**이라는 새 개념의 효과이므로, 그 개념을 정의하고 이름 붙여 보고해야 합니다. 두 척도를 하나로 묶어도 되는지는 3권의 요인분석이 답하는 질문입니다.

② 통제변수끼리 겹친다면 — 그대로 둡니다.

7장에서 연령과 근속연수를 통제변수로 함께 넣습니다. 두 변수는 상관이 .86이고 VIF가 3.8 정도 됩니다. 그러나 연령과 근속연수 각각의 계수를 해석할 것이 아니라 **둘을 함께 통제하는 것**이 목적이므로 문제가 되지 않습니다. 다중공선성은 겹치는 변수들 사이에서만 일어나며, 다른 변수의 계수에는 영향을 주지 않습니다.

③ 서로 다른 개념이고 둘 다 연구 질문이라면 — 넣고, 한계를 밝힙니다.

두 변수의 고유한 효과를 구분하는 것 자체가 연구 질문이라면 하나를 빼는 것은 질문을 바꾸는 것입니다. 이 경우에는 그대로 넣고, 넓은 신뢰구간을 그대로 보고하고, 개별 계수보다 **두 변수의 공동 기여**(위의 F 검정)를 함께 제시합니다. 표본을 늘리는 것도 근본적인 해결책입니다.

하지 말아야 할 것

- **유의하지 않은 쪽을 지우기.** 표본의 우연이 결정하게 됩니다. 위의 두 절반처럼 다른 표본이었다면 지워진 변수가 달랐을 것입니다.
- **부호가 이상한 계수를 그대로 해석하기.** "업무과부하는 소진을 줄인다"고 쓰면 안 됩니다.
- **중심화로 해결하려 하기.** 평균 중심화는 VIF를 바꾸지 않습니다. 단, 8장의 **상호작용항**처럼 변수를 곱해 만든 항의 공선성은 중심화로 줄어듭니다. 이 둘은 다른 문제입니다.

■ 논문에 쓰는 법

결과 서술 예시

독립변수 간 다중공선성을 확인하기 위해 분산팽창지수(VIF)를 산출하였다. 직무스트레스와 업무과부하의 상관이 .89로 높았고, 두 변수를 함께 투입한 모형에서 VIF가 각각 4.79, 4.77로 나타났으며 업무과부하의 회귀계수가 단순상관과 반대 부호를 보였다. 두 변수는 개념적으로 중첩되므로 이후 분석에서는 직무스트레스만을 투입하였다.

다중공선성이 없을 때는 한 문장으로 충분합니다.

모든 독립변수의 VIF가 1.06~1.15로 다중공선성의 문제는 없었다.

3장 모형(스트레스, 지지, 효능감)의 실제 값입니다.

점검 항목

- ☐ 상관표에서 독립변수끼리 .80 이상인 쌍을 먼저 확인했다
- ☐ VIF를 보고했고, 10 미만이라는 이유만으로 안심하지 않았다
- ☐ 단순회귀와 부호가 반대인 계수가 있는지 확인했다
- ☐ 개별 계수가 유의하지 않아도 공동 기여를 F 검정으로 확인했다
- ☐ 같은 개념의 중복이면 하나를 고르거나 합성했고, 그 근거를 밝혔다
- ☐ 유의하지 않은 쪽을 기계적으로 지우지 않았다

요약 — 다중공선성은 독립변수끼리 너무 닮아서 **각자의 고유한 몫을 가를 정보가 부족한 상태**입니다. 계수의 표준오차가 배로 커지고, 표본마다 계수가 크게 흔들리며 부호가 뒤집히기도 합니다. 함께 가진 설명력은 정확하므로 예측에는 문제가 적고, 개별 효과를 해석할 때 문제가 됩니다. 해결은 통계가 아니라 **두 변수가 무엇인지**에서 출발합니다.

집단도 회귀에 넣는다 — 더미변수

회귀분석의 독립변수는 연속변수만이 아닙니다. 성별이나 직급 같은 범주도 0과 1로 바꾸면 그대로 들어갑니다. 그렇게 하고 나면 1권의 t-검정과 분산분석이 회귀분석의 한 형태였다는 것이 드러납니다.

■ 범주를 숫자로 넣으면 안 되는 이유

직급에 따라 직무만족이 다를까요. 직급은 사원, 대리, 과장이상의 세 범주입니다.

가장 먼저 떠오르는 방법은 사원 = 1, 대리 = 2, 과장이상 = 3으로 숫자를 매겨 회귀분석에 넣는 것입니다. 그러나 이렇게 하면 회귀분석은 이 숫자를 **등간척도**로 받아들입니다. 1권 1장에서 다룬 척도 구분이 여기서 문제가 됩니다.

- 사원 → 대리의 차이와 대리 → 과장이상의 차이가 **같다고** 가정하게 됩니다.
- 범주에 순서가 없는 경우(부서: 영업, 생산, 연구)라면 숫자 자체가 의미가 없습니다. 영업 = 1, 생산 = 2로 매길지 반대로 매길지에 따라 결과가 달라집니다.

필요한 것은 "어느 범주에 속하는가"만을 담은 숫자입니다.

■ 더미변수

범주마다 "여기에 속하면 1, 아니면 0"인 변수를 만듭니다. 이것을 **더미변수(dummy variable)**라 합니다. 범주가 k 개면 더미변수는 $k - 1$ 개를 만듭니다.

직급	$D_{\text{대리}}$	$D_{\text{과장이상}}$
사원	0	0
대리	1	0
과장이상	0	1

사원에게는 더미변수가 없습니다. 두 더미가 모두 0이면 사원입니다. 이렇게 **모든 더미가 0인 범주를 기준 집단(reference group)**이라 합니다. 더미를 k 개 만들지 않는 이유는, 세 번째 더미가 앞의 두 더미로 완전히 결정되기 때문입니다($D_{\text{사원}} = 1 - D_{\text{대리}} - D_{\text{과장이상}}$). 5장의 다중공선성이 극단으로 간 상태여서 계산이 불가능합니다.

R에서는 범주형 변수를 `factor` 로 만들어 두면 더미변수를 자동으로 만듭니다. **첫 번째 수준이 기준 집단**이 됩니다.

- 직급을 factor로, 사원이 첫 번째(기준)가 되도록

```
d <- read.csv("data/survey.csv")
d$position <- factor(d$position, levels = c("사원", "대리", "과장이상"))
tapply(d$satisfaction, d$position, mean)
```

실행 결과

```
사원      대리 과장이상
3.057692 3.250000 3.550000
```

`levels` 를 지정하지 않으면 R은 가나다순으로 정렬해 과장이상이 기준 집단이 됩니다. 기준을 의도대로 정하는 습관을 들이십시오.

■ 계수 읽기

- 직급으로 직무만족을 회귀

```
m_pos <- lm(satisfaction ~ position, data = d)
summary(m_pos)
```

실행 결과

Call:

```
lm(formula = satisfaction ~ position, data = d)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-1.6577 -0.4577 -0.0500  0.4500  1.7500
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    3.05769    0.06223  49.138 < 2e-16 ***
position대리    0.19231    0.08800   2.185  0.0297 *
position과장이상 0.49231    0.09083   5.420 1.23e-07 ***
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 0.6346 on 297 degrees of freedom

Multiple R-squared: 0.09072, Adjusted R-squared: 0.0846

F-statistic: 14.82 on 2 and 297 DF, p-value: 7.35e-07

ROI 만든 더미변수가 실제로 어떻게 생겼는지 `model.matrix()` 로 볼 수 있습니다.

● R이 만든 더미변수 (처음 네 사람)

```
head(model.matrix(m_pos), 4)
d$position[1:4]
```

실행 결과

```
(Intercept) position대리 position과장이상
1           1           1           0
2           1           0           1
3           1           0           1
4           1           1           0
[1] 대리      과장이상 과장이상 대리
Levels: 사원 대리 과장이상
```

첫 번째 사람은 대리라서 `position대리` 열이 1, 두 번째 사람은 과장이상이라서 `position과장이상` 열이 1입니다. 회귀식은 이렇습니다.

$$\widehat{\text{만족}} = 3.058 + 0.192 \times D_{\text{대리}} + 0.492 \times D_{\text{과장이상}}$$

직급마다 더미 값을 넣어 보면 계수의 의미가 드러납니다.

직급	대입	예측값	실제 평균
사원	$3.058 + 0 + 0$	3.058	3.058
대리	$3.058 + 0.192$	3.250	3.250
과장이상	$3.058 + 0.492$	3.550	3.550

더미변수의 계수는 평균의 차이입니다

절편은 기준 집단(사원)의 평균입니다. 각 더미의 계수는 그 집단의 평균이 기준 집단보다 얼마나 높은지입니다.

- `position대리` 0.192 = 대리 평균 - 사원 평균
- `position과장이상` 0.492 = 과장이상 평균 - 사원 평균

계수 옆의 t 검정은 "그 집단과 기준 집단의 평균이 같은가"를 검정합니다. 대리과 사원의 차이는 $p = .030$, 과장이상과 사원의 차이는 $p < .001$ 입니다.




그림 6-1 직급별 직무만족 평균. 절편은 기준 집단인 사원의 평균이고, 두 더미의 계수는 사원 평균에서 각 집단 평균까지의 높이 차이이다.

■ 분산분석과 같은 결과

`summary()` 마지막 줄을 보십시오. $F(2, 297) = 14.82, p < .001$. 1권 9장의 일원분산분석을 그대로 돌려 봅니다.

● 같은 자료를 분산분석으로

```
summary(aov(satisfaction ~ position, data = d))
```

실행 결과

```

      Df Sum Sq Mean Sq F value    Pr(>F)
position    2  11.93    5.967   14.82 7.35e-07 ***
Residuals 297 119.60    0.403
---

```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

F 값, 자유도, 유의확률이 모두 같습니다. 우연이 아닙니다. 분산분석은 독립변수가 더미변수뿐인 회귀분석입니다.

	분산분석	회귀분석
집단 간 제곱합	$SS_B = 11.93$	$SS_R = 11.93$
집단 내 제곱합	$SS_W = 119.60$	$SS_E = 119.60$
설명된 비율	$\eta^2 = .091$	$R^2 = .091$

1권 9장에서 " η^2 은 회귀분석의 R^2 과 같은 개념"이라고 했던 것이 여기서 확인됩니다. 같은 개념이 아니라 같은 숫자입니다.

1권의 결과를 회귀분석으로

1권 9장의 교수법 자료를 회귀분석으로 다시 돌려 봅니다.

1권 9장 교수법 자료

```
tc <- read.csv("data/teaching.csv")
summary(lm(score ~ method, data = tc))
```

실행 결과

Call:

```
lm(formula = score ~ method, data = tc)
```

Residuals:

Min	1Q	Median	3Q	Max
-7.300	-1.875	1.050	1.800	5.800

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	68.200	1.075	63.434	< 2e-16 ***
methodB	5.400	1.520	3.552	0.00143 **
methodC	9.100	1.520	5.985	2.2e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.4 on 27 degrees of freedom

Multiple R-squared: 0.573, Adjusted R-squared: 0.5414

F-statistic: 18.12 on 2 and 27 DF, p-value: 1.024e-05

마지막 줄의 $F(2, 27) = 18.12, p = 1.02e-05$ 가 1권의 분산분석 결과와 같고, $R^2 = .573$ 은 1권의 $\eta^2 = .57$ 입니다. 절편 68.2는 교수법 A의 평균, `methodB` 5.4와 `methodC` 9.1은 각각 B와 C가 A보다 높은 만큼입니다(73.6 - 68.2, 77.3 - 68.2).

t-검정은 더미 하나짜리 회귀입니다

집단이 둘이면 더미변수가 하나입니다. 1권 7장의 자아존중감 자료로 확인합니다.

1권 7장 자료: t-검정과 회귀분석

```
df <- read.csv("data/sample_data.csv")
df$gender <- factor(df$gender, levels = c(1, 2), labels = c("남성", "여성"))

t.test(selfesteem ~ gender, data = df, var.equal = TRUE)$statistic
summary(lm(selfesteem ~ gender, data = df))$coefficients
```

실행 결과

```

t
-3.934343

      Estimate Std. Error   t value    Pr(>|t|)
(Intercept) 3.2882203 0.07453289 44.117706 1.481892e-116
gender여성   0.4112879 0.10453788  3.934343 1.095125e-04
  
```

t 의 크기 3.934와 유의확률 .0001095가 같습니다. 부호만 다른데, t -검정은 남성 - 여성을, 회귀분석은 여성 - 남성(기준 집단이 남성)을 계산했기 때문입니다. 회귀계수 0.411은 1권에서 구한 두 평균의 차이(3.6995 - 3.2882)입니다.




그림 6-2 두 집단을 0과 1에 놓고 평균끼리 이으면 그 선의 기울기가 평균 차이이다. 독립표본 t -검정은 이 기울기가 0인지를 검정하는 회귀분석이다.

하나의 모형, 여러 이름

1권과 2권에서 배운 분석은 대부분 **같은 모형의 다른 모습**입니다.

독립변수	분석 이름
집단 2개	독립표본 t -검정 = 더미 1개 회귀
집단 3개 이상	일원분산분석 = 더미 여러 개 회귀
연속변수 1개	단순회귀
연속변수 여러 개	다중회귀
집단 + 연속변수	공분산분석 = 더미와 연속변수를 함께 넣은 회귀

통계학에서는 이 모두를 **일반선형모형(general linear model)**이라는 하나의 이름으로 부릅니다. R의 `t.test()`, `aov()`, `lm()` 에 모두 같은 `y ~ x` 문법을 쓰는 이유입니다.

■ 기준 집단 바꾸기

기준 집단을 과장이상으로 바꾸면 계수가 달라집니다.

● 과장이상을 기준으로

```
d$position_m <- relevel(d$position, ref = "과장이상")
coef(lm(satisfaction ~ position_m, data = d))
```

실행 결과

```
(Intercept) position_m사원 position_m대리
      3.5500000      -0.4923077      -0.3000000
```

절편이 과장이상의 평균 3.55가 되고, 두 계수는 사원과 대리가 과장이상보다 낮은 만큼(-0.492, -0.300)이 됩니다. 모형 자체는 바뀌지 않습니다. R^2 , F , 각 집단의 예측값이 모두 같습니다. **기준 집단은 어떤 비교를 계수로 보고 싶은지에 따라 고릅니다.** 보통은 가장 큰 집단, 통제 집단, 또는 이론적 출발점(가장 낮은 직급)을 기준으로 삼습니다.

■ 모든 쌍을 비교하려면

기준 집단이 사원이면 계수는 "사원 대 대리", "사원 대 과장이상"만 보여줍니다. 대리와 과장이상의 비교는 없습니다. 세 쌍을 모두 비교하려면 1권 10장의 다중비교가 필요합니다. `emmeans` 패키지가 회귀모형에서 바로 Tukey 비교를 해 줍니다.

● 회귀모형에서 Tukey 다중비교

```
library(emmeans)
emmeans(m_pos, pairwise ~ position)
```

실행 결과

\$emmeans

position	emmean	SE	df	lower.CL	upper.CL
사원	3.06	0.0622	297	2.94	3.18
대리	3.25	0.0622	297	3.13	3.37
과장이상	3.55	0.0662	297	3.42	3.68

Confidence level used: 0.95

\$contrasts

contrast	estimate	SE	df	t.ratio	p.value
사원 - 대리	-0.192	0.0880	297	-2.185	0.0754
사원 - 과장이상	-0.492	0.0908	297	-5.420	<.0001
대리 - 과장이상	-0.300	0.0908	297	-3.303	0.0031

P value adjustment: tukey method for comparing a family of 3 estimates

`$contrasts` 의 세 줄이 Tukey 방법으로 보정한 비교입니다. 사원과 대리의 차이는 더미의 t 검정에서 $p = .030$ 이었지만 **보정 후에는 $p = .075$ 로 유의하지 않습니다.** 비교를 세 번 하므로 오류 누적을 막는 대가입니다. 1권 10장에서 본 그대로입니다.

더미의 t 검정만으로 "직급 차이가 있다"고 하지 않습니다

"직급이 직무만족과 관련이 있는가"는 **두 더미를 함께** 검정하는 질문입니다. 위의 $F(2, 297) = 14.82$ 가 그 답입니다. 개별 더미의 t 검정은 기준 집단과의 비교일 뿐이라서, 기준 집단을 바꾸면 결과가 달라집니다.

순서는 1권 9~10장과 같습니다. **먼저 F 검정으로 범주 전체의 효과를 확인하고, 유의하면 다중비교로 어느 쌍이 다른지 봅니다.**

■ 연속변수와 함께 넣기

더미변수는 연속변수와 함께 넣을 수 있습니다. 직급이 높으면 만족이 높은 이유가 **소진이 덜해서**일 수도 있습니다. 소진을 함께 넣어 봅니다.

● 직급과 소진을 함께

```
m_both <- lm(satisfaction ~ position + burnout, data = d)
round(summary(m_both)$coefficients, 3)
anova(lm(satisfaction ~ burnout, data = d), m_both)
```

실행 결과

```
Estimate Std. Error t value Pr(>|t|)
(Intercept)      4.261      0.154  27.740    0.000
position대리      0.199      0.079   2.512    0.013
position과장이상  0.424      0.082   5.160    0.000
burnout          -0.414      0.049  -8.412    0.000
```

Analysis of Variance Table

Model 1: satisfaction ~ burnout

Model 2: satisfaction ~ position + burnout

```
Res.Df    RSS Df Sum of Sq    F    Pr(>F)
1     298 105.211
2     296  96.527  2     8.6839 13.315 2.904e-06 ***
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

3장의 해석이 그대로 적용됩니다. `position과장이상` 0.424는 "소진 수준이 같다면, 과장이상이 사원보다 만족이 0.42점 높다"입니다. 소진을 넣기 전의 0.492보다 조금 줄었습니다. 직급 차이의 일부가 소진 차이로 설명된 것입니다.

직급 전체의 효과는 `anova()` 로 두 더미를 함께 검정합니다. 소진을 통제해도 $F(2, 296) = 13.32, p < .001$ 로 직급의 효과가 유의합니다. 1권에서 다루지 않은 **공분산분석(ANCOVA)**이 바로 이것입니다. 집단 비교에 연속변수를 통제변수로 더한 회귀분석입니다.

■ 이분 변수는 0과 1로

성별처럼 범주가 둘인 변수는 직접 0과 1로 만들어 넣어도 됩니다. 어느 쪽을 1로 했는지를 반드시 밝힙니다.

● 성별을 0과 1로

```
d$female <- ifelse(d$gender == "여", 1, 0)
coef(lm(burnout ~ female, data = d))
```

실행 결과

```
(Intercept)      female
2.82743750    0.06863393
```

`female` 의 계수 0.069는 여성의 소진이 남성보다 0.07점 높다는 뜻입니다(유의하지 않음). 결과표에는 "성별(0 = 남, 1 = 여)"처럼 코딩을 함께 적습니다. 그래야 독자가 계수의 부호를 해석할 수 있습니다.

■ 논문 결과표

표 6. 직급과 소진이 직무만족에 미치는 영향

변수	B	SE	t	p
(상수)	4.261	0.154	27.74	< .001
직급 (기준: 사원)				
대리	0.199	0.079	2.51	.013
과장이상	0.424	0.082	5.16	< .001
소진	-0.414	0.049	-8.41	< .001

주. $N = 300$. $R^2 = .266$, $F(3, 296) = 35.79$, $p < .001$. 직급 전체의 효과: $F(2, 296) = 13.32$, $p < .001$.

결과 서술 예시

직급(기준 집단: 사원)을 더미변수로 변환하여 소진과 함께 투입한 회귀분석을 실시하였다(표 6). 소진을 통제된 상태에서 직급의 효과는 통계적으로 유의하였다($F(2, 296) = 13.32$, $p < .001$). 과장이상($B = 0.424$, $p < .001$)과 대리($B = 0.199$, $p = .013$)는 사원보다 직무만족이 유의하게 높았다. 소진은 직무만족에 부정적으로 유의한 영향을 미쳤다($B = -0.414$, $p < .001$).

더미변수에는 표준화 계수 β 를 보고하지 않는 편이 좋습니다. 0과 1뿐인 변수에서 "1 표준편차 높다"는 말은 의미가 없기 때문입니다.

점검 항목

- ☐ 범주형 변수를 1, 2, 3 숫자 그대로 넣지 않았다
- ☐ 더미는 범주 수보다 하나 적게 만들었다
- ☐ 기준 집단을 의도대로 지정했고(`levels` , `relevel`) 결과표에 밝혔다
- ☐ 더미 계수를 "기준 집단과의 평균 차이"로 읽었다
- ☐ 범주 전체의 효과는 F 검정으로, 모든 쌍 비교는 다중비교로 확인했다
- ☐ 이분 변수의 코딩(0 = ?, 1 = ?)을 표기했다

요약 — 범주형 변수는 **더미변수**로 바꿔 회귀분석에 넣습니다. 절편은 기준 집단의 평균, 더미의 계수는 기준 집단과의 평균 차이입니다. 이렇게 하면 -검정은 더미 하나, 분산분석은 더미 여러 개, 공분산분석은 더미와 연속변수를 함께 넣은 회귀분석이 됩니다. 1권과 2권의 분석은 모두 **일반선형모형** 하나의 다른 모습입니다.

무엇을 더 설명하는가 — 위계적 회귀

학위논문의 회귀분석 표는 대부분 모형 1, 모형 2로 나뉘어 있습니다. 변수를 한꺼번에 넣지 않고 묶음으로 나눠 차례로 넣는 이유, 그리고 그때 보고하는 설명력의 증가분이 무엇인지를 다룹니다.

■ 한꺼번에 넣으면 알 수 없는 것

3장에서는 스트레스, 지지, 효능감을 한꺼번에 넣었습니다. 그런데 소진에 영향을 줄 만한 것은 그것만이 아닙니다. 성별, 연령, 근속연수 같은 **인구학적 변수**도 소진과 관련이 있을 수 있습니다.

연구자가 정말 묻고 싶은 것은 대개 이렇습니다.

"인구학적 특성의 영향을 감안하고도, 직무 관련 변수들이 소진을 추가로 설명하는가. 얼마나 더 설명하는가."

여섯 변수를 한꺼번에 넣으면 각 계수는 알 수 있지만, **직무 관련 변수 묶음이 더해 준 설명력**은 따로 보이지 않습니다. 이 질문에 답하려면 변수를 묶음으로 나눠 **순서대로** 넣고, 묶음이 들어갈 때마다 R^2 이 얼마나 늘어나는지 봐야 합니다. 이것이 **위계적 회귀분석(hierarchical regression)**입니다.

■ 순서는 연구자가 정합니다

변수를 넣는 순서는 연구 질문이 정합니다. 일반적인 원칙은 다음과 같습니다.

단계	넣는 변수	이유
1단계	통제변수 (성별, 연령, 근속연수)	관심 변수와 무관하게 결과에 영향을 줄 수 있는 것을 먼저 건어 냄
2단계	주요 독립변수 (스트레스, 지지, 효능감)	연구의 핵심 질문
3단계	상호작용항 등	2단계 위에서만 의미가 있는 것 (8장)

시간이나 인과의 순서를 따르기도 합니다. 성별과 연령은 직장 경험보다 먼저 정해져 있으므로 앞에 둡니다.

위계적 회귀 ≠ 단계선택 ≠ 위계적 선형모형

이름이 비슷해서 자주 혼동합니다.

- **위계적 회귀분석**: 연구자가 **이론에 따라** 묶음과 순서를 정합니다. 이 장의 내용입니다.
- **단계선택(stepwise)**: 컴퓨터가 **유의확률에 따라** 변수를 넣고 뺍니다. 3장에서 피해야 한다고 했던 방법입니다.

- **위계적 선형모형(HLM):** 학생이 학급에, 직원이 팀에 속하는 것처럼 **자료 자체가 위계적인** 경우의 다층모형입니다. 4장의 독립성 위반에 대한 해결책이며, 전혀 다른 분석입니다.

논문의 연구방법에 "위계적 회귀분석"이라고 쓸 때 어느 것인지 혼동이 없도록 투입 단계를 함께 밝힙니다.

■ R로 돌리기

1단계 — 통제변수만

- 1단계: 성별, 연령, 근속연수

```
d <- read.csv("data/survey.csv")
d$female <- ifelse(d$gender == "여", 1, 0)

m1 <- lm(burnout ~ female + age + tenure, data = d)
summary(m1)
```

실행 결과

Call:

```
lm(formula = burnout ~ female + age + tenure, data = d)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-1.89432	-0.47675	-0.04907	0.43317	1.67863

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.204276	0.315947	10.142	<2e-16 ***
female	0.081676	0.078588	1.039	0.300
age	-0.010452	0.010692	-0.978	0.329
tenure	0.001109	0.014810	0.075	0.940

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6744 on 296 degrees of freedom

Multiple R-squared: 0.01302, Adjusted R-squared: 0.003016

F-statistic: 1.301 on 3 and 296 DF, p-value: 0.2741

1단계 모형은 소진 변동의 1.3%를 설명하며 유의하지 않습니다($F(3, 296) = 1.30, p = .274$). 세 통제변수 가운데 개별적으로 유의한 것도 없습니다.

통제변수가 유의하지 않아도 그대로 둡니다

"유의하지 않으니 빼자"는 판단은 하지 않습니다. 통제변수를 넣은 것은 그 효과를 검증하기 위해서가 아니라 감안하기 위해서입니다. 연구 설계 단계에서 넣기로 했다면, 결과와 상관없이 그대로 두고 보고합니다.

2단계 — 주요 독립변수를 더함

`update()` 는 기존 모형에 변수를 더할 때 편리합니다. `. ~ .` 은 "기존 모형 그대로"라는 뜻입니다.

● 2단계: 스트레스, 지지, 효능감을 더함

```
m2 <- update(m1, . ~ . + stress + support + efficacy)
summary(m2)
```

실행 결과

Call:

```
lm(formula = burnout ~ female + age + tenure + stress + support +
    efficacy, data = d)
```

Residuals:

Min	1Q	Median	3Q	Max
-1.59654	-0.30840	0.02094	0.35546	1.25092

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	3.161474	0.405408	7.798	1.11e-13	***
female	0.074002	0.061325	1.207	0.228514	
age	-0.007663	0.008361	-0.916	0.360162	
tenure	-0.002476	0.011560	-0.214	0.830539	
stress	0.520697	0.050651	10.280	< 2e-16	***
support	-0.210956	0.054783	-3.851	0.000145	***
efficacy	-0.247094	0.058321	-4.237	3.04e-05	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.526 on 293 degrees of freedom

Multiple R-squared: 0.4056, Adjusted R-squared: 0.3935

F-statistic: 33.33 on 6 and 293 DF, p-value: < 2.2e-16

R^2 이 .013에서 **.406**으로 늘었습니다. 늘어난 만큼이 결정계수 변화량 ΔR^2 입니다.

$$\Delta R^2 = R_2^2 - R_1^2 = .4056 - .0130 = .393$$

2단계 변수들이 추가로 설명한 몫

늘어난 몫이 유의한가

ΔR^2 의 유의성은 두 모형을 비교하는 F 검정으로 확인합니다. 3장과 5장에서 변수 묶음을 함께 뺄 때 썼던 바로 그 `anova()` 입니다.

● 두 모형 비교 (F 변화량 검정)

```
anova(m1, m2)
```

실행 결과

Analysis of Variance Table

Model 1: burnout ~ female + age + tenure

Model 2: burnout ~ female + age + tenure + stress + support + efficacy

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	296	134.633				
2	293	81.075	3	53.557	64.517	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$$F_{\text{change}} = \frac{(SS_{E1} - SS_{E2})/\Delta df}{SS_{E2}/df_2} = \frac{(134.633 - 81.075)/3}{81.075/293} = 64.52$$

줄어든 잔차제곱합 ÷ 남은 잔차제곱합

$\Delta R^2 = .393$, $F(3, 293) = 64.52$, $p < .001$. 인구학적 변수를 통제한 뒤에도 직무 관련 세 변수가 소진 변동의 39.3%를 추가로 설명합니다.




그림 7-1 단계별 설명력. 통제변수가 1.3%를 설명하고, 직무 관련 변수가 39.3%를 더한다. 위계적 회귀가 보고하는 핵심은 이 '더해진 몫'이다.

F 변화량 검정은 늘 같은 질문입니다

"작은 모형에 변수 몇 개를 더했더니 잔차가 줄었다. 그 줄어든 만큼이 우연으로 볼 수 있는 수준보다 큰가."

5장에서 스트레스와 업무과부하를 함께 뺀 때, 6장에서 직급 더미 두 개를 함께 검정할 때, 지금 세 변수 묶음을 더할 때 모두 같은 검정입니다. 분자의 자유도(Δdf)는 더한 변수의 수, 분모의 자유도는 큰 모형의 잔차 자유도입니다.

효과크기

ΔR^2 자체가 효과크기이지만, Cohen의 f^2 으로 바꿔 보고하기도 합니다.

$$f^2 = \frac{\Delta R^2}{1 - R^2} = \frac{.393}{1 - .406} = 0.66$$

더해진 몫 ÷ 아직 설명되지 않은 몫

f^2	해석 (Cohen, 1988)
.02	작은 효과
.15	중간 효과
.35 이상	큰 효과

0.66은 큰 효과입니다. 8장의 조절효과처럼 ΔR^2 이 .02~.04 수준일 때 이 기준이 특히 쓸모가 있습니다.

■ 계수는 마지막 모형에서 읽습니다

2단계의 스트레스 계수(0.521)는 3장의 0.526과 조금 다릅니다. 성별, 연령, 근속연수까지 통제한 값이기 때문입니다. 각 변수의 효과를 해석할 때는 **모든 변수가 들어간 마지막 모형**의 계수를 씁니다. 1단계 계수는 "통제변수만 있을 때" 어떠했는지를 보여줄 뿐입니다.

- 2단계 모형의 표준화 계수

```
library(effects)
standardize_parameters(m2)
```

실행 결과

```
# Standardization method: refit
```

Parameter	Std. Coef.	95% CI
(Intercept)	-1.32e-16	[-0.09, 0.09]
female	0.05	[-0.03, 0.14]
age	-0.08	[-0.25, 0.09]
tenure	-0.02	[-0.19, 0.15]
stress	0.48	[0.39, 0.57]
support	-0.19	[-0.28, -0.09]
efficacy	-0.20	[-0.30, -0.11]

순서가 바뀌는 것과 바뀌지 않는 것

같은 여섯 변수를 거꾸로, 직무 변수를 먼저 넣고 통제변수를 나중에 넣으면 어떻게 될까요.

- 순서를 뒤집으면: 통제변수를 나중에

```
m_job <- lm(burnout ~ stress + support + efficacy, data = d)
anova(m_job, m2)
summary(m2)$r.squared - summary(m_job)$r.squared
```

실행 결과

Analysis of Variance Table

Model 1: burnout ~ stress + support + efficacy

Model 2: burnout ~ female + age + tenure + stress + support + efficacy

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	296	82.579				
2	293	81.075	3	1.5041	1.8119	0.1451

[1] 0.01102614

순서	통제변수의 ΔR^2	직무 변수의 ΔR^2
통제변수 먼저	.013	.393
직무 변수 먼저	.011	.395

마지막 모형은 같습니다. 계수, R^2 , 표준오차 모두 그대로입니다. 바뀌는 것은 각 묶음에 돌아가는 ΔR^2 입니다. 두 묶음이 함께 설명하는 몫(여기서는 아주 작음)이 **먼저 들어간 쪽에 돌아갑니다.** 그래서 순서가 곧 연구자의 주장입니다. "통제변수를 먼저 넣었다"는 것은 겁치는 몫이 있다면 통제변수 쪽에 양보하고, 그래도 남는 직무 변수의 몫만 주장하겠다는 보수적인 선택입니다.

결측치가 있으면 두 모형의 사례 수가 달라집니다

`lm()` 은 모형에 들어간 변수 중 하나라도 비어 있는 사람을 빼고 계산합니다. 2단계에서 넣은 변수에 결측이 있으면 2단계 모형의 사례 수가 1단계보다 적어지고, `anova()` 는 다음 오류를 냅니다.

```
models were not all fitted to the same size of dataset
```

사례 수가 다른 두 모형의 R^2 을 빼는 것은 의미가 없습니다. **분석에 쓸 모든 변수가 있는 사람만 먼저 골라 두고** 그 자료로 모든 단계를 돌립니다.

```
d_c <- na.omit(d[, c("burnout", "female", "age", "tenure", "stress", "support",  
"efficacy")])
```

■ 논문 결과표

위계적 회귀분석의 결과표는 단계마다 열을 나란히 둡니다.

표 7. 소진에 대한 위계적 회귀분석 결과

변수	모형 1 B	모형 1 β	모형 2 B	모형 2 β
성별 (0 = 남, 1 = 여)	0.082	—	0.074	—
연령	-0.010	-.11	-0.008	-.08
근속연수	0.001	.01	-0.002	-.02
직무스트레스			0.521***	.48
사회적지지			-0.211***	-.19
자기효능감			-0.247***	-.20
R^2	.013		.406	
수정 R^2	.003		.393	
ΔR^2			.393***	
F	1.30		33.33***	

주. N = 300. 성별은 더미변수이므로 β 를 보고하지 않았다. *** $p < .001$.

결과 서술 예시

인구학적 변수를 통제한 상태에서 직무 관련 변수가 소진에 미치는 영향을 검증하기 위해 위계적 회귀분석을 실시하였다(표 7). 1단계에서 투입한 성별, 연령, 근속연수는 소진을 유의하게 설명하지 못하였다($R^2 = .013$, $F(3, 296) = 1.30$, $p = .274$).

2단계에서 직무스트레스, 사회적지지, 자기효능감을 추가로 투입한 결과 설명력이 39.3% 증가하였으며 이는 통계적으로 유의하였다($\Delta R^2 = .393$, $F(3, 293) = 64.52$, $p < .001$, $f^2 = 0.66$). 직무스트레스는 소진에 정적인 영향을($\beta = .48$, $p < .001$), 사회적지지($\beta = -.19$, $p < .001$)와 자기효능감($\beta = -.20$, $p < .001$)은 부적인 영향을 미쳤다.

ΔR^2 과 그 F 검정이 위계적 회귀분석의 결론입니다. 이 두 값을 반드시 함께 씁니다.

점검 항목

- ☐ 투입 순서를 연구 질문과 이론에 따라 정했다
- ☐ 위계적 회귀와 단계선택, 위계적 선형모형을 구분했다
- ☐ 단계마다 R^2 , ΔR^2 , F 변화량 검정을 보고했다
- ☐ 모든 단계를 같은 사례로 돌렸다(결측 처리)
- ☐ 계수는 마지막 모형에서 해석했다
- ☐ 통제변수가 유의하지 않아도 빼지 않았다

요약 — 위계적 회귀분석은 변수를 연구자가 정한 순서대로 묶음으로 넣고, 묶음이 더해질 때마다 늘어나는 설명력 과 그 유의성(변화량 검정)을 봅니다. 마지막 모형은 순서와 상관없이 같지만, 겹치는 묶이 먼저 들어간 묶음에 돌아가므로 순서가 곧 연구자의 주장입니다. 통제변수를 먼저 넣는 것은 그 주장을 보수적으로 하겠다는 뜻입니다.

언제, 누구에게 더 강한가 — 조절효과

스트레스가 소진을 높인다는 것은 이미 확인했습니다. 다음 질문은 "모든 사람에게 똑같이 그런가"입니다. 어떤 조건에서 그 영향이 강해지거나 약해지는지를 보는 것이 조절효과 분석입니다.

■ 질문이 바뀝니다

지금까지의 질문은 "스트레스가 소진과 관련이 있는가, 얼마나 관련이 있는가"였습니다. 답은 기울기 하나였습니다. 모든 사람에게 같은 기울기를 적용했습니다.

그런데 직관적으로 이런 생각이 듭니다. 같은 스트레스를 받아도 **기댈 곳이 있는 사람은 덜 무너지지 않을까**. 동료와 상사의 지지가 스트레스의 충격을 흡수해 주는 것입니다. 이를 **완충 가설(buffering hypothesis)**이라 합니다(Cohen & Wills, 1985).

이 가설을 통계의 언어로 바꾸면 이렇습니다.

"스트레스가 소진에 미치는 영향(기울기)의 크기가 사회적지지 수준에 따라 달라지는가."

이처럼 한 변수의 효과 크기를 바꾸는 제3의 변수를 **조절변수(moderator)**라 하고, 그 현상을 **조절효과(moderation)**라 합니다.




그림 8-1 조절효과의 개념 모형과 통계 모형. 왼쪽처럼 조절변수는 화살표 자체를 겨냥한다. 실제 분석은 오른쪽처럼 두 변수의 곱을 하나의 독립변수로 넣어서 한다. (개념도)

1권 11장의 상호작용과 같은 것입니다

1권 11장에서 성별과 학교 유형의 **상호작용**을 보았습니다. 학교 유형에 따라 남녀 차이가 달랐고, 그래프의 선이 평행하지 않았습니다.

조절효과는 그것과 **같은 개념**입니다. 차이는 조절변수가 집단(학교 유형)이 아니라 연속변수(지지 점수)라는 것입니다. 그래서 "선이 평행하지 않다"가 "기울기가 조절변수 값에 따라 연속적으로 변한다"로 바뀝니다.

■ 곱하기 항 하나

조절효과는 두 변수를 **곱한 항**을 회귀식에 넣어 표현합니다.

$$\hat{Y} = b_0 + b_1X + b_2W + b_3XW$$

X 스트레스, W 지지, XW 둘의 곱

곱하기 항이 왜 "기울기가 달라진다"를 뜻하는지는 식을 X 에 대해 묶어 보면 보입니다.

$$\hat{Y} = (b_0 + b_2W) + (b_1 + b_3W)X$$

X 의 기울기 자리에 W 가 들어 있습니다

스트레스의 기울기가 하나의 숫자 b_1 이 아니라 $b_1 + b_3W$ 입니다. 지지(W)가 1점 높아질 때마다 스트레스의 기울기가 b_3 만큼 바뀝니다. b_3 이 **0이 아니면 조절효과가 있다**는 뜻이고, 검정할 것은 b_3 하나입니다.

계수	의미
b_3	지지가 1점 높아질 때 스트레스 기울기의 변화량. 조절효과 의 크기
b_1	지지가 0일 때 의 스트레스 기울기
b_2	스트레스가 0일 때 의 지지 기울기

b_1 과 b_2 의 해석에 주의하십시오. 곱하기 항이 들어가면 이들은 더 이상 "평균적인 효과"가 아니라 **상대 변수가 0일 때의 효과**입니다. 이것이 다음 절의 중심화가 필요한 이유입니다.

■ 먼저 중심화합니다

지지와 스트레스는 1~5점 척도라 0점이 없습니다. 원점수 그대로 곱하기 항을 넣으면 어떻게 되는지 봅시다.

● 원점수로 곱하기 항을 넣으면

```
library(car)
d <- read.csv("data/survey.csv")
m_raw <- lm(burnout ~ efficacy + stress * support, data = d)
round(coef(m_raw), 3)
round(vif(m_raw), 2)
```

실행 결과

(Intercept)	efficacy	stress	support	stress:support
-1.295	-0.237	1.871	0.948	-0.380
efficacy	stress	support	stress:support	
1.12	37.32	26.75	49.59	

R 모형식의 `stress * support` 는 `stress + support + stress:support` 를 줄인 것입니다. 결과에 두 가지 문제가 보입니다.

① 계수가 엉뚱합니다. 스트레스 계수 1.871은 "지지가 0점인 사람"의 기울기이고, 지지 계수 **+0.948**은 "스트레스가 0점인 사람"의 기울기입니다. 둘 다 존재하지 않는 사람입니다. 지지가 소진을 높이는 것처럼 보이는 양수 부호도 이 때문입니다.

② VIF가 37~50입니다. XW 는 X 와 W 를 곱해 만들었으니 원래 변수들과 상관이 높을 수밖에 없습니다. 이를 **비본질적 다중공선성**이라 합니다. 5장의 다중공선성과 달리 변수의 측정 원점을 옮기기만 하면 사라집니다.

해결책은 2장에서 본 **평균 중심화**입니다. 곱하기 전에 각 변수에서 평균을 뺍니다.

● 중심화한 뒤 곱하기 항

```
d$stress_c <- d$stress - mean(d$stress)
d$support_c <- d$support - mean(d$support)
m_int <- lm(burnout ~ efficacy + stress_c * support_c, data = d)
round(coef(m_int), 3)
round(vif(m_int), 2)
```

실행 결과

(Intercept)	efficacy	stress_c	support_c
3.684	-0.237	0.533	-0.223
stress_c:support_c			
-0.380			
efficacy	stress_c	support_c	stress_c:support_c
1.12	1.06	1.15	1.00

VIF가 모두 1 근처로 떨어졌습니다. 그리고 이제 `stress_c` 의 계수는 **지지가 평균인 사람의 스트레스 기울기**, `support_c` 의 계수는 **스트레스가 평균인 사람의 지지 기울기**가 됩니다. 해석할 수 있는 값입니다.

중심화는 모형을 바꾸지 않습니다

중심화 전후로 바뀌는 것은 b_1 , b_2 와 그 표준오차뿐입니다. 곱하기 항의 계수 b_3 과 그 검정, R^2 , 예측값은 완전히 같습니다. 위 두 출력에서 `stress:support`와 `stress_c:support_c`의 계수가 모두 -0.380인 것을 확인하십시오. 중심화는 결과를 바꾸는 조작이 아니라 해석하기 좋은 자리로 원점을 옮기는 것입니다.

종속변수는 중심화하지 않습니다. 곱하기 항에 들어가는 독립변수와 조절변수만 중심화합니다.

■ R로 돌리기

7장의 위계적 회귀와 같은 방식으로, 곱하기 항을 마지막 단계에 넣어 ΔR^2 을 봅니다. 자기효능감은 통제변수로 함께 넣습니다.

- 1단계: 주효과, 2단계: 곱하기 항

```
m_main <- lm(burnout ~ efficacy + stress_c + support_c, data = d)
summary(m_int)
anova(m_main, m_int)
```

실행 결과

Call:

```
lm(formula = burnout ~ efficacy + stress_c * support_c, data = d)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-1.36830 -0.30804  0.02486  0.34398  1.39691
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    3.68364    0.20384  18.071 < 2e-16 ***
efficacy       -0.23651    0.05587  -4.234 3.08e-05 ***
stress_c        0.53297    0.04911  10.852 < 2e-16 ***
support_c      -0.22287    0.05294  -4.210 3.40e-05 ***
stress_c:support_c -0.38015    0.08133  -4.674 4.50e-06 ***
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5105 on 295 degrees of freedom

Multiple R-squared: 0.4364, Adjusted R-squared: 0.4287

F-statistic: 57.1 on 4 and 295 DF, p-value: < 2.2e-16

Analysis of Variance Table

Model 1: burnout ~ efficacy + stress_c + support_c

Model 2: burnout ~ efficacy + stress_c * support_c

```
   Res.Df  RSS Df Sum of Sq    F    Pr(>F)
1     296 82.579
2     295 76.886  1    5.6937 21.846 4.499e-06 ***
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

출력의 이 자리	값	의미
<code>stress_c:support_c</code>	-0.380, $p < .001$	조절효과. 지지가 1점 높을수록 스트레스의 기울기가 0.38 작아진다
<code>stress_c</code>	0.533	지지가 평균(3.52점)인 사람의 스트레스 기울기
<code>support_c</code>	-0.223	스트레스가 평균인 사람의 지지 기울기
<code>anova()</code> 의 F	21.85, $p < .001$	곱하기 항이 더한 설명력의 검정

곱하기 항이 더한 설명력은 $\Delta R^2 = .4364 - .3946 = .042$ 입니다. 7장의 f^2 으로는 $.042/(1 - .436) = 0.074$ 로, 작은 효과(.02)와 중간 효과(.15) 사이입니다.

조절효과의 ΔR^2 은 원래 작습니다

4%라고 하면 작아 보입니다. 그러나 조절효과는 "효과의 차이"를 재는 것이라 주효과보다 훨씬 작게 나오는 것이 정상입니다. Aguinis 등(2005)이 30년간의 연구를 검토한 결과 조절효과의 f^2 중앙값은 .002였습니다. 이 기준으로 보면 0.074는 상당히 큰 조절효과입니다.

같은 이유로 조절효과를 검정하려면 주효과보다 **훨씬 큰 표본**이 필요합니다. 사례가 적은 연구에서 조절효과가 유의하지 않았다고 "조절효과가 없다"고 결론 내리지 않습니다.

■ 단순기울기 — 지지 수준별로 나눠 보기

$b_3 = -0.380$ 은 "기울기가 달라진다"는 것을 알려주지만, 구체적으로 지지가 낮은 사람과 높은 사람에게 스트레스의 기울기가 각각 얼마인지는 따로 구해야 합니다. 이것을 **단순기울기(simple slope)**라 합니다.

관례적으로 조절변수의 **평균 -1 SD**, **평균**, **평균 +1 SD** 세 지점에서 구합니다. 지지의 표준편차는 0.597이므로 2.92점, 3.52점, 4.12점입니다.

원점을 옮기는 방법

`stress_c`의 계수가 "`support_c`가 0인 사람의 기울기"라는 성질을 이용합니다. 지지에서 평균 대신 **"평균 - 1 SD"**를 빼서 중심화하면, 그 변수가 0인 사람은 지지가 낮은 사람이 되고, `stress_c`의 계수는 그 사람들의 기울기가 됩니다.

● 지지 수준을 바꿔 가며 스트레스 기울기 구하기

```
s ← sd(d$support)
for(k in c(-1, 0, 1)) {
  d$w ← d$support - (mean(d$support) + k * s)
  mk ← lm(burnout ~ efficacy + stress_c * w, data = d)
  cat(sprintf("지지 %d SD (%.2f점): 기울기 %.3f, SE %.3f, p = %.2g\n",
    k, mean(d$support) + k * s,
    coef(mk)["stress_c"], sqrt(vcov(mk)["stress_c", "stress_c"]),
    summary(mk)$coefficients["stress_c", 4]))
}
```

실행 결과

```
지지 -1 SD (2.92점): 기울기 0.760, SE 0.070, p = 2.6e-23
지지 +0 SD (3.52점): 기울기 0.533, SE 0.049, p = 2.6e-23
지지 +1 SD (4.12점): 기울기 0.306, SE 0.068, p = 1e-05
```

같은 결과를 `emmeans` 패키지로 한 번에 얻을 수도 있습니다.

● emmeans로 단순기울기와 신뢰구간

```
library(emmeans)
emtrends(m_int, ~ support_c, var = "stress_c", at = list(support_c = c(-s, 0, s)))
```

실행 결과

support_c	stress_c.trend	SE	df	lower.CL	upper.CL
-0.597	0.760	0.0700	295	0.622	0.898
0.000	0.533	0.0491	295	0.436	0.630
0.597	0.306	0.0681	295	0.172	0.440

Confidence level used: 0.95

사회적지지	스트레스의 기울기	95% CI
낮음 (-1 SD, 2.92점)	0.760***	[0.622, 0.898]
평균 (3.52점)	0.533***	[0.436, 0.630]
높음 (+1 SD, 4.12점)	0.306***	[0.172, 0.440]

지지가 낮은 사람에게는 스트레스가 1점 높을 때 소진이 0.76점 높지만, 지지가 높은 사람에게는 0.31점입니다. 기울기가 절반 이하로 줄어듭니다. 완충 가설이 지지됩니다.




그림 8-2 사회적지지 수준별 스트레스와 소진의 관계(단순기울기). 지지가 낮을수록 선이 가파르다. 자기효능감은 평균에 고정했다.

■ 어디서부터 유의하지 않은가 — 존슨-네이만 구간

± 1 SD라는 세 지점은 관례일 뿐 특별한 의미가 없습니다. 지지가 계속 높아지면 스트레스의 기울기는 점점 작아지다가 언젠가 0과 구분되지 않게 됩니다. 그 경계가 어디인지를 찾는 것이 존슨-네이만(Johnson-Neyman) 방법입니다.

단순기울기 $b_1 + b_3 W$ 의 표준오차는 계수들의 분산과 공분산으로 계산됩니다. 이것을 지지의 모든 값에서 구해 t 가 임계값 밑으로 내려가는 지점을 찾습니다.

● 존슨-네이만: 기울기가 유의하지 않게 되는 지지 점수

```
b ← coef(m_int); V ← vcov(m_int)
w ← seq(-2, 2, by = .001) # 중심화된 지지
sl ← b["stress_c"] + b["stress_c:support_c"] * w
se ← sqrt(V["stress_c", "stress_c"] + w^2 * V["stress_c:support_c", "stress_c:support_c"] +
          2 * w * V["stress_c", "stress_c:support_c"])
crit ← qt(.975, df.residual(m_int))
jn ← min(w[abs(sl / se) < crit]) + mean(d$support) # 원래 척도로
jn
sum(d$support ≥ jn)
```

실행 결과

```
[1] 4.4592
[1] 23
```

지지가 4.46점 이상이면 스트레스의 기울기가 유의하지 않습니다. 300명 가운데 23명이 이 범위에 있습니다. 지지가 아주 높은 사람에게는 스트레스와 소진의 관련이 통계적으로 확인되지 않는다는 뜻입니다.




그림 8-3 사회적지지 점수에 따른 스트레스 기울기와 95% 신뢰구간. 신뢰구간이 0을 포함하기 시작하는 4.46점이 존슨-네이만 경계다. 아래 막대는 지지 점수의 분포다.

경계 밖에서는 "효과가 없다"가 아닙니다

존슨-네이만 경계 위쪽은 기울기가 0과 구분되지 않는 구간이지, 0인 구간이 아닙니다. 그 범위의 사람이 23명뿐이라 추정이 불안정한 것도 이유입니다. "지지가 매우 높은 집단에서는 스트레스와 소진의 관련이 유의하지 않았다"로 씁니다.

4장에서 남긴 숙제

4장에서 직선 모형의 잔차에 약한 힘이 있었고, Tukey 검정이 유의했습니다. 그 이유로 이 장의 상호작용을 짐작했습니다. 곱하기 항을 넣은 모형으로 다시 확인합니다.

상호작용 모형의 곡선 검정

```
residualPlots(m_int, plot = FALSE)
```

실행 결과

```
Test stat Pr(>|Test stat|)
efficacy    -1.0096      0.31350
stress_c     2.4139      0.01639 *
support_c   -2.2258      0.02678 *
Tukey test   1.1287      0.25902
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

모형 전체의 힘을 보는 **Tukey 검정이 $p = .259$ 로 사라졌습니다.** 4장에서 보인 힘의 상당 부분은 스트레스의 기울기가 지지에 따라 다른 것을 직선 하나로 요약한 데서 왔던 것입니다. 스트레스 축의 약한 힘($p = .016$)은 남지만, 이차항을 더해도 설명력은 1.1%p 늘 뿐이어서 이 정도는 직선 모형으로 충분하다고 판단합니다.

집단이 모형에 빠진 것을 가리키고, 이론이 그것이 무엇인지 알려준 예입니다.

■ 조절효과를 볼 때 하지 말아야 할 것

조절변수를 두 집단으로 쪼개지 않습니다

지지를 중앙값 기준으로 "높은 집단"과 "낮은 집단"으로 나눠 따로 회귀분석하는 방법이 흔히 쓰입니다. 피해야 합니다.

- 연속변수를 둘로 자르면 정보를 버립니다. 중앙값 바로 위와 바로 아래의 사람이 완전히 다른 집단이 되고, 검정력이 크게 떨어집니다(MacCallum et al., 2002).
- 두 집단의 기울기가 **서로 다른지**는 검정하지 않습니다.

"한쪽은 유의, 다른 쪽은 비유의"는 조절효과의 증거가 아닙니다

남녀를 나눠 분석했더니 남자는 $p = .03$, 여자는 $p = .08$ 이었다고 합시다. 이것으로 "성별이 조절한다"고 할 수 없습니다. 두 기울기가 0.30과 0.27로 거의 같은데 한쪽 표본이 작아서 유의성만 갈렸을 수 있습니다.

"유의함과 유의하지 않음의 차이는 그 자체로 유의하지 않을 수 있습니다"(Gelman & Stern, 2006). 조절효과는 반드시 **곱하기 항의 검정**으로 확인합니다. 성별처럼 범주형 조절변수라면 더미변수와 독립변수의 곱을 넣으면 됩니다.

■ 논문 결과표

표 8. 사회적지지의 조절효과

변수	1단계 B (SE)	2단계 B (SE)
자기효능감	-0.227 (0.058)***	-0.237 (0.056)***
직무스트레스 (X)	0.526 (0.051)***	0.533 (0.049)***
사회적지지 (W)	-0.222 (0.055)***	-0.223 (0.053)***
X × W		-0.380 (0.081)***
R^2	.395	.436
ΔR^2		.042***

주. $N = 300$. 직무스트레스와 사회적지지는 평균 중심화하였다. *** $p < .001$.

1단계 계수는 3장 모형과 같습니다. 변수를 중심화해도 곱하기 항이 없는 모형의 기울기는 바뀌지 않기 때문입니다.

결과 서술 예시

직무스트레스와 소진의 관계에서 사회적지지의 조절효과를 검증하기 위해, 자기효능감을 통제한 상태에서 위계적 회귀분석을 실시하였다. 다중공선성을 줄이고 해석을 쉽게 하기 위해 직무스트레스와 사회적지지는 평균 중심화하였다($VIF \leq 1.15$).

2단계에서 상호작용항을 투입한 결과 설명력이 유의하게 증가하였으며($\Delta R^2 = .042$, $F(1, 295) = 21.85$, $p < .001$), 상호작용항의 계수는 부적으로 유의하였다($B = -0.380$, $p < .001$). 단순기울기 분석 결과, 직무스트레스가 소진에 미치는 영향은 사회적지지가 낮을 때($-1\ SD$; $B = 0.760$, $p < .001$) 가장 컸고, 평균일 때($B = 0.533$, $p < .001$), 높을 때($+1\ SD$; $B = 0.306$, $p < .001$) 순으로 작아졌다(그림 8-2). 존슨-네이만 분석에 따르면 사회적지지가 4.46점 이상인 경우($n = 23$) 직무스트레스의 영향은 유의하지 않았다. 이는 사회적지지가 직무스트레스의 부정적 영향을 완충한다는 가설을 지지한다.

조절효과는 표, 단순기울기, 그림 세 가지를 함께 보고하는 것이 원칙입니다. 그림 없이 계수만 있으면 독자가 방향을 해석하기 어렵습니다.

점검 항목

- ☐ 조절변수가 "효과 크기"를 바꾸는지 묻는 질문임을 확인했다
- ☐ 곱하기 전에 독립변수와 조절변수를 평균 중심화했다
- ☐ 곱하기 항이 있을 때 주효과 계수는 "상대 변수가 0(평균)일 때"의 효과로 읽었다
- ☐ 곱하기 항의 ΔR^2 과 계수의 검정을 보고했다
- ☐ 단순기울기($-1\ SD$, 평균, $+1\ SD$)를 구하고 그림으로 제시했다
- ☐ 필요하면 존슨-네이만 경계를 보고했다
- ☐ 조절변수를 집단으로 쪼개 따로 분석하지 않았다

요약 — 조절효과는 한 변수의 기울기가 다른 변수의 값에 따라 달라지는 것이며, 두 변수의 곱을 회귀식에 넣어 그 계수로 검정합니다. 곱하기 항이 있으면 주효과 계수는 상대 변수가 0일 때의 기울기이므로, **평균 중심화**로 원점을 해석 가능한 자리로 옮깁니다. 조절효과가 확인되면 단순기울기와 그림으로 "누구에게 더 강한지"를 구체적으로 보여줍니다.

어떤 경로로 영향을 주는가 — 매개효과

스트레스가 이직의도를 높인다는 것을 확인했다면, 다음 질문은 "어떻게"입니다. 스트레스가 사람을 소진시키고, 소진된 사람이 떠나고 싶어 하는 것일까요. 영향이 지나가는 중간 경로를 찾는 것이 매개효과 분석입니다.

■ '얼마나'에서 '어떻게'로

직무스트레스와 이직의도의 상관은 .44였습니다(1장). 스트레스가 높은 사람이 이직을 더 생각합니다. 그런데 **왜** 그럴까요.

하나의 설명은 이렇습니다. 스트레스가 쌓이면 정서적으로 지치고(소진), 지친 사람이 조직을 떠나고 싶어 한다. 이 설명이 맞다면 스트레스의 영향은 **소진을 거쳐서** 이직의도에 도달합니다.

이처럼 독립변수의 영향을 종속변수로 전달하는 중간 변수를 **매개변수(mediator)**라 하고, 그 경로를 통해 전달되는 효과를 **매개효과(mediation)** 또는 **간접효과(indirect effect)**라 합니다.




그림 9-1 매개모형. 스트레스의 영향은 소진을 거쳐 가는 간접경로(a, b)와 소진을 거치지 않는 직접경로(c')로 나뉜다. (개념도)

조절과 매개는 다른 질문입니다

이름이 비슷하고 둘 다 제3의 변수를 다루지만 묻는 것이 다릅니다.

	조절효과 (8장)	매개효과 (9장)
질문	언제, 누구에게 효과가 강한가	어떻게, 무엇을 거쳐 효과가 생기는가
제3변수의 위치	화살표를 겨냥함	화살표 사이에 끼어듦
제3변수와 X의 관계	상관이 없어도 됨	X가 제3변수에 영향을 줌 (경로 a)
분석	곱하기 항	경로 계수의 곱

사회적지지는 스트레스의 효과를 **바꾸는** 변수(조절), 소진은 스트레스의 효과를 **나르는** 변수(매개)입니다.

■ 효과를 쪼갬다

매개분석은 회귀분석 세 개로 이루어집니다.

● 세 개의 회귀식

```
d <- read.csv("data/survey.csv")
m_c <- lm(turnover ~ stress, data = d)           # 총효과 c
m_a <- lm(burnout ~ stress, data = d)           # 경로 a
m_b <- lm(turnover ~ stress + burnout, data = d) # 경로 b와 직접효과 c'

round(rbind(c      = summary(m_c)$coefficients["stress", ],
             a      = summary(m_a)$coefficients["stress", ],
             b      = summary(m_b)$coefficients["burnout", ],
             c_prime = summary(m_b)$coefficients["stress", ]), 4)
```

실행 결과

	Estimate	Std. Error	t value	Pr(> t)
c	0.5837	0.0692	8.4381	0.0000
a	0.6017	0.0529	11.3833	0.0000
b	0.5621	0.0686	8.1972	0.0000
c_prime	0.2455	0.0749	3.2750	0.0012

경로	회귀식	값	의미
c	이직의도 ~ 스트레스	0.584	총효과. 스트레스가 1점 높을 때 이직의도가 높은 정도
a	소진 ~ 스트레스	0.602	스트레스가 1점 높을 때 소진이 높은 정도 (2장과 같은 값)
b	이직의도 ~ 스트레스 + 소진	0.562	스트레스가 같을 때, 소진이 1점 높으면 이직의도가 높은 정도
c'	이직의도 ~ 스트레스 + 소진	0.245	직접효과. 소진이 같을 때 스트레스의 효과

b 와 c' 은 같은 회귀식에서 나옵니다. 3장의 다중회귀 계수이므로 각각 "다른 쪽이 같을 때"로 읽습니다.

$$\text{간접효과} = a \times b$$

스트레스가 1점 높으면 소진이 $a = 0.602$ 점 높고, 소진이 1점 높으면 이직의도가 $b = 0.562$ 점 높습니다. 그러면 스트레스 1점이 **소진을 거쳐서** 이직의도에 전달하는 몫은 두 기울기의 곱입니다.

$$\text{간접효과} = a \times b = 0.602 \times 0.562 = 0.338$$

소진을 거쳐 전달되는 스트레스의 효과

그리고 다음 관계가 정확히 성립합니다.

$$\underbrace{c}_{\text{총효과}} = \underbrace{c'}_{\text{직접효과}} + \underbrace{a \times b}_{\text{간접효과}} \quad 0.584 = 0.245 + 0.338$$

총효과는 직접효과와 간접효과로 남김없이 나뉩니다

● 간접효과를 두 방법으로

```
a ← coef(m_a)["stress"]
b ← coef(m_b)["burnout"]
unnamed(a * b) # a × b
unnamed(coef(m_c)["stress"] - coef(m_b)["stress"]) # c - c'
```

실행 결과

```
[1] 0.3382168
[1] 0.3382168
```

두 값이 소수점 끝까지 같습니다. 소진을 모형에 넣었을 때 스트레스의 계수가 0.584에서 0.245로 **줄어든 만큼이 바로 소진을 거쳐 가던 몫**입니다. 3장에서 다른 변수를 넣으면 계수가 줄어든다고 했던 현상을, 매개분석은 "경로"로 해석합니다.




그림 9-2 총효과 0.584(위)가 소진을 거치는 간접효과 0.338과 직접효과 0.245(아래)로 나뉜다. 스트레스가 이직의도에 미치는 영향의 58%가 소진을 거쳐 간다.

■ 고전적 방법 — Baron과 Kenny의 4단계

오랫동안 매개효과는 Baron과 Kenny(1986)의 절차로 확인했습니다. 지금도 많은 학위논문에서 볼 수 있습니다.

단계	확인할 것	이 자료
1	$X \rightarrow Y$ (경로 c)가 유의하다	0.584, $p < .001$ 충족
2	$X \rightarrow M$ (경로 a)이 유의하다	0.602, $p < .001$ 충족
3	X 를 통제한 $M \rightarrow Y$ (경로 b)가 유의하다	0.562, $p < .001$ 충족
4	M 을 통제하면 c' 이 c 보다 작아진다	0.584 → 0.245 충족

네 조건을 모두 만족하므로 이 절차로는 "매개효과가 있다"고 결론 내립니다. 4단계에서 c' 이 유의하지 않게 되면 **완전매개**, 여전히 유의하면 **부분매개**라 불렀습니다. 여기서는 $c' = 0.245$ 가 유의하므로 부분매개입니다.

4단계 절차의 한계

이 절차는 지금은 권장되지 않습니다(Hayes, 2009; Zhao et al., 2010).

- **간접효과 $a \times b$ 자체를 검정하지 않습니다.** a 와 b 가 각각 유의한지만 곱합니다. 매개효과의 크기와 불확실성을 알 수 없습니다.

- **1단계가 불필요하게 엄격합니다.** 간접효과와 직접효과가 서로 반대 방향이면 둘이 상쇄되어 총효과 c 가 유의하지 않을 수 있습니다. 그래도 매개는 존재합니다.
- 유의성 검정을 여러 번 거치므로 **검정력이 낮습니다.** 실제 매개효과가 있어도 놓치기 쉽습니다.

지금은 **간접효과** $a \times b$ 를 **직접** 검정하는 것이 표준입니다.

■ 간접효과를 직접 검정하기

Sobel 검정

간접효과 ab 의 표준오차를 근사해 z 검정을 하는 방법입니다(Sobel, 1982).

$$SE_{ab} = \sqrt{b^2 s_a^2 + a^2 s_b^2}, \quad z = \frac{ab}{SE_{ab}}$$

s_a, s_b 는 두 경로 계수의 표준오차

● Sobel 검정

```
sa <- summary(m_a)$coefficients["stress", "Std. Error"]
sb <- summary(m_b)$coefficients["burnout", "Std. Error"]
se_ab <- sqrt(b^2 * sa^2 + a^2 * sb^2)
z <- a * b / se_ab
round(c(ab = unname(a * b), se = unname(se_ab), z = unname(z), p = 2 * pnorm(-abs(unname(z)))), 4)
```

실행 결과

ab	se	z	p
0.3382	0.0508	6.6520	0.0000

$z = 6.65, p < .001$ 로 간접효과가 유의합니다. 그러나 Sobel 검정에는 근본적인 문제가 있습니다. **두 정규분포 변수의 곱은 정규분포가 아닙니다.** a 와 b 가 각각 정규분포를 따라도 ab 의 표집분포는 한쪽으로 치우칩니다. 정규분포를 가정한 z 검정은 이 치우침을 무시하므로, 특히 표본이 작을 때 부정확하고 검정력이 낮습니다.

부트스트랩 — 지금의 표준

ab 의 표집분포를 공식으로 구하기 어렵다면, **직접 만들어 보면** 됩니다. 1권 4장에서 표본을 무한히 다시 뽑는 상상으로 표집분포를 이해했습니다. 부트스트랩은 그 상상을 컴퓨터로 실제로 합니다.

1. 300명의 자료에서 **300명을 복원추출**로 다시 뽑습니다. 같은 사람이 두세 번 뽑히기도 하고 한 번도 안 뽑히기도 합니다.
2. 그 표본으로 a 와 b 를 추정하고 ab 를 계산합니다.
3. 이것을 2,000번 반복합니다.
4. 2,000개의 ab 를 크기순으로 늘어놓고 **아래 2.5%와 위 2.5% 지점**을 95% 신뢰구간으로 삼습니다.

신뢰구간이 0을 포함하지 않으면 간접효과가 유의하다고 판단합니다. 분포의 모양을 가정하지 않으므로 치우친 분포에서도 정확합니다(Preacher & Hayes, 2008).

R에서는 `lavaan` 패키지로 합니다. 4권 구조방정식에서 쓸 패키지이기도 합니다. 모형을 문자열로 적고, 경로마다 이름표 (`a`, `b`, `cp`)를 붙인 뒤, `:=` 로 간접효과를 정의합니다.

● lavaan으로 매개모형과 부트스트랩 (2,000회)

```
library(lavaan)
model <- '
  burnout ~ a * stress
  turnover ~ b * burnout + cp * stress
  indirect := a * b
  total    := cp + a * b
'

set.seed(2026)
fit <- sem(model, data = d, se = "bootstrap", bootstrap = 2000)
pe <- parameterEstimates(fit, boot.ci.type = "perc")
pe[pe$label != "", c("label", "est", "se", "pvalue", "ci.lower", "ci.upper")]
```

실행 결과

	label	est	se	pvalue	ci.lower	ci.upper
1	a	0.602	0.056	0	0.493	0.712
2	b	0.562	0.069	0	0.424	0.694
3	cp	0.245	0.069	0	0.110	0.386
7	indirect	0.338	0.051	0	0.242	0.442
8	total	0.584	0.069	0	0.453	0.720

출력의 이 자리	값	의미
<code>a</code> , <code>b</code> , <code>cp</code> 의 <code>est</code>	0.602, 0.562, 0.245	<code>lm()</code> 으로 구한 값과 같음
<code>se</code>	부트스트랩 표준오차	2,000번 추정값의 표준편차
<code>indirect</code> 의 <code>ci.lower</code> , <code>ci.upper</code>	[0.242, 0.442]	간접효과 95% 부트스트랩 신뢰구간
<code>total</code>	0.584	총효과 = $cp + a \times b$

간접효과는 **0.338**, 95% 부트스트랩 신뢰구간 **[0.242, 0.442]**로 0을 포함하지 않습니다. 소진을 통한 매개효과가 유의합니다.




그림 9-3 부트스트랩으로 얻은 간접효과 2,000개의 분포. 가운데 95%가 0.242에서 0.442 사이이고 0과 멀리 떨어져 있다. 분포가 오른쪽으로 약간 치우쳐 있다.

`set.seed()` 를 꼭 씁니다

부트스트랩은 무작위로 다시 뽑기 때문에 돌릴 때마다 신뢰구간이 조금씩 달라집니다. `set.seed(2026)` 처럼 난수의 출발점을 고정하면 같은 결과가 재현됩니다. 논문에는 반복 횟수(2,000회 또는 5,000회)와 신뢰구간 방식(백분위수)을 적습니다. SPSS의 PROCESS 매크로는 기본값이 5,000회입니다.

표준화 간접효과

● 표준화 계수

```
ss <- standardizedSolution(fit)
ss[ss$label != "", c("label", "est.std")]
```

실행 결과

	label	est.	std
1	a	0.551	
2	b	0.462	
3	cp	0.185	
7	indirect	0.254	
8	total	0.439	

표준화 간접효과는 .254입니다. 스트레스가 1 표준편차 높을 때 소진을 거쳐 이직의도가 0.25 표준편차 높다는 뜻입니다.

■ 완전매개와 부분매개

직접효과 $c' = 0.245$ 는 95% 신뢰구간 [0.110, 0.386]이 0을 포함하지 않아 유의합니다. 소진을 통제해도 스트레스가 이직의도와 직접 관련된 몫이 남는다는 뜻이고, 전통적인 용어로는 **부분매개**입니다.

총효과 가운데 간접효과의 비율을 계산하기도 합니다.

$$\frac{ab}{c} = \frac{0.338}{0.584} = .58$$

총효과의 58%가 소진을 거쳐 감

완전매개라는 말을 아껴 씁니다

"완전매개"는 c' 이 유의하지 않다는 뜻인데, 이는 **표본크기에 크게 좌우됩니다**. 표본이 작으면 직접효과가 있어도 유의하지 않아 완전매개로 보이고, 같은 모형이라도 표본이 크면 부분매개가 됩니다. 그래서 최근에는 완전/부분의 구분보다 **간접효과와 직접효과를 각각의 크기와 신뢰구간으로 보고**하는 것을 권합니다(Hayes, 2018).

매개 비율(ab/c)도 총효과가 작을 때 매우 불안정합니다. 참고 수치로만 씁니다.

■ 인과에 대한 주의

매개분석은 본질적으로 **인과에 대한 주장**입니다. "스트레스가 소진을 일으키고, 소진이 이직의도를 일으킨다." 그런데 이 자료는 한 시점에 세 변수를 모두 설문으로 잴습니다.

같은 자료에 방향을 바꾼 모형, 예컨대 "이직을 생각하는 사람이 일에서 마음이 떠나 소진을 더 느낀다"를 적합해도 통계적으로는 똑같이 잘 맞습니다. **자료는 화살표의 방향을 말해 주지 않습니다**.

횡단 자료의 매개분석

Maxwell과 Cole(2007)은 한 시점 자료로 추정한 매개효과가 실제 시간에 따라 일어나는 매개효과를 크게 왜곡할 수 있음을 보였습니다. 횡단 자료로 매개분석을 할 때는 다음을 지킵니다.

- 화살표의 방향을 **이론과 선행연구**로 정당화합니다.
- 결과를 "소진이 매개하였다"보다 "**매개모형과 일치하는 결과를 보였다**"로 조심스럽게 씁니다.
- 연구의 한계에 횡단 설계의 제약을 밝히고, 종단 연구가 필요함을 적습니다.

0장에서 "영향을 미친다"는 표현에 대해 했던 이야기가 매개분석에서 가장 중요해집니다.

SPSS PROCESS 매크로와의 관계

학위논문에서는 Hayes의 **PROCESS 매크로**로 매개분석을 하는 경우가 많습니다. 이 장의 모형은 PROCESS의 **Model 4**이고, 위 `lavaan` 결과와 같은 계수와 (부트스트랩 난수에 따른 작은 차이를 빼면) 같은 신뢰구간을 줍니다. 8장의 조절효과는 **Model 1**, 10장의 조절된 매개는 **Model 7**입니다.

Hayes는 R용 PROCESS(`process.R`)도 공식 홈페이지에서 배포합니다. 이 책은 4권 구조방정식으로 이어지도록 `lavaan` 을 씁니다.

■ 논문 결과표

표 9. 소진의 매개효과

경로	B	SE	95% CI	β
직무스트레스 → 소진 (a)	0.602***	0.056	[0.493, 0.712]	.551
소진 → 이직의도 (b)	0.562***	0.069	[0.424, 0.694]	.462
직무스트레스 → 이직의도 (c', 직접효과)	0.245***	0.069	[0.110, 0.386]	.185
간접효과 (a × b)	0.338	0.051	[0.242, 0.442]	.254
총효과 (c)	0.584***	0.069	[0.453, 0.720]	.439

주. N = 300. 표준오차와 신뢰구간은 2,000회 부트스트랩의 백분위수 방식이며, 유의확률은 부트스트랩 표준오차로 계산하였다. 간접효과의 유의성은 신뢰구간으로 판단. *** $p < .001$.

결과 서술 예시

직무스트레스와 이직의도의 관계에서 소진의 매개효과를 검증하기 위해 `lavaan` 패키지로 매개모형을 추정하고, 간접효과의 유의성을 2,000회 부트스트랩의 백분위수 신뢰구간으로 검정하였다(표 9, 그림 9-2).

직무스트레스는 소진에 정적인 영향을 미쳤고($B = 0.602, p < .001$), 직무스트레스를 통제한 상태에서 소진은 이직의도에 정적인 영향을 미쳤다($B = 0.562, p < .001$). 소진을 통한 간접효과는 0.338로, 95% 신뢰구간 $[0.242, 0.442]$ 이 0을 포함하지 않아 유의하였다. 소진을 통제한 후에도 직무스트레스의 직접효과는 유의하였다($B = 0.245, p < .001$). 즉, 직무스트레스는 이직의도에 직접 영향을 미칠 뿐 아니라 소진을 거쳐 간접적으로도 영향을 미쳤으며, 총효과의 약 58%가 소진을 통해 전달되었다.

경로도(그림 9-2 아래쪽)에 계수를 적어 함께 제시하면 독자가 한눈에 구조를 파악합니다.

점검 항목

- ☐ 매개(어떻게)와 조절(언제)의 질문을 구분했다
- ☐ 화살표의 방향을 이론으로 정당화했다
- ☐ 간접효과 $a \times b$ 를 직접 검정했다(4단계 절차만으로 결론 내리지 않음)
- ☐ 부트스트랩 반복 횟수, 신뢰구간 방식, `set.seed()` 를 밝혔다
- ☐ 간접효과·직접효과·총효과를 모두 신뢰구간과 함께 보고했다
- ☐ 완전/부분매개는 참고로만 쓰고, 횡단 설계의 한계를 밝혔다

요약 — 매개분석은 총효과 를 매개변수를 거치는 **간접효과** 와 거치지 않는 **직접효과** 로 나눕니다(). 간접효과는 곱이라서 표집분포가 치우치므로, **부트스트랩 신뢰구간**이 0을 포함하는지로 검정합니다. 계산은 회귀분석 세 개면 되지만, 화살표의 방향은 자료가 아니라 이론과 설계가 정당화해야 합니다.

경로가 사람마다 다르다면 — 조절된 매개

8장에서는 사회적지지가 스트레스의 영향을 줄인다는 것을, 9장에서는 스트레스가 소진을 거쳐 이직의도로 이어진다는 것을 보았습니다. 두 결과를 합치면 새로운 질문이 생깁니다. 소진을 거쳐 가는 그 경로의 크기도 지지에 따라 달라질까요.

■ 두 질문을 합친다

지금까지의 결과를 나란히 놓습니다.

- **8장 (조절):** 스트레스 → 소진의 기울기가 지지가 높을수록 작다.
- **9장 (매개):** 스트레스 → 소진 → 이직의도의 간접효과가 있다.

간접효과는 두 경로의 곱 $a \times b$ 였습니다. 그런데 8장에 따르면 경로 a (스트레스 → 소진)의 크기가 지지에 따라 다릅니다. 그렇다면 **간접효과 $a \times b$ 도 지지에 따라 달라질** 것입니다. 지지가 낮은 사람에게는 스트레스가 소진을 크게 높이고 그 소진이 이직의도로 이어지지만, 지지가 높은 사람에게는 첫 단계부터 약하게 전달됩니다.

이처럼 **매개효과의 크기가 조절변수에 따라 달라지는 것을 조절된 매개(moderated mediation)**라 합니다(Preacher, Rucker, & Hayes, 2007).




그림 10-1 조절된 매개모형. 사회적지지가 첫 번째 경로(스트레스 → 소진)를 조절하므로, 소진을 거치는 간접효과 전체가 지지 수준에 따라 달라진다. PROCESS의 Model 7에 해당한다. (개념도)

■ 식으로 보면

8장에서 스트레스 → 소진의 기울기는 하나의 숫자가 아니라 $a_1 + a_3W$ 였습니다(W 는 중심화한 지지). 여기에 소진 → 이직의도 경로 b 를 곱하면 간접효과가 됩니다.

$$\text{조건부 간접효과}(W) = (a_1 + a_3W) \times b$$

지지 수준 W 마다 다른 간접효과

W 가 1 늘 때 간접효과는 $a_3 \times b$ 만큼 바뀝니다. 이 값을 **조절된 매개지수(index of moderated mediation)**라 합니다 (Hayes, 2015).

$$\text{조절된 매개지수} = a_3 \times b$$

지지가 1점 높을 때 간접효과의 변화량

기호	경로	장
a_1	지지 평균일 때 스트레스 → 소진	8장의 <code>stress_c</code>
a_3	지지에 따른 그 기울기의 변화	8장의 곱하기 항
b	스트레스를 통제한 소진 → 이직의도	9장
$a_3 \times b$	조절된 매개지수	이 장

조절된 매개를 검정한다는 것은 이 지수가 0이 아닌지를 검정하는 것입니다. 지수도 두 계수의 곱이므로 9장과 같은 이유로 부트스트랩 신뢰구간을 씁니다.

■ R로 돌리기

8장처럼 스트레스와 지지를 중심화하고 곱하기 항을 미리 만들어 둡니다. 자기효능감은 8장과 같이 첫 번째 식의 통제변수로 넣습니다.

● 변수 준비

```
d <- read.csv("data/survey.csv")
d$stress_c <- d$stress - mean(d$stress)
d$support_c <- d$support - mean(d$support)
d$sxw <- d$stress_c * d$support_c # 곱하기 항
s <- sd(d$support)
s
```

실행 결과

```
[1] 0.596914
```

`lavaan` 모형에 지지 -1 SD, 평균, $+1$ SD에서의 조건부 간접효과와 조절된 매개지수를 정의합니다. 모형 문자열 안에 표준편차 값을 넣기 위해 `sprintf()` 를 씁니다. `%.4f` 자리에 `s` 가 소수 넷째 자리까지 들어갑니다.

● 조절된 매개모형 (부트스트랩 2,000회)

```
library(lavaan)
model <- sprintf('
  burnout ~ a1 * stress_c + a2 * support_c + a3 * sxw + efficacy
  turnover ~ b * burnout + cp * stress_c
  ind_low  := (a1 - %.4f * a3) * b
  ind_mid  := a1 * b
  ind_high := (a1 + %.4f * a3) * b
  index    := a3 * b
', s, s)

set.seed(2026)
fit <- sem(model, data = d, se = "bootstrap", bootstrap = 2000)
pe <- parameterEstimates(fit, boot.ci.type = "perc")
pe[pe$label != "", c("label", "est", "se", "pvalue", "ci.lower", "ci.upper")]
```

실행 결과

	label	est	se	pvalue	ci.lower	ci.upper
1	a1	0.533	0.050	0	0.436	0.633
2	a2	-0.223	0.056	0	-0.334	-0.112
3	a3	-0.380	0.080	0	-0.537	-0.217
5	b	0.562	0.069	0	0.424	0.694
6	cp	0.245	0.069	0	0.110	0.386
19	ind_low	0.427	0.064	0	0.308	0.558
20	ind_mid	0.300	0.045	0	0.217	0.395
21	ind_high	0.172	0.046	0	0.087	0.266
22	index	-0.214	0.055	0	-0.329	-0.112

출력	값	의미
a1, a2, a3	0.533, -0.223, -0.380	8장 2단계와 같은 값
b, cp	0.562, 0.245	9장과 같은 값
ind_low	0.427 [0.308, 0.558]	지지가 낮을 때(-1 SD)의 간접효과
ind_mid	0.300 [0.217, 0.395]	지지가 평균일 때의 간접효과
ind_high	0.172 [0.087, 0.266]	지지가 높을 때(+1 SD)의 간접효과
index	-0.214 [-0.329, -0.112]	조절된 매개지수

■ 결과 읽기

조건부 간접효과

지지가 낮은 사람의 간접효과는 0.427, 높은 사람은 0.172입니다. **지지가 낮을수록 스트레스가 소진을 거쳐 이직의도로 이어지는 경로가 2.5배 강합니다.** 세 신뢰구간 모두 0을 포함하지 않으므로 지지 수준과 상관없이 매개효과 자체는 존재합니다.




그림 10-2 사회적지지 수준별 조건부 간접효과와 95% 부트스트랩 신뢰구간. 지지가 높을수록 소진을 거치는 경로가 약해진다. 세 점을 잇는 선의 기울기가 조절된 매개지수다.

조절된 매개지수

지수는 **-0.214**, 95% 신뢰구간 **[-0.329, -0.112]**로 **0을 포함하지 않습니다.** 사회적지지가 1점 높을 때마다 소진을 통한 간접효과가 0.214씩 작아지며, 이 변화가 유의합니다. 조절된 매개가 성립합니다.

세 간접효과를 비교하는 것으로는 부족합니다

"지지가 낮을 때 유의, 높을 때 유의하지 않음"을 보고 조절된 매개를 주장하는 경우가 많습니다. 8장에서 본 "한쪽은 유의, 다른 쪽은 비유의" 오류와 같습니다. 이 자료처럼 세 간접효과가 **모두 유의해도** 크기가 유의하게 다를 수 있고, 반대로 한쪽만 유의해도 차이는 유의하지 않을 수 있습니다.

조절된 매개의 판단은 **조절된 매개지수의 신뢰구간**으로 합니다. 조건부 간접효과는 그 다음에 "어떻게 다른지"를 보여주는 용도입니다.

9장과 숫자가 다른 이유

9장의 간접효과는 0.338이었는데, 여기서 지지가 평균일 때의 간접효과는 0.300입니다. 두 모형이 다른 질문을 하기 때문입니다. 9장의 경로 α (0.602)는 지지와 효능감을 고려하지 않은 스트레스의 기울기이고, 이 장의 α_1 (0.533)은 **지지와 효능감을 통제하고 지지가 평균인 사람**의 기울기입니다. 3장에서 변수를 더 넣으면 계수가 달라졌던 것과 같습니다.

■ 어디에 조절을 거는가

조절변수가 어느 경로를 조절하는지는 이론이 정합니다. Hayes의 PROCESS는 이를 모형 번호로 구분합니다.

PROCESS	조절되는 경로	예
Model 4	없음 (단순 매개)	9장
Model 7	$X \rightarrow M$ (첫 단계)	이 장: 지지가 스트레스의 소진 효과를 완충
Model 14	$M \rightarrow Y$ (둘째 단계)	예: 이직 기회가 많을수록 소진이 이직의도로 더 쉽게 이어짐
Model 8	$X \rightarrow M$ 과 $X \rightarrow Y$	첫 단계와 직접효과를 함께 조절
Model 58	$X \rightarrow M$ 과 $M \rightarrow Y$	두 단계를 같은 변수가 조절

`lavaan`에서는 조절하려는 경로가 있는 식에 곱하기 항을 넣고, 간접효과의 정의를 그에 맞게 바꾸기만 하면 됩니다. Model 14라면 두 번째 식에 `burnout * W` 항을 넣고, 간접효과를 `a * (b1 + b3 * W)`로 정의합니다.

무엇을 먼저 확인해야 하는가

조절된 매개모형을 바로 돌리기보다, 이 책의 순서처럼 단계를 밟는 것이 해석에 도움이 됩니다.

1. 단순 매개(9장)로 간접효과가 있는지 봅니다.
2. 조절이 걸릴 경로에서 조절효과(8장)를 확인합니다.
3. 조절된 매개지수로 둘을 합칩니다.

각 단계의 결과가 다음 단계의 해석을 받쳐 줍니다. 논문에서도 이 순서로 서술하면 독자가 따라오기 쉽습니다.

■ 논문 결과표

표 10. 사회적지지에 따른 조건부 간접효과

사회적지지	간접효과	Boot SE	95% 부트스트랩 CI
낮음 (-1 SD)	0.427	0.064	[0.308, 0.558]
평균	0.300	0.045	[0.217, 0.395]
높음 (+1 SD)	0.172	0.046	[0.087, 0.266]
조절된 매개지수	-0.214	0.055	[-0.329, -0.112]

주. N = 300. 간접효과 경로: 직무스트레스 → 소진 → 이직의도. 자기효능감 통제. 2,000회 부트스트랩의 백분위수 신뢰구간.

결과 서술 예시

사회적지지가 직무스트레스와 소진의 관계를 조절함으로써 소진의 매개효과를 조건화하는지 검증하기 위해 조절된 매개모형(Hayes, 2018의 Model 7)을 추정하였다. 자기효능감을 통제하였으며, 간접효과의 유의성은 2,000회 부트스트랩의 백분위수 신뢰구간으로 판단하였다.

조절된 매개지수는 -0.214로, 95% 신뢰구간 [-0.329, -0.112]가 0을 포함하지 않아 조절된 매개효과가 유의하였다. 조건부 간접효과는 사회적지지가 낮을 때(-1 SD) 0.427 [0.308, 0.558], 평균일 때 0.300 [0.217, 0.395], 높을 때(+1 SD) 0.172 [0.087, 0.266]로, 사회적지지가 높을수록 직무스트레스가 소진을 거쳐 이직의도에 미치는 간접효과가 약해졌다(표 10, 그림 10-2).

점검 항목

- ☐ 어느 경로를 조절하는지 이론으로 정했다(Model 7, 14 등)
- ☐ 단순 매개와 조절효과를 먼저 확인했다
- ☐ 조절된 매개지수와 그 부트스트랩 신뢰구간을 보고했다
- ☐ 조건부 간접효과를 여러 조절변수 수준에서 제시했다

☐ 조건부 간접효과의 유의성 차이만으로 조절된 매개를 주장하지 않았다

요약 — 조절된 매개는 **간접효과의 크기가 조절변수에 따라 달라지는 것**입니다. 첫 단계가 조절되는 경우 간접효과는 이고, 그 변화율인 **조절된 매개지수**의 부트스트랩 신뢰구간이 0을 포함하지 않으면 조절된 매개가 성립합니다. 8장의 곱하기 항과 9장의 경로 곱을 하나의 모형에 합친 것일 뿐, 새로운 원리는 없습니다.

예 또는 아니오를 예측하기 — 로지스틱 회귀

이직의도는 1~5점으로 찬 마음이었습니다. 실제로 1년 뒤 회사를 떠났는지는 '떠났다'와 '남았다' 둘뿐입니다. 종속변수가 두 범주일 때 쓰는 회귀분석이 로지스틱 회귀입니다.

■ 종속변수가 0과 1이면

이 자료의 `quit` 은 조사 1년 뒤 실제로 퇴사했으면 1, 재직 중이면 0입니다. 300명 가운데 63명(21%)이 퇴사했습니다. 이직의도가 높았던 사람이 실제로 더 많이 떠났을까요.

● 퇴사 여부별 이직의도 평균

```
d ← read.csv("data/survey.csv")
table(d$quit)
tapply(d$turnover, d$quit, mean)
```

실행 결과

```
0    1
237  63

      0      1
2.564346 3.317460
```

퇴사자의 이직의도 평균이 3.32점으로 재직자(2.56점)보다 높습니다. 그렇다면 지금까지처럼 `lm()` 으로 회귀분석을 하면 될까요.

직선으로는 안 되는 이유

● 0/1 종속변수에 직선을 적합하면

```
m_lin ← lm(quit ~ turnover, data = d)
coef(m_lin)
predict(m_lin, newdata = data.frame(turnover = c(1, 5)))
```

실행 결과

```
(Intercept)      turnover
-0.2959035      0.1858231

      1      2
-0.1100803  0.6332122
```

이직의도가 1점인 사람의 예측값이 **-0.11**입니다. 퇴사 "확률"이 음수일 수는 없습니다. 이직의도가 아주 높은 사람이 있었다면 1을 넘는 확률도 나왔을 것입니다. 직선은 양쪽으로 끝없이 뻗지만 확률은 0과 1 사이에 갇혀 있기 때문입니다.




그림 11-1 0과 1뿐인 퇴사 여부에 직선(점선)과 S자 곡선(실선)을 적합한 결과. 직선은 0 아래로 내려가지만 S자 곡선은 0과 1 사이에 머문다. 점은 겹치지 않도록 위아래로 조금씩 흘렸다.

4장의 가정도 맞지 않습니다. 종속변수가 0과 1뿐이니 잔차는 정규분포가 될 수 없고, 예측값이 0.5 근처일 때 잔차가 가장 크게 흩어지므로 등분산도 깨집니다.

필요한 것은 **0과 1 사이에 머무는 S자 곡선**입니다.

■ 확률을 로짓으로

S자 곡선을 회귀분석의 틀로 다루기 위해, 확률을 두 단계로 변환합니다.

① **확률 → 오즈(odds)**. 일어날 확률을 일어나지 않을 확률로 나눈 값입니다.

$$\text{odds} = \frac{p}{1 - p}$$

퇴사할 확률이 퇴사하지 않을 확률의 몇 배인가

퇴사율 21%라면 오즈는 $.21 / .79 = 0.27$ 입니다. "퇴사자 1명당 재직자 약 4명"이라는 뜻입니다. 오즈는 0에서 무한대까지 갑니다.

② **오즈 → 로짓(logit)**. 오즈에 자연로그를 씹습니다.

$$\text{logit}(p) = \ln \frac{p}{1-p}$$

로그오즈, $-\infty$ 에서 $+\infty$ 까지 움직인다

● 확률, 오즈, 로짓의 관계

```
p <- c(.10, .21, .50, .79, .90)
data.frame(p, odds = round(p / (1 - p), 3), logit = round(log(p / (1 - p)), 3))
```

실행 결과

	p	odds	logit
1	0.10	0.111	-2.197
2	0.21	0.266	-1.325
3	0.50	1.000	0.000
4	0.79	3.762	1.325
5	0.90	9.000	2.197

확률 .5가 로짓 0이고, .5보다 작으면 음수, 크면 양수입니다. 확률 .21과 .79의 로짓이 부호만 다르게 대칭입니다. 로짓은 음의 무한대에서 양의 무한대까지 움직이므로, 직선 회귀식을 그대로 받아 줄 수 있습니다.




그림 11-2 로짓과 확률의 관계. 로짓은 어떤 값이든 될 수 있지만, 확률로 되돌리면 언제나 0과 1 사이의 S자 곡선이 된다.

■ 로지스틱 회귀식

확률 대신 로짓을 직선으로 예측하는 것이 **로지스틱 회귀(logistic regression)**입니다.

$$\ln \frac{p}{1-p} = b_0 + b_1 X_1 + b_2 X_2$$

좌변이 로짓이라는 것만 다르고 우변은 지금까지의 회귀식과 같다

R에서는 `lm()` 대신 `glm()` 을 쓰고 `family = binomial` 을 지정합니다. 이직의도와 직무만족으로 퇴사를 예측합니다.

● 로지스틱 회귀

```
m_log <- glm(quit ~ turnover + satisfaction, family = binomial, data = d)
summary(m_log)
```

실행 결과

Call:

```
glm(formula = quit ~ turnover + satisfaction, family = binomial,
    data = d)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-2.7889	1.0555	-2.642	0.00824 **
turnover	1.2319	0.2193	5.617	1.94e-08 ***
satisfaction	-0.6835	0.2585	-2.645	0.00818 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 308.37 on 299 degrees of freedom
 Residual deviance: 256.75 on 297 degrees of freedom
 AIC: 262.75

Number of Fisher Scoring iterations: 5

계수 옆의 검정이 t 가 아니라 z (Wald 검정)입니다. 이직의도($z = 5.62, p < .001$)와 직무만족($z = -2.65, p = .008$) 모두 퇴사를 유의하게 예측합니다.

■ 계수 읽기 — 오즈비

계수 1.232는 "이직의도가 1점 높으면 로짓이 1.232 높다"입니다. 로짓은 직관적으로 와닿지 않으므로 계수에 지수를 씌워 **오즈비(odds ratio, OR)**로 바꿉니다.

$$OR = e^b$$

설명변수가 1 높을 때 오즈가 몇 배가 되는가

● 오즈비와 95% 신뢰구간

```
round(exp(cbind(OR = coef(m_log), confint(m_log))), 3)
```

실행 결과

```

              OR 2.5 % 97.5 %
(Intercept) 0.061 0.007 0.473
turnover    3.428 2.268 5.377
satisfaction 0.505 0.299 0.828

```

변수	OR	읽는 법
이직의도	3.428	만족이 같을 때, 이직의도가 1점 높으면 퇴사할 오즈가 3.43배
직무만족	0.505	이직의도가 같을 때, 만족이 1점 높으면 퇴사할 오즈가 0.51배 (약 절반)

오즈비가 1이면 관계가 없다는 뜻입니다. 1보다 크면 오즈를 높이고, 작으면 낮춥니다. 그래서 **오즈비의 신뢰구간이 1을 포함하는지**가 유의성 판단 기준입니다. 이직의도 [2.27, 5.38], 직무만족 [0.30, 0.83] 모두 1을 포함하지 않습니다.

0.505처럼 1보다 작은 오즈비는 $(1 - 0.505) \times 100 = 49.5\%$ 감소로 표현하기도 합니다.

오즈비는 확률의 배수가 아닙니다

"이직의도가 1점 높으면 퇴사 확률이 3.43배"라고 쓰면 틀립니다. 3.43배가 되는 것은 **오즈**입니다. 확률로는 몇 배가 되는지 직접 계산해 봅니다.

● 직무만족이 평균일 때 이직의도별 퇴사 확률

```

predict(m_log, newdata = data.frame(turnover = c(2, 3, 4),
                                     satisfaction = mean(d$satisfaction)),
       type = "response")

```

실행 결과

```

      1      2      3
0.07149714 0.20882797 0.47499757

```

이직의도 2점 → 3점에서 확률은 0.071 → 0.209로 2.9배, 3점 → 4점에서는 0.209 → 0.475로 2.3배입니다. **오즈비는 어디서나 3.43으로 같지만 확률의 배수는 위치마다 다릅니다.** S자 곡선의 기울기가 위치마다 다르기 때문입니다. 확률이 작을 때(10% 미만)만 오즈비와 확률의 배수가 비슷해집니다.

독자에게 효과의 크기를 전달하려면 이처럼 **대표적인 값에서의 예측 확률**을 함께 제시하는 것이 좋습니다.




그림 11-3 직무만족이 평균일 때 이직의도에 따른 퇴사 예측 확률. 이직의도 2점에서 7%, 3점에서 21%, 4점에서 48%로 오른다.

■ 모형 전체 평가

우도비 검정

로지스틱 회귀에는 제곱합이 없습니다. 대신 **이탈도(deviance)**로 모형이 자료에서 얼마나 벗어나는지를 잹니다.

`summary()` 아래쪽의 두 값입니다.

이탈도	값	의미
Null deviance	308.37	설명변수 없이 퇴사율 21%만으로 예측했을 때
Residual deviance	256.75	이직의도와 만족으로 예측했을 때

두 값의 차이가 설명변수 덕분에 줄어든 이탈도이며, 카이제곱 분포를 따릅니다. 이것이 1~7장의 F 검정에 해당하는 **우도비 검정(likelihood ratio test)**입니다.

- 설명변수가 없는 모형과 비교 (우도비 검정)

```
m_null <- glm(quit ~ 1, family = binomial, data = d)
anova(m_null, m_log, test = "Chisq")
```

실행 결과

Analysis of Deviance Table

Model 1: quit ~ 1

Model 2: quit ~ turnover + satisfaction

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	299	308.37			
2	297	256.75	2	51.624	6.165e-12 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$\chi^2(2) = 51.62, p < .001$. 두 설명변수가 퇴사 예측을 유의하게 개선합니다.

유사 결정계수

로지스틱 회귀에는 R^2 이 없습니다. 비슷한 역할을 하는 지표가 여러 개 있으며 **유사 결정계수(pseudo R^2)**라 부릅니다.

● 유사 결정계수와 적합도 검정

```
library(performance)
r2_nagelkerke(m_log)
r2_coxsnell(m_log)
performance_hosmer(m_log)
```

실행 결과

```
Nagelkerke's R2
0.2461491
Cox & Snell's R2
0.1580886
# Hosmer-Lemeshow Goodness-of-Fit Test

Chi-squared: 7.734
df: 8
p-value: 0.460
```

Nagelkerke $R^2 = .246$, Cox & Snell $R^2 = .158$ 입니다. 학위논문에서는 Nagelkerke 값을 가장 많이 보고합니다.

유사 R^2 은 '설명된 분산'이 아닙니다

이름은 비슷하지만 1~3장의 R^2 처럼 "변동의 몇 %를 설명한다"는 뜻이 아닙니다. 지표마다 값도 다르고, 일반적으로 OLS의 R^2 보다 작게 나옵니다. 같은 지표끼리 모형을 비교하는 용도로 쓰고, ".25이므로 25%를 설명한다"라고 쓰지 않습니다.

Hosmer-Lemeshow 검정은 예측 확률과 실제 비율이 맞는지를 봅니다. 1권 3장의 정규성 검정처럼 *p*가 커야 좋은 검정입니다. *p* = .460이므로 모형이 자료와 잘 맞습니다.

■ 분류표 — 몇 명을 맞혔나

예측 확률이 .5 이상이면 퇴사, 미만이면 재직으로 분류하고 실제와 비교합니다.

● 분류표 (기준 0.5)

```
p_hat <- predict(m_log, type = "response")
table(실제 = d$quit, 예측 = ifelse(p_hat >= .5, 1, 0))
```

실행 결과

	예측	
실제	0	1
0	228	9
1	50	13



그림 11-4 분류표. 전체 정확도는 80.3%이지만, 실제 퇴사자 63명 가운데 맞힌 것은 13명(20.6%)뿐이다.

지표	계산	값
정확도	(228 + 13) / 300	80.3%
민감도 (퇴사자를 퇴사로)	13 / 63	20.6%
특이도 (재직자를 재직으로)	228 / 237	96.2%

정확도 80.3%는 좋아 보입니다. 그러나 모두 "재직"으로 찍어도 79%(237 / 300)를 맞힙니다. 모형이 더한 것은 1.3%p입니다. 그리고 정작 알고 싶은 퇴사자는 다섯 명 중 한 명만 맞혔습니다.

결과가 드물면 정확도는 믿을 만한 지표가 아닙니다

퇴사율이 21%이므로 예측 확률이 .5를 넘는 사람이 원래 적습니다. 그래서 대부분을 재직으로 분류하고, 정확도는 높지만 퇴사자는 놓칩니다.

로지스틱 회귀의 목적이 **분류**가 아니라 **관계의 크기를 추정**하는 것이라면 분류표는 보조 자료입니다. 이직의도의 오즈비 3.43과 예측 확률의 변화가 이 연구의 핵심 결과이고, 그것은 분류 정확도와 상관없이 유효합니다. 분류가 목적이라면 기준값을 퇴사율(.21) 근처로 낮추거나, 민감도와 특이도를 함께 보는 ROC 분석을 씁니다.

■ 가정과 주의할 점

로지스틱 회귀에는 정규성과 등분산 가정이 없습니다. 대신 다음을 확인합니다.

- **독립성** — 4장과 같습니다. 자료 수집 방식이 결정합니다.
- **로지스틱의 선형성** — 연속 설명변수가 확률이 아니라 **로짓**과 직선 관계여야 합니다. 의심되면 4장처럼 이차항을 넣어 확인합니다.
- **다중공선성** — 5장과 같습니다. `car::vif()` 가 `glm` 모형에도 작동합니다.
- **사례 수** — 사건(여기서는 퇴사)의 수가 중요합니다. 설명변수 하나당 사건이 **최소 10건**은 있어야 한다는 경험 규칙 (Peduzzi et al., 1996)이 흔히 인용됩니다. 퇴사 63건, 설명변수 2개이므로 31.5건으로 충분합니다. 300명이어도 퇴사자가 15명뿐이라면 설명변수를 하나만 넣을 수 있습니다.

■ 논문 결과표

표 11. 실제 퇴사에 대한 로지스틱 회귀분석 결과

변수	B	SE	Wald z	p	OR	95% CI
(상수)	-2.789	1.055	-2.64	.008	0.061	
이직의도	1.232	0.219	5.62	< .001	3.428	[2.268, 5.377]
직무만족	-0.684	0.258	-2.64	.008	0.505	[0.299, 0.828]

주. N = 300 (퇴사 63명). $\chi^2(2) = 51.62$, $p < .001$. Nagelkerke $R^2 = .246$. Hosmer-Lemeshow $\chi^2(8) = 7.73$, $p = .460$.

SPSS는 Wald 통계량을 z^2 으로 보고합니다(이직의도 $5.617^2 = 31.55$). 어느 쪽인지 표에 밝힙니다.

결과 서술 예시

이직의도와 직무만족이 1년 후 실제 퇴사에 미치는 영향을 검증하기 위해 로지스틱 회귀분석을 실시하였다(표 11). 모형은 통계적으로 유의하였으며($\chi^2(2) = 51.62, p < .001$, Nagelkerke $R^2 = .246$), Hosmer-Lemeshow 검정 결과 모형의 적합도가 양호하였다($\chi^2(8) = 7.73, p = .460$).

직무만족을 통제한 상태에서 이직의도가 1점 높을수록 퇴사할 오즈가 3.43배 증가하였고($OR = 3.43, 95\% CI [2.27, 5.38]$), 이직의도를 통제한 상태에서 직무만족이 1점 높을수록 퇴사할 오즈가 49.5% 감소하였다($OR = 0.51, 95\% CI [0.30, 0.83]$). 직무만족이 평균일 때 퇴사 예측 확률은 이직의도 2점에서 7.1%, 3점에서 20.9%, 4점에서 47.5%였다.

점검 항목

- ☐ 종속변수가 0/1이면 `lm()` 이 아니라 `glm(family = binomial)` 을 썼다
- ☐ 계수를 오즈비로 바꿔 해석했고, 확률의 배수로 쓰지 않았다
- ☐ 오즈비의 신뢰구간이 1을 포함하는지 확인했다
- ☐ 대표적인 값에서 예측 확률을 함께 제시했다
- ☐ 우도비 검정, 유사 R^2 (어느 지표인지 명시), 적합도 검정을 보고했다
- ☐ 분류표를 볼 때 기저율과 민감도를 함께 봤다
- ☐ 설명변수당 사건 수가 10건 이상인지 확인했다

요약 — 종속변수가 두 범주이면 확률을 **로짓**(로그오즈)으로 바꿔 직선으로 예측하는 로지스틱 회귀를 씁니다. 계수에 지수를 씌운 **오즈비**는 설명변수가 1 높을 때 오즈가 몇 배가 되는지를 나타내며, 확률의 배수와는 다릅니다. 모형 평가는 이탈도와 우도비 검정, 유사 R^2 으로 하고, 결과가 드물면 분류 정확도에 속지 않도록 기저율과 민감도를 함께 봅니다.

실전 참고자료

실제 분석에서 꺼내 쓰는 자료만 모았습니다. 분석 선택 흐름도, 분석 비교표, 진단 요약, R 코드 모음, 보고 문장 템플릿, 그리고 회귀분석에서 자주 마주치는 오류 메시지입니다.

■ 분석 선택 흐름도

분석 방법을 정하지 못할 때는 **종속변수의 척도**에서 시작해 **무엇을 묻고 싶은지**로 내려갑니다.



그림 12-1 2권의 분석 선택 흐름도. 종속변수가 연속형이면 묻는 질문에 따라 분석이 정해지고, 0과 1이면 로지스틱 회귀로 간다. 어느 회귀분석이든 4장의 진단과 5장의 다중공선성 점검을 거친다.

① 종속변수가 연속형인가 이분형인가 — 연속형이면 `lm()`, 0과 1이면 `glm(family = binomial)` 입니다. ② 독립변수에 범주형이 있는가 — 있으면 더미변수로 바꿉니다(6장). 어느 분석에서든 같습니다. ③ 무엇을 묻는가 — 관계의 크기(2~3장), 추가 설명력(7장), 조건에 따른 차이(8장), 경로(9장), 둘의 결합(10장).

■ 분석 비교표

분석	핵심 질문	핵심 값	검정	효과크기	장
상관	함께 움직이는가	r	t (df = $n - 2$)	r, r^2	1장
단순회귀	1 높으면 얼마나	b_1	t, F	R^2, β	2장
다중회귀	다른 변수가 같을 때	b_j	t , 모형 F	R^2 , 수정 R^2, β, sr^2	3장
더미 회귀	기준 집단과의 차이	더미 계수	t , 범주 전체 F	R^2 ($= \eta^2$)	6장
위계적 회귀	묵음이 더 설명하는가	ΔR^2	F 변화량	$\Delta R^2, f^2$	7장
조절	언제, 누구에게	b_3 (곱하기 항)	$t, \Delta R^2$	$\Delta R^2, f^2$	8장
매개	어떤 경로로	$a \times b$	부트스트랩 CI	표준화 간접효과	9장
조절된 매개	경로가 조건에 따라	$a_3 \times b$	부트스트랩 CI	조건부 간접효과	10장
로지스틱	예/아니오의 오즈	e^b (OR)	Wald z , 우도비 χ^2	OR, 유사 R^2	11장

■ 진단 요약

확인할 것	보는 곳	R	기준	문제가 있으면
선형성	예측값 대 잔차	<code>car::residualPlots()</code>	휨이 없는가	이차항, 빠진 상호작용 확인
독립성	자료 수집 방식	<code>car::durbinWatsonTest()</code> (시계열)	설계로 판단	다층모형
정규성	잔차 Q-Q 그림	<code>shapiro.test(resid(fit))</code>	표본이 작을 때 중요	표본이 크면 대체로 무방
등분산성	예측값 대 잔차	<code>lmtest::bptest()</code>	$p > .05$	HC3 강건 표준오차
영향점	Cook의 거리	<code>cooks.distance()</code>	1 초과	입력 오류 확인, 민감도 분석
다중공선성	VIF, 상관표	<code>car::vif()</code>	증상과 함께 판단	개념 정리, 합성, 그대로 보고

■ R 코드 모음

코드는 이 책의 자료(`survey.csv`)에 그대로 돌아가도록 적었습니다. 변수명만 바꿔 쓰십시오.

자료 준비

● 분석을 시작할 때

```
d <- read.csv("data/survey.csv")
str(d)                                # 변수 형태 확인
colSums(is.na(d))                     # 변수별 결측 수

d$position <- factor(d$position,      # 범주형은 factor로, 기준 집단을 첫 번째로
                     levels = c("사원", "대리", "과장이상"))
d$female <- ifelse(d$gender == "여", 1, 0) # 이분 변수는 0/1로

vars <- c("burnout", "stress", "support", "efficacy", "female", "age", "tenure")
d_c <- na.omit(d[, c(vars, "turnover", "position")]) # 모든 모형을 같은 사례로
```

상관

● 상관행렬과 산점도

```
library(psych)
v <- d[, c("stress", "support", "efficacy", "burnout", "turnover")]
pairs(v)                                # 모든 쌍의 산점도
ct <- corr.test(v, adjust = "none")
round(ct$r, 2); round(ct$p, 3)
cor.test(d$stress, d$burnout)           # 한 쌍의 검정과 신뢰구간
cor.test(d$stress, d$burnout, method = "spearman", exact = FALSE)
```

회귀분석과 해석

● 단순·다중회귀

```
fit <- lm(burnout ~ stress + support + efficacy, data = d)
summary(fit)                            # 계수,  $R^2$ ,  $F$ 
confint(fit)                            # 계수의 신뢰구간
library(effects)
standardize_parameters(fit)             # 표준화 계수  $\beta$ 

predict(fit, newdata = data.frame(stress = 4, support = 3.5, efficacy = 3.6),
        interval = "confidence")        # 평균의 신뢰구간 ("prediction"은 개인)
```

진단

● 가정과 영향점

```
library(car); library(lmtest); library(sandwich)
par(mfrow = c(2, 2)); plot(fit)                # 기본 진단 그림 네 장
residualPlots(fit)                             # 곡선 검정
shapiro.test(resid(fit))                       # 잔차의 정규성
bptest(fit)                                    # 등분산성
coeftest(fit, vcov = vcovHC(fit, type = "HC3")) # 이분산이면 강건한 표준오차
max(cooks.distance(fit))                       # 영향점
vif(fit)                                       # 다중공선성
```

더미변수와 위계적 회귀

● 범주형 독립변수, 단계별 투입

```
m_pos <- lm(satisfaction ~ position + burnout, data = d)
anova(lm(satisfaction ~ burnout, data = d), m_pos) # 범주 전체의 효과
library(emmeans)
emmeans(m_pos, pairwise ~ position)              # 모든 쌍 비교 (Tukey)

m1 <- lm(burnout ~ female + age + tenure, data = d_c)
m2 <- update(m1, . ~ . + stress + support + efficacy)
anova(m1, m2)                                    #  $\Delta R^2$ 의 F검정
summary(m2)$r.squared - summary(m1)$r.squared    #  $\Delta R^2$ 
```

조절효과

● 중심화, 곱하기 항, 단순기울기

```
d$stress_c <- d$stress - mean(d$stress)
d$support_c <- d$support - mean(d$support)
m_main <- lm(burnout ~ efficacy + stress_c + support_c, data = d)
m_int <- lm(burnout ~ efficacy + stress_c * support_c, data = d)
anova(m_main, m_int)                            # 곱하기 항의  $\Delta R^2$ 

s <- sd(d$support)
emtrends(m_int, ~ support_c, var = "stress_c",
          at = list(support_c = c(-s, 0, s)))    # 단순기울기
```

매개효과와 조절된 매개

● lavaan으로 부트스트랩

```
library(lavaan)
med <- '
  burnout ~ a * stress
  turnover ~ b * burnout + cp * stress
  indirect := a * b
  total    := cp + a * b
'

set.seed(2026)
fit_med <- sem(med, data = d, se = "bootstrap", bootstrap = 5000)
parameterEstimates(fit_med, boot.ci.type = "perc")
standardizedSolution(fit_med)

# 조절된 매개 (첫 단계 조절, PROCESS Model 7)
d$sxw <- d$stress_c * d$support_c
modmed <- sprintf('
  burnout ~ a1 * stress_c + a2 * support_c + a3 * sxw
  turnover ~ b * burnout + cp * stress_c
  ind_low  := (a1 - %.4f * a3) * b
  ind_high := (a1 + %.4f * a3) * b
  index    := a3 * b
', s, s)
fit_mm <- sem(modmed, data = d, se = "bootstrap", bootstrap = 5000)
parameterEstimates(fit_mm, boot.ci.type = "perc")
```

로지스틱 회귀

● 이분 종속변수

```
m_log <- glm(quit ~ turnover + satisfaction, family = binomial, data = d)
summary(m_log)
exp(cbind(OR = coef(m_log), confint(m_log))) # 오즈비와 신뢰구간
anova(glm(quit ~ 1, family = binomial, data = d), m_log, test = "Chisq")
library(performance)
r2_nagelkerke(m_log); performance_hosmer(m_log)
p_hat <- predict(m_log, type = "response")
table(실제 = d$quit, 예측 = ifelse(p_hat ≥ .5, 1, 0))
```

■ 보고 문장 템플릿

빈칸을 채우면 그대로 쓸 수 있는 형태입니다. 기울임체 표기와 소수점 자릿수를 그대로 유지하십시오.

상관분석

주요 변수 간의 관계를 확인하기 위해 피어슨 상관분석을 실시하였다(표). ○○은 □□($r = \text{.}, p < .001$)과 정적 상관을, △△($r = -\text{.}, p = \text{.}$)과 부적 상관을 보였다. ○○과 ◇◇의 상관은 유의하지 않았다($r = \text{.}, p = \text{.}$).

다중회귀분석

○○, □□, △△가 ◇◇에 미치는 영향을 검증하기 위해 다중회귀분석을 실시하였다. 모든 독립변수의 VIF는 __ 이하로 다중공선성의 문제는 없었다. 회귀모형은 통계적으로 유의하였으며($F(\text{ }, \text{ }) = \text{ }, p < .001$), 독립변수들은 ◇◇ 변동의 __%를 설명하였다($R^2 = \text{.}, \text{수정 } R^2 = \text{.}$).

○○은 ◇◇에 정적으로 유의한 영향을 미쳤고($B = \text{ }, \beta = \text{.}, p < .001$), □□은 부적으로 유의한 영향을 미쳤다($B = -\text{ }, \beta = -\text{.}, p = \text{.}$). △△의 영향은 유의하지 않았다($B = \text{ }, \beta = \text{.}, p = \text{.}$).

위계적 회귀분석

○○을 통제된 상태에서 □□이 ◇◇에 미치는 영향을 검증하기 위해 위계적 회귀분석을 실시하였다. 1단계에서 ○○을 투입한 모형은 ◇◇ 변동의 __%를 설명하였다($R^2 = \text{.}, F(\text{ }, \text{ }) = \text{ }, p = \text{.}$). 2단계에서 □□을 추가 투입한 결과 설명력이 __% 증가하였으며 이는 통계적으로 유의하였다($\Delta R^2 = \text{.}, F(\text{ }, \text{ }) = \text{ }, p < .001$).

조절효과

○○과 ◇◇의 관계에서 □□의 조절효과를 검증하기 위해 위계적 회귀분석을 실시하였다. ○○과 □□은 평균 중심화하였다. 상호작용항을 투입한 결과 설명력이 유의하게 증가하였으며($\Delta R^2 = \text{.}, F(1, \text{ }) = \text{ }, p = \text{.}$), 상호작용항의 계수가 유의하였다($B = \text{ }, p = \text{.}$).

단순기울기 분석 결과, ○○이 ◇◇에 미치는 영향은 □□이 낮을 때(-1 SD ; $B = \text{ }, p = \text{.}$)보다 높을 때($+1 \text{ SD}$; $B = \text{ }, p = \text{.}$) [크게/작게] 나타났다(그림).

매개효과

○○과 ◇◇의 관계에서 □□의 매개효과를 검증하기 위해 매개모형을 추정하고, 간접효과의 유의성을 ___회 부트스트랩의 백분위수 신뢰구간으로 검정하였다. ○○은 □□에 유의한 영향을 미쳤고($B = _, p = _.$), ○○을 통제된 상태에서 □□은 ◇◇에 유의한 영향을 미쳤다($B = _, p = _.$).

□□을 통한 간접효과는 ___로, 95% 신뢰구간 [$_, _.$]이 0을 포함하지 않아 유의하였다. 직접효과는 [유의하였다($B = _, p = _.$) / 유의하지 않았다($B = _, p = _.$)].

조절된 매개

□□의 매개효과가 △△에 따라 달라지는지 검증하기 위해 조절된 매개모형(Hayes, 2018의 Model ___)을 추정하였다. 조절된 매개지수는 ___로, 95% 부트스트랩 신뢰구간 [$_, _.$]이 0을 포함하지 않아 유의하였다. 조건부 간접효과는 △△이 낮을 때 $_ [_, _]$, 높을 때 $_ [_, _]$ 였다.

로지스틱 회귀분석

○○이 □□ 여부에 미치는 영향을 검증하기 위해 로지스틱 회귀분석을 실시하였다. 모형은 통계적으로 유의하였으며 ($\chi^2(_) = _, p < .001$, Nagelkerke $R^2 = _.$), Hosmer-Lemeshow 검정 결과 적합도가 양호하였다($\chi^2(_) = _, p = _.$).

○○이 1점 높을수록 □□할 오즈가 ___배 증가하였다($OR = _, 95\% CI [_, _]$). ○○이 ___점일 때 □□의 예측 확률은 $_ \%$, ___점일 때 $_ \%$ 였다.

■ 표기 규칙

1권의 표기 규칙에 회귀분석에서 추가되는 것들입니다.

항목	올바른 표기	주의
비표준화 계수	B 또는 b (기울임)	원래 척도 단위
표준화 계수	β (정자)	더미변수에는 보고하지 않음
결정계수	R² , 수정 R² , ΔR^2	1을 넘지 않으므로 .395
회귀계수	0.526, -2.789	1을 넘을 수 있으므로 앞의 0 유지
오즈비	OR = 3.43	1이 기준. 1을 넘을 수 있음
신뢰구간	95% CI [0.43, 0.63]	부트스트랩이면 반복 횟수와 방식 명시
범주형 변수	직급 (기준: 사원)	기준 집단을 반드시 표기
이분 변수	성별 (0 = 남, 1 = 여)	코딩을 반드시 표기
중심화	"평균 중심화하였다"	조절효과 표의 주에 명시

■ 자주 마주치는 오류 메시지

메시지	원인	해결
models were not all fitted to the same size of dataset	단계마다 결측이 달라 사례 수가 다름	<code>na.omit()</code> 으로 분석 자료를 먼저 확정 (7장)
계수가 NA 로 나옴	완전한 공선성. 더미를 범주 수만큼 만들었거나 같은 변수가 두 번 들어감	더미는 $k - 1$ 개, 변수 목록 확인
there are aliased coefficients in the model	위와 같음 (<code>vif()</code> 에서)	위와 같음
contrasts can be applied only to factors with 2 or more levels	부분 자료에서 범주가 하나만 남음	<code>table()</code> 로 범주별 사례 수 확인
glm.fit: fitted probabilities numerically 0 or 1 occurred	설명변수가 결과를 거의 완벽하게 가름 (완전분리)	해당 변수의 분포 확인, 범주 합치기
glm.fit: algorithm did not converge	완전분리 또는 척도 문제	위와 같음, 변수 척도 확인
some observed variances are (at least) a factor 1000 times larger than others	<code>lavaan</code> 에서 변수 단위 차이가 큼 (예: 소득 원 단위)	큰 변수를 1,000 등으로 나눠 단위 조정
더미의 기준 집단이 의도와 다름	문자 변수는 가나다순으로 수준이 정해짐	<code>factor(levels = ...)</code> 또는 <code>relevel()</code> (6장)

오류가 나지 않는데 결과가 이상한 경우

회귀분석에서 가장 흔한 셋은 다음과 같습니다.

- ① 범주형을 숫자로 넣음 — 직급을 1, 2, 3 그대로 넣으면 오류 없이 계수 하나가 나옵니다. `str(d)` 로 확인합니다 (6장).
- ② 원점수로 곱하기 항을 만들 — 주효과 계수가 엉뚱한 부호로 나옵니다. 중심화했는지 확인합니다(8장).
- ③ 종속변수가 0/1인데 `lm()` 을 씀 — 오류 없이 계수가 나오지만 확률이 음수가 됩니다(11장).

■ 분석 점검표

분석 전

- ☐ 변수의 척도를 확인했고, 범주형은 factor로 바꿔 기준 집단을 정했다

- ☐ 상관표로 변수 간 관계를 훑었고, 독립변수끼리 .80 이상인 쌍이 있는지 봤다
- ☐ 산점도로 곡선이나 이상치를 확인했다
- ☐ 분석에 쓸 사례를 확정했다(결측 처리)
- ☐ 독립변수 수에 비해 사례 수가 충분한지 확인했다

분석 중

- ☐ 투입할 변수와 순서를 이론에 따라 미리 정했다
- ☐ 곱하기 항을 만들기 전에 중심화했다
- ☐ 잔차 진단과 VIF를 확인했다
- ☐ 부트스트랩에 `set.seed()` 를 썼다

보고

- ☐ B와 β , R^2 (위계적이면 ΔR^2)를 함께 보고했다
- ☐ 범주형 변수의 기준 집단과 이분 변수의 코딩을 밝혔다
- ☐ 조절효과는 표, 단순기울기, 그림을 함께 제시했다
- ☐ 매개효과는 간접효과의 신뢰구간으로 판단했다
- ☐ 로지스틱 회귀는 오즈비를 확률의 배수로 쓰지 않았다
- ☐ 횡단 자료라면 인과 해석의 한계를 밝혔다

■ 다음 권 안내

2권에서는 **변수 사이의 관계**를 다뤘습니다. 얼마나 관련되는지, 다른 변수를 통제해도 그런지, 언제 더 강한지, 어떤 경로로 이어지는지.

그런데 2권 내내 한 가지를 당연하게 여겼습니다. **직무스트레스, 소진, 사회적지지 같은 점수가 그 개념을 제대로 재고 있다는 것입니다.** 0장에서 문항을 평균 내어 척도 점수를 만들었고, 5장에서 두 척도를 합쳐 합성 변수를 만들었습니다. 그렇게 해도 되는지는 묻지 않았습니

권	다루는 내용	2권과의 연결
3권 요인분석	탐색적·확인적 요인분석, 신뢰도와 타당도	문항을 평균 내도 되는 근거, 5장의 합성 변수
4권 구조방정식	측정모형, 구조모형, 적합도 지수	9~10장의 lavaan 경로모형에 측정오차를 반영

3권과 4권에서 이어지는 지점

0장의 척도 점수 — 여러 문항을 평균 내 변수 하나를 만들려면 문항들이 같은 것을 재고 있어야 합니다. 그 확인이 3권의 요인분석과 신뢰도 분석입니다.

5장의 다중공선성 — 스트레스와 업무과부하가 .89로 상관된 것은 두 척도가 사실상 같은 개념을 재고 있다는 신호일 수 있습니다. 판별타당도라는 이름으로 3권에서 다시 다룹니다.

9~10장의 lavaan — 이번에는 관측된 점수 사이의 경로만 추정했습니다. 4권에서는 같은 문법으로 **잠재변수**를 정의해 측정오차를 걸어 낸 경로를 추정합니다. 회귀분석이 측정오차 때문에 관계를 과소추정하는 문제가 거기서 해결됩니다.

■ 마치며

1권이 "왜 이 분석을 쓰는가"였다면, 2권은 "**이 숫자가 정확히 무엇을 말하는가**"였습니다. 회귀계수 하나도 단순회귀에서와 다중회귀에서, 곱하기 항이 있을 때와 없을 때 뜻이 다릅니다. 같은 0.5라도 무엇을 통제했는지, 원점이 어디인지에 따라 다른 문장이 됩니다.

학위논문의 회귀분석 표에서 가장 자주 보는 실수는 계산이 아니라 해석입니다. 다중회귀 계수를 단순상관처럼 읽고, 원점수 곱하기 항의 주효과를 그대로 해석하고, 오즈비를 확률의 배수로 씁니다. 이 책이 계산보다 **읽는 법**에 지면을 많이 쓴 이유입니다.

책에 실린 R 출력은 모두 실제로 실행한 결과입니다. 같은 코드를 같은 자료에 돌리면 같은 값이 나옵니다.

후기를 남겨 주시면

읽고 나서 도움이 되었다면 **후기를 남겨 주십시오**. 어느 장이 특히 유용했는지, 어디가 더 설명이 필요했는지 알려주시면 다음 권에 반영합니다.

자신의 연구에서 막혔던 분석이 있다면 그것도 알려주십시오. 3권과 4권의 예제와 순서를 정하는 데 그대로 쓰겠습니다.

2권을 마쳤습니다. 이제 변수 사이의 관계를 회귀식으로 추정하고, 다른 변수를 통제한 계수를 정확히 읽고, 가정과 다중공선성을 진단하고, 조절효과와 매개효과를 검정해 결과표와 논문 문장으로 옮길 수 있습니다. 3권에서는 그 변수들을 재는 척도 자체를 검증합니다.